N/T харьцаа бага үед багцын оновчлолд ковариацын матрицын агшилтын аргуудыг харьцуулах нь

Г.Нарангоо[1] Ч.Анхбаяр[2]
[1]Монгол улсын их сургууль, Мэдээллийн технологи, электроникийн сургууль
narangoo.g@num.edu.mn
[2]Монгол улсын их сургууль, Бизнесийн сургууль
ankhbayar.ch@num.edu.mn

Хураангуй

Энэхүү судалгаагаар хөрөнгийн тоо болон ковариацын матрицыг үнэлэх ажиглалтын тооны харьцаа (N/T) бага нөхцөлд ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багцын (GMVP) түүврээс гадуурх гүйцэтгэлийг харьцуулан үнэлэв. Түүврийн ковариацын матриц, дөрвөн төрлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгч болон шугаман бус агшилтын үнэлэгчийг богино борлуулалтыг зөвшөөрөөгүй багцын оновчлолд ашиглав.

Корреляцийн бүтэц ялгаатай, тус бүр 10 хувьцаанаас бүрдсэн гурван багцад $T = 120$ сарын шилжих үнэлгээний цонх ашиглан ($N/T \approx 0.0833$) 52 сарын түүврээс гадуурх үнэлгээ хийв. Үр дүнгийн тогтвортой байдлыг сургалтын цонхны уртад хийсэн мэдрэмжийн шинжилгээ, нэмэлт 150 багцын шинжилгээ, HAC шалгалт болон блок bootstrap аргаар үнэлэв.

Үндсэн шинжилгээнд өндөр корреляцитай багцад тогтмол вариацын зорилтот матрицад суурилсан агшилтын үнэлэгч түүврийн ковариацын аргатай харьцуулахад дисперсийг 5.81%-иар, дунд корреляцитай багцад тогтмол корреляцийн зорилтот матрицад суурилсан агшилтын үнэлэгч 2.26%-иар бууруулсан. Харин үндсэн бага корреляцитай багцад агшилтын бүх үнэлэгчийн харьцангуй дисперсийн бууралт сөрөг байв.

Нэмэлт 150 багцын шинжилгээгээр агшилтын үнэлэгчдийн гүйцэтгэл багцын бүрэлдэхүүн болон корреляцийн бүтцээс хамааран өөрчлөгдөж байгааг харуулав. Тэнцүү жинтэй багцтай харьцуулахад GMVP стратегиуд бага хэлбэлзэл үзүүлсэн боловч олон харьцуулалтын засварын дараа агшилтын үнэлэгчид түүврийн ковариацын аргаас, мөн GMVP стратегиуд тэнцүү жинтэй багцаас статистикийн ач холбогдолтой давуу болох нь тогтоогдоогүй.

Арилжааны зардлыг харгалзан үзэхэд хэлбэлзлийн бууралт нь эрсдэлд тохируулсан цэвэр өгөөжийн өсөлтийг заавал баталгаажуулахгүй байв.

Иймд бага (N/T) нөхцөлд ковариацын матрицын агшилтын аргуудын эрсдэл бууруулах үр ашиг нь багцын корреляцийн бүтэц, бүрэлдэхүүн болон үнэлгээний цонхны уртаас хамаарах бөгөөд бүх нөхцөлд тогтвортой давуу тал үзүүлэхгүй гэж дүгнэв.

Keywords: Ковариацын матрицын агшилт; глобал хамгийн бага вариацтай багц; түүврээс гадуурх гүйцэтгэл; харьцангуй дисперсийн бууралт; шилжих цонхны арга; блок bootstrap.

1 Удиртгал

Багц сонголтын дундаж–вариацын онолын суурийг Markowitz [1952] тавьсан бөгөөд багцын эрсдэлийг тодорхойлоход хөрөнгийн өгөөжийн ковариацын матриц гол үүрэгтэй. Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP) нь хүлээгдэж буй өгөөжийн векторыг үнэлэхгүйгээр багцын вариацыг хамгийн бага байлгах жинг тодорхойлдог. Гэвч эх олонлогийн ковариацын матриц үл мэдэгдэх тул түүврээс үнэлэх шаардлагатай. Түүврийн ковариацын матриц N хөрөнгийн хувьд $N(N+1)/2$ ялгаатай параметртэй бөгөөд N/T харьцаа өсөхөд үнэлгээний алдаа, матрицын нөхцөлт тоо ($\lambda_{max}/\lambda_{min}$) болон багцын жингийн тогтворгүй байдал зэрэгт хүндрэл үүсгэж болно [Ledoit and Wolf, 2004a]. Ковариацын матрицын урвуу олдох боломжтой, N/T бага байсан ч ковариацын үнэлгээний алдаа GMVP-ийн түүврээс гадуурх гүйцэтгэлд нөлөөлөх боломжтой. DeMiguel et al.

[2009] сарын өгөөжийн долоон өгөгдлийн сан дээр багц сонголтын 14 загварыг $1/N$ жишиг-тэй харьцуулж, оновчлолын аргууд уг жишгээс бүх нөхцөлд тогтвортой давуу байгаагүйг харуулсан.

Ковариацын матрицын үнэлгээний алдааг бууруулах түгээмэл арга нь агшилтын үнэл-гээ юм. Шугаман агшилт түүврийн ковариацын матриц S-ийг бүтэцтэй зорилтот матрицтай хослуулдаг. Энэ чиглэлийн судалгаанд нэг хүчин зүйлийн загварт суурилсан зорилтот мат-риц [Ledoit and Wolf, 2003], тогтмол вариацын зорилтот матриц [Ledoit and Wolf, 2004a], тогтмол корреляцын зорилтот матриц [Ledoit and Wolf, 2004b], мөн диагональ зэрэг бүт-цийн хувилбарууд [Schäfer and Strimmer, 2005, Ando and Xiao, 2023] багтана. Эдгээр нь хөрөнгүүдийн дисперс, ковариац болон нийтлэг хүчин зүйлийн талаарх ялгаатай таамаглал ашигладаг. Харин шугаман бус агшилт нь ковариацын матрицын түүврийн хувийн утгуу-дыг ялгаатай хэмжээгээр засварлах боломжтой [Ledoit and Wolf, 2012, 2020]. Иймээс аль үнэлэгч илүү сайн ажиллах нь зөвхөн агшилт хэрэглэсэн эсэхээс бус, зорилтот бүтцийн то-хироо, өгөгдлийн шинж чанар болон багцын оновчлолын нөхцөлөөс хамаарч болно [Ledoit and Wolf, 2022].

Ковариацын үнэлэгчийн статистикийн алдагдлыг бууруулах нь багцын түүврээс гадуурх эрсдэлийг заавал бууруулна гэсэн үг биш. Ledoit and Wolf [2017] багцын оновчлолд зо-риулсан шугаман бус агшилтын аргыг судалж, түүврээс гадуурх гүйцэтгэлийг үнэлсэн. Shi et al. [2025] сарын өгөөж болон 120 сарын шилжих цонх ашиглан агшилтын эрчмийг cross-validation-д суурилсан negative log-likelihood шалгуураар сонгох аргыг санал болгож, харь-цангуй олон хөрөнгөтэй, богино борлуулалтыг зөвшөөрсөн GMVP-ийн хүрээнд диагональ болон нэг хүчин зүйлийн зорилтот матрицын давуу талыг тайлагнасан. Эдгээр судалгаа нь ковариацын үнэлгээний зорилго, агшилтын эрчим болон багцын бодит гүйцэтгэлийн хоо-рондын холбоог тодруулсан боловч тэдгээрийн үр дүнг бага N/T-тэй, богино борлуулалт хориглосон багцад шууд шилжүүлэн үзэх боломжгүй.

Багцын жингийн хязгаарлалт өөрөө үнэлгээний алдааны нөлөөг бууруулж болох нь энэ асуудлыг улам чухал болгодог. Jagannathan and Ma [2003] жинг сөрөг бус байлгах хязгаар-лалт нь ковариацын үнэлгээнд агшилттай төстэй нөлөө үзүүлж болохыг тайлбарлаж, ийм нөхцөлд түүврийн ковариацад суурилсан GMVP фактор болон агшилтын үнэлэгчдэд суу-рилсан багцуудтай ойролцоо гүйцэтгэлтэй байж болохыг харуулсан. Ledoit and Wolf [2017] мөн багцын хязгаарлалттай болон хязгаарлалтгүй тохиолдлын үр дүнг ялган авч үзсэн. Сүүлийн үеийн De Nard and Kostovic [2026] судалгаа агшилтын эрчмийг өгөгдөлд суурилан суралцах аргыг санал болгож, unrestricted болон long-only GMVP-ийг харьцуулсан бөгөөд жингийн хязгаарлалт нь нэмэлт агшилтын үр ашгийг багасгаж болохыг тэмдэглэсэн. Гэвч тус судалгааны үндсэн эмпирик дизайн өдрийн өгөөжид тулгуурласан тул сарын өгөөжтэй, бага N/T нөхцөлд адил дүгнэлт гарах эсэх нь тусдаа эмпирик асуулт юм.

Эдгээр судалгаанаас харахад ковариацын агшилтын онол, өндөр хэмжээст багцын хэрэг-лээ болон жингийн хязгаарлалтын нөлөөг өргөн судалжээ. Харин сарын өгөөжид суурил-сан, N/T харьцаа бага, long-only GMVP-ийн хүрээнд агшилтын өөр өөр зорилтот бүтэцтэй үнэлэгчдийг хөрөнгүүдийн корреляцийн ялгаатай түвшин болон олон багцын бүрэлдэхүүнд зэрэгцүүлэн шалгах нь ач холбогдолтой хэвээр байна. Ялангуяа нэг багцад илэрсэн дисперсийн бууралт бусад багцад давтагдах эсэх, мөн ажиглагдсан ялгаа статистикийн тодорхой бус байдлыг харгалзсаны дараа хадгалагдах эсэхийг тусад нь үнэлэх шаардлагатай. Энэхүү судалгаа нь өмнөх ажлууд агшилтыг эсвэл long-only GMVP-ийг огт судлаагүй гэж үзэхгүй; харин эдгээр нөхцөлийг нэг эмпирик хүрээнд хослуулан харьцуулж байгаагаараа ялгаатай.

Судалгааны зорилго нь түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцын (Corr), нэг хүчин зүйлийн (SF) зорилтот матрицад суурилсан дөрвөн шугаман агшилтын үнэлэгч болон аналитик шугаман бус агшилтын үнэ-лэгчийг (NLS) богино борлуулалтыг хориглосон GMVP-ийн ижил нөхцөлд харьцуулах яв-дал юм. Сарын өгөөжид үндэслэн тус бүр 10 хувьцаатай, дундаж корреляци өндөр, дунд, бага гурван багц байгуулж, 120 сарын шилжих сургалтын цонхоор 2022 оны 6 дугаар са-раас 2026 оны 9 дүгээр сар хүртэлх 52 сарын түүврээс гадуурх гүйцэтгэлийг үнэлнэ. Үндсэн шалгуур нь түүврээс гадуурх хэлбэлзэл болон Sample аргатай харьцуулсан дисперсийн буу-рал (RVR) бөгөөд Sharpe-ийн харьцаа, багцын жингийн эргэлт (turnover), төвлөрлийг мөн авч үзнэ.

Судалгааны эмпирик хувь нэмэр нь дараах харилцан нөхөх шинжилгээнд оршино. Нэг-дүгээрт, корреляцийн гурван ангилалд үнэлэгчдийн харьцангуй гүйцэтгэлийг харьцуулж,

сургалтын цонхыг 60, 90, 120 сар болгон өөрчилснөөр N/T-ийн мэдрэмжийг шалгана. Хоёрдугаарт, ангилал тус бүрээс 50, нийт 150 нэмэлт багц сонгож, үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг үнэлнэ. Гуравдугаарт, HAC болон circular moving-block bootstrap аргаар статистикийн тодорхой бус байдлыг тооцож, олон харьцуулалтын p-утгад Holm-ийн засвар хэрэглэнэ. Дөрөвдүгээрт, $1/N$ жишиг багц болон арилжааны зардлын дараах гүйцэтгэлийг нэмэлтээр харьцуулна.

Үндсэн гурван багцын үр дүнгээр өндөр корреляцитай багцад Var, дунд корреляцитай багцад Corr үнэлэгч Sample аргатай харьцуулахад түүврээс гадуурх дисперсийг тус тус 5.81% болон 2.26%-иар бууруулсан бол бага корреляцитай багцад агшилтын таван үнэлэгчийн RVR бүгд сөрөг байв. Нэмэлт 150 багцын үр дүн нь агшилтын харьцангуй гүйцэтгэл багцын бүрэлдэхүүнээс хамаарч өөрчлөгдөж болохыг харуулсан. Олон харьцуулалтын засварын дараа агшилтын үнэлэгчдийн Sample аргаас, мөн үндсэн багцуудын GMVP стратегиудын $1/N$ жишгээс статистикийн ач холбогдолтой давуу байдал тогтоогдоогүй. Иймээс ажиглагдсан эрсдэлийн ялгааг бүх багцад хамаарах баталгаатай давуу тал бус, сонгосон өгөгдөл болон багцын бүтцийн хүрээнд илэрсэн эмпирик үр дүн гэж тайлбарлана.

2 Онол, арга зүйн үндэслэл

2.1 Багцын өгөөж ба эрсдэл

Энэхүү судалгаанд N ширхэг хөрөнгөөс бүрдэх хөрөнгө оруулалтын багцыг авч үзье. x_i нь i-р хөрөнгийн багцад эзлэх жин, G_i нь тухайн хөрөнгийн өгөөж гэж тэмдэглэвэл багцын өгөөжийг

$$r_p = \sum_{i=1}^{N} x_i G_i$$

гэж тодорхойлно. Багцын хүлээгдэж буй өгөөж нь

$$\mu_p = E[r_p] = E\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i E[G_i]$$

байна. Энд $E[G_i]$ нь i-р хөрөнгийн хүлээгдэж буй өгөөжийг илэрхийлнэ.

Багцын эрсдэлийг өгөөжийн вариацаар хэмжвэл

$$\sigma_p^2 = \mathrm{Var}(r_p) = \mathrm{Var}\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i^2 \sigma_i^2 + \sum_{i \neq j} x_i x_j \sigma_{ij},$$

байна. Энд $\sigma_i^2 = \mathrm{Var}(G_i)$ нь i-р хөрөнгийн өгөөжийн вариац, харин

$$\sigma_{ij} = \mathrm{Cov}(G_i, G_j)$$

нь i болон j-р хөрөнгийн өгөөжийн ковариац юм.

Багцын жингийн векторыг

$$\mathbf{x} = (x_1, x_2, \ldots, x_N)^\top,$$

хөрөнгүүдийн өгөөжийн ковариацын матрицыг

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1N} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \cdots & \sigma_{NN} \end{pmatrix}$$

гэж тэмдэглэвэл багцын вариацыг матриц хэлбэрээр

$$\sigma_p^2 = \mathbf{x}^\top \Sigma \mathbf{x}$$

гэж бичиж болно.

Иймээс багцын эрсдэл нь хөрөнгө тус бүрийн вариацаас гадна хөрөнгүүдийн өгөөж хоорондын ковариацаас хамаарна. Иймд ковариацын матрицыг хэрхэн үнэлэх нь багц сонголтын үр дүнд чухал нөлөөтэй.

Ковариацын матрицын үнэлэгчдийн харьцуулалтын үндсэн шалгуураар түүврээс гадуурх багцын хэлбэлзлийг ашиглана [Ledoit and Wolf, 2022, De Nard and Kostovic, 2026]. Энэ нь хүлээгдэж буй өгөөжийн векторыг үнэлэх шаардлагагүйгээр глобал хамгийн бага вариацтай багцын бодит хэрэгжилтийн эрсдэлийг үнэлэх боломж олгоно.

2.2 Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)

Энэхүү судалгаанд ковариацын матрицын өөр өөр үнэлэгчийг багцын оновчлолд ашиглахад үүсэх ялгааг харьцуулахын тулд глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)-ийг ашиглана. GMVP-ийн зорилго нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилах нөхцөлд багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлоход оршино. GMVP-ийн оновчтой жинг тодорхойлоход хөрөнгүүдийн хүлээгдэж буй өгөөжийн үнэлгээ шаардлагагүй бөгөөд ковариацын матрицад тулгуурладаг.

Энэхүү судалгаанд богино арилжааг зөвшөөрөхгүй, хөрөнгө бүрийн багцад эзлэх жин сөрөг биш байх long-only GMVP загварыг ашиглана. Энэхүү хязгаарлалт нь богино арилжаа болон сөрөг жингээс үүдэх хөшүүрэгтэй байрлалыг хязгаарлахаас гадна ковариацын матрицын үнэлгээний алдаанаас шалтгаалан багцын жин хэт туйлшрах эрсдэлийг бууруулах боломжтой. Jagannathan and Ma [2003]-ийн судалгаанд багцын жинг сөрөг бишээр хязгаарлах нь үнэлсэн оновчтой багцын эрсдэлийг бууруулж болохыг харуулсан. Түүнчлэн ийм хязгаарлалт нь ковариацын матрицын зарим элементийг агшаасантай төстэй нөлөө үзүүлж болохыг тайлбарласан.

Гэхдээ long-only хязгаарлалт нь өөрөө ковариацын матрицын үнэлгээний алдааны нөлөөг бууруулж болох тул агшилтын үнэлэгчдийн хоорондын гүйцэтгэлийн ялгааг багасгаж болзошгүй. Иймээс энэхүү судалгаанд ковариацын матрицын үнэлэгчдийн үр дүнг ижил long-only оновчлолын нөхцөлийн хүрээнд харьцуулж, гарсан дүгнэлтийг уг хязгаарлалтын хүрээнд тайлбарлана.

N ширхэг хөрөнгөөс бүрдэх багцын жингийн векторыг

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_N)^\top$$

гэж тэмдэглэе. Мөн хөрөнгүүдийн өгөөжийн ковариацын матрицын үнэлэгчийг $\widehat{\Sigma}$ гэвэл багцын үнэлэгдсэн вариац

$$\widehat{\sigma}_p^2 = \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x}$$

байна.

Тэгвэл long-only GMVP-ийн оновчлолын бодлогыг

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x} \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{x} = 1, \\ & x_i \geq 0, \qquad i = 1, 2, \ldots, N \end{aligned}$$

гэж тодорхойлно. Энд $\mathbf{1}$ нь бүх элемент нь нэгтэй N хэмжээст вектор юм.

$\mathbf{1}^\top \boldsymbol{x} = 1$ нөхцөл нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилахыг, харин $x_i \geq 0$ нөхцөл нь хөрөнгө бүрийн жин сөрөг биш байхыг илэрхийлнэ. Эдгээр нөхцөлөөс

$$0 \leq x_i \leq 1, \qquad i = 1, 2, \ldots, N$$

байх нь шууд мөрдөнө.

Long-only GMVP-ийн оновчтой жинг хязгаарлалттай квадратлаг оновчлолын бодлогын шийдээр тодорхойлно. Хэрэв $\widehat{\Sigma}$ нь эерэг хагас тодорхой матриц бол зорилгын функц гүдгэр байна. Мөн боломжит жингийн олонлог хоосон биш, хаалттай, хязгаарлагдмал тул оновчтой шийд оршино. Харин оновчтой шийд цорын ганц байх нь ковариацын матрицын шинж чанараас хамаарна.

Энэхүү судалгаанд түүврийн ковариацын матрицыг суурь үнэлэгч болгон авч, тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг харьцуулна.

Эдгээр зургаан ковариацын матрицын үнэлэгчийг ерөнхийд нь $\widehat{\Sigma}^{(k)}$, $k = 1, 2, \ldots, 6$ гэж тэмдэглэе. Тэгвэл k-р үнэлэгчид харгалзах long-only GMVP-ийн оновчтой жинг

$$\widehat{\boldsymbol{x}}^{(k)} \in \underset{\substack{\boldsymbol{x}\in\mathbb{R}^N \\ \mathbf{1}^\top \boldsymbol{x}=1 \\ \boldsymbol{x}\geq \mathbf{0}}}{\arg\min} \boldsymbol{x}^\top \widehat{\Sigma}^{(k)} \boldsymbol{x}$$

гэж тодорхойлно.

Энд бүх үнэлэгчийн хувьд багцын оновчлолын зорилгын функцийн хэлбэр болон хөрөнгө оруулалтын жинд тавих хязгаарлалтууд ижил байх бөгөөд зөвхөн ковариацын матрицын үнэлэгч $\widehat{\Sigma}^{(k)}$ өөрчлөгдөнө.

Иймээс ковариацын матрицын үнэлэгчийн сонголтоос хамааран GMVP-ийн оновчтой жин, улмаар багцын эрсдэл болон бодит өгөөжийн үзүүлэлтүүд ялгаатай байж болно. Энэхүү судалгаанд эдгээр үнэлэгчээр байгуулсан long-only GMVP-үүдийн гүйцэтгэлийг ижил нөхцөлд харьцуулан үнэлнэ.

2.3 Түүврийн ковариацын матриц

Бодит нөхцөлд хөрөнгүүдийн өгөөжийн эх олонлогийн ковариацын матриц Σ үл мэдэгдэх тул түүнийг ажиглагдсан өгөгдлөөс үнэлэх шаардлагатай. Энэхүү судалгаанд n ажиглалт, N хөрөнгөөс бүрдэх өгөөжийн ажиглалтын матрицыг

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1N} \\ y_{21} & y_{22} & \cdots & y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nN} \end{pmatrix} \in \mathbb{R}^{n\times N}$$

гэж тэмдэглэнэ. Энд y_{ti} нь t-р хугацаанд ажиглагдсан i-р хөрөнгийн өгөөж, n нь ажиглалтын тоо, N нь хөрөнгийн тоо юм.

i-р хөрөнгийн дундаж өгөөжийг

$$\overline{Y}_i = \frac{1}{n}\sum_{t=1}^{n} y_{ti}, \qquad i = 1, 2, \ldots, N,$$

гэж тооцно.

Тэгвэл i болон j-р хөрөнгийн өгөөжийн түүврийн ковариацыг

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

гэж тодорхойлно. Энд $1/n$ хуваарь ашигласан тул уг үнэлэгч нь ерөнхий тохиолдолд хазайлтгүй түүврийн ковариацын үнэлэгч ($1/(n-1)$ хуваарьтай) биш болохыг анхаарна. Эдгээр түүврийн ковариацуудаас бүрдэх түүврийн ковариацын матриц нь

$$S = (s_{ij}) = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1N} \\ s_{21} & s_{22} & \cdots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \cdots & s_{NN} \end{pmatrix}$$

байна. Энд S нь $N \times N$ хэмжээст түүврийн ковариацын матриц бөгөөд эх олонлогийн ковариацын матриц Σ-г үнэлэхэд ашиглагдана.

2.4 Шугаман агшилтын үнэлгээ (Linear Shrinkage Estimation)

Шугаман агшилт (Linear Shrinkage) нь агшилтын үнэлгээний хамгийн өргөн хэрэглэгддэг хэлбэрүүдийн нэг юм. Энэхүү аргын үндсэн санаа нь түүврийн ковариацын матриц болон тодорхой бүтэц бүхий зорилтот матрицыг гүдгэр хослол хэлбэрээр нэгтгэн ковариацын матрицын үнэлэгчийг байгуулахад оршино. Шугаман агшилтын үнэлэгчийг ерөнхий хэлбэрээр

$$\widehat{\Sigma}_{LS} = (1-\alpha)S + \alpha T, \qquad 0 \leq \alpha \leq 1,$$

гэж тодорхойлно. Энд S нь түүврийн ковариацын матриц, T нь зорилтот матриц, α нь агшилтын эрчим юм. $\alpha = 0$ үед $\widehat{\Sigma}_{LS} = S$, харин $\alpha = 1$ үед $\widehat{\Sigma}_{LS} = T$ болно. Иймээс α-ийн утга ихсэх тусам зорилтот матриц T-д өгөх жин нэмэгдэж, түүврийн ковариацын матриц S-д өгөх жин буурна.

Хэрэв зорилтот матриц T нь эерэг тодорхой бөгөөд $0 < \alpha \leq 1$ бол шугаман агшилтын үнэлэгч $\widehat{\Sigma}_{LS}$ нь эерэг тодорхой байна. Энэ шинж нь ковариацын матрицын тооцооллын тогтвортой байдлыг сайжруулахад ач холбогдолтой.

Шугаман агшилтын арга нь түүврийн ковариацын матрицын бүх элементэд нэг ижил агшилтын эрчим α-г хэрэглэдэг. Иймээс ковариацын матрицын бодит бүтэц нарийн төвөгтэй, эсвэл хөрөнгүүдийн хоорондын хамаарал харилцан адилгүй үед нэг ижил агшилтын эрчим хэрэглэх нь уг аргын уян хатан байдлыг хязгаарлаж болно.

Шугаман агшилтын үнэлгээний үр дүнд зорилтот матрицын сонголт чухал үүрэгтэй. Энэхүү судалгаанд тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицыг авч үзнэ. Эдгээр зорилтот матрицууд нь шугаман агшилтын ерөнхий хэлбэр дэх T-ийн үүргийг гүйцэтгэх бөгөөд тэдгээрийн ялгаа нь ковариацын матрицын бүтцэд тавих таамаглалд оршино.

2.4.1 Тогтмол вариацын зорилтот матриц

Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн вариацыг нэг нийтлэг утгаар төлөөлүүлж, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг. Уг зорилтот матрицыг

$$T_{\text{var}} = \widehat{\mu} I$$

гэж тодорхойлно. Энд I нь $N \times N$ хэмжээст нэгж матриц, харин

$$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii} = \frac{\text{tr}(S)}{N}$$

нь хөрөнгүүдийн өгөөжийн түүврийн вариацуудын дундаж юм. Иймээс

$$T_{\text{var}} = \begin{pmatrix} \widehat{\mu} & 0 & \cdots & 0 \\ 0 & \widehat{\mu} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \widehat{\mu} \end{pmatrix}$$

хэлбэртэй байна [Ledoit and Wolf, 2004b].

Тогтмол вариацын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{var}} = (1-\widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}, \qquad 0 \leq \widehat{\alpha}_{\text{var}} \leq 1$$

гэж тодорхойлно.

Агшилтын эрчмийн онолын үндэслэлийг Ledoit болон Wolf (2004)-ийн үр дүнд тулгуурлан дараах хэмжигдэхүүнүүдийг авч үзье:

$$\begin{aligned} a &= E\left[\|\Sigma - T\|^2\right] = \|\Sigma - T\|^2, \\ b &= E\left[\|S - \Sigma\|^2\right], \\ d &= E\left[\|S - T\|^2\right]. \end{aligned}$$

Лемма 1 (Ledoit–Wolf, 2004). Хэрэв $E[S] = \Sigma$ бөгөөд квадратын математик дунджууд төгсгөлөг бол

$$a + b = d$$

тэнцэтгэл биелнэ.

Баталгаа. Математик дундаж ба нормын чанараас

$$\begin{aligned} d &= E\left[\|S - T\|^2\right] = E\left[\|S - \Sigma + \Sigma - T\|^2\right] \\ &= E\left[\|S - \Sigma\|^2\right] + \|\Sigma - T\|^2 + 2E\left[\langle S - \Sigma, \Sigma - T\rangle\right]. \end{aligned}$$

$E[S] = \Sigma$ бөгөөд T нь санамсаргүй бус матриц тул

$$E\left[\langle S - \Sigma, \Sigma - T\rangle\right] = \langle E[S - \Sigma], \Sigma - T\rangle = 0.$$

Иймээс

$$d = b + a.$$

Лемма батлагдав. □

Теорем 1 (Ledoit–Wolf, 2004). Дараах оновчлолын бодлогыг авч үзье:

$$\min_{0 \le \alpha \le 1} E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right],$$

энд

$$\Sigma^*(\alpha) = (1 - \alpha)S + \alpha T.$$

Хэрэв $d > 0$ бол оновчтой агшилтын эрчим

$$\alpha^* = \frac{b}{d}$$

бөгөөд харгалзах үнэлэгч

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T$$

байна.

Баталгаа. Агшилтын үнэлэгчийн алдааг

$$\Sigma^*(\alpha) - \Sigma = (1 - \alpha)(S - \Sigma) + \alpha(T - \Sigma)$$

гэж бичиж болно.

Одоо нормын квадратын томьёо болон математик дунджийн шугаман чанарыг хэрэглэнэ.

$$\begin{aligned} \|\Sigma^*(\alpha) - \Sigma\|^2 &= \|(1 - \alpha)(S - \Sigma) + \alpha(T - \Sigma)\|^2 \\ &= (1 - \alpha)^2\|S - \Sigma\|^2 + \alpha^2\|T - \Sigma\|^2 + 2\alpha(1 - \alpha)\langle S - \Sigma, T - \Sigma\rangle. \end{aligned}$$

Хоёр талаас математик дундаж авбал:

$$\begin{aligned} E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right] &= (1 - \alpha)^2 E\left[\|S - \Sigma\|^2\right] + \alpha^2 E\left[\|T - \Sigma\|^2\right] + 2\alpha(1 - \alpha)E\left[\langle S - \Sigma, T - \Sigma\rangle\right] \\ &= (1 - \alpha)^2 b + \alpha^2 a. \end{aligned}$$

Иймээс зорилгын функц

$$R(\alpha) = (1 - \alpha)^2 b + \alpha^2 a$$

болно.

Алдааг хамгийн бага болгох α-г олох нь бидний зорилго учраас уламжлал аваад тэгтэй тэнцүүлнэ.

$$R'(\alpha) = -2(1 - \alpha)b + 2\alpha a = 0.$$

Лемма 1-ээс $a+b=d$ тул

$$\alpha^* = \frac{b}{d}, \qquad 1-\alpha^* = \frac{a}{d}.$$

Иймээс

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T.$$

$R''(\alpha) = 2d > 0$ учраас энэ нь минимум шийд юм.
Теорем батлагдав. □

Теорем 1-ээс оновчтой агшилтын эрчим нь түүврийн ковариацын матрицын үнэлгээний алдаа болон зорилтот матрицаас хазайх хэмжээнээс хамаарах нь харагдана.

Гэвч b болон d нь үл мэдэгдэх бодит ковариацын матрицаас хамаардаг тул тэдгээрийг өгөгдлөөс үнэлэх шаардлагатай. Ledoit болон Wolf (2004)-ийн оновчтой агшилтын эрчмийг өгөгдлөөс үнэлэх аргыг боловсруулсан.

Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын квадрат Фробениусын зайг

$$\widehat{d}_{\text{var}} = \|S - T_{\text{var}}\|_F^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij}-t_{ij})^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг нормчилсон Фробениусын нормын тодорхойлолтоос

$$b_{var} = E\left[\|S-\Sigma\|^2\right] = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}E\left[(s_{ij}-\sigma_{ij})^2\right].$$

Хэрэв $E[S]=\Sigma$ бол $E\left[(s_{ij}-\sigma_{ij})^2\right] = \text{Var}(s_{ij})$.
Иймээс

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\text{Var}(s_{ij}).$$

Одоо

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}\{(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)\}$$

гэж тэмдэглэе.

Ажиглалтууд хугацааны хувьд харилцан хамааралгүй, ижил тархалттай бол

$$\text{Var}(s_{ij}) \approx \frac{1}{n^2}\sum_{t=1}^{n}\text{Var}\left((y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)\right) = \frac{1}{n}\text{Var}\left((y_{1i}-\overline{Y}_i)(y_{1j}-\overline{Y}_j)\right).$$

Тэгвэл

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\frac{1}{n}\text{Var}\left((y_{1i}-\overline{Y}_i)(y_{1j}-\overline{Y}_j)\right) = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\text{Var}\left((y_{1i}-\overline{Y}_i)(y_{1j}-\overline{Y}_j)\right).$$

Энд $\text{Var}\left((y_{1i}-\overline{Y}_i)(y_{1j}-\overline{Y}_j)\right)$ нь үл мэдэгдэх тул түүний үнэлгээг $\frac{1}{n}\sum_{t=1}^{n}((y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij})^2$ байгуулвал

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\right\}^2\right] =$$

$$= \frac{1}{nN}\left[\frac{1}{n}\sum_{t=1}^{n}\sum_{i=1}^{N}\sum_{j=1}^{N}\left\{(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\right\}^2\right].$$

Иймээс агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{var}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004b].

Тооцоолох алгоритм. Тогтмол вариацын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Түүврийн ковариацын матрицыг байгуулах.
   n ажиглалт, N хөрөнгийн өгөөжийн өгөгдлөөс
   $$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$
   гэж тооцож, $S = (s_{ij})$ матрицыг байгуулна.
2. Тогтмол вариацын зорилтот матрицыг байгуулах.
   $$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii}, \qquad T_{\text{var}} = \widehat{\mu} I.$$
3. Ковариацын матрицын квадрат алдааг үнэлэх.
   $$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\}^2\right].$$
4. Зорилтот матрицаас хазайх квадрат зайг тооцох.
   $$\widehat{d}_{\text{var}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2.$$
5. Агшилтын эрчмийг үнэлэх.
   $\widehat{d}_{\text{var}} > 0$ үед
   $$\widehat{\alpha}_{\text{var}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}.$$
6. Агшилтын ковариацын матрицыг байгуулах.
   $$\boxed{\widehat{\Sigma}_{\text{var}} = (1 - \widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}}.$$

2.4.2 Диагональ зорилтот матриц

Диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг гэж үзнэ. Уг зорилтот матрицыг

$$T_{\text{diag}} = \text{diag}(S) = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

гэж тодорхойлно. Матриц хэлбэрээр

$$T_{\text{diag}} = \begin{pmatrix} s_{11} & 0 & \cdots & 0 \\ 0 & s_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_{NN} \end{pmatrix}.$$

Өөрөөр хэлбэл,

$$(T_{\text{diag}})_{ij} = \begin{cases} s_{ii}, & i = j, \\ 0, & i \neq j. \end{cases}$$

Иймээс диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалах боловч хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг болгон хялбаршуулдаг.

Диагональ зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}, \qquad 0 \leq \widehat{\alpha}_{\text{diag}} \leq 1,$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{diag}}$ нь диагональ зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Диагональ зорилтот матриц нь түүврийн ковариацын матрицын диагональ элементүүдийг өөрчлөхгүй хадгалдаг тул агшилт нь зөвхөн диагоналийн бус элементүүдэд үйлчилнэ.

Иймээс агшилтын эрчмийг үнэлэхдээ диагоналийн бус элементүүдийн квадрат алдааг авч үзнэ.

Түүврийн ковариацын матриц болон диагональ зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{diag}} = \|S - T_{\text{diag}}\|^2 = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2$$

гэж тодорхойлно.

Учир нь S болон T_{diag} матрицын диагональ элементүүд ижил тул тэдгээрийн ялгавар диагональ дээр тэг байна.

Өмнөх тогтмол вариацын зорилтот матрицын хэсэгт үзсэнтэй адилтаар $\widehat{b}_{diag}$-г дараах байдлаар тодорхойлно.

$$\widehat{b}_{\text{diag}} = \frac{1}{nN} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} (z_{tij} - s_{ij})^2 \right].$$

Иймээс диагональ зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{diag}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}} \right\} \right\}$$

гэж байгуулна.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}$$

гэж тооцно.

Тооцоолох алгоритм. Диагональ зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Диагональ зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$T_{\text{diag}} = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

   гэж байгуулна.

2. Диагоналийн бус элементүүдийн квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{diag}} = \frac{1}{nN} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} (z_{tij} - s_{ij})^2 \right].$$

3. Зорилтот матрицаас хазайх квадрат зайг тооцох.

   $$\widehat{d}_{\text{diag}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2.$$

4. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{diag}} > 0$ үед

   $$\widehat{\alpha}_{\text{diag}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}} \right\} \right\}.$$

5. Агшилтын ковариацын матрицыг байгуулах.

   $$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}.$$

2.4.3 Тогтмол корреляцийн зорилтот матриц

Тогтмол корреляцийн зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг тэдгээрийн дундаж утгаар төлөөлүүлэн байгуулдаг зорилтот матриц юм [Ledoit and Wolf, 2004a].

i болон j дугаар хөрөнгийн өгөөжийн түүврийн корреляцийн коэффициентийг

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii} s_{jj}}}$$

гэж тодорхойлно [Ledoit and Wolf, 2004a].

Хөрөнгүүдийн хоорондын түүврийн корреляцуудын дундажийг

$$\bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

гэж тооцно.

Тогтмол корреляцийн зорилтот матрицын элементүүдийг

$$(T_{\text{corr}})_{ij} = t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii} s_{jj}}, & i \neq j \end{cases}$$

гэж тодорхойлно.

Иймээс уг зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг нэг ижил дундаж утгаар орлуулна.

Тогтмол корреляцийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}, \qquad 0 \leq \widehat{\alpha}_{\text{corr}} \leq 1$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{corr}}$ нь тогтмол корреляцийн зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Тогтмол корреляцийн зорилтот матриц нь түүврийн ковариацын матрицын элементүүдээс хамааран байгуулагддаг тул агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг харгалзан үзнэ.

Түүврийн ковариацын матриц болон тогтмол корреляцийн зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{corr}} = \|S - T_{\text{corr}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2 = \frac{1}{N}\sum_{\substack{i,j=1 \\ i \neq j}}^{N}\left(s_{ij} - \bar{r}\sqrt{s_{ii}s_{jj}}\right)^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг өмнөх хэсгүүдэд үзсэнтэй адилаар

$$\widehat{b}_{\text{corr}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж бичигдэнэ.

Тогтмол корреляцийн зорилтот матриц нь түүврийн ковариацын матрицаас хамаардаг учраас тэдгээрийн харгалзах элементүүдийн асимптотик ковариацыг тооцох шаардлагатай.

Энэ хэмжигдэхүүний нормчилсон үнэлгээг $\widehat{c}_{\text{corr}}$ гэж тэмдэглэе.

Эхлээд

$$\widehat{\vartheta}_{ii,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

болон

$$\widehat{\vartheta}_{jj,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{tj} - \overline{Y}_j)^2 - s_{jj}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

гэж тодорхойлно.

Эдгээр нь түүврийн вариац болон ковариацын элементүүдийн асимптотик ковариацыг үнэлэхэд ашиглагдана.

Ledoit болон Wolf (2004) нь түүврийн ковариацын матриц болон тогтмол корреляцийн зорилтот матрицын асимптотик хам хэлбэлзлийг тооцох аргыг боловсруулсан [Ledoit and Wolf, 2004a]. Тэдгээрийн Appendix B-д өгсөн үр дүнд тулгуурлан

$$\widehat{c}_{\text{corr}} = \frac{1}{nN}\left[\sum_{i=1}^{N}\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) + \frac{\bar{r}}{2}\sum_{\substack{i,j=1 \\ i \neq j}}^{N}\left(\sqrt{\frac{s_{jj}}{s_{ii}}}\widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\widehat{\vartheta}_{jj,ij}\right)\right]$$

гэж үнэлнэ.

Энд

$$\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2$$

юм.

Иймээс тогтмол корреляцийн зорилтот матрицад харгалзах агшилтын эрчмийн практик

үнэлгээг

$$\widehat{\alpha}_{\text{corr}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004a].

Энд $\widehat{b}_{\text{corr}}$ нь түүврийн ковариацын матрицын үнэлгээний квадрат алдааны асимптотик ойролцоо үнэлгээ, $\widehat{c}_{\text{corr}}$ нь түүврийн ковариацын матриц болон зорилтот матрицын харгалзах элементүүдийн асимптотик ковариацуудын нийлбэрийн нормчилсон үнэлгээ, $\widehat{d}_{\text{corr}}$ нь хоёр матрицын хоорондын нормчилсон квадрат Фробениусын зай юм.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}$$

гэж тооцно.

Тооцоолох алгоритм. Тогтмол корреляцийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Тогтмол корреляцийн зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}, \qquad \bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

   гэж тооцно.

   Дараа нь

   $$t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii}s_{jj}}, & i \neq j \end{cases}$$

   гэж тодорхойлж, $T_{\text{corr}} = (t_{ij})$ матрицыг байгуулна.

2. Ковариацын матрицын квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{corr}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right]$$

   гэж тооцно.

3. Түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг үнэлэх.

   $$\widehat{\vartheta}_{ii,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   болон

   $$\widehat{\vartheta}_{jj,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{tj} - \overline{Y}_j)^2 - s_{jj} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   гэж тооцно.

   Дараа нь

   $$\widehat{c}_{\text{corr}} = \frac{1}{nN} \left[\sum_{i=1}^{N} \widehat{\text{Var}} \left((y_{1i} - \overline{Y}_i)^2 \right) + \frac{\bar{r}}{2} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left(\sqrt{\frac{s_{jj}}{s_{ii}}} \widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}} \widehat{\vartheta}_{jj,ij} \right) \right]$$

   гэж үнэлнэ.

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{corr}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} (s_{ij} - t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{corr}} > 0$ үед

$$\widehat{\alpha}_{\text{corr}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}} \right\} \right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}.$$

2.4.4 Нэг хүчин зүйлийн зорилтот матриц

Нэг хүчин зүйлийн зорилтот матриц нь хөрөнгүүдийн өгөөжийн хоорондын хамаарлыг зах зээлийн нийтлэг хүчин зүйлээр тайлбарлах нэг хүчин зүйлийн загварт (Single-Index Model) суурилдаг. Уг загварт хөрөнгийн өгөөжийг зах зээлийн нийтлэг хүчин зүйлтэй холбоотой хэсэг болон тухайн хөрөнгийн өөрийн онцлогоос хамаарах үлдэгдэл хэсэгт хуваан авч үздэг [Ledoit and Wolf, 2003].

Энэхүү судалгаанд зах зээлийн нийтлэг хүчин зүйлийг S&P 500 индексийн өгөөжөөр төлөөлүүлнэ.

i-р хөрөнгийн t-р хугацаан дахь өгөөжийг

$$y_{ti} = a_i + \beta_i R_{m,t} + \varepsilon_{ti}$$

гэж загварчилна. Энд $R_{m,t}$ нь t-р хугацаан дахь зах зээлийн өгөөж, a_i нь регрессийн тогтмол коэффициент, β_i нь i-р хөрөнгийн өгөөжийн зах зээлийн өөрчлөлтөд мэдрэг байдлыг илэрхийлэх коэффициент, ε_{ti} нь тухайн хөрөнгийн үлдэгдэл өгөөж юм.

Нэг хүчин зүйлийн загварын регрессийн коэффициентийг

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n} (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2}$$

гэж үнэлнэ. Энд

$$\overline{R}_m = \frac{1}{n} \sum_{t=1}^{n} R_{m,t}$$

нь зах зээлийн өгөөжийн түүврийн дундаж юм.

Регрессийн тогтмол коэффициентийг

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m$$

гэж тооцно.

Тэгвэл i-р хөрөнгийн t-р хугацаан дахь регрессийн үлдэгдэл

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}$$

болно. Үүнийг

$$\widehat{\varepsilon}_{ti} = (y_{ti} - \overline{Y}_i) - \widehat{\beta}_i (R_{m,t} - \overline{R}_m)$$

гэж илэрхийлж болно.

Нэг хүчин зүйлийн загварын үндсэн таамаглалаар үлдэгдэл өгөөжүүд нь зах зээлийн хүчин зүйлтэй хамааралгүй, мөн өөр өөр хөрөнгүүдийн үлдэгдэл өгөөжүүд хоорондоо ха-

мааралгүй байна. Өөрөөр хэлбэл,

$$\mathrm{Cov}(R_m, \varepsilon_i) = 0, \qquad i = 1, 2, \ldots, N,$$

ба

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0, \qquad i \neq j.$$

Эдгээр таамаглалын дор i болон j-р хөрөнгийн өгөөжийн ковариацыг

$$\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cov}(a_i + \beta_i R_m + \varepsilon_i, a_j + \beta_j R_m + \varepsilon_j)$$

гэж илэрхийлнэ.

Ковариацын чанарыг ашиглавал

$$\mathrm{Cov}(Y_i, Y_j) = \beta_i \beta_j \,\mathrm{Var}(R_m), \qquad i \neq j,$$

болно.

Харин i-р хөрөнгийн өгөөжийн вариац

$$\mathrm{Var}(Y_i) = \beta_i^2 \,\mathrm{Var}(R_m) + \mathrm{Var}(\varepsilon_i)$$

болно.

Зах зээлийн өгөөжийн түүврийн вариацыг

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2$$

гэж тооцно.

Мөн i-р хөрөнгийн регрессийн үлдэгдлийн вариацыг

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2$$

гэж тооцно.

Иймээс нэг хүчин зүйлийн зорилтот матриц $T_{\mathrm{SF}} = (t_{ij})$-ын элементүүдийг

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j \end{cases}$$

гэж тодорхойлно [Ledoit and Wolf, 2003].

Нэг хүчин зүйлийн зорилтот матрицыг матриц хэлбэрээр

$$T_{\mathrm{SF}} = \widehat{\boldsymbol{\beta}} \widehat{\boldsymbol{\beta}}^{\top} \widehat{\sigma}_m^2 + \widehat{D}_{\varepsilon}$$

гэж илэрхийлж болно.

Энд

$$\widehat{\boldsymbol{\beta}} = (\widehat{\beta}_1, \widehat{\beta}_2, \ldots, \widehat{\beta}_N)^{\top}$$

нь регрессийн коэффициентүүдийн вектор, харин

$$\widehat{D}_{\varepsilon} = \mathrm{diag}\left(\widehat{\sigma}_{\varepsilon,1}^2, \ldots, \widehat{\sigma}_{\varepsilon,N}^2\right)$$

нь үлдэгдлийн вариацуудаас бүрдэх диагональ матриц юм.

Нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}}) S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}, \qquad 0 \leq \widehat{\alpha}_{\mathrm{SF}} \leq 1,$$

гэж тодорхойлно.

Энд $\widehat{\alpha}_{\mathrm{SF}}$ нь нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Ledoit and Wolf [2003] нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзэл, түүврийн ковариацын матриц болон зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзэл, мөн эдгээр матрицуудын хоорондын зайг харгалзан үзсэн.

Эхлээд түүврийн ковариацын матриц S болон нэг хүчин зүйлийн зорилтот матриц T_{SF} хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\mathrm{SF}} = \|S - T_{\mathrm{SF}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Дараа нь түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг нэгтгэн хэмжих хэмжигдэхүүнийг

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж тооцно.

Нэг хүчин зүйлийн зорилтот матриц нь түүврийн өгөгдлөөс үнэлэгддэг учраас S болон T_{SF} матрицуудын үнэлгээний алдаанууд хоорондоо хамааралтай байж болно.

Иймээс агшилтын эрчмийг тооцоход эдгээр үнэлгээний алдаануудын хам хэлбэлзлийг харгалзах шаардлагатай.

Энэ хам хэлбэлзлийн нөлөөг $\widehat{c}_{\mathrm{SF}}$ хэмжигдэхүүнээр илэрхийлнэ.

Нэг хүчин зүйлийн зорилтот матрицын диагональ элементүүд нь түүврийн ковариацын матрицын диагональ элементүүдтэй тэнцүү буюу $t_{ii} = s_{ii}$ байна.

Ledoit and Wolf [2003]-ийн Lemma 2-т үндэслэн үнэлгээний алдаануудын хам хэлбэлзлийг дараах байдлаар тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

Харин $i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big]\times$$

$$\times\Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\Big].$$

Иймээс хам хэлбэлзлийн нийлбэрийн нормчилсон үнэлгээг

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тодорхойлно. Ингэснээр нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчмийг

$$\widehat{\alpha}_{\mathrm{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\mathrm{SF}} - \widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}$$

гэж үнэлнэ.

Энэ нь Ledoit and Wolf [2003]-ийн асимптотик оновчтой агшилтын эрчмийн үнэлгээг нормчилсон квадрат Фробениусын зайд нийцүүлэн илэрхийлсэн хэлбэр юм.

Энд $\widehat{d}_{\mathrm{SF}} > 0$ байхыг шаардана.

Эцэст нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын мат-

рицыг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}$$

гэж олно.

Тооцоолох алгоритм. Нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Зах зээлийн дундаж өгөөжийг тооцно.

$$\overline{R}_m = \frac{1}{n} \sum_{t=1}^{n} R_{m,t}.$$

2. Зах зээлийн өгөөжийн түүврийн вариацыг тооцно.

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2.$$

3. Хөрөнгө тус бүрийн регрессийн коэффициентийг тооцно.

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n} (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2}.$$

4. Регрессийн тогтмол коэффициент болон үлдэгдлийг тооцно.

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m,$$

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}.$$

5. Хөрөнгө тус бүрийн үлдэгдлийн вариацыг тооцно.

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2.$$

6. Нэг хүчин зүйлийн зорилтот матрицыг байгуулна.

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j. \end{cases}$$

   Эдгээр элементүүдээр $T_{\mathrm{SF}} = (t_{ij})$ матрицыг байгуулна.

7. Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг тооцно.

$$\widehat{d}_{\mathrm{SF}} = \frac{1}{N} \sum_{i=1}^{N} \sum_{j=1}^{N} (s_{ij} - t_{ij})^2.$$

8. Түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг тооцно.

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right].$$

9. Түүврийн ковариацын матриц болон нэг хүчин зүйлийн зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзлийг тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

$i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big] \times$$

$$\times\Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\Big].$$

Дараа нь

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тооцно.

10. Агшилтын эрчмийг тооцно.

$\widehat{d}_{\mathrm{SF}} > 0$ үед

$$\widehat{\alpha}_{\mathrm{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\mathrm{SF}} - \widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}.$$

11. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}}T_{\mathrm{SF}}.$$

2.5 Шугаман бус агшилтын үнэлгээ

Шугаман агшилтын аргын хязгаарлалтыг даван туулах зорилгоор шугаман бус агшилтын (Nonlinear Shrinkage) аргуудыг боловсруулсан. Эдгээр аргууд нь түүврийн ковариацын матрицын спектрийн задлалд суурилдаг бөгөөд урьдчилан тодорхойлсон нэг зорилтот матриц руу бүхэлд нь агшаахын оронд түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засварладаг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U\Lambda U^\top$$

гэж тэмдэглэе. Энд $U = (u_1, u_2, \ldots, u_N)$ нь S матрицын хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь түүврийн ковариацын матрицын хувийн утгуудыг агуулсан диагональ матриц юм.

Шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\widehat{D}U^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \widehat{d}_2, \ldots, \widehat{d}_N)$$

нь агшааж засварласан хувийн утгуудаас бүрдэх диагональ матриц бөгөөд $\widehat{d}_i$ нь λ_i хувийн утгад харгалзах засварласан хувийн утга юм.

Шугаман бус агшилтын арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, харин хувийн утга бүрийг өгөгдөлд тулгуурлан ялгаатай хэмжээгээр засварладаг. Иймээс хувийн утгуудын хэмжээ болон тэдгээрийн спектрийн тархалт дахь байрлалаас хамааран агшилтын хэмжээ өөр өөр байж болно.

Шугаман агшилтын аргын хувьд түүврийн ковариацын матриц болон зорилтот матрицыг нэг агшилтын эрчмээр хослуулдаг бол шугаман бус агшилтын арга нь хувийн утга

бүрд тусгайлан тохируулсан хувиргалт хийдгээрээ ялгаатай. Ингэснээр түүврийн ковариацын матрицын хувийн утгуудын үнэлгээний алдааг бууруулах боломжийг олгодог.

Ledoit болон Wolf (2012) нар шугаман бус агшилтын аргын онолын үндэслэлийг боловсруулж, улмаар Ledoit болон Wolf (2015) нар QuEST (Quantized Eigenvalues Sampling Transform) алгоритмд суурилсан тоон хэрэгжилтийг хөгжүүлсэн. Энэхүү арга нь тоон оновчлол шаарддаг тул тооцооллын хувьд харьцангуй төвөгтэй байдаг.

Үүний дараа Ledoit and Wolf [2020] санамсаргүй матрицын онол болон спектрийн тархалтын шинж чанарт тулгуурласан аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн утгуудыг аналитик илэрхийлэлд суурилан засварладаг. Энэхүү судалгаанд аналитик шугаман бус агшилтын аргыг ашиглах бөгөөд түүний математик үндэслэл болон тооцоолох алгоритмыг дараагийн хэсэгт авч үзнэ.

2.5.1 Аналитик шугаман бус агшилтын үнэлгээ

Аналитик шугаман бус агшилтын үнэлгээ (Analytical Nonlinear Shrinkage Estimation) нь санамсаргүй матрицын онол (Random Matrix Theory)-д тулгуурлан түүврийн ковариацын матрицын хувийн утгуудыг засварлах арга юм. Шугаман агшилтын аргуудаас ялгаатай нь энэхүү арга нь хувийн утга бүрийн хэмжээ болон спектрийн тархалт дахь байрлалыг харгалзан ялгаатай агшилт хийдэг.

Ledoit and Wolf [2020] нь спектрийн тархалтын нягт болон түүний Hilbert хувиргалтыг kernel аргаар үнэлэх замаар аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, хувийн утгуудыг засварлах замаар ковариацын матрицын үнэлгээний алдааг бууруулахад чиглэдэг.

Судалгаанд хамрагдсан хөрөнгийн тоог N, ажиглалтын тоог n гэж тэмдэглэж, тэдгээрийн харьцааг

$$c = \frac{N}{n}$$

гэж тодорхойлно. Аргын үндсэн онолын хувьд $N, n \to \infty$ үед

$$\frac{N}{n} \longrightarrow c \in (0, 1)$$

байх асимптотик нөхцөлийг авч үздэг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U \Lambda U^\top$$

гэж тэмдэглэе. Энд

$$U = (u_1, u_2, \ldots, u_N), \qquad U^\top U = I_N,$$

нь хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь хувийн утгуудыг агуулсан диагональ матриц юм. Хувийн утгуудыг

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_N > 0$$

гэж эрэмбэлнэ.

Аналитик шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U \widehat{D} U^\top = \sum_{i=1}^{N} \widehat{d}_i u_i u_i^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \ldots, \widehat{d}_N)$$

нь агшсан хувийн утгуудаас бүрдэх диагональ матриц юм.

Агшсан хувийн утгуудын үнэлгээ. Ledoit and Wolf [2020]-ийн (4.3) томьёоны дагуу агшсан хувийн утгуудыг

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}$$

гэж тооцно.

Энд $\widehat{f}(\lambda_i)$ нь спектрийн тархалтын нягтын үнэлгээ, $\widehat{Hf}(\lambda_i)$ нь уг нягтын Hilbert хувиргалтын үнэлгээ юм. Эдгээрийг түүврийн ковариацын матрицын хувийн утгуудад тулгуурлан kernel аргаар тооцдог.

Иймээс агшсан хувийн утга нь зөвхөн тухайн λ_i-ийн хэмжээнээс бус, спектрийн тархалтын нягт болон түүний Hilbert хувиргалтын утгаас хамаарна.

Тооцоолох алгоритм. Ledoit and Wolf [2020]-ийн Section 4.7-д үндэслэн аналитик шугаман бус агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Түүврийн ковариацын матрицын спектрийн задлалыг байгуулна.

$$S = U\Lambda U^\top.$$

2. Хөрөнгийн тоо болон ажиглалтын тооны харьцааг тооцно.

$$c = \frac{N}{n}.$$

3. Спектрийн нягтыг үнэлэхэд ашиглах bandwidth параметрийг

$$h = n^{-1/3}$$

гэж сонгоно. Хувийн утга бүрд харгалзах локал bandwidth нь

$$h_j = \lambda_j h, \qquad j = 1, \ldots, N$$

байна.

4. Спектрийн нягтыг Epanechnikov kernel ашиглан үнэлнэ.

$$\widehat{f}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} k\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд

$$k(x) = \begin{cases} \dfrac{3}{4\sqrt{5}}\left(1 - \dfrac{x^2}{5}\right), & |x| \le \sqrt{5}, \\ 0, & |x| > \sqrt{5}. \end{cases}$$

5. Спектрийн нягтын Hilbert хувиргалтыг үнэлнэ.

$$\widehat{Hf}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} \ell\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд $\ell(x) = Hk(x)$ бөгөөд

$$\ell(x) = \begin{cases} -\dfrac{3x}{10\pi} + \dfrac{3}{4\sqrt{5}\pi}\left(1 - \dfrac{x^2}{5}\right)\ln\left|\dfrac{\sqrt{5} - x}{\sqrt{5} + x}\right|, & |x| \ne \sqrt{5}, \\ -\dfrac{3x}{10\pi}, & |x| = \sqrt{5}. \end{cases}$$

6. Агшсан хувийн утгуудыг тооцно.

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}.$$

7. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\text{NLS}} = U \operatorname{diag}(\widehat{d}_1, \ldots, \widehat{d}_N) U^\top.$$

2.6 Эмпирик үнэлгээний арга зүй

Энэхүү судалгаанд түүврийн ковариацын матриц болон агшилтын таван үнэлэгчийг ижил long-only GMVP загварын хүрээнд түүврээс гадуурх (out-of-sample, OOS) гүйцэтгэлээр харьцуулна. Ковариацын матрицын үнэлгээний алдаа бага байх нь багцын бодит эрсдэл заавал бага байна гэсэн үг биш тул үнэлэгчдийн гүйцэтгэлийг багцын түвшинд үнэлэх шаардлагатай.

Энэ зорилгоор [Ledoit and Wolf, 2003, DeMiguel et al., 2009] судалгаанд хэрэглэсэн эмпирик үнэлгээний зарчимд тулгуурлан шилжих цонхны аргыг ашиглана. Бүх үнэлэгчийн хувьд хөрөнгө оруулалтын хязгаарлалт, түүврээс гадуурх үнэлгээний хугацаа болон гүйцэтгэлийн шалгуурыг ижил байлгана.

2.6.1 Шилжих цонхны аргаар түүврээс гадуурх үнэлгээ хийх

Шилжих цонхны (rolling-window) арга нь тогтмол урттай түүхэн өгөгдлөөр ковариацын матрицыг үнэлж, багцын жинг тодорхойлсны дараа уг жинг дараагийн сарын өгөөжид хэрэглэнэ.

Нийт сарын өгөөжийн ажиглалтын тоог n, хөрөнгийн тоог N, сургалтын цонхны уртыг T гэж тэмдэглэе. t сарын өгөөжийн вектор нь

$$\boldsymbol{R}_t = (R_{1,t}, R_{2,t}, \ldots, R_{N,t})^\top.$$

t сарын эцэст ашиглах сургалтын өгөгдлийг

$$\mathcal{D}_t = \{\boldsymbol{R}_{t-T+1}, \ldots, \boldsymbol{R}_t\}, \qquad t = T, \ldots, n-1$$

гэж тодорхойлно.

Ковариацын матрицын үнэлэгчийг $k = 0, 1, \ldots, 5$ гэж тэмдэглэе. Энд $k = 0$ нь түүврийн ковариацын матриц, $k = 1, \ldots, 5$ нь агшилтын үнэлэгчид юм. Сургалтын цонх бүрд ковариацын матрицыг

$$\widehat{\boldsymbol{\Sigma}}_t^{(k)} = \widehat{\boldsymbol{\Sigma}}^{(k)}(\mathcal{D}_t)$$

гэж үнэлнэ. Нэг хүчин зүйлийн үнэлэгчийн хувьд сургалтын цонхтой ижил хугацааны зах зээлийн индексийн өгөөжийг нэмж ашиглана.

Үнэлсэн ковариацын матрицад үндэслэн багцын оновчтой жинг

$$\begin{aligned} \widehat{\boldsymbol{w}}_t^{(k)} \in \arg\min_{\boldsymbol{w}} \quad & \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}}_t^{(k)} \boldsymbol{w}, \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{w} = 1, \\ & w_i \geq 0, \qquad i = 1, \ldots, N \end{aligned}$$

гэсэн long-only GMVP бодлогоор тодорхойлно.

Тэгвэл дараагийн сарын багцын өгөөж нь

$$r_{p,t+1}^{(k)} = \left(\widehat{\boldsymbol{w}}_t^{(k)}\right)^\top \boldsymbol{R}_{t+1}$$

байна.

Сургалтын цонхыг сар бүр нэг алхмаар урагшлуулж, ковариацын матриц, агшилтын эрчим болон багцын жинг дахин тооцно. Ирээдүйн өгөөжийг параметрийн үнэлгээнд ашиглахгүй.

Үндсэн шинжилгээнд $N = 10$, $n = 172$, $T = 120$ тул түүврээс гадуурх ажиглалтын тоо

$$M = n - T = 172 - 120 = 52$$

байна. Ийнхүү үнэлэгч бүрийн хувьд ижил 52 сарын OOS өгөөжийн цуваа үүсгэнэ.

2.6.2 Багцын гүйцэтгэлийн үзүүлэлтүүд

Ковариацын үнэлэгчдийн гүйцэтгэлийг OOS хэлбэлзэл, харьцангуй дисперсийн бууралт (RVR) болон Sharpe-ийн харьцаагаар үнэлнэ.

Түүврээс гадуурх хэлбэлзэл (Out-of-Sample Volatility). k-р үнэлэгчээр байгуулсан багцын дундаж сарын өгөөж болон түүврийн вариацыг

$$\overline{r}_p^{(k)} = \frac{1}{M} \sum_{t=T+1}^{n} r_{p,t}^{(k)},$$

$$\widehat{\sigma}_{p,k}^2 = \frac{1}{M-1} \sum_{t=T+1}^{n} \left(r_{p,t}^{(k)} - \overline{r}_p^{(k)} \right)^2$$

гэж тодорхойлно.

Тэгвэл сарын болон жилийн хэлбэлзэл нь

$$\widehat{\sigma}_{p,k} = \sqrt{\widehat{\sigma}_{p,k}^2}, \qquad \widehat{\sigma}_{p,k}^{ann} = \sqrt{12}\, \widehat{\sigma}_{p,k}$$

байна. Жилийн хэлбэлзэлд шилжүүлэхдээ сарын өгөөжүүдийн автоковариацыг тэг гэж үзнэ.

Харьцангуй дисперсийн бууралт (Relative Variance Reduction). Агшилтын үнэлэгчийн OOS вариацыг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулж,

$$RVR_k^{(\%)} = 100 \left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,0}^2} \right), \qquad k = 1, \ldots, 5$$

гэж тооцно.

$RVR_k^{(\%)} > 0$ бол агшилтын үнэлэгчийн багц суурь загвараас бага вариацтай, харин $RVR_k^{(\%)} < 0$ бол их вариацтай байна.

Sharpe-ийн харьцаа (Sharpe Ratio). Сарын эрсдэлгүй өгөөжийг $r_{f,t}$ гэвэл илүүдэл өгөөж нь

$$r_{e,t}^{(k)} = r_{p,t}^{(k)} - r_{f,t}$$

байна. Сарын Sharpe-ийн харьцааг

$$\widehat{SR}_k = \frac{\overline{r}_e^{(k)}}{\widehat{\sigma}_{e,k}}$$

гэж тодорхойлно.

Энэхүү судалгаанд $r_{f,t} = 0$ гэж авч үзсэн тул

$$\widehat{SR}_k = \frac{\overline{r}_p^{(k)}}{\widehat{\sigma}_{p,k}}, \qquad \widehat{SR}_k^{ann} = \sqrt{12}\, \widehat{SR}_k.$$

Жилийн Sharpe-ийн харьцаанд шилжүүлэхдээ мөн сарын өгөөжийн автоковариацыг тэг гэж үзнэ. GMVP-ийн зорилго нь вариацыг хамгийн бага байлгах тул Sharpe-ийн харьцааг нэмэлт гүйцэтгэлийн үзүүлэлт болгон ашиглана.

2.6.3 Багцын жингийн тогтвортой байдал ба эргэлт

Ковариацын үнэлэгчийн сонголт нь багцын жингийн бүтэц болон дахин тэнцвэржүүлэлтийн хэмжээнд нөлөөлж болох тул багцын эргэлт, жингийн төвлөрлийг үнэлнэ.

Багцын эргэлт (Portfolio Turnover). t сард ашиглах багцын жинг $\widehat{\boldsymbol{w}}_{t-1}^{(k)}$ гэж тэмдэглэе. Тухайн сарын өгөөж хэрэгжсэний дараах, дахин тэнцвэржүүлэхээс өмнөх жин нь

$$\widetilde{w}_{i,t}^{(k)} = \frac{\widehat{w}_{i,t-1}^{(k)}(1+R_{i,t})}{1+r_{p,t}^{(k)}}$$

байна.

Дараагийн сард ашиглах шинэ оновчтой жинд шилжихэд шаардагдах багцын эргэлтийг

$$TO_t^{(k)} = \frac{1}{2}\sum_{i=1}^{N}\left|\widehat{w}_{i,t}^{(k)} - \widetilde{w}_{i,t}^{(k)}\right|$$

гэж тодорхойлно.

Түүврээс гадуурх дундаж эргэлт нь

$$\overline{TO}^{(k)} = \frac{1}{M-1}\sum_{t=T+1}^{n-1} TO_t^{(k)}$$

байна.

Ийнхүү 52 сарын OOS хугацаанд 51 удаагийн дахин тэнцвэржүүлэлтийг тооцно. Эхний багц бүрдүүлэлтийг эргэлтийн тооцоонд оруулахгүй. Энд тооцсон үндсэн OOS өгөөж нь арилжааны зардлын өмнөх өгөөж юм. Арилжааны зардлын нөлөөг нэмэлт шинжилгээнд тусад нь үнэлнэ.

Багцын жингийн төвлөрөл (Weight Concentration). Жингийн төвлөрлийг Herfindahl–Hirschman Index (HHI)-ээр

$$HHI_t^{(k)} = \sum_{i=1}^{N}\left(\widehat{w}_{i,t}^{(k)}\right)^2$$

гэж хэмжинэ.

Long-only GMVP-ийн хувьд

$$\frac{1}{N} \le HHI_t^{(k)} \le 1.$$

Түүврээс гадуурх дундаж төвлөрөл нь

$$\overline{HHI}^{(k)} = \frac{1}{M}\sum_{t=T}^{n-1} HHI_t^{(k)}$$

байна. HHI өндөр байх нь багцын жин цөөн хөрөнгөд төвлөрснийг илэрхийлнэ.

2.6.4 Ковариацын үнэлэгчдийн статистик харьцуулалт

Агшилтын үнэлэгчдийн OOS гүйцэтгэлийн ялгааг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулан статистикаар үнэлнэ.

k-р агшилтын үнэлэгч болон суурь загварын сарын квадрат өгөөжийн ялгааг

$$d_t^{(k)} = \left(r_{p,t}^{(k)}\right)^2 - \left(r_{p,t}^{(0)}\right)^2, \qquad t = T+1, \ldots, n$$

гэж тодорхойлно.

Дараах хоёр талт таамаглалыг шалгана:

$$H_0 : E[d_t^{(k)}] = 0, \qquad H_1 : E[d_t^{(k)}] \neq 0.$$

Дундаж ялгааны стандарт алдааг Newey–West төрлийн HAC аргаар, гурван лаг ашиглан үнэлнэ. Шалгах статистик нь

$$t_{HAC}^{(k)} = \frac{\overline{d}^{(k)}}{\widehat{SE}_{HAC}(\overline{d}^{(k)})}, \qquad \overline{d}^{(k)} = \frac{1}{M}\sum_{t=T+1}^{n} d_t^{(k)}$$

байна.

Хоёр талт p-утгыг асимптотик нормаль ойролцооллоор тооцож, таван агшилтын үнэлэгчийг суурь загвартай харьцуулсан олон шалгалтад Holm-ийн засвар хэрэглэнэ.

Квадрат өгөөжийн дундаж ялгаа нь дисперсийн ялгаатай заавал тэнцүү биш. Учир нь

$$E[r_p^2] = \mathrm{Var}(r_p) + \left(E[r_p]\right)^2.$$

Иймээс HAC шалгалтыг RVR болон OOS хэлбэлзлийн үр дүнтэй хамтатган тайлбарлана. Мөн OOS хугацаа 52 сар тул статистик шалгалтын чадал хязгаарлагдмал байж болно.

2.6.5 Хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцааны мэдрэмжийн шинжилгээ

Ковариацын матрицын үнэлгээний алдаа нь хөрөнгийн тоо N болон сургалтын ажиглалтын тоо T-ийн харьцаанаас хамаарч болно. Уг харьцааг

$$c = \frac{N}{T}$$

гэж тодорхойлно.

Энэхүү судалгаанд $N = 10$ гэж тогтмол байлгаж,

$$T \in \{60, 90, 120\}$$

гэсэн сургалтын цонхуудыг авч үзнэ. Харгалзах N/T харьцаа нь

$$\frac{10}{60} \approx 0.1667, \qquad \frac{10}{90} \approx 0.1111, \qquad \frac{10}{120} \approx 0.0833$$

байна.

Сургалтын цонхны уртаас үүдэх OOS хугацааны ялгааг арилгахын тулд бүх хувилбарт хамгийн урт сургалтын цонхонд харгалзах ижил 52 сарын OOS хугацааг ашиглана.

Цонхны урт бүрд зургаан үнэлэгчийг дахин тооцож, багцын хэлбэлзэл, RVR, Sharpe-ийн харьцаа, эргэлт болон төвлөрлийг харьцуулна.

Энэ шинжилгээнд N тогтмол тул N/T харьцааны өөрчлөлт нь сургалтын цонхны уртын өөрчлөлттэй давхцана. Иймээс тэдгээрийн нөлөөг бүрэн тусгаарлан тайлбарлахгүй.

2.6.6 Багцын сонголтын robustness шинжилгээ

Агшилтын үнэлэгчдийн гүйцэтгэл сонгосон хөрөнгүүдийн бүрэлдэхүүнээс хамаарах эсэхийг үнэлэхийн тулд корреляцийн ялгаатай бүтэцтэй 150 багцад шинжилгээг давтан гүйцэтгэнэ.

Сарын өгөөжийн бүрэн өгөгдөлтэй 337 хувьцаанаас тус бүр 10 хөрөнгөтэй багцуудыг сонгоно. Энэхүү 337 хувьцааны олонлог нь 2012–2026 оны хугацаанд бүрэн өгөгдөлтэй байх шалгууруар бүрдсэн тул үр дүнг уг сонгогдсон олонлогийн хүрээнд тайлбарлана. Өгөгдлийн

бүрэн байдлын шалгууруас үүдэх сонголтын хазайлтыг энэ шинжилгээ бүрэн арилгахгүй. Корреляцыг эхний 120 сарын сургалтын өгөөжөөр тооцож, багцын дундаж хос корреляцыг

$$\overline{\rho} = \frac{2}{N(N-1)} \sum_{i<j} \rho_{ij}$$

гэж тодорхойлно.

Багцуудыг өндөр (High), дунд (Medium), бага (Low) корреляцтай гурван ангиллаар авч үзнэ. Үндсэн шинжилгээнд сонгосон High, Medium, Low багцуудын эхний 120 сарын өгөөжөөр тооцсон дундаж хос корреляц нь харгалзан 0.557048, 0.303609, 0.101523 байна. Robustness шинжилгээнд эдгээр утгыг зорилтот корреляц болгон ашиглана.

Багц сонгохдоо 337 хувьцаанаас 10 хувьцааг буцаалтгүйгээр санамсаргүй сонгох туршилтыг 250000 удаа гүйцэтгэж, давхардсан нэр дэвшигч багцуудыг хасна.

Үлдсэн багцуудыг зорилтот корреляцаас хазайх абсолют зөрүүгээр эрэмбэлж, ангилал бүрд 50 багц сонгоно. Нэг ангиллын сонгогдсон дурын хоёр багцын нийтлэг хувьцааны тоо зургаагаас хэтрэхгүй байх хязгаарлалт тавина.

Ийнхүү сонгосон 150 багц бүрд зургаан үнэлэгчээр long-only GMVP байгуулж, 120 сарын шилжих цонх болон ижил 52 сарын OOS хугацаагаар үнэлнэ. Багц сонгох үе шатанд OOS өгөөжийг ашиглахгүй.

Багц тус бүрийн RVR-ийг тооцож, ангилал бүрийн дундаж, медиан болон эрэг RVR-тэй багцын эзлэх хувийг харьцуулна.

Эдгээр 150 багц нь бүх боломжит 10 хувьцаатай багцуудаас энгийн санамсаргүй түүврийн аргаар сонгогдоогүй, харин зорилтот корреляцийн түвшинд ойр байх нөхцөлөөр сонгогдсон болохыг үр дүнг тайлбарлахдаа харгалзан үзнэ.

2.6.7 RVR-ийн bootstrap итгэх завсар

150 багцын robustness шинжилгээнд ажиглагдсан дундаж RVR-ийн тодорхой бус байдлыг үнэлэхийн тулд circular moving-block bootstrap аргыг ашиглана.

Корреляцын ангиллыг $g \in \{H, M, L\}$, тухайн ангиллын багцын тоог $P_g = 50$ гэж тэмдэглэе. j-р багцын k-р үнэлэгчийн RVR-ийг $RVR^{(\%)}_{g,j,k}$ гэвэл ангиллын дундаж RVR нь

$$\overline{RVR}^{(\%)}_{g,k} = \frac{1}{P_g} \sum_{j=1}^{P_g} RVR^{(\%)}_{g,j,k}$$

байна.

Bootstrap давталт бүрд 52 сарын OOS хугацаанаас зургаан сарын урттай блокуудын эхлэх байрлалыг санамсаргүй сонгоно. Блокийг цувааны төгсгөлд хүрвэл эхлэлээс үргэлжлүүлэх circular зарчмаар байгуулж, сонгосон блокуудыг нэгтгэн 52 ажиглалттай түүвэр үүсгэнэ.

Тухайн давталтад сонгосон сарын индексүүдийг бүх 150 багц болон зургаан үнэлэгчид ижил хэрэглэнэ. Ингэснээр багцуудын өгөөжийн хоорондын хамаарлыг дахин түүвэрлэх явцад хадгална.

Bootstrap түүвэр бүрд багц тус бүрийн OOS вариац, RVR болон ангиллын дундаж RVR-ийг шинээр тооцно.

Нийт $B = 3000$ давталт гүйцэтгэж, давталтуудаас гарсан дундаж RVR-ийн тархалтын 2.5 болон 97.5 хувийн квантилуудаар 95%-ийн percentile bootstrap итгэх завсрыг байгуулна.

Итгэх завсар тэгийг агуулаагүй тохиолдолд тухайн ангиллын дундаж RVR тэгээс ялгаатай байж болохыг илтгэх боловч энэ нь олон харьцуулалтын засвартай шалгалттай адил биш. Эдгээр нь олон харьцуулалтын засвар хийгдээгүй итгэх завсрууд тул үр дүнг болгоомжтой тайлбарлана.

Харин итгэх завсар тэгийг агуулсан тохиолдолд эрэг эсвэл сөрөг нөлөөг статистикийн хувьд баталгаатай гэж дүгнэхгүй.

Энэхүү bootstrap шинжилгээнд сонгосон 150 багцын бүрэлдэхүүнийг тогтмол байлгаж, зөвхөн OOS хугацааны ажиглалтуудыг дахин түүвэрлэнэ.

Иймээс итгэх завсар нь тухайн сонгосон багцуудын OOS гүйцэтгэлийн тодорхой бус байдлыг илэрхийлэх бөгөөд бүх боломжит хувьцааны багцад шууд ерөнхийлөх үндэслэл болохгүй.

2.6.8 Тэнцүү жинтэй багц ба арилжааны зардлын шинжилгээ

GMVP загваруудын практик гүйцэтгэлийг харьцуулах нэмэлт жишиг болгон хөрөнгө бүрд ижил жин оноодог $1/N$ багцыг ашиглана. Тухайн багцын зорилтот жин нь

$$\boldsymbol{w}^{EW} = \frac{1}{N}\mathbf{1}, \qquad N = 10,$$

бөгөөд сарын эхэнд дахин тэнцвэржүүлж, зорилтот жинг хадгална. Иймээс t сарын жишиг багцын зардлын өмнөх өгөөж нь

$$r_{p,t}^{EW} = \left(\boldsymbol{w}^{EW}\right)^{\top} \boldsymbol{R}_t = \frac{1}{N}\sum_{i=1}^{N} R_{i,t}.$$

$1/N$ багц болон зургаан GMVP загварт OOS хугацаа, жилийн хэлбэлзэл, Sharpe-ийн харьцаа, багцын эргэлт, HHI үзүүлэлтийг ижил аргачлалаар тооцно. Тэнцүү жинтэй багцын төвлөрөл нь бүх сард $HHI^{EW} = 1/N$ байна.

Арилжааны зардлыг тооцохдоо нэг талын арилжааны зардлын хувь хэмжээг c гэж тэмдэглэж, $c \in \{0, 5, 10, 25\}$ суурь пункт (basis points) гэсэн хувилбаруудыг авч үзнэ. Энд нэг суурь пункт нь 0.0001-тэй тэнцэнэ.

Өмнөх сарын өгөөж хэрэгжсэний дараах жин $\widetilde{\boldsymbol{w}}_t^{(k)}$ болон шинэ зорилтот жингийн ялгаагаар тооцсон $TO_t^{(k)}$ нь нийт худалдан авалт эсвэл нийт борлуулалтын эзлэх хувийг илэрхийлнэ. Тиймээс нэг талын зардлын хувь c үед хоёр талын нийт арилжааны зардлын хувь нь

$$C_t^{(k)} = 2cTO_t^{(k)}$$

байна. Тухайн сарын эхэнд зардлыг суутгасан гэж үзвэл цэвэр өгөөж нь

$$r_{p,t}^{(k),net} = \left(1 - C_t^{(k)}\right)\left(1 + r_{p,t}^{(k)}\right) - 1,$$

энд $k \in \{0, 1, \ldots, 5, EW\}$.

OOS эхний сарын багцыг анх бүрдүүлэх арилжааны зардлыг тооцохгүй, өөрөөр хэлбэл $C_{T+1}^{(k)} = 0$ гэж авна. Үлдсэн 51 сарын дахин тэнцвэржүүлэлтийн зардлыг тооцно. Арилжааны зардлын хувилбар бүрд цэвэр өгөөжийн цуваагаар жилийн хэлбэлзэл, Sharpe-ийн харьцаа, хуримтлагдсан өгөөжийг дахин үнэлнэ. Хуримтлагдсан цэвэр өгөөжийг

$$CR_k^{net} = \prod_{t=T+1}^{n}\left(1 + r_{p,t}^{(k),net}\right) - 1$$

гэж тодорхойлно.

2.6.9 GMVP ба тэнцүү жинтэй багцын bootstrap харьцуулалт

Үндсэн High, Medium, Low багц тус бүрд зургаан GMVP загварын OOS вариацыг $1/N$ багцын вариацтай харьцуулна. k-р GMVP загварын $1/N$ багцтай харьцуулсан дисперсийн бууралтыг

$$RVR_{k|EW}^{(\%)} = 100\left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,EW}^2}\right), \qquad k = 0, \ldots, 5$$

гэж тодорхойлно. Энэ үзүүлэлтийн суурь нь өмнөх хэсгийн Sample GMVP биш, харин $1/N$ багц юм.

Тодорхой бус байдлыг үнэлэхдээ 52 сарын OOS өгөөжид зургаан сарын блокийн урттай circular moving-block bootstrap аргыг хэрэглэнэ. Нэг багцын долоон стратегийн (зургаан

GMVP болон $1/N$) өгөөжийг нэг ижил сарын индексээр дахин түүвэрлэж, стратегиудын хоорондын хос хамаарлыг хадгална.

Нийт $B = 3000$ давталт бүрд түүврийн вариац ($M - 1$ хуваарьтай) болон $RVR^{(\%)}_{k|EW}$-ийг шинээр тооцно. Bootstrap тархалтын 2.5 ба 97.5 хувийн квантилуудаар засвар хийгдээгүй 95%-ийн percentile итгэх завсар байгуулна.

Мөн тэг таамаглал $H_0 : RVR^{(\%)}_{k|EW} = 0$-ийг хоёр талт, ажиглагдсан статистикийн эргэн тойронд төвлөрүүлсэн bootstrap ойролцооллоор үнэлнэ. Ажиглагдсан RVR-ийг $\widehat{\theta}$, bootstrap давталтын RVR-ийг $\widehat{\theta}^{*(b)}$ гэвэл тооцоолсон p-утга нь

$$\widehat{p}_{boot} = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{\left|\widehat{\theta}^{*(b)} - \widehat{\theta}\right| \geq \left|\widehat{\theta}\right|\right\}}{B + 1}.$$

Нэг үндсэн багц дахь зургаан GMVP–$1/N$ харьцуулалтын p-утгуудад Holm-ийн засвар хэрэглэнэ. Гурван багцын нийт 18 шалгалтыг нэг бүл болгон засварлахгүй. Percentile итгэх завсар болон төвлөрүүлсэн bootstrap p-утга нь нэг шалгалтын харилцан урвуу хувилбар биш тул тэдгээрийн дүгнэлт зарим тохиолдолд зөрж болно.

Энэ шинжилгээ нь зөвхөн үндсэн гурван багцын зардлын өмнөх OOS өгөөжид тулгуурлана. Иймээс арилжааны зардлын дараах гүйцэтгэлийн статистик шалгалт гэж тайлбарлахгүй. OOS хугацаа 52 сар болохыг үр дүнгийн тодорхой бус байдлыг тайлбарлахдаа харгалзан үзнэ.

3 Өгөгдөл

Энэхүү судалгаанд ковариацын матрицын агшилтын үнэлэгчдийн гүйцэтгэлийг хөрөнгүүдийн хоорондын корреляцийн ялгаатай бүтэцтэй багцуудад харьцуулах зорилгоор АНУ-ын S&P 500 индексийн түүхэн бүрэлдэхүүнээс сонгосон хувьцааны сарын өгөөжийг ашигласан.

3.1 Өгөгдлийн эх сурвалж ба өгөөжийн тооцоолол

Нэр дэвшигч хувьцаануудыг S&P 500 индексийн түүхэн бүрэлдэхүүний нээлттэй өгөгдлийн сангаас 2012 оны 5 дугаар сарын 30-ны өдрийн байдлаар сонгосон [chinobing]. Тухайн жагсаалтад 453 хувьцааны код байсан бөгөөд 2012 оны 5 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх сарын эцсийн үнийн мэдээлэл бүрэн байгаа 337 хувьцааг шинжилгээнд хамруулсан.

Хувьцааны үнийн өгөгдлийг Yahoo Finance мэдээллийн сангаас Python програмчлалын хэлний `yfinance` сангаар татаж, `auto_adjust=True` тохиргоогоор ногдол ашиг болон хувьцаа хуваалтын нөлөөг харгалзан үзсэн.

Хувьцаа тус бүрийн сарын энгийн өгөөжийг

$$R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

гэж тооцсон. Энд $P_{i,t}$ нь i-р хувьцааны t сарын эцсийн тохируулгатай хаалтын үнэ юм.

Судалгаанд 2012 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх нийт $n = 172$ сарын өгөөжийг ашигласан. Эдгээрээс эхний 120 сарын өгөөжийг багцын бүрэлдэхүүнийг сонгох сургалтын хугацаа, үлдсэн 52 сарын өгөөжийг түүврээс гадуурх гүйцэтгэлийг үнэлэх хугацаа болгон ашигласан.

3.2 Корреляцийн бүтцээр багц сонгох

Ковариацын матрицын агшилтын аргуудын гүйцэтгэл хөрөнгүүдийн хоорондын корреляцийн бүтцээс хамаарах эсэхийг судлах зорилгоор өндөр, дунд, бага дундаж корреляцитай гурван багц байгуулсан.

Багцын бүрэлдэхүүнийг сонгохдоо 2012 оны 6 дугаар сараас 2022 оны 5 дугаар сар хүртэлх эхний 120 сарын өгөөжид үндэслэн 337 хувьцааны хоорондын түүврийн корреляцийн матрицыг тооцсон. Ингэснээр багцын бүрэлдэхүүнийг тодорхойлоход түүврээс гадуурх хугацааны өгөөжийг ашиглаагүй.

Хөрөнгийн тоо $N = 10$ байх багцын дундаж хос корреляцийг

$$\bar{\rho}_P = \frac{2}{N(N-1)} \sum_{i<j,\, i,j \in P} \rho_{ij}$$

гэж тодорхойлсон. Энд P нь тухайн багцын хөрөнгүүдийн олонлог, ρ_{ij} нь сургалтын хугацааны өгөөжөөс тооцсон i, j хөрөнгийн түүврийн корреляци юм.

Үндсэн гурван багцыг Monte Carlo хайлтын аргаар сонгосон. Үүнд 337 хувьцаанаас 10 хувьцаатай багцын 100 000 санамсаргүй хувилбарыг ангилал тус бүрд шалгасан.

Эхлээд дундаж хос корреляц хамгийн өндөр байх багцыг, дараа нь хамгийн бага байх багцыг сонгосон. Эцэст нь дундаж хос корреляци нь 337 хувьцааны бүх хосын дундаж корреляцад хамгийн ойр байх багцыг сонгосон.

Багцуудыг өндөр, бага, дунд гэсэн дарааллаар сонгохдоо өмнөх багцуудад орсон хувьцаануудыг дараагийн сонголтоос хассан. Иймээс үндсэн гурван багц хоорондоо давхцахгүй бөгөөд нийт 30 ялгаатай хувьцаанаас бүрдэнэ.

Энэхүү Monte Carlo хайлтаар боломжит бүх багцыг бүрэн шалгаагүй тул сонгосон гурван багцыг дундаж корреляцийн хувьд глобал оновчтой гэж үзэхгүй. Харин эдгээр нь санамсаргүй хайлтын хүрээнд тодорхойлсон, корреляцийн ялгаатай түвшнийг төлөөлөх багцууд юм.

Хүснэгт 1: Үндсэн шинжилгээнд сонгосон багцуудын шинж чанар

Үзүүлэлт	Өндөр	Дунд	Бага
Хөрөнгийн тоо	10	10	10
Дундаж хос корреляци	0.5570	0.3036	0.1015
Ковариацын матрицын нөхцөлт тоо	72.99	16.82	27.45

Хүснэгт 1-д үзүүлсэн дундаж хос корреляцийг багц тус бүрийн эхний 120 сарын өгөөжид үндэслэн тооцсон.

Ковариацын матрицын нөхцөлт тоог мөн тухайн 120 сарын өгөөжөөс тооцсон түүврийн ковариацын матрицаар тодорхойлсон. Эерэг тодорхой ковариацын матрицын хувьд нөхцөлт тоо нь хамгийн их болон хамгийн бага хувийн утгын харьцаатай тэнцүү бөгөөд

$$\kappa(S) = \frac{\lambda_{\max}(S)}{\lambda_{\min}(S)}$$

гэж илэрхийлэгдэнэ.

Нөхцөлт тоо их байх тусам матрицын нөхцөлжилт муу байгааг илэрхийлнэ. Хүснэгтээс өндөр корреляцитай багцын ковариацын матрицын нөхцөлт тоо хамгийн их байгааг харж болно. Гэхдээ нөхцөлт тоо нь зөвхөн дундаж корреляциар тодорхойлогдохгүй, хөрөнгүүдийн дисперс болон ковариацын бүтцээс мөн хамаарна.

Өндөр корреляцитай багцад CCL, CME, COF, CTAS, FLS, MET, PRU, SWK, UNM, WFC; дунд корреляцитай багцад AMGN, AMT, BEN, DTE, EXPD, MO, MRK, PG, SNA, UPS; бага корреляцитай багцад BAX, BIIB, CTSH, GNW, HRB, MTB, NEM, QCOM, RRC, WEC хувьцаанууд сонгогдсон.

3.3 Нэмэлт багцууд ба түүврээс гадуурх үнэлгээ

Үндсэн шинжилгээний үр дүн тодорхой 30 хувьцааны сонголтоос хамаарах эсэхийг шалгах зорилгоор нэмэлт 150 багц сонгосон. Үүнд өндөр, дунд, бага корреляцын ангилал тус бүрээс 50 багц хамруулсан.

Нэмэлт багцуудыг мөн эхний 120 сарын өгөөжид үндэслэн Monte Carlo хайлтын аргаар сонгож, нэг ангиллын хоёр багцад хамгийн ихдээ зургаан ижил хувьцаа байх нөхцөл тавьсан.

Үндсэн шинжилгээнд ковариацын матрицыг $T = 120$ сарын шилжих цонхоор үнэлж, 2022 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх $M = 52$ сарын түүврээс гадуурх (OOS) гүйцэтгэлийг харьцуулсан.

Сонгосон багц бүрийн хувьцааны бүрэлдэхүүнийг OOS хугацаанд тогтмол хадгалж, багцын оновчтой жинг сар бүр шинэчилсэн.

3.4 Өгөгдлийн сонголтын хязгаарлалт

Судалгааны нэг хязгаарлалт нь шинжилгээний бүх хугацаанд үнийн мэдээлэл бүрэн байгаа хувьцаануудыг сонгосон явдал юм.

Хэдийгээр нэр дэвшигч хувьцаануудыг 2012 оны түүхэн бүрэлдэхүүнээс тодорхойлж, багцын корреляцын бүтцийг зөвхөн 2022 оны 5 дугаар сар хүртэлх өгөөжид үндэслэн сонгосон боловч шинжилгээнд хамрагдах 337 хувьцааг тодорхойлохдоо 2026 оны 9 дүгээр сар хүртэлх үнийн өгөгдлийн бүрэн байдлыг шаардсан.

Иймээс өгөгдлийн олдоцтой холбоотой сонголтын хазайлт, тэр дундаа survivorship bias болон ирээдүйн мэдээлэлд тулгуурласан сонголтын хазайлт үүсэх боломжийг бүрэн үгүйсгэхгүй.

Энэ хязгаарлалтыг үр дүнг тайлбарлах, ялангуяа судалгааны дүгнэлтийг илүү өргөн хүрээний хөрөнгийн зах зээлд ерөнхийлөн хэрэглэх үед харгалзан үзнэ.

4 Эмпирик судалгааны үр дүн

Энэ хэсэгт ковариацын матрицын зургаан үнэлэгчийн гүйцэтгэлийг корреляцийн бүтэц ялгаатай багцуудад харьцуулна. Үндсэн шинжилгээнд 120 сарын сургалтын цонх, 52 сарын түүврээс гадуурх (OOS) өгөөжийг ашигласан. Үр дүнгийн тогтвортой байдлыг сургалтын цонхны мэдрэмжийн шинжилгээ, нэмэлт 150 багц болон bootstrap аргаар шалгав. Мөн тэнцүү жинтэй $1/N$ жишиг багц, арилжааны зардлын нөлөө болон GMVP–$1/N$ харьцуулалтын bootstrap үр дүнг авч үзэв.

4.1 Ковариацын үнэлэгчдийн OOS гүйцэтгэл

Ковариацын үнэлэгчдийн жилд шилжүүлсэн хэлбэлзэл, харьцангуй дисперсийн бууралт (RVR) болон Sharpe-ийн харьцааг Хүснэгт 2-д үзүүлэв. Энэ хүснэгтэд RVR-ийг Sample үнэлэгчтэй харьцуулан тооцсон бөгөөд эерэг утга нь түүврээс гадуурх дисперс буурсныг илэрхийлнэ.

Хүснэгт 2: Ковариацын үнэлэгчдийн OOS гүйцэтгэл ($T = 120$)

Багц	Үнэлэгч	Жилийн хэлбэлзэл	RVR (%)	Sharpe
High	Sample	0.1705	0.00	0.7877
	Var	0.1655	5.81	0.8435
	Diag	0.1678	3.18	0.8159
	Corr	0.1716	-1.26	0.8207
	SF	0.1666	4.56	0.8192
	NLS	0.1690	1.70	0.8011
Medium	Sample	0.1428	0.00	0.6006
	Var	0.1427	0.15	0.6117
	Diag	0.1426	0.35	0.6035
	Corr	0.1412	2.26	0.5550
	SF	0.1416	1.65	0.5774
	NLS	0.1419	1.27	0.6035
Low	Sample	0.1377	0.00	0.2687
	Var	0.1526	-22.70	0.3925
	Diag	0.1432	-8.11	0.2549
	Corr	0.1505	-19.47	0.1109
	SF	0.1465	-13.13	0.1905
	NLS	0.1399	-3.24	0.3132

High багцад Var үнэлэгчийн RVR хамгийн өндөр буюу 5.81%, Medium багцад Corr үнэлэгчийнх 2.26% байна. Харин Low багцад агшилтын бүх үнэлэгчийн RVR сөрөг гарч, Sample арга хамгийн бага OOS дисперстэй байв.

Иймээс анхны гурван багцын хувьд нэг үнэлэгч бүх нөхцөлд тогтмол давуу гүйцэтгэл үзүүлээгүй. Эдгээр нь ажиглагдсан ялгаа бөгөөд статистикийн ач холбогдлыг дараах шалгалтаар тусад нь үнэлнэ.

4.2 Багцын жингийн тогтвортой байдал

Багцын жингийн тогтвортой байдлыг дундаж turnover, төвлөрлийг Херфиндал–Хиршманы индексээр (HHI) үнэлэв.

Хүснэгт 3: Багцын дундаж turnover болон HHI

Багц	Үнэлэгч	Turnover	HHI
High	Sample	0.02767	0.44468
	Var	0.02744	0.33715
	Diag	0.02769	0.40338
	Corr	0.02062	0.50315
	SF	0.02571	0.40821
	NLS	0.02757	0.40117
Medium	Sample	0.03009	0.20008
	Var	0.02701	0.17750
	Diag	0.02804	0.18949
	Corr	0.02297	0.20775
	SF	0.02479	0.19316
	NLS	0.02603	0.18178
Low	Sample	0.02964	0.24203
	Var	0.02926	0.12850
	Diag	0.02631	0.18012
	Corr	0.02534	0.20568
	SF	0.02569	0.20912
	NLS	0.02856	0.19904

Corr үнэлэгч гурван багцад хамгийн бага turnover, Var үнэлэгч хамгийн бага HHI үзүүлсэн. Гэвч эдгээр үзүүлэлт бага байх нь OOS дисперс заавал бага байхыг илэрхийлэхгүй байна.

4.3 Статистик харьцуулалт

Агшилтын үнэлэгчдийн сарын квадрат өгөөжийн дундаж ялгааг Sample аргатай HAC шалгалтаар харьцуулж, олон харьцуулалтад Holm-ийн засвар хэрэглэв.

Хүснэгт 4: Ковариацын үнэлэгчдийн HAC шалгалт ($T = 120$)

Багц	Үнэлэгч	HAC p	Holm p
High	Var	0.3266	0.9799
	Diag	0.0762	0.3048
	Corr	0.8850	0.9799
	SF	0.0368	0.1842
	NLS	0.4639	0.9799
Medium	Var	0.9747	1.0000
	Diag	0.5811	1.0000
	Corr	0.2840	1.0000
	SF	0.3197	1.0000
	NLS	0.4438	1.0000
Low	Var	0.0680	0.2041
	Diag	0.0983	0.2041
	Corr	0.0100	0.0501
	SF	0.0286	0.1145
	NLS	0.1995	0.2041

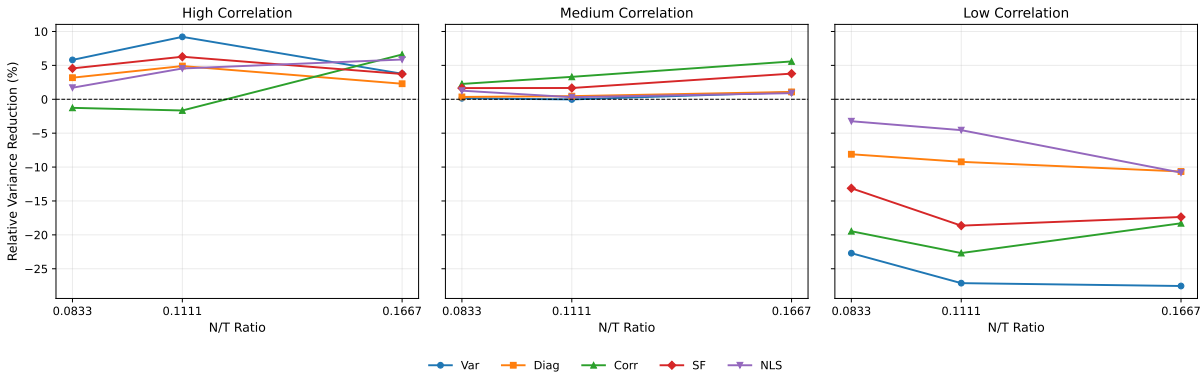
Holm-ийн засварын дараа бүх p-утга 0.05-аас их байна. Иймээс анхны гурван багцад квадрат өгөөжийн дундаж ялгаа 5%-ийн түвшинд статистикийн хувьд ач холбогдолтой болох нь тогтоогдсонгүй.

4.4 Сургалтын цонхны мэдрэмжийн шинжилгээ

Сургалтын цонхны уртыг $T = 60, 90, 120$ сар болгон өөрчилж, ижил 52 сарын түүврээс гадуурх (OOS) хугацаанд ковариацын үнэлэгчдийн гүйцэтгэлийг харьцуулав. Хөрөнгийн тоо $N = 10$ тогтмол тул харгалзах N/T харьцаа нь 0.1667, 0.1111, 0.0833 байна. Үр дүнг Хүснэгт 5 болон Зураг 1-т үзүүлэв.

Хүснэгт 5: Сургалтын цонхны уртаас хамаарах RVR (%)

Багц	T	Var	Diag	Corr	SF	NLS
High	60	3.76	2.29	6.60	3.73	5.86
	90	9.21	4.90	-1.65	6.28	4.54
	120	5.81	3.18	-1.26	4.56	1.70
Medium	60	1.03	1.09	5.58	3.78	0.90
	90	-0.02	0.46	3.31	1.66	0.31
	120	0.15	0.35	2.26	1.65	1.27
Low	60	-27.54	-10.65	-18.29	-17.36	-10.81
	90	-27.12	-9.23	-22.68	-18.64	-4.55
	120	-22.70	-8.11	-19.47	-13.13	-3.24



Зураг 1: Корреляцын бүтэц ялгаатай гурван багцын N/T харьцаанаас хамаарах RVR

Зураг 1-ээс харахад High багцад Corr үнэлэгчээс бусад аргууд бүх сургалтын цонхонд эерэг RVR үзүүлсэн боловч хамгийн сайн үнэлэгч N/T харьцаанаас хамааран өөрчлөгдөж байна. Medium багцад RVR-ийн хэмжээ харьцангуй бага бөгөөд Corr үнэлэгч бүх цонхонд хамгийн өндөр дисперсийн бууралт үзүүлэв. Харин Low багцад бүх агшилтын үнэлэгчийн RVR сөрөг байгаа нь Sample арга бүх цонхонд хамгийн бага OOS дисперстэй байсныг харуулна.

Иймхүү агшилтын үнэлэгчдийн гүйцэтгэл корреляцийн бүтэц болон сургалтын цонхны уртаас хамааран ялгаатай байна. Гэхдээ T-г өөрчлөхөд сургалтын өгөгдлийн хугацаа давхар өөрчлөгдөх тул ажиглагдсан ялгааг зөвхөн N/T харьцааны нөлөө гэж тайлбарлах боломжгүй.

Мэдрэмжийн шинжилгээний HAC шалгалт. Багц тус бүрийн 15 харьцуулалтад Holm-ийн засвар хэрэглэв.

Тайлбар: Багц тус бүрийн хамгийн бага засварлаагүй p-утгатай хувилбарыг үзүүлэв.

Holm-ийн засварыг хэрэглэсний дараа 5%-ийн ач холбогдлын түвшинд статистикийн ач холбогдолтой ялгаа тогтоогдоогүй нь ажиглагдсан гүйцэтгэлийн зөрүүг агшилтын үнэлэгчдийн түүврийн ковариацын аргаас давуу эсвэл сул байгааг нотлох хангалттай статистик үндэслэл гэж үзэх боломжгүйг харуулж байна.

Хүснэгт 6: Мэдрэмжийн шинжилгээний HAC шалгалт

Багц	T	Үнэлэгч	HAC p	Holm p
High	90	Diag	0.0189	0.2839
Medium	90	Corr	0.1860	1.0000
Low	120	Corr	0.0100	0.1504

4.5 150 багцын robustness шинжилгээ

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг шалгах зорилгоор High, Medium, Low ангилал тус бүрээс 50, нийт 150 багцад шинжилгээг давтав. Ангиллуудын сургалтын хугацааны дундаж корреляц харгалзан 0.5267, 0.3036, 0.1346 байв.

Хүснэгт 7: 150 багцын дундаж RVR болон эерэг RVR-ийн хувь

Ангилал	Үнэлэгч	Дундаж RVR (%)	Эерэг RVR (%)
High	Var	1.13	72
	Diag	0.81	82
	Corr	0.65	60
	SF	0.53	74
	NLS	0.39	66
Medium	Var	-1.31	48
	Diag	0.57	68
	Corr	0.55	54
	SF	0.67	64
	NLS	0.37	56
Low	Var	-35.02	28
	Diag	-0.61	54
	Corr	0.16	64
	SF	-1.36	42
	NLS	0.99	74

High ангилалд бүх агшилтын үнэлэгчийн дундаж RVR эерэг байна. Medium ангилалд Var-аас бусад үнэлэгчдийн дундаж RVR эерэг боловч бууралтын хэмжээ бага байв.

Low ангилалд Var үнэлэгчийн дундаж RVR -35.02% байгаа бол NLS үнэлэгчийнх 0.99% байна. Иймээс анхны Low багцад бүх агшилтын үнэлэгчийн RVR сөрөг гарсан үр дүн нэмэлт 50 багцад бүрэн давтагдсангүй.

4.6 Bootstrap итгэх завсар

Ангилал тус бүрийн дундаж RVR-ийн тодорхой бус байдлыг зургаан сарын блоктой, 3000 давталт бүхий circular moving-block bootstrap аргаар үнэлэв.

Low ангиллын Var үнэлэгчээс бусад бүх үнэлэгчийн 95%-ийн итгэх завсар тэгийг агуулж байна. Харин Low ангиллын Var үнэлэгчийн итгэх завсар $[-65.61, -14.67]$ байгаа нь Sample аргатай харьцуулахад дундаж OOS дисперс өссөнийг дэмжиж байна.

Иймээс 150 багцын robustness шинжилгээний үр дүнгээр агшилтын үнэлэгчид Sample аргатай харьцуулахад OOS дисперсийг статистикийн хувьд ач холбогдолтойгоор бууруулдаг гэсэн хангалттай нотолгоо тогтоогдсонгүй. Харин Low ангиллын Var үнэлэгчийн дундаж RVR-ийн итгэх завсар тэгийг агуулаагүй бөгөөд энэ нь тухайн ангилалд дисперс өсөх хандлага ажиглагдсаныг илэрхийлнэ. Гэвч уг итгэх завсарт олон харьцуулалтын засвар хийгдээгүй тул энэ үр дүнг олон үнэлэгч, ангиллыг хамарсан статистик дүгнэлтийн түвшинд баталгаатай гэж үзэх боломжгүй.

4.7 Корреляцийн ангилал хоорондын харьцуулалт

Агшилтын үнэлэгчдийн дундаж RVR корреляцийн ангиллаас хамааран ялгаатай эсэхийг шалгах зорилгоор High–Medium, High–Low болон Medium–Low гэсэн гурван хос харьцуу-

Хүснэгт 8: Дундаж RVR-ийн 95%-ийн bootstrap итгэх завсар

Ангилал	Үнэлэгч	RVR (%)	Доод	Дээд
High	Var	1.13	-1.16	3.38
	Diag	0.81	-0.09	1.83
	Corr	0.65	-1.83	3.45
	SF	0.53	-0.54	1.55
	NLS	0.39	-0.45	1.40
Medium	Var	-1.31	-5.08	2.55
	Diag	0.57	-0.67	1.87
	Corr	0.55	-0.96	1.85
	SF	0.67	-0.39	1.46
	NLS	0.37	-0.66	1.45
Low	Var	-35.02	-65.61	-14.67
	Diag	-0.61	-5.21	3.58
	Corr	0.16	-1.95	2.15
	SF	-1.36	-5.58	1.76
	NLS	0.99	-0.52	2.41

лалт хийв. Ангилал бүрд таван агшилтын үнэлэгчийг авч үзсэн тул нийт 15 харьцуулалт хийгдсэн.

Ангилал хоорондын дундаж RVR-ийн ялгааг ижил сарын индексүүдээр гүйцэтгэсэн circular moving-block bootstrap аргаар үнэлж, 95%-ийн итгэх завсрыг тооцсон. Олон харьцуулалтаас үүдэх алдааг хянахын тулд нийт 15 харьцуулалтын p-утгад Holm-ийн засвар хэрэглэв.

Хүснэгт 9: Корреляцийн ангилал хоорондын дундаж RVR-ийн ялгааны bootstrap шинжилгээ

Харьцуулалт	Үнэлэгч	Ялгаа	95% CI доод	95% CI дээд	Holm p
High–Medium	Var	2.43	-0.57	5.46	1.000
	Diag	0.24	-0.60	1.10	1.000
	Corr	0.10	-2.62	3.32	1.000
	SF	-0.14	-1.36	1.46	1.000
	NLS	0.02	-0.95	1.07	1.000
High–Low	Var	36.15	16.55	66.37	0.220
	Diag	1.42	-2.03	5.45	1.000
	Corr	0.49	-1.57	2.51	1.000
	SF	1.89	-1.67	6.82	1.000
	NLS	-0.60	-1.71	0.81	1.000
Medium–Low	Var	33.71	15.23	63.54	0.252
	Diag	1.18	-1.79	4.61	1.000
	Corr	0.39	-2.45	2.81	1.000
	SF	2.03	-0.79	5.51	1.000
	NLS	-0.62	-1.38	0.18	1.000

Тайлбар: Ялгааг эхний ангиллын дундаж RVR-ээс хоёр дахь ангиллын дундаж RVR-ийг хасаж тооцсон. RVR-ийн ялгаа болон итгэх завсрын хязгаарууды процентын пунктээр илэрхийлэв. 95%-ийн итгэх завсрууд нь олон харьцуулалтын засвар хийгдээгүй bootstrap итгэх завсар бөгөөд сүүлийн баганад 15 харьцуулалтад Holm-ийн засвар хэрэглэсэн p-утгуудыг харуулав.

Хүснэгт 9-ээс харахад High–Medium харьцуулалтад Var үнэлэгчийн дундаж RVR-ийн ялгаа 2.43 процентын пункт байгаа бол бусад үнэлэгчдийн ялгаа харьцангуй бага байна. Гэхдээ таван үнэлэгчийн бүх итгэх завсар тэгийг агуулж, Holm-ийн засварласан p-утгууд 1.000 гарсан тул эдгээр хоёр ангиллын хооронд статистикийн ач холбогдолтой ялгаа тогтоогдсонгүй.

Харин High–Low болон Medium–Low харьцуулалтад Var үнэлэгчийн дундаж RVR-ийн ялгаа харгалзан 36.15 болон 33.71 процентын пункт байна. Эдгээр ялгааны засварлаагүй

95%-ийн bootstrap итгэх завсар харгалзан [16.55, 66.37] болон [15.23, 63.54] байгаа нь хоёулаа тэгийг агуулаагүй. Энэ нь засварлаагүй шинжилгээний түвшинд Var үнэлэгчийн дундаж RVR Low ангилалд High болон Medium ангиллаас бага байгааг илэрхийлж байна.

Гэвч олон харьцуулалтын засвар хэрэглэсний дараа эдгээр хоёр харьцуулалтын p-утга харгалзан 0.220 болон 0.252 болж, 5%-ийн ач холбогдлын түвшнээс давсан байна. Иймээс засварлаагүй итгэх завсрууд тэгийг агуулаагүй боловч олон харьцуулалтыг хамтад нь авч үзэхэд эдгээр ялгааг статистикийн хувьд ач холбогдолтой гэж дүгнэх хангалттай үндэслэлгүй байна.

Бусад дөрвөн үнэлэгчийн хувьд High–Low болон Medium–Low харьцуулалтын бүх итгэх завсар тэгийг агуулж байна. Тухайлбал, NLS үнэлэгчийн High–Low болон Medium–Low ялгаа харгалзан -0.60, -0.62 процентын пункт байгаа боловч эдгээр ялгаа статистикийн хувьд ач холбогдолтой биш байна.

Ерөнхийд нь дүгнэвэл, корреляцийн ангиллуудын хооронд агшилтын үнэлэгчдийн дундаж RVR-ийн ялгаа ажиглагдсан боловч нийт 15 харьцуулалтад Holm-ийн засвар хэрэглэсний дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа тогтоогдсонгүй. Иймээс корреляцийн ангиллаас хамааран агшилтын үнэлэгчдийн гүйцэтгэл ялгаатай байж болох шинж тэмдэг ажиглагдсан ч энэхүү ялгааг статистикийн хувьд баталгаатай гэж дүгнэх боломжгүй байна.

4.8 Тэнцүү жинтэй багцтай харьцуулалт

Ковариацын үнэлэгчид суурилсан GMVP-ийн практик гүйцэтгэлийг үнэлэхийн тулд хөрөнгө тус бүрд $1/N$ жин оноож, сар бүр дахин тэнцвэржүүлдэг жишиг багцтай харьцуулав. Бүх стратегид үндсэн шинжилгээтэй ижил 52 сарын OOS хугацааг ашиглав.

Хүснэгт 10: GMVP болон $1/N$ багцын OOS гүйцэтгэл ($T = 120$)

Багц	Стратеги	Жилийн хэлбэлзэл (%)	$1/N$-тэй харьцуулсан RVR (%)	Sharpe
High	Sample	17.05	35.89	0.788
	Var	16.55	39.61	0.843
	Diag	16.78	37.93	0.816
	Corr	17.16	35.08	0.821
	SF	16.66	38.81	0.819
	NLS	16.90	36.98	0.801
	$1/N$	21.29	0.00	0.840
Medium	Sample	14.28	15.72	0.601
	Var	14.27	15.85	0.612
	Diag	14.26	16.02	0.603
	Corr	14.12	17.63	0.555
	SF	14.16	17.11	0.577
	NLS	14.19	16.79	0.603
	$1/N$	15.56	0.00	0.602
Low	Sample	13.77	26.06	0.269
	Var	15.26	9.28	0.393
	Diag	14.32	20.07	0.255
	Corr	15.05	11.67	0.111
	SF	14.65	16.36	0.190
	NLS	13.99	23.67	0.313
	$1/N$	16.02	0.00	0.573

Энэ хүснэгтийн RVR-ийг Sample бус, $1/N$ жишиг багцын дисперстэй харьцуулан тооцсон. Хүснэгт 10-ээс харахад гурван багцын хувьд зургаан GMVP стратеги бүгд $1/N$ жишиг багцаас бага OOS хэлбэлзэлтэй байна. $1/N$ багцын жилийн хэлбэлзэл High, Medium, Low багцад харгалзан 21.29%, 15.56%, 16.02% байв. Харин хамгийн бага хэлбэлзэлтэй GMVP стратегиуд нь High багцад Var (16.55%), Medium багцад Corr (14.12%), Low багцад Sample (13.77%) байна.

Гэхдээ хэлбэлзлийн давуу байдал нь Sharpe-ийн харьцаагаар давуу байна гэсэн үг биш. Тухайлбал, Low багцад $1/N$ стратегийн Sharpe 0.573 байхад GMVP стратегиудын Sharpe

0.111–0.393 хооронд байна. Иймээс GMVP-ийн эрсдэлийг бууруулах зорилгыг өгөөж–эрсдэлийн харьцааны үнэлгээнээс тусад нь авч үзэх шаардлагатай.

4.9 Арилжааны зардлын нөлөө

Сар бүрийн дахин тэнцвэржүүлэлтийн арилжааны зардлыг тооцохдоо нэг талын арилжаанд 0, 5, 10, 25 суурь нэгж (basis points, bps)-ийн хувилбаруудыг ашиглав. Эхний OOS багц бүрдүүлэлтийн зардлыг тооцоогүй. Доорх хүснэгтэд нэг талын 10 bps зардлын хувилбарын үр дүнг үзүүлэв.

Хүснэгт 11: Нэг талын 10 bps арилжааны зардлын дараах OOS гүйцэтгэл

Багц	Стратеги	Цэвэр Sharpe	Хуримтлагдсан цэвэр өгөөж (%)
High	Sample	0.784	67.46
	Var	0.840	71.91
	Diag	0.812	69.65
	Corr	0.818	72.27
	SF	0.816	69.53
	NLS	0.797	68.45
	$1/N$	0.837	96.05
Medium	Sample	0.596	38.36
	Var	0.607	39.31
	Diag	0.599	38.56
	Corr	0.551	34.21
	SF	0.573	36.15
	NLS	0.599	38.40
	$1/N$	0.599	42.07
Low	Sample	0.264	12.35
	Var	0.388	22.92
	Diag	0.251	11.77
	Corr	0.107	2.13
	SF	0.186	7.48
	NLS	0.308	15.57
	$1/N$	0.568	40.28

Арилжааны зардлыг тусгахад стратегиудын Sharpe-ийн харьцаа зардалгүй хувилбартай харьцуулахад бага зэрэг буурч байна. Тухайлбал, High багцад Var стратегийн Sharpe 0.843-аас 0.840 болж буурсан. Medium багцад Var стратегийн цэвэр Sharpe 0.607, Low багцад $1/N$ стратегийнх 0.568 байна.

High багцад $1/N$ стратегийн хуримтлагдсан цэвэр өгөөж 96.05% байхад Var стратегийнх 71.91% байна. Иймээс GMVP стратегиудын хэлбэлзэл бага байгаа нь хуримтлагдсан өгөөж өндөр байна гэсэн баталгаа биш. Эдгээр дүгнэлт нь сонгосон зардлын хувилбар, сарын дахин тэнцвэржүүлэлт болон 52 сарын OOS хугацаанд хамаарна.

4.10 GMVP ба $1/N$ багцын bootstrap харьцуулалт

GMVP стратегиудын $1/N$ жишиг багцтай харьцуулсан дисперсийн бууралтын тодорхой бус байдлыг 52 сарын OOS өгөөжид суурилсан, зургаан сарын блоктой, 3000 давталт бүхий circular moving-block bootstrap аргаар үнэлэв. Сар бүрийн индексүүдийг харьцуулж буй стратегиудад ижил сонгож, 95%-ийн percentile итгэх завсар байгуулав. Багц тус бүрийн зургаан харьцуулалтын bootstrap p-утгад Holm-ийн засвар хэрэглэв.

Хүснэгт 12-д бүх GMVP стратегийн RVR эерэг байна. Хамгийн бага хэлбэлзэлтэй стратегиудын $1/N$-тэй харьцуулсан RVR нь High багцад Var 39.61%, Medium багцад Corr 17.63%, Low багцад Sample 26.06% байна. Гэвч эдгээрийн 95%-ийн итгэх завсар харгалзан $[-7.09, 62.44]$, $[-3.95, 34.33]$, $[-7.84, 51.16]$ тул тэгийг агуулж байна.

Мөн багц тус бүрийн зургаан харьцуулалтад Holm-ийн засвар хэрэглэсний дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй. Bootstrap p-утгыг төвлөрүүлсэн bootstrap тархалтаас, харин итгэх завсрыг percentile аргаар байгуулсан тул засварлаагүй

Хүснэгт 12: GMVP-ийн $1/N$-тэй харьцуулсан RVR ба bootstrap шалгалт

Багц	Стратеги	RVR (%)	95% CI доод	95% CI дээд	Holm p
High	Sample	35.89	-21.61	63.60	0.3149
	Var	39.61	-7.09	62.44	0.2639
	Diag	37.93	-15.32	64.14	0.3149
	Corr	35.08	-38.50	69.33	0.3149
	SF	38.81	-15.41	64.90	0.3149
	NLS	36.98	-16.53	62.84	0.3149
Medium	Sample	15.72	-4.31	31.44	0.3399
	Var	15.85	-2.62	30.02	0.3399
	Diag	16.02	-3.31	31.15	0.3399
	Corr	17.63	-3.95	34.33	0.3399
	SF	17.11	-4.21	33.32	0.3399
	NLS	16.79	-3.61	31.72	0.3399
Low	Sample	26.06	-7.84	51.16	0.5498
	Var	9.28	-16.30	29.00	0.8144
	Diag	20.07	-9.26	42.20	0.5498
	Corr	11.67	-20.01	35.14	0.8144
	SF	16.36	-18.68	40.65	0.8107
	NLS	23.67	-8.70	47.86	0.5498

p-утга ба итгэх завсрын шийдвэр зарим тохиолдолд зөрж болохыг харгалзан үзнэ. Иймээс ажиглагдсан эрэг RVR-ийг статистикийн хувьд баталгаатай давуу байдал гэж тайлбарлахгүй.

4.11 Үр дүнгийн нэгтгэл

Эмпирик шинжилгээгээр ковариацын матрицын агшилтын үнэлэгчдийн гүйцэтгэл багцын бүрэлдэхүүн болон сургалтын цонхны уртаас хамааран ялгаатай байгааг ажиглав.

Анхны гурван багцын HAC шалгалт болон 150 багцын bootstrap шинжилгээ нь агшилтын үнэлэгчдийн Sample аргаас тогтвортой давуу байдлыг статистикийн хувьд батлаагүй.

Харин бага корреляцтай багцуудад Var үнэлэгчийн дундаж RVR мэдэгдэхүйц сөрөг гарсан нь агшилтын арга бүр OOS эрсдэлийг бууруулах баталгаагүйг харуулж байна.

Ангилал хоорондын харьцуулалтаар ажиглагдсан ялгаа олон шалгалтын засварын дараа статистикийн ач холбогдолтой болох нь тогтоогдсонгүй.

$1/N$ жишиг багцтай харьцуулахад зургаан GMVP стратеги гурван багцад бүгд бага OOS хэлбэлзэлтэй байсан боловч bootstrap шалгалтын олон харьцуулалтын засварын дараа статистикийн ач холбогдолтой давуу байдал тогтоогдсонгүй. Мөн арилжааны зардлыг тооцоход стратегиудын цэвэр гүйцэтгэл буурч, хэлбэлзлийн давуу байдал Sharpe болон хуримтлагдсан өгөөжийн давуу байдалтай заавал давхцахгүй байв.

Ковариацын үнэлэгчдийн хоорондын OOS хэлбэлзлийн ялгаа олон тохиолдолд бага байгаа нь long-only хязгаарлалттай багцад нэмэлт агшилтын үр ашиг хязгаарлагдаж болохыг харуулсан De Nard and Kostovic [2026]-ийн үр дүнтэй нийцэж байна. Тэдний судалгаанд багцын жингийн хязгаарлалт нь өөрөө зохицуулах нөлөө үзүүлж, ковариацын матрицад нэмэлт агшилт хийх хэрэгцээг бууруулж болохыг авч үзсэн. Гэхдээ уг судалгаанд өдрийн өгөөж, илүү олон хөрөнгөтэй багцуудыг шинжилсэн бол энэхүү судалгаанд зөвхөн сарын өгөөж, бага N/T харьцаатай 10 хөрөнгийн багцуудыг ашигласан. Иймээс хоёр судалгааны үр дүнг шууд ижил нөхцөлийн нотолгоо гэж үзэхгүй.

5 Дүгнэлт

Энэхүү судалгаанд хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцаа (N/T) бага үед ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багцын (GMVP) гүйцэтгэлийг харьцуулан шинжиллээ. Түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцын (Corr), нэг хүчин зүйлийн

(SF) зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид болон шугаман бус агшилтын үнэлэгчийг (NLS) авч үзсэн. Корреляцын бүтэц ялгаатай, тус бүр 10 хувьцаатай гурван багцад богино борлуулалтыг зөвшөөрөөгүй GMVP байгуулж, 120 сарын шилжих сургалтын цонх болон 52 сарын түүврээс гадуурх (OOS) хугацаагаар үнэлэв.

Үндсэн гурван багцын үр дүнгээр агшилтын үнэлэгчдийн гүйцэтгэл корреляцын бүтцээс хамааран ялгаатай байлаа. Өндөр корреляцтай багцад Var үнэлэгч Sample аргатай харьцуулахад OOS дисперсийг 5.81%-иар, дунд корреляцтай багцад Corr үнэлэгч 2.26%-иар бууруулсан. Харин бага корреляцтай багцад Sample арга хамгийн бага OOS дисперстэй байсан бөгөөд агшилтын таван үнэлэгчийн харьцангуй дисперсийн бууралт (RVR) бүгд сөрөг гарсан. Иймээс аль нэг агшилтын үнэлэгч бүх багцад тогтмол давуу байгаагүй.

Жингийн бүтцийн шинжилгээнд Corr үнэлэгч гурван багцад хамгийн бага дундаж жингийн эргэлт (turnover), Var үнэлэгч хамгийн бага дундаж төвлөрлийн индекс (HHI) үзүүлсэн. Гэхдээ бага эргэлт, бага төвлөрөл нь бага OOS дисперсийг заавал илэрхийлээгүй. Тухайлбал, бага корреляцтай багцад Var үнэлэгчийн OOS дисперс Sample аргынхаас 22.70%-иар өндөр байв. Сургалтын цонхыг 60, 90, 120 сар болгон өөрчлөхөд үнэлэгчдийн эрэмбэ бүх багцад тогтвортой хадгалагдсангүй. Иймээс судалсан хүрээнд N/T харьцаа буурах тусам агшилтын давуу тал заавал нэмэгдэнэ гэсэн зүй тогтол ажиглагдсангүй.

Үндсэн гурван багцын сарын квадрат өгөөжийн ялгаанд хийсэн HAC шалгалтаар Holmийн олон харьцуулалтын засварын дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй; сургалтын цонхны мэдрэмжийн шинжилгээнд мөн адил байв. Эдгээр шалгалт квадрат өгөөжийн дундаж ялгаанд суурилдаг тул OOS дисперсийн ялгааг шууд шалгасан гэж тайлбарлахгүй.

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг шалгахын тулд корреляцын ангилал тус бүрд 50, нийт 150 нэмэлт багцад шинжилгээг давтсан. Өндөр корреляцтай ангилалд агшилтын бүх үнэлэгчийн дундаж RVR эерэг байсан бол дунд болон бага корреляцтай ангиллуудад үр дүн ялгаатай байв. Бага корреляцтай ангилалд Var үнэлэгчийн дундаж RVR -35.02%, NLS үнэлэгчийнх 0.99% байсан нь үндсэн бага корреляцтай багцын сөрөг RVR-ийн дүр зураг бүх нэмэлт багцад ижил давтагдаагүйг харуулна. Circular moving-block bootstrap аргаар тооцсон засварлаагүй 95%-ийн итгэх завсар бага корреляцтай ангиллын Var үнэлэгчийн хувьд $[-65.61, -14.67]$ байсан бол бусад үнэлэгчдийнх тэгийг агуулсан. Гэвч ангилал хоорондын Var үнэлэгчийн High–Low болон Medium–Low ялгааны засварлаагүй bootstrap p-утгууд $0.0147, 0.0180$ байсан ч 15 харьцуулалтад Holm-ийн засвар хийсний дараа $0.2199, 0.2519$ болж, статистикийн ач холбогдолтой ялгаа тогтоогдоогүй.

Тэнцүү жинтэй $1/N$ багцыг жишиг болгон авч үзэхэд үндсэн гурван багцад ковариацын зургаан үнэлэгчид суурилсан GMVP стратегиуд бүгд түүнээс бага OOS хэлбэлзэлтэй байв. Өндөр корреляцтай багцад Var, дунд корреляцтай багцад Corr, бага корреляцтай багцад Sample аргын $1/N$-тэй харьцуулсан дисперсийн бууралт харгалзан 39.61%, 17.63%, 26.06% байв. Гэвч эдгээр харьцуулалтын засварлаагүй bootstrap 95%-ийн итгэх завсруud харгалзан $[-7.09, 62.44]$, $[-3.95, 34.33]$, $[-7.84, 51.16]$ бөгөөд бүгд тэгийг агуулсан. Holm-ийн засварын дараа ч статистикийн ач холбогдолтой ялгаа тогтоогдоогүй. Мөн бага корреляцтай багцад $1/N$ стратегийн жилийн Sharpe-ийн харьцаа GMVP стратегиудынхаас өндөр байсан. Иймээс ажиглагдсан хэлбэлзлийн бууралтыг эрсдэлд тохируулсан өгөөжийн эсвэл статистикийн хувьд батлагдсан давуу тал гэж үзэхгүй.

Нэг талын 10 суурь нэгжийн арилжааны зардлыг тооцоход стратегиудын Sharpe-ийн харьцаа бага хэмжээгээр буурсан ч үндсэн харьцуулалтын ерөнхий дүр зураг өөрчлөгдөөгүй. Иймээс ковариацын үнэлэгчийн практик үр ашгийг зөвхөн OOS дисперсээр бус, жингийн эргэлт, төвлөрөл, Sharpe-ийн харьцаа болон арилжааны зардлын дараах гүйцэтгэлтэй хамтатган үнэлэх шаардлагатай.

Судалгааны үр дүнг тайлбарлахад хэд хэдэн хязгаарлалтыг харгалзана. Нэгдүгээрт, шинжилгээ нь сонгосон хувьцаанууд, богино борлуулалтыг зөвшөөрөөгүй GMVP болон 52 сарын OOS хугацаагаар хязгаарлагдана. Хоёрдугаарт, 2012 оны S&P 500 индексийн түүхэн бүрэлдэхүүний 453 хувьцаанаас 337 нь 2022 оны 5 дугаар сар хүртэлх сургалтын хугацаанд бүрэн үнийн мэдээлэлтэй байсан бөгөөд бүрэн байдлын шаардлагыг 2026 оны 9 дүгээр сар хүртэл сунгахад нэмэлт хувьцаа хасагдаагүй. Гэвч сургалтын хугацаанд өгөгдөл дутуу байсан 116 хувьцааг хассан нь сонголтын хазайлт үүсгэсэн байх боломжийг үгүйсгэхгүй. Гуравдугаарт, сургалтын цонхны уртыг өөрчлөхөд N/T харьцаатай зэрэгцэн ашигласан сургалтын өгөгдлийн хугацаа өөрчлөгдөнө. Дөрөвдүгээрт, нэмэлт 150 багц нь бие даасан

санамсаргүй түүвэр биш бөгөөд bootstrap шинжилгээнд багцын бүрэлдэхүүнийг тогтмол гэж үзсэн. Түүнчлэн арилжааны зардлын тооцоолол нь тогтмол зардлын таамаглалд тулгуурласан.

Нэгдсэн дүнгээр бага N/T харьцаатай нөхцөлд ковариацын матрицын агшилт GMVP-ийн OOS дисперсийг зарим багцад бууруулж болох боловч энэхүү үр нөлөө багцын корреляцын бүтэц, бүрэлдэхүүн болон сургалтын цонхны уртаас хамаарч байна. Богино борлуулалтыг хязгаарласан нөхцөлд агшилтын нэмэлт үр ашиг бүх тохиолдолд илэрнэ гэж үзэх үндэслэлгүй байгаа нь Jagannathan and Ma [2003] болон De Nard and Kostovic [2026]-ийн судалгаатай харьцуулан хэлэлцэх боломжтой үр дүн юм. Гэвч олон харьцуулалтын засварын дараах статистикийн шалгалтууд агшилтын үнэлэгчдийн Sample аргаас, эсвэл GMVP стратегиудын $1/N$ багцаас тогтвортой давуу гүйцэтгэлийг батлаагүй. Иймээс агшилтын аргыг бага N/T нөхцөлд эрсдэлийг заавал бууруулах шийдэл бус, харин тухайн багцын бүтэц, түүврээс гадуурх гүйцэтгэл болон хэрэгжүүлэх зардалд тулгуурлан сонгох шаардлагатай хувилбар гэж дүгнэв.

Ашигласан ном

Sakai Ando and Mingmei Xiao. High-dimensional covariance matrix estimation: Shrinkage toward a diagonal target. IMF Working Paper WP/23/257, International Monetary Fund, 2023.

Peter J. Bickel and Elizaveta Levina. Regularized estimation of large covariance matrices. *The Annals of Statistics*, 36(1):199–227, 2008. doi: 10.1214/009053607000000758.

Yilun Chen, Ami Wiesel, Yonina C. Eldar, and Alfred O. Hero. Shrinkage algorithms for MMSE covariance estimation. *IEEE Transactions on Signal Processing*, 58(10):5016–5029, 2010. doi: 10.1109/TSP.2010.2053029.

chinobing. Historical S&P 500 constituents. GitHub repository. URL https://github.com/chinobing/historical_sp500_constituents. Accessed: 2026-10-21.

Gianluca De Nard and Damjan Kostovic. Learning the shrinkage intensity: A data-driven approach for risk-optimized portfolios. *Journal of Financial Econometrics*, 24(2):nbag002, 2026. doi: 10.1093/jjfinec/nbag002.

Gianluca De Nard, Olivier Ledoit, and Michael Wolf. Factor models for portfolio selection in large dimensions: The good, the better and the ugly. *Journal of Financial Econometrics*, 19 (2):236–257, 2021. doi: 10.1093/jjfinec/nby033.

Victor DeMiguel, Lorenzo Garlappi, and Raman Uppal. Optimal versus naive diversification: How inefficient is the 1/n portfolio strategy? *The Review of Financial Studies*, 22(5):1915–1953, 2009. doi: 10.1093/rfs/hhm075.

Peter A. Frost and James E. Savarino. An empirical bayes approach to efficient portfolio selection. *Journal of Financial and Quantitative Analysis*, 21(3):293–305, 1986. doi: 10.2307/2331043.

Ravi Jagannathan and Tongshu Ma. Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4):1651–1683, 2003. doi: 10.1111/1540-6261.00580.

Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5):603–621, 2003. doi: 10.1016/S0927-5398(03)00007-0.

Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004a. doi: 10.1016/S0047-259X(03)00096-4.

Olivier Ledoit and Michael Wolf. Honey, i shrunk the sample covariance matrix. *The Journal of Portfolio Management*, 30(4):110–119, 2004b. doi: 10.3905/jpm.2004.110.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage estimation of large-dimensional covariance matrices. *The Annals of Statistics*, 40(2):1024–1060, 2012. doi: 10.1214/12-AOS989.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets goldilocks. *The Review of Financial Studies*, 30(12):4349–4388, 2017. doi: 10.1093/rfs/hhx052.

Olivier Ledoit and Michael Wolf. Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5):3043–3065, 2020. doi: 10.1214/19-AOS1921.

Olivier Ledoit and Michael Wolf. The power of (non-)linear shrinking: A review and guide to covariance matrix estimation. *Journal of Financial Econometrics*, 20(1):187–218, 2022. doi: 10.1093/jjfinec/nbaa007.

Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952. doi: 10.1111/j.1540-6261.1952.tb01525.x.

Juliane Schäfer and Korbinian Strimmer. A shrinkage approach to large-scale covariance matrix estimation and implications for functional genomics. *Statistical Applications in Genetics and Molecular Biology*, 4(1):Article 32, 2005. doi: 10.2202/1544-6115.1175.

Fangquan Shi, Lianjie Shu, Fangyi He, and Wenpo Huang. Improving minimum-variance portfolio through shrinkage of large covariance matrices. *Economic Modelling*, 144:106981, 2025. doi: 10.1016/j.econmod.2024.106981.