N/T харьцаа бага үед багцын оновчлолд ковариацын матрицын агшилтын аргуудыг харьцуулах нь

Г.Нарангоо[1] Ч.Анхбаяр[2]
[1]Монгол улсын их сургууль, Мэдээллийн технологи, электроникийн сургууль
narangoo.g@num.edu.mn
[2]Монгол улсын их сургууль, Бизнесийн сургууль
ankhbayar.ch@num.edu.mn

Хураангуй

Энэхүү судалгаагаар хөрөнгийн тоо болон ковариацын матрицыг үнэлэх ажиглалтын тооны харьцаа (N/T) бага нөхцөлд ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багцын (GMVP) түүврээс гадуурх гүйцэтгэлийг харьцуулан үнэлэв. Түүврийн ковариацын матриц, дөрвөн төрлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгч болон шугаман бус агшилтын үнэлэгчийг богино борлуулалтыг зөвшөөрөөгүй багцын оновчлолд ашиглав.

Корреляцийн бүтэц ялгаатай, тус бүр 10 хувьцаанаас бүрдсэн гурван багцад $T = 120$ сарын шилжих үнэлгээний цонх ашиглан ($N/T \approx 0.0833$) 52 сарын түүврээс гадуурх үнэлгээ хийв. Үр дүнгийн тогтвортой байдлыг сургалтын цонхны уртад хийсэн мэдрэмжийн шинжилгээ, нэмэлт 150 багцын шинжилгээ, HAC шалгалт болон блок bootstrap аргаар үнэлэв.

Үндсэн шинжилгээнд өндөр корреляцитай багцад тогтмол вариацын зорилтот матрицад суурилсан агшилтын үнэлэгч түүврийн ковариацын аргатай харьцуулахад дисперсийг 5.81%-иар, дунд корреляцитай багцад тогтмол корреляцийн зорилтот матрицад суурилсан агшилтын үнэлэгч 2.26%-иар бууруулсан. Харин үндсэн бага корреляцитай багцад агшилтын бүх үнэлэгчийн харьцангуй дисперсийн бууралт сөрөг байв.

Нэмэлт 150 багцын шинжилгээгээр агшилтын үнэлэгчдийн гүйцэтгэл багцын бүрэлдэхүүн болон корреляцийн бүтцээс хамааран өөрчлөгдөж байгааг харуулав. Тэнцүү жинтэй багцтай харьцуулахад GMVP стратегиуд бага хэлбэлзэл үзүүлсэн боловч олон харьцуулалтын засварын дараа агшилтын үнэлэгчид түүврийн ковариацын аргаас, мөн GMVP стратегиуд тэнцүү жинтэй багцаас статистикийн ач холбогдолтой давуу болох нь тогтоогдоогүй.

Арилжааны зардлыг харгалзан үзэхэд хэлбэлзлийн бууралт нь эрсдэлд тохируулсан цэвэр өгөөжийн өсөлтийг заавал баталгаажуулахгүй байв.

Иймд бага (N/T) нөхцөлд ковариацын матрицын агшилтын аргуудын эрсдэл бууруулах үр ашиг нь багцын корреляцийн бүтэц, бүрэлдэхүүн болон үнэлгээний цонхны уртаас хамаарах бөгөөд бүх нөхцөлд тогтвортой давуу тал үзүүлэхгүй гэж дүгнэв.

Keywords: Ковариацын матрицын агшилт; глобал хамгийн бага вариацтай багц; түүврээс гадуурх гүйцэтгэл; харьцангуй дисперсийн бууралт; шилжих цонхны арга; блок bootstrap.

1 Удиртгал

Багц сонголтын дундаж–вариацын онолын суурийг Markowitz [1952] тавьсан бөгөөд багцын эрсдэлийг тодорхойлоход хөрөнгийн өгөөжийн ковариацын матриц гол үүрэгтэй. Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP) нь хүлээгдэж буй өгөөжийн векторыг үнэлэх шаардлагагүйгээр багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлдог. Гэвч эх олонлогийн ковариацын матриц үл мэдэгдэх тул түүврийн өгөгдлөөс үнэлэх шаардлагатай. N хөрөнгийн түүврийн ковариацын матриц $N(N+1)/2$ ялгаатай параметртэй бөгөөд хөрөнгийн тоог ажиглалтын тоонд харьцуулсан N/T харьцаа өсөхөд үнэлгээний алдаа, матрицын нөхцөлт тоо болон оновчтой жингийн тогтворгүй байдалтай холбоотой хүндрэл үүсэж болно [Ledoit and Wolf, 2004a]. Гэхдээ N/T харьцаа бага, түүврийн ковариацын матриц урвуутай байсан ч үнэлгээний алдаа багцын

оновчлолын шийдэл болон түүврээс гадуурх эрсдэлд нөлөөлөх боломжтой. DeMiguel et al. [2009] багц сонголтын 14 загварыг $1/N$ жишиг багцтай харьцуулж, оновчлолд суурилсан стратегиуд уг жишгээс түүврээс гадуурх гүйцэтгэлээр тогтвортой давуу байх албагүйг харуулсан.

Ковариацын матрицын үнэлгээний алдааг бууруулах түгээмэл арга нь агшилтын үнэлгээ юм. Шугаман агшилт нь түүврийн ковариацын матриц S-ийг урьдчилан тодорхойлсон бүтэцтэй зорилтот матрицтай хослуулдаг. Энэ чиглэлийн судалгаанд нэг хүчин зүйлийн загварт суурилсан зорилтот матриц [Ledoit and Wolf, 2003], тогтмол вариацын зорилтот матриц [Ledoit and Wolf, 2004a], тогтмол корреляцийн зорилтот матриц [Ledoit and Wolf, 2004b], мөн диагональ зэрэг бүтцийн хувилбарууд [Schäfer and Strimmer, 2005, Ando and Xiao, 2023] багтана. Эдгээр зорилтот матрицууд нь хөрөнгийн дисперс, хөрөнгүүдийн хоорондын корреляци болон нийтлэг хүчин зүйлийн бүтцийн талаар ялгаатай таамаглал ашигладаг. Харин шугаман бус агшилтын аргууд нь түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засварлах боломж олгодог [Ledoit and Wolf, 2012, 2020]. Иймээс агшилтын үнэлэгчдийн харьцангуй гүйцэтгэл нь зөвхөн агшилт хэрэглэсэн эсэхээс бус, зорилтот матрицын бүтцийн тохироо, өгөгдлийн шинж чанар болон багцын оновчлолын нөхцөлөөс хамаарч болно [Ledoit and Wolf, 2022].

Ковариацын матрицын үнэлгээний нарийвчлал сайжрах нь оновчтой багцын түүврээс гадуурх эрсдэлийг заавал бууруулна гэсэн үг биш. Ledoit and Wolf [2017] багцын оновчлолд зориулсан шугаман бус агшилтын аргыг судалж, түүврээс гадуурх гүйцэтгэлийг үнэлсэн. Shi et al. [2025] сарын өгөөж болон 120 сарын шилжих цонх ашиглан агшилтын эрчмийг cross-validation-д суурилсан negative log-likelihood шалгууруар сонгох аргыг санал болгож, харьцангуй олон хөрөнгөтэй, богино борлуулалтыг зөвшөөрсөн GMVP-ийн хүрээнд диагональ болон нэг хүчин зүйлийн зорилтот матрицын давуу талыг тайлагнасан. Эдгээр судалгаа нь ковариацын үнэлгээний арга, агшилтын эрчим болон багцын бодит гүйцэтгэлийн хоорондын холбоог тодруулсан боловч тэдгээрийн үр дүнг бага N/T-тэй, богино борлуулалтыг хориглосон багцад шууд шилжүүлэн үзэх боломжгүй.

Багцын оновчлолд тавих хязгаарлалт нь ковариацын үнэлгээний алдааны нөлөөг өөрчилж болох тул агшилтын аргуудын гүйцэтгэлийг хязгаарлалтын нөхцөлтэй хамтатган үнэлэх шаардлагатай. Jagannathan and Ma [2003] багцын жинг сөрөг бус байлгах хязгаарлалт нь ковариацын матрицад агшилттай төстэй нөлөө үзүүлж болохыг тайлбарласан. Ийм хязгаарлалт нь үнэлгээний алдаанаас үүдэх хэт их болон сөрөг жинг хязгаарлаж, түүврийн ковариацын матрицад суурилсан GMVP-ийн гүйцэтгэлийг сайжруулах боломжтой. Ledoit and Wolf [2017] мөн багцын хязгаарлалттай болон хязгаарлалтгүй нөхцөл дэх ковариацын үнэлэгчдийн гүйцэтгэлийг авч үзсэн.

Энэ асуудлыг сүүлийн үеийн эмпирик судалгаагаар улам тодруулсан. Dom et al. [2025] ковариацын матрицын үнэлэгчдийн гүйцэтгэлийг хязгаарлалтгүй GMVP, богино борлуулалтыг хориглосон GMVP болон жингийн нэмэлт хязгаарлалт, арилжааны зардлын тооцоотой GMVP-ийн хүрээнд харьцуулсан. Тэдний үр дүнгээр хязгаарлалтгүй GMVP-д шугаман бус агшилтын үнэлэгчид түүврийн ковариацын үнэлэгчээс давуу гүйцэтгэл үзүүлсэн бол long-only хязгаарлалттай нөхцөлд статик агшилтын үнэлэгчдийн нэмэлт үр ашиг мэдэгдэхүйц буурсан. Жингийн нэмэлт хязгаарлалт болон арилжааны зардлын торгууль оруулахад түүврийн ковариацын матрицад суурилсан багц нь агшилтын үнэлэгчдэд суурилсан багцуудтай ойролцоо гүйцэтгэлтэй болсон. Харин өгөөжийн цаг хугацааны динамикийг харгалзсан үнэлэгчид түүврээс гадуурх хэлбэлзлийг бууруулахад ач холбогдолтой хэвээр байгааг тогтоосон.

Эдгээр үр дүн нь ковариацын үнэлэгчийн давуу тал багцын оновчлолын хязгаарлалтаас хамаарч өөрчлөгдөж болохыг харуулж байна. Гэхдээ Dom et al. [2025] голчлон олон хөрөнгөтэй багцуудыг судалж, агшилтын аргуудын гүйцэтгэлийг багц байгуулах өөр өөр стратеги, жингийн хязгаарлалт болон арилжааны зардлын нөхцөлд харьцуулсан. Иймээс хөрөнгийн тоо харьцангуй цөөн, N/T харьцаа бага үед long-only хязгаарлалтыг тогтмол хадгалж, хөрөнгүүдийн корреляцийн бүтцийг өөрчлөхөд агшилтын үнэлэгчдийн харьцангуй гүйцэтгэл хэрхэн өөрчлөгдөх нь тусдаа эмпирик асуулт юм. Мөн De Nard and Kostovic [2026] агшилтын эрчмийг өгөгдөлд суурилан сонгох аргыг судалж, хязгаарлалтгүй болон long-only GMVP-ийн гүйцэтгэлийг харьцуулсан. Гэвч тэдний үндсэн эмпирик шинжилгээ өдрийн өгөөжид тулгуурласан тул сарын өгөөжтэй, бага N/T нөхцөлд ижил үр дүн гарах эсэхийг тусад нь шалгах шаардлагатай.

Өмнөх судалгаануудад ковариацын агшилтын онол, өндөр хэмжээст багцын оновчлол болон жингийн хязгаарлалтын нөлөөг өргөн хүрээнд авч үзсэн. Харин сарын өгөөжид суурилсан, N/T харьцаа бага, богино борлуулалтыг хориглосон GMVP-ийн хүрээнд ялгаатай зорилтот бүтэцтэй ковариацын агшилтын үнэлэгчдийн гүйцэтгэлийг хөрөнгүүдийн корреляцийн түвшин болон багцын бүрэлдэхүүний өөрчлөлттэй хамтатган үнэлэх нь ач холбогдолтой хэвээр байна. Ялангуяа нэг багцад ажиглагдсан дисперсийн бууралт бусад багцад давтагдах эсэх, корреляцийн ялгаатай бүтэц үнэлэгчдийн харьцангуй гүйцэтгэлд хэрхэн нөлөөлөх, мөн түүврээс гадуурх дисперсийн ялгаа HAC тестээр статистикийн ач холбогдолтой эсэхийг үнэлэх шаардлагатай.

Энэхүү судалгааны зорилго нь бага N/T нөхцөлд ковариацын матрицын ялгаатай үнэлэгчдийг богино борлуулалтыг хориглосон глобал хамгийн бага вариацтай багцын (GMVP) ижил оновчлолын нөхцөлд харьцуулж, агшилтын аргуудын түүврээс гадуурх эрсдэлийг бууруулах үр нөлөө нь хөрөнгүүдийн корреляцийн бүтэц болон багцын бүрэлдэхүүнээс хамаарч өөрчлөгдөх эсэхийг эмпирик аргаар үнэлэхэд оршино. Үүний тулд түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцийн (Corr), нэг хүчин зүйлийн (SF) зорилтот матрицад суурилсан дөрвөн шугаман агшилтын үнэлэгч болон шугаман бус агшилтын үнэлэгчийг (NLS) харьцуулна. Бүх үнэлэгчийн хувьд багцын жинг сөрөг бус, нийлбэрийг нэгтэй тэнцүү байлгах ижил хязгаарлалтыг ашиглана.

Үндсэн харьцуулсан шинжилгээний үр дүнг хөрөнгө оруулалтын практик хэрэглээтэй холбох зорилгоор 10 хувьцаатай боломжит багцуудыг сонгох нэмэлт шинжилгээ хийнэ. Энэ хүрээнд 337 хувьцааны олонлогоос санамсаргүй хайлтаар үүсгэсэн 5000 нэр дэвшигч багцаас validation хугацааны дисперсийн бууралтад суурилсан шалгуураар багцуудыг сонгоно. Улмаар сонгогдсон багцуудын түүврээс гадуурх өгөөж, хэлбэлзэл, дисперсийн бууралт (RVR), HAC тестийн үр дүн, Sharpe-ийн харьцаа, багцын жингийн өөрчлөлт (turnover) болон төвлөрөл (HHI)-ийг хамтад нь харьцуулан үнэлж, давуу болон сул талд нь үндэслэн хөрөнгө оруулалтын боломжит хувилбаруудыг тодорхойлно.

Үндсэн эмпирик шинжилгээнд сарын өгөөжийн өгөгдөл ашиглан тус бүр 10 хувьцаатай, дундаж корреляцийн түвшнээрээ өндөр, дунд, бага гурван багц байгуулна. 120 сарын шилжих сургалтын цонх ашиглан 2022 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх 52 сарын түүврээс гадуурх гүйцэтгэлийг үнэлнэ. Үндсэн шалгуур нь түүврээс гадуурх хэлбэлзэл болон түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулсан дисперсийн бууралт (RVR) байх бөгөөд нэмэлтээр Sharpe-ийн харьцаа, багцын жингийн эргэлт, төвлөрөл болон арилжааны зардлын дараах гүйцэтгэлийг авч үзнэ.

Судалгааны эмпирик хувь нэмэр нь ковариацын агшилтын үнэлэгчдийн гүйцэтгэлийг бага N/T нөхцөлд хэд хэдэн талаас нь үнэлсэнд оршино. Тухайлбал, корреляцийн ялгаатай бүтэц болон N/T харьцааны өөрчлөлтийн нөлөөг судалж, 150 нэмэлт багцаар үр дүнгийн тогтвортой байдлыг шалгана. Мөн түүврээс гадуурх дисперсийн ялгааны статистикийн ач холбогдол, багцын жингийн тогтвортой байдал болон арилжааны зардлын нөлөөг үнэлнэ. Эдгээр үр дүнг практик хэрэглээтэй холбон, санамсаргүй хайлтаар сонгосон боломжит багцуудын хөрөнгө оруулалтын давуу болон сул талыг харьцуулан авч үзнэ.

Эмпирик шинжилгээний үр дүнд ковариацын агшилтын аргуудын түүврээс гадуурх эрсдэлийг бууруулах үр нөлөө багцын корреляцийн бүтэц болон хөрөнгийн бүрэлдэхүүнээс хамаарч ялгаатай байв. Тухайлбал, өндөр корреляцитай багцад Var үнэлэгч түүврийн ковариацын матрицтай харьцуулахад дисперсийг 5.81%-иар бууруулсан бол бага корреляцитай багцад агшилтын таван үнэлэгчийн аль нь ч дисперсийн бууралт үзүүлээгүй. Нэмэлт 150 багцын шинжилгээнд мөн үнэлэгчдийн харьцангуй гүйцэтгэл багцын бүрэлдэхүүнээс хамаарч өөрчлөгдөж байв. Эдгээр үр дүн нь бага N/T нөхцөлд ковариацын агшилтын аргууд бүх багцад тогтвортой давуу байх албагүйг харуулж байна.

Энэхүү судалгаанд $N/T < 0.1$ нөхцөлийг хөрөнгийн тоо ажиглалтын тоотой харьцуулахад бага байх орчныг тодорхойлох үйл ажиллагааны шалгуур болгон ашигласан. Уг босго нь онолын хувьд тогтоогдсон универсал утга бус, харин судалгааны хамрах хүрээг тодорхойлох зорилгоор сонгосон хязгаар юм. Энэ нөхцөлд түүврийн ковариацын матрицын үнэлгээний алдаа нь глобал хамгийн бага вариацтай багцын жин болон түүврээс гадуурх эрсдэлд нөлөөлж болзошгүй.

Эмпирик шинжилгээний үр дүнд ковариацын агшилтын аргуудын түүврээс гадуурх гүйцэтгэл багц бүрд ижил бус байв. Зарим багцад түүврийн ковариацын матрицтай харьцуулахад дисперсийн бууралт ажиглагдсан бол бусад багцад агшилтын аргууд давуу үр дүн

үзүүлээгүй. Нэмэлт 150 багцын шинжилгээ мөн үнэлэгчдийн харьцангуй гүйцэтгэл багцын бүрэлдэхүүнээс хамаарч өөрчлөгдөж байгааг харуулсан. Иймээс бага N/T нөхцөлд ковариацын агшилт нь түүврээс гадуурх эрсдэлийг бүх багцад тогтвортой бууруулдаг гэж дүгнэх боломжгүй байна.

2 Онол, арга зүйн үндэслэл

2.1 Багцын өгөөж ба эрсдэл

Энэхүү судалгаанд N ширхэг хөрөнгөөс бүрдэх хөрөнгө оруулалтын багцыг авч үзье. x_i нь i-р хөрөнгийн багцад эзлэх жин, G_i нь тухайн хөрөнгийн өгөөж гэж тэмдэглэвэл багцын өгөөжийг

$$r_p = \sum_{i=1}^{N} x_i G_i$$

гэж тодорхойлно. Багцын хүлээгдэж буй өгөөж нь

$$\mu_p = E[r_p] = E\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i E[G_i]$$

байна. Энд $E[G_i]$ нь i-р хөрөнгийн хүлээгдэж буй өгөөжийг илэрхийлнэ.

Багцын эрсдэлийг өгөөжийн вариацаар хэмжвэл

$$\sigma_p^2 = \mathrm{Var}(r_p) = \mathrm{Var}\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i^2 \sigma_i^2 + \sum_{i \neq j} x_i x_j \sigma_{ij},$$

байна. Энд $\sigma_i^2 = \mathrm{Var}(G_i)$ нь i-р хөрөнгийн өгөөжийн вариац, харин

$$\sigma_{ij} = \mathrm{Cov}(G_i, G_j)$$

нь i болон j-р хөрөнгийн өгөөжийн ковариац юм.

Багцын жингийн векторыг

$$\mathbf{x} = (x_1, x_2, \ldots, x_N)^\top,$$

хөрөнгүүдийн өгөөжийн ковариацын матрицыг

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1N} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \cdots & \sigma_{NN} \end{pmatrix}$$

гэж тэмдэглэвэл багцын вариацыг матриц хэлбэрээр

$$\sigma_p^2 = \mathbf{x}^\top \Sigma \mathbf{x}$$

гэж бичиж болно.

Иймээс багцын эрсдэл нь хөрөнгө тус бүрийн вариацаас гадна хөрөнгүүдийн өгөөж хоорондын ковариацаас хамаарна. Иймд ковариацын матрицыг хэрхэн үнэлэх нь багц сонголтын үр дүнд чухал нөлөөтэй.

Ковариацын матрицын үнэлэгчдийн харьцуулалтын үндсэн шалгууруур түүврээс гадуурх багцын хэлбэлзлийг ашиглана [Ledoit and Wolf, 2022, De Nard and Kostovic, 2026]. Энэ нь хүлээгдэж буй өгөөжийн векторыг үнэлэх шаардлагагүйгээр глобал хамгийн бага вариацтай багцын бодит хэрэгжилтийн эрсдэлийг үнэлэх боломж олгоно.

2.2 Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)

Энэхүү судалгаанд ковариацын матрицын өөр өөр үнэлэгчийг багцын оновчлолд ашиглахад үүсэх ялгааг харьцуулахын тулд глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)-ийг ашиглана. GMVP-ийн зорилго нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилах нөхцөлд багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлоход оршино. GMVP-ийн оновчтой жинг тодорхойлоход хөрөнгүүдийн хүлээгдэж буй өгөөжийн үнэлгээ шаардлагагүй бөгөөд ковариацын матрицад тулгуурладаг.

Энэхүү судалгаанд богино арилжааг зөвшөөрөхгүй, хөрөнгө бүрийн багцад эзлэх жин сөрөг биш байх long-only GMVP загварыг ашиглана. Энэхүү хязгаарлалт нь богино арилжаа болон сөрөг жингээс үүдэх хөшүүрэгтэй байрлалыг хязгаарлахаас гадна ковариацын матрицын үнэлгээний алдаанаас шалтгаалан багцын жин хэт туйлшрах эрсдэлийг бууруулах боломжтой. Jagannathan and Ma [2003]-ийн судалгаанд багцын жинг сөрөг бишээр хязгаарлах нь үнэлсэн оновчтой багцын эрсдэлийг бууруулж болохыг харуулсан. Түүнчлэн ийм хязгаарлалт нь ковариацын матрицын зарим элементийг агшаасантай төстэй нөлөө үзүүлж болохыг тайлбарласан.

Гэхдээ long-only хязгаарлалт нь өөрөө ковариацын матрицын үнэлгээний алдааны нөлөөг бууруулж болох тул агшилтын үнэлэгчдийн хоорондын гүйцэтгэлийн ялгааг багасгаж болзошгүй. Иймээс энэхүү судалгаанд ковариацын матрицын үнэлэгчдийн үр дүнг ижил long-only оновчлолын нөхцөлийн хүрээнд харьцуулж, гарсан дүгнэлтийг уг хязгаарлалтын хүрээнд тайлбарлана.

N ширхэг хөрөнгөөс бүрдэх багцын жингийн векторыг

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_N)^\top$$

гэж тэмдэглэе. Мөн хөрөнгүүдийн өгөөжийн ковариацын матрицын үнэлэгчийг $\widehat{\Sigma}$ гэвэл багцын үнэлэгдсэн вариац

$$\widehat{\sigma}_p^2 = \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x}$$

байна.

Тэгвэл long-only GMVP-ийн оновчлолын бодлогыг

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x} \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{x} = 1, \\ & x_i \geq 0, \qquad i = 1, 2, \ldots, N \end{aligned}$$

гэж тодорхойлно. Энд $\mathbf{1}$ нь бүх элемент нь нэгтэй N хэмжээст вектор юм.

$\mathbf{1}^\top \boldsymbol{x} = 1$ нөхцөл нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилахыг, харин $x_i \geq 0$ нөхцөл нь хөрөнгө бүрийн жин сөрөг биш байхыг илэрхийлнэ. Эдгээр нөхцөлөөс

$$0 \leq x_i \leq 1, \qquad i = 1, 2, \ldots, N$$

байх нь шууд мөрдөнө.

Long-only GMVP-ийн оновчтой жинг хязгаарлалттай квадратлаг оновчлолын бодлогын шийдээр тодорхойлно. Хэрэв $\widehat{\Sigma}$ нь эерэг хагас тодорхой матриц бол зорилгын функц гүдгэр байна. Мөн боломжит жингийн олонлог хоосон биш, хаалттай, хязгаарлагдмал тул оновчтой шийд оршино. Харин оновчтой шийд цорын ганц байх нь ковариацын матрицын шинж чанараас хамаарна.

Энэхүү судалгаанд түүврийн ковариацын матрицыг суурь үнэлэгч болгон авч, тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг харьцуулна.

Эдгээр зургаан ковариацын матрицын үнэлэгчийг ерөнхийд нь $\widehat{\Sigma}^{(k)}$, $k = 1, 2, \ldots, 6$ гэж

тэмдэглэе. Тэгвэл k-р үнэлэгчид харгалзах long-only GMVP-ийн оновчтой жинг

$$\widehat{\boldsymbol{x}}^{(k)} \in \underset{\substack{\boldsymbol{x}\in\mathbb{R}^N \\ \mathbf{1}^\top \boldsymbol{x}=1 \\ \boldsymbol{x}\geq \mathbf{0}}}{\arg\min} \boldsymbol{x}^\top \widehat{\Sigma}^{(k)} \boldsymbol{x}$$

гэж тодорхойлно.

Энд бүх үнэлэгчийн хувьд багцын оновчлолын зорилгын функцийн хэлбэр болон хөрөнгө оруулалтын жинд тавих хязгаарлалтууд ижил байх бөгөөд зөвхөн ковариацын матрицын үнэлэгч $\widehat{\Sigma}^{(k)}$ өөрчлөгдөнө.

Иймээс ковариацын матрицын үнэлэгчийн сонголтоос хамааран GMVP-ийн оновчтой жин, улмаар багцын эрсдэл болон бодит өгөөжийн үзүүлэлтүүд ялгаатай байж болно. Энэхүү судалгаанд эдгээр үнэлэгчээр байгуулсан long-only GMVP-үүдийн гүйцэтгэлийг ижил нөхцөлд харьцуулан үнэлнэ.

2.3 Түүврийн ковариацын матриц

Бодит нөхцөлд хөрөнгүүдийн өгөөжийн эх олонлогийн ковариацын матриц Σ үл мэдэгдэх тул түүнийг ажиглагдсан өгөгдлөөс үнэлэх шаардлагатай. Энэхүү судалгаанд n ажиглалт, N хөрөнгөөс бүрдэх өгөөжийн ажиглалтын матрицыг

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1N} \\ y_{21} & y_{22} & \cdots & y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nN} \end{pmatrix} \in \mathbb{R}^{n\times N}$$

гэж тэмдэглэнэ. Энд y_{ti} нь t-р хугацаанд ажиглагдсан i-р хөрөнгийн өгөөж, n нь ажиглалтын тоо, N нь хөрөнгийн тоо юм.

i-р хөрөнгийн дундаж өгөөжийг

$$\overline{Y}_i = \frac{1}{n}\sum_{t=1}^{n} y_{ti}, \qquad i = 1, 2, \ldots, N,$$

гэж тооцно.

Тэгвэл i болон j-р хөрөнгийн өгөөжийн түүврийн ковариацыг

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

гэж тодорхойлно. Энд $1/n$ хуваарь ашигласан тул уг үнэлэгч нь ерөнхий тохиолдолд хазайлтгүй түүврийн ковариацын үнэлэгч ($1/(n-1)$ хуваарьтай) биш болохыг анхаарна. Эдгээр түүврийн ковариацуудаас бүрдэх түүврийн ковариацын матриц нь

$$S = (s_{ij}) = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1N} \\ s_{21} & s_{22} & \cdots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \cdots & s_{NN} \end{pmatrix}$$

байна. Энд S нь $N \times N$ хэмжээст түүврийн ковариацын матриц бөгөөд эх олонлогийн ковариацын матриц Σ-г үнэлэхэд ашиглагдана.

2.4 Шугаман агшилтын үнэлгээ (Linear Shrinkage Estimation)

Шугаман агшилт (Linear Shrinkage) нь агшилтын үнэлгээний хамгийн өргөн хэрэглэгддэг хэлбэрүүдийн нэг юм. Энэхүү аргын үндсэн санаа нь түүврийн ковариацын матриц болон тодорхой бүтэц бүхий зорилтот матрицыг гүдгэр хослол хэлбэрээр нэгтгэн ковариацын мат-

рицын үнэлэгчийг байгуулахад оршино. Шугаман агшилтын үнэлэгчийг ерөнхий хэлбэрээр

$$\widehat{\Sigma}_{LS} = (1-\alpha)S + \alpha T, \qquad 0 \leq \alpha \leq 1,$$

гэж тодорхойлно. Энд S нь түүврийн ковариацын матриц, T нь зорилтот матриц, α нь агшилтын эрчим юм. $\alpha = 0$ үед $\widehat{\Sigma}_{LS} = S$, харин $\alpha = 1$ үед $\widehat{\Sigma}_{LS} = T$ болно. Иймээс α-ийн утга ихсэх тусам зорилтот матриц T-д өгөх жин нэмэгдэж, түүврийн ковариацын матриц S-д өгөх жин буурна.

Хэрэв зорилтот матриц T нь эерэг тодорхой бөгөөд $0 < \alpha \leq 1$ бол шугаман агшилтын үнэлэгч $\widehat{\Sigma}_{LS}$ нь эерэг тодорхой байна. Энэ шинж нь ковариацын матрицын тооцооллын тогтвортой байдлыг сайжруулахад ач холбогдолтой.

Шугаман агшилтын арга нь түүврийн ковариацын матрицын бүх элементэд нэг ижил агшилтын эрчим α-г хэрэглэдэг. Иймээс ковариацын матрицын бодит бүтэц нарийн төвөгтэй, эсвэл хөрөнгүүдийн хоорондын хамаарал харилцан адилгүй үед нэг ижил агшилтын эрчим хэрэглэх нь уг аргын уян хатан байдлыг хязгаарлаж болно.

Шугаман агшилтын үнэлгээний үр дүнд зорилтот матрицын сонголт чухал үүрэгтэй. Энэхүү судалгаанд тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицыг авч үзнэ. Эдгээр зорилтот матрицууд нь шугаман агшилтын ерөнхий хэлбэр дэх T-ийн үүргийг гүйцэтгэх бөгөөд тэдгээрийн ялгаа нь ковариацын матрицын бүтцэд тавих таамаглалд оршино.

2.4.1 Тогтмол вариацын зорилтот матриц

Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн вариацыг нэг нийтлэг утгаар төлөөлүүлж, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг. Уг зорилтот матрицыг

$$T_{\text{var}} = \widehat{\mu} I$$

гэж тодорхойлно. Энд I нь $N \times N$ хэмжээст нэгж матриц, харин

$$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii} = \frac{\text{tr}(S)}{N}$$

нь хөрөнгүүдийн өгөөжийн түүврийн вариацуудын дундаж юм. Иймээс

$$T_{\text{var}} = \begin{pmatrix} \widehat{\mu} & 0 & \cdots & 0 \\ 0 & \widehat{\mu} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \widehat{\mu} \end{pmatrix}$$

хэлбэртэй байна [Ledoit and Wolf, 2004b].

Тогтмол вариацын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{var}} = (1-\widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}, \qquad 0 \leq \widehat{\alpha}_{\text{var}} \leq 1$$

гэж тодорхойлно.

Агшилтын эрчмийн онолын үндэслэлийг Ledoit болон Wolf (2004)-ийн үр дүнд тулгуурлан дараах хэмжигдэхүүнүүдийг авч үзье:

$$\begin{aligned} a &= E\left[\|\Sigma - T\|^2\right] = \|\Sigma - T\|^2, \\ b &= E\left[\|S - \Sigma\|^2\right], \\ d &= E\left[\|S - T\|^2\right]. \end{aligned}$$

Лемма 1 (Ledoit–Wolf, 2004). Хэрэв $E[S] = \Sigma$ бөгөөд квадратын математик дунджууд төгсгөлөг бол

$$a + b = d$$

тэнцэтгэл биелнэ.

Баталгаа. Математик дундаж ба нормын чанараас

$$\begin{aligned} d &= E\left[\|S-T\|^2\right] = E\left[\|S-\Sigma+\Sigma-T\|^2\right] \\ &= E\left[\|S-\Sigma\|^2\right] + \|\Sigma-T\|^2 + 2E\left[\langle S-\Sigma, \Sigma-T\rangle\right]. \end{aligned}$$

$E[S]=\Sigma$ бөгөөд T нь санамсаргүй бус матриц тул

$$E\left[\langle S-\Sigma, \Sigma-T\rangle\right] = \langle E[S-\Sigma], \Sigma-T\rangle = 0.$$

Иймээс

$$d = b + a.$$

Лемма батлагдав. □

Теорем 1 (Ledoit–Wolf, 2004). Дараах оновчлолын бодлогыг авч үзье:

$$\min_{0\le\alpha\le 1} E\left[\|\Sigma^*(\alpha)-\Sigma\|^2\right],$$

энд

$$\Sigma^*(\alpha) = (1-\alpha)S + \alpha T.$$

Хэрэв $d>0$ бол оновчтой агшилтын эрчим

$$\alpha^* = \frac{b}{d}$$

бөгөөд харгалзах үнэлэгч

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T$$

байна.

Баталгаа. Агшилтын үнэлэгчийн алдааг

$$\Sigma^*(\alpha)-\Sigma = (1-\alpha)(S-\Sigma) + \alpha(T-\Sigma)$$

гэж бичиж болно.

Одоо нормын квадратын томьёо болон математик дунджийн шугаман чанарыг хэрэглэнэ.

$$\begin{aligned} \|\Sigma^*(\alpha)-\Sigma\|^2 &= \|(1-\alpha)(S-\Sigma)+\alpha(T-\Sigma)\|^2 \\ &= (1-\alpha)^2\|S-\Sigma\|^2 + \alpha^2\|T-\Sigma\|^2 + 2\alpha(1-\alpha)\langle S-\Sigma, T-\Sigma\rangle. \end{aligned}$$

Хоёр талаас математик дундаж авбал:

$$\begin{aligned} E\left[\|\Sigma^*(\alpha)-\Sigma\|^2\right] &= (1-\alpha)^2 E\left[\|S-\Sigma\|^2\right] + \alpha^2 E\left[\|T-\Sigma\|^2\right] + 2\alpha(1-\alpha)E\left[\langle S-\Sigma, T-\Sigma\rangle\right] \\ &= (1-\alpha)^2 b + \alpha^2 a. \end{aligned}$$

Иймээс зорилгын функц

$$R(\alpha) = (1-\alpha)^2 b + \alpha^2 a$$

болно.

Алдааг хамгийн бага болгох α-г олох нь бидний зорилго учраас уламжлал аваад тэгтэй тэнцүүлнэ.

$$R'(\alpha) = -2(1-\alpha)b + 2\alpha a = 0.$$

Лемма 1-ээс $a+b=d$ тул

$$\alpha^* = \frac{b}{d}, \qquad 1-\alpha^* = \frac{a}{d}.$$

Иймээс

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T.$$

$R''(\alpha) = 2d > 0$ учраас энэ нь минимум шийд юм.
Теорем батлагдав. □

Теорем 1-ээс оновчтой агшилтын эрчим нь түүврийн ковариацын матрицын үнэлгээний алдаа болон зорилтот матрицаас хазайх хэмжээнээс хамаарах нь харагдана.

Гэвч b болон d нь үл мэдэгдэх бодит ковариацын матрицаас хамаардаг тул тэдгээрийг өгөгдлөөс үнэлэх шаардлагатай. Ledoit болон Wolf (2004)-ийн оновчтой агшилтын эрчмийг өгөгдлөөс үнэлэх аргыг боловсруулсан.

Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын квадрат Фробениусын зайг

$$\widehat{d}_{\text{var}} = \|S - T_{\text{var}}\|_F^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг нормчилсон Фробениусын нормын тодорхойлолтоос

$$b_{var} = E\left[\|S - \Sigma\|^2\right] = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}E\left[(s_{ij} - \sigma_{ij})^2\right].$$

Хэрэв $E[S] = \Sigma$ бол $E\left[(s_{ij} - \sigma_{ij})^2\right] = \text{Var}(s_{ij})$.
Иймээс

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\text{Var}(s_{ij}).$$

Одоо

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\}$$

гэж тэмдэглэе.

Ажиглалтууд хугацааны хувьд харилцан хамааралгүй, ижил тархалттай бол

$$\text{Var}(s_{ij}) \approx \frac{1}{n^2}\sum_{t=1}^{n}\text{Var}\left((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\right) = \frac{1}{n}\text{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Тэгвэл

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\frac{1}{n}\text{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right) = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\text{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Энд $\text{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right)$ нь үл мэдэгдэх тул түүний үнэлгээг $\frac{1}{n}\sum_{t=1}^{n}((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij})^2$ байгуулвал

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right] =$$

$$= \frac{1}{nN}\left[\frac{1}{n}\sum_{t=1}^{n}\sum_{i=1}^{N}\sum_{j=1}^{N}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right].$$

Иймээс агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{var}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004b].

Тооцоолох алгоритм. Тогтмол вариацын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Түүврийн ковариацын матрицыг байгуулах.
   n ажиглалт, N хөрөнгийн өгөөжийн өгөгдлөөс
   $$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$
   гэж тооцож, $S = (s_{ij})$ матрицыг байгуулна.
2. Тогтмол вариацын зорилтот матрицыг байгуулах.
   $$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii}, \qquad T_{\text{var}} = \widehat{\mu} I.$$
3. Ковариацын матрицын квадрат алдааг үнэлэх.
   $$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\}^2\right].$$
4. Зорилтот матрицаас хазайх квадрат зайг тооцох.
   $$\widehat{d}_{\text{var}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2.$$
5. Агшилтын эрчмийг үнэлэх.
   $\widehat{d}_{\text{var}} > 0$ үед
   $$\widehat{\alpha}_{\text{var}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}.$$
6. Агшилтын ковариацын матрицыг байгуулах.
   $$\boxed{\widehat{\Sigma}_{\text{var}} = (1 - \widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}}.$$

2.4.2 Диагональ зорилтот матриц

Диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг гэж үзнэ. Уг зорилтот матрицыг

$$T_{\text{diag}} = \text{diag}(S) = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

гэж тодорхойлно. Матриц хэлбэрээр

$$T_{\text{diag}} = \begin{pmatrix} s_{11} & 0 & \cdots & 0 \\ 0 & s_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_{NN} \end{pmatrix}.$$

Өөрөөр хэлбэл,

$$(T_{\text{diag}})_{ij} = \begin{cases} s_{ii}, & i = j, \\ 0, & i \neq j. \end{cases}$$

Иймээс диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалах боловч хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг болгон хялбаршуулдаг.

Диагональ зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}, \qquad 0 \leq \widehat{\alpha}_{\text{diag}} \leq 1,$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{diag}}$ нь диагональ зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Диагональ зорилтот матриц нь түүврийн ковариацын матрицын диагональ элементүүдийг өөрчлөхгүй хадгалдаг тул агшилт нь зөвхөн диагоналийн бус элементүүдэд үйлчилнэ.

Иймээс агшилтын эрчмийг үнэлэхдээ диагоналийн бус элементүүдийн квадрат алдааг авч үзнэ.

Түүврийн ковариацын матриц болон диагональ зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{diag}} = \|S - T_{\text{diag}}\|^2 = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2$$

гэж тодорхойлно.

Учир нь S болон T_{diag} матрицын диагональ элементүүд ижил тул тэдгээрийн ялгавар диагональ дээр тэг байна.

Өмнөх тогтмол вариацын зорилтот матрицын хэсэгт үзсэнтэй адилтаар $\widehat{b}_{diag}$-г дараах байдлаар тодорхойлно.

$$\widehat{b}_{\text{diag}} = \frac{1}{nN} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} (z_{tij} - s_{ij})^2 \right].$$

Иймээс диагональ зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{diag}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}} \right\} \right\}$$

гэж байгуулна.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}$$

гэж тооцно.

Тооцоолох алгоритм. Диагональ зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Диагональ зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$T_{\text{diag}} = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

   гэж байгуулна.

2. Диагоналийн бус элементүүдийн квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{diag}} = \frac{1}{nN} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} (z_{tij} - s_{ij})^2 \right].$$

3. Зорилтот матрицаас хазайх квадрат зайг тооцох.

   $$\widehat{d}_{\text{diag}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2.$$

4. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{diag}} > 0$ үед

   $$\widehat{\alpha}_{\text{diag}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}} \right\} \right\}.$$

5. Агшилтын ковариацын матрицыг байгуулах.

   $$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}.$$

2.4.3 Тогтмол корреляцийн зорилтот матриц

Тогтмол корреляцийн зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг тэдгээрийн дундаж утгаар төлөөлүүлэн байгуулдаг зорилтот матриц юм [Ledoit and Wolf, 2004a].

i болон j дугаар хөрөнгийн өгөөжийн түүврийн корреляцийн коэффициентийг

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii} s_{jj}}}$$

гэж тодорхойлно [Ledoit and Wolf, 2004a].

Хөрөнгүүдийн хоорондын түүврийн корреляцуудын дундажийг

$$\bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

гэж тооцно.

Тогтмол корреляцийн зорилтот матрицын элементүүдийг

$$(T_{\text{corr}})_{ij} = t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii} s_{jj}}, & i \neq j \end{cases}$$

гэж тодорхойлно.

Иймээс уг зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг нэг ижил дундаж утгаар орлуулна.

Тогтмол корреляцийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}, \qquad 0 \leq \widehat{\alpha}_{\text{corr}} \leq 1$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{corr}}$ нь тогтмол корреляцийн зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Тогтмол корреляцийн зорилтот матриц нь түүврийн ковариацын матрицын элементүүдээс хамааран байгуулагддаг тул агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг харгалзан үзнэ.

Түүврийн ковариацын матриц болон тогтмол корреляцийн зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{corr}} = \|S - T_{\text{corr}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2 = \frac{1}{N}\sum_{\substack{i,j=1 \\ i \neq j}}^{N}\left(s_{ij} - \bar{r}\sqrt{s_{ii}s_{jj}}\right)^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг өмнөх хэсгүүдэд үзсэнтэй адилаар

$$\widehat{b}_{\text{corr}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж бичигдэнэ.

Тогтмол корреляцийн зорилтот матриц нь түүврийн ковариацын матрицаас хамаардаг учраас тэдгээрийн харгалзах элементүүдийн асимптотик ковариацыг тооцох шаардлагатай.

Энэ хэмжигдэхүүний нормчилсон үнэлгээг $\widehat{c}_{\text{corr}}$ гэж тэмдэглэе.

Эхлээд

$$\widehat{\vartheta}_{ii,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

болон

$$\widehat{\vartheta}_{jj,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{tj} - \overline{Y}_j)^2 - s_{jj}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

гэж тодорхойлно.

Эдгээр нь түүврийн вариац болон ковариацын элементүүдийн асимптотик ковариацыг үнэлэхэд ашиглагдана.

Ledoit болон Wolf (2004) нь түүврийн ковариацын матриц болон тогтмол корреляцийн зорилтот матрицын асимптотик хам хэлбэлзлийг тооцох аргыг боловсруулсан [Ledoit and Wolf, 2004a]. Тэдгээрийн Appendix B-д өгсөн үр дүнд тулгуурлан

$$\widehat{c}_{\text{corr}} = \frac{1}{nN}\left[\sum_{i=1}^{N}\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) + \frac{\bar{r}}{2}\sum_{\substack{i,j=1 \\ i \neq j}}^{N}\left(\sqrt{\frac{s_{jj}}{s_{ii}}}\widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\widehat{\vartheta}_{jj,ij}\right)\right]$$

гэж үнэлнэ.

Энд

$$\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2$$

юм.

Иймээс тогтмол корреляцийн зорилтот матрицад харгалзах агшилтын эрчмийн практик

үнэлгээг

$$\widehat{\alpha}_{\text{corr}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004a].

Энд $\widehat{b}_{\text{corr}}$ нь түүврийн ковариацын матрицын үнэлгээний квадрат алдааны асимптотик ойролцоо үнэлгээ, $\widehat{c}_{\text{corr}}$ нь түүврийн ковариацын матриц болон зорилтот матрицын харгалзах элементүүдийн асимптотик ковариацуудын нийлбэрийн нормчилсон үнэлгээ, $\widehat{d}_{\text{corr}}$ нь хоёр матрицын хоорондын нормчилсон квадрат Фробениусын зай юм.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}$$

гэж тооцно.

Тооцоолох алгоритм. Тогтмол корреляцийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Тогтмол корреляцийн зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}, \qquad \bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

   гэж тооцно.

   Дараа нь

   $$t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii}s_{jj}}, & i \neq j \end{cases}$$

   гэж тодорхойлж, $T_{\text{corr}} = (t_{ij})$ матрицыг байгуулна.

2. Ковариацын матрицын квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{corr}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right]$$

   гэж тооцно.

3. Түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг үнэлэх.

   $$\widehat{\vartheta}_{ii,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   болон

   $$\widehat{\vartheta}_{jj,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{tj} - \overline{Y}_j)^2 - s_{jj} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   гэж тооцно.

   Дараа нь

   $$\widehat{c}_{\text{corr}} = \frac{1}{nN} \left[\sum_{i=1}^{N} \widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2 \right) + \frac{\bar{r}}{2} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left(\sqrt{\frac{s_{jj}}{s_{ii}}} \widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}} \widehat{\vartheta}_{jj,ij} \right) \right]$$

   гэж үнэлнэ.

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{corr}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} (s_{ij} - t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{corr}} > 0$ үед

$$\widehat{\alpha}_{\text{corr}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}} \right\} \right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}.$$

2.4.4 Нэг хүчин зүйлийн зорилтот матриц

Нэг хүчин зүйлийн зорилтот матриц нь хөрөнгүүдийн өгөөжийн хоорондын хамаарлыг зах зээлийн нийтлэг хүчин зүйлээр тайлбарлах нэг хүчин зүйлийн загварт (Single-Index Model) суурилдаг. Уг загварт хөрөнгийн өгөөжийг зах зээлийн нийтлэг хүчин зүйлтэй холбоотой хэсэг болон тухайн хөрөнгийн өөрийн онцлогоос хамаарах үлдэгдэл хэсэгт хуваан авч үздэг [Ledoit and Wolf, 2003].

Энэхүү судалгаанд зах зээлийн нийтлэг хүчин зүйлийг S&P 500 индексийн өгөөжөөр төлөөлүүлнэ.

i-р хөрөнгийн t-р хугацаан дахь өгөөжийг

$$y_{ti} = a_i + \beta_i R_{m,t} + \varepsilon_{ti}$$

гэж загварчилна. Энд $R_{m,t}$ нь t-р хугацаан дахь зах зээлийн өгөөж, a_i нь регрессийн тогтмол коэффициент, β_i нь i-р хөрөнгийн өгөөжийн зах зээлийн өөрчлөлтөд мэдрэг байдлыг илэрхийлэх коэффициент, ε_{ti} нь тухайн хөрөнгийн үлдэгдэл өгөөж юм.

Нэг хүчин зүйлийн загварын регрессийн коэффициентийг

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n} (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2}$$

гэж үнэлнэ. Энд

$$\overline{R}_m = \frac{1}{n} \sum_{t=1}^{n} R_{m,t}$$

нь зах зээлийн өгөөжийн түүврийн дундаж юм.

Регрессийн тогтмол коэффициентийг

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m$$

гэж тооцно.

Тэгвэл i-р хөрөнгийн t-р хугацаан дахь регрессийн үлдэгдэл

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}$$

болно. Үүнийг

$$\widehat{\varepsilon}_{ti} = (y_{ti} - \overline{Y}_i) - \widehat{\beta}_i (R_{m,t} - \overline{R}_m)$$

гэж илэрхийлж болно.

Нэг хүчин зүйлийн загварын үндсэн таамаглалаар үлдэгдэл өгөөжүүд нь зах зээлийн хүчин зүйлтэй хамааралгүй, мөн өөр өөр хөрөнгүүдийн үлдэгдэл өгөөжүүд хоорондоо ха-

мааралгүй байна. Өөрөөр хэлбэл,

$$\mathrm{Cov}(R_m, \varepsilon_i) = 0, \qquad i = 1, 2, \ldots, N,$$

ба

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0, \qquad i \neq j.$$

Эдгээр таамаглалын дор i болон j-р хөрөнгийн өгөөжийн ковариацыг

$$\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cov}(a_i + \beta_i R_m + \varepsilon_i, a_j + \beta_j R_m + \varepsilon_j)$$

гэж илэрхийлнэ.

Ковариацын чанарыг ашиглавал

$$\mathrm{Cov}(Y_i, Y_j) = \beta_i \beta_j \,\mathrm{Var}(R_m), \qquad i \neq j,$$

болно.

Харин i-р хөрөнгийн өгөөжийн вариац

$$\mathrm{Var}(Y_i) = \beta_i^2 \,\mathrm{Var}(R_m) + \mathrm{Var}(\varepsilon_i)$$

болно.

Зах зээлийн өгөөжийн түүврийн вариацыг

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2$$

гэж тооцно.

Мөн i-р хөрөнгийн регрессийн үлдэгдлийн вариацыг

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2$$

гэж тооцно.

Иймээс нэг хүчин зүйлийн зорилтот матриц $T_{\mathrm{SF}} = (t_{ij})$-ын элементүүдийг

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j \end{cases}$$

гэж тодорхойлно [Ledoit and Wolf, 2003].

Нэг хүчин зүйлийн зорилтот матрицыг матриц хэлбэрээр

$$T_{\mathrm{SF}} = \widehat{\boldsymbol{\beta}} \widehat{\boldsymbol{\beta}}^{\top} \widehat{\sigma}_m^2 + \widehat{D}_{\varepsilon}$$

гэж илэрхийлж болно.

Энд

$$\widehat{\boldsymbol{\beta}} = (\widehat{\beta}_1, \widehat{\beta}_2, \ldots, \widehat{\beta}_N)^{\top}$$

нь регрессийн коэффициентүүдийн вектор, харин

$$\widehat{D}_{\varepsilon} = \mathrm{diag}\left(\widehat{\sigma}_{\varepsilon,1}^2, \ldots, \widehat{\sigma}_{\varepsilon,N}^2\right)$$

нь үлдэгдлийн вариацуудаас бүрдэх диагональ матриц юм.

Нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}}) S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}, \qquad 0 \leq \widehat{\alpha}_{\mathrm{SF}} \leq 1,$$

гэж тодорхойлно.

Энд $\widehat{\alpha}_{\mathrm{SF}}$ нь нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Ledoit and Wolf [2003] нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзэл, түүврийн ковариацын матриц болон зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзэл, мөн эдгээр матрицуудын хоорондын зайг харгалзан үзсэн.

Эхлээд түүврийн ковариацын матриц S болон нэг хүчин зүйлийн зорилтот матриц T_{SF} хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\mathrm{SF}} = \|S - T_{\mathrm{SF}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Дараа нь түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг нэгтгэн хэмжих хэмжигдэхүүнийг

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж тооцно.

Нэг хүчин зүйлийн зорилтот матриц нь түүврийн өгөгдлөөс үнэлэгддэг учраас S болон T_{SF} матрицуудын үнэлгээний алдаанууд хоорондоо хамааралтай байж болно.

Иймээс агшилтын эрчмийг тооцоход эдгээр үнэлгээний алдаануудын хам хэлбэлзлийг харгалзах шаардлагатай.

Энэ хам хэлбэлзлийн нөлөөг $\widehat{c}_{\mathrm{SF}}$ хэмжигдэхүүнээр илэрхийлнэ.

Нэг хүчин зүйлийн зорилтот матрицын диагональ элементүүд нь түүврийн ковариацын матрицын диагональ элементүүдтэй тэнцүү буюу $t_{ii} = s_{ii}$ байна.

Ledoit and Wolf [2003]-ийн Lemma 2-т үндэслэн үнэлгээний алдаануудын хам хэлбэлзлийг дараах байдлаар тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

Харин $i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big]\times$$

$$\times\Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\Big].$$

Иймээс хам хэлбэлзлийн нийлбэрийн нормчилсон үнэлгээг

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тодорхойлно. Ингэснээр нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчмийг

$$\widehat{\alpha}_{\mathrm{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\mathrm{SF}} - \widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}$$

гэж үнэлнэ.

Энэ нь Ledoit and Wolf [2003]-ийн асимптотик оновчтой агшилтын эрчмийн үнэлгээг нормчилсон квадрат Фробениусын зайд нийцүүлэн илэрхийлсэн хэлбэр юм.

Энд $\widehat{d}_{\mathrm{SF}} > 0$ байхыг шаардана.

Эцэст нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын мат-

рицыг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}$$

гэж олно.

Тооцоолох алгоритм. Нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Зах зээлийн дундаж өгөөжийг тооцно.

$$\overline{R}_m = \frac{1}{n} \sum_{t=1}^{n} R_{m,t}.$$

2. Зах зээлийн өгөөжийн түүврийн вариацыг тооцно.

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2.$$

3. Хөрөнгө тус бүрийн регрессийн коэффициентийг тооцно.

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n} (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2}.$$

4. Регрессийн тогтмол коэффициент болон үлдэгдлийг тооцно.

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m,$$

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}.$$

5. Хөрөнгө тус бүрийн үлдэгдлийн вариацыг тооцно.

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2.$$

6. Нэг хүчин зүйлийн зорилтот матрицыг байгуулна.

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j. \end{cases}$$

   Эдгээр элементүүдээр $T_{\mathrm{SF}} = (t_{ij})$ матрицыг байгуулна.

7. Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг тооцно.

$$\widehat{d}_{\mathrm{SF}} = \frac{1}{N} \sum_{i=1}^{N} \sum_{j=1}^{N} (s_{ij} - t_{ij})^2.$$

8. Түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг тооцно.

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right].$$

9. Түүврийн ковариацын матриц болон нэг хүчин зүйлийн зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзлийг тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

$i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big] \times$$

$$\times\Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\Big].$$

Дараа нь

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тооцно.

10. Агшилтын эрчмийг тооцно.

$\widehat{d}_{\mathrm{SF}} > 0$ үед

$$\widehat{\alpha}_{\mathrm{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\mathrm{SF}} - \widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}.$$

11. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}}T_{\mathrm{SF}}.$$

2.5 Шугаман бус агшилтын үнэлгээ

Шугаман агшилтын аргын хязгаарлалтыг даван туулах зорилгоор шугаман бус агшилтын (Nonlinear Shrinkage) аргуудыг боловсруулсан. Эдгээр аргууд нь түүврийн ковариацын матрицын спектрийн задлалд суурилдаг бөгөөд урьдчилан тодорхойлсон нэг зорилтот матриц руу бүхэлд нь агшаахын оронд түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засварладаг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U\Lambda U^\top$$

гэж тэмдэглэе. Энд $U = (u_1, u_2, \ldots, u_N)$ нь S матрицын хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь түүврийн ковариацын матрицын хувийн утгуудыг агуулсан диагональ матриц юм.

Шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\widehat{D}U^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \widehat{d}_2, \ldots, \widehat{d}_N)$$

нь агшааж засварласан хувийн утгуудаас бүрдэх диагональ матриц бөгөөд $\widehat{d}_i$ нь λ_i хувийн утгад харгалзах засварласан хувийн утга юм.

Шугаман бус агшилтын арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, харин хувийн утга бүрийг өгөгдөлд тулгуурлан ялгаатай хэмжээгээр засварладаг. Иймээс хувийн утгуудын хэмжээ болон тэдгээрийн спектрийн тархалт дахь байрлалаас хамааран агшилтын хэмжээ өөр өөр байж болно.

Шугаман агшилтын аргын хувьд түүврийн ковариацын матриц болон зорилтот матрицыг нэг агшилтын эрчмээр хослуулдаг бол шугаман бус агшилтын арга нь хувийн утга

бүрд тусгайлан тохируулсан хувиргалт хийдгээрээ ялгаатай. Ингэснээр түүврийн ковариацын матрицын хувийн утгуудын үнэлгээний алдааг бууруулах боломжийг олгодог.

Ledoit болон Wolf (2012) нар шугаман бус агшилтын аргын онолын үндэслэлийг боловсруулж, улмаар Ledoit болон Wolf (2015) нар QuEST (Quantized Eigenvalues Sampling Transform) алгоритмд суурилсан тоон хэрэгжилтийг хөгжүүлсэн. Энэхүү арга нь тоон оновчлол шаарддаг тул тооцооллын хувьд харьцангуй төвөгтэй байдаг.

Үүний дараа Ledoit and Wolf [2020] санамсаргүй матрицын онол болон спектрийн тархалтын шинж чанарт тулгуурласан аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн утгуудыг аналитик илэрхийлэлд суурилан засварладаг. Энэхүү судалгаанд аналитик шугаман бус агшилтын аргыг ашиглах бөгөөд түүний математик үндэслэл болон тооцоолох алгоритмыг дараагийн хэсэгт авч үзнэ.

2.5.1 Аналитик шугаман бус агшилтын үнэлгээ

Аналитик шугаман бус агшилтын үнэлгээ (Analytical Nonlinear Shrinkage Estimation) нь санамсаргүй матрицын онол (Random Matrix Theory)-д тулгуурлан түүврийн ковариацын матрицын хувийн утгуудыг засварлах арга юм. Шугаман агшилтын аргуудаас ялгаатай нь энэхүү арга нь хувийн утга бүрийн хэмжээ болон спектрийн тархалт дахь байрлалыг харгалзан ялгаатай агшилт хийдэг.

Ledoit and Wolf [2020] нь спектрийн тархалтын нягт болон түүний Hilbert хувиргалтыг kernel аргаар үнэлэх замаар аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, хувийн утгуудыг засварлах замаар ковариацын матрицын үнэлгээний алдааг бууруулахад чиглэдэг.

Судалгаанд хамрагдсан хөрөнгийн тоог N, ажиглалтын тоог n гэж тэмдэглэж, тэдгээрийн харьцааг

$$c = \frac{N}{n}$$

гэж тодорхойлно. Аргын үндсэн онолын хувьд $N, n \to \infty$ үед

$$\frac{N}{n} \longrightarrow c \in (0, 1)$$

байх асимптотик нөхцөлийг авч үздэг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U \Lambda U^\top$$

гэж тэмдэглэе. Энд

$$U = (u_1, u_2, \ldots, u_N), \qquad U^\top U = I_N,$$

нь хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь хувийн утгуудыг агуулсан диагональ матриц юм. Хувийн утгуудыг

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_N > 0$$

гэж эрэмбэлнэ.

Аналитик шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U \widehat{D} U^\top = \sum_{i=1}^{N} \widehat{d}_i u_i u_i^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \ldots, \widehat{d}_N)$$

нь агшсан хувийн утгуудаас бүрдэх диагональ матриц юм.

Агшсан хувийн утгуудын үнэлгээ. Ledoit and Wolf [2020]-ийн (4.3) томьёоны дагуу агшсан хувийн утгуудыг

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}$$

гэж тооцно.

Энд $\widehat{f}(\lambda_i)$ нь спектрийн тархалтын нягтын үнэлгээ, $\widehat{Hf}(\lambda_i)$ нь уг нягтын Hilbert хувиргалтын үнэлгээ юм. Эдгээрийг түүврийн ковариацын матрицын хувийн утгуудад тулгуурлан kernel аргаар тооцдог.

Иймээс агшсан хувийн утга нь зөвхөн тухайн λ_i-ийн хэмжээнээс бус, спектрийн тархалтын нягт болон түүний Hilbert хувиргалтын утгаас хамаарна.

Тооцоолох алгоритм. Ledoit and Wolf [2020]-ийн Section 4.7-д үндэслэн аналитик шугаман бус агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Түүврийн ковариацын матрицын спектрийн задлалыг байгуулна.

$$S = U\Lambda U^\top.$$

2. Хөрөнгийн тоо болон ажиглалтын тооны харьцааг тооцно.

$$c = \frac{N}{n}.$$

3. Спектрийн нягтыг үнэлэхэд ашиглах bandwidth параметрийг

$$h = n^{-1/3}$$

гэж сонгоно. Хувийн утга бүрд харгалзах локал bandwidth нь

$$h_j = \lambda_j h, \qquad j = 1, \ldots, N$$

байна.

4. Спектрийн нягтыг Epanechnikov kernel ашиглан үнэлнэ.

$$\widehat{f}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} k\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд

$$k(x) = \begin{cases} \dfrac{3}{4\sqrt{5}}\left(1 - \dfrac{x^2}{5}\right), & |x| \le \sqrt{5}, \\ 0, & |x| > \sqrt{5}. \end{cases}$$

5. Спектрийн нягтын Hilbert хувиргалтыг үнэлнэ.

$$\widehat{Hf}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} \ell\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд $\ell(x) = Hk(x)$ бөгөөд

$$\ell(x) = \begin{cases} -\dfrac{3x}{10\pi} + \dfrac{3}{4\sqrt{5}\pi}\left(1 - \dfrac{x^2}{5}\right)\ln\left|\dfrac{\sqrt{5} - x}{\sqrt{5} + x}\right|, & |x| \ne \sqrt{5}, \\ -\dfrac{3x}{10\pi}, & |x| = \sqrt{5}. \end{cases}$$

6. Агшсан хувийн утгуудыг тооцно.

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}.$$

7. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\text{NLS}} = U \operatorname{diag}(\widehat{d}_1, \ldots, \widehat{d}_N) U^\top.$$

2.6 Эмпирик үнэлгээний арга зүй

Энэхүү судалгаанд түүврийн ковариацын матриц болон агшилтын таван үнэлэгчийг ижил long-only GMVP загварын хүрээнд түүврээс гадуурх (out-of-sample, OOS) гүйцэтгэлээр харьцуулна. Ковариацын матрицын үнэлгээний алдаа бага байх нь багцын бодит эрсдэл заавал бага байна гэсэн үг биш тул үнэлэгчдийн гүйцэтгэлийг багцын түвшинд үнэлэх шаардлагатай.

Энэ зорилгоор [Ledoit and Wolf, 2003, DeMiguel et al., 2009] судалгаанд хэрэглэсэн эмпирик үнэлгээний зарчимд тулгуурлан шилжих цонхны аргыг ашиглана. Бүх үнэлэгчийн хувьд хөрөнгө оруулалтын хязгаарлалт, түүврээс гадуурх үнэлгээний хугацаа болон гүйцэтгэлийн шалгуурыг ижил байлгана.

2.6.1 Шилжих цонхны аргаар түүврээс гадуурх үнэлгээ хийх

Шилжих цонхны (rolling-window) арга нь тогтмол урттай түүхэн өгөгдлөөр ковариацын матрицыг үнэлж, багцын жинг тодорхойлсны дараа уг жинг дараагийн сарын өгөөжид хэрэглэнэ.

Нийт сарын өгөөжийн ажиглалтын тоог n, хөрөнгийн тоог N, сургалтын цонхны уртыг T гэж тэмдэглэе. t сарын өгөөжийн вектор нь

$$\boldsymbol{R}_t = (R_{1,t}, R_{2,t}, \ldots, R_{N,t})^\top.$$

t сарын эцэст ашиглах сургалтын өгөгдлийг

$$\mathcal{D}_t = \{\boldsymbol{R}_{t-T+1}, \ldots, \boldsymbol{R}_t\}, \qquad t = T, \ldots, n-1$$

гэж тодорхойлно.

Ковариацын матрицын үнэлэгчийг $k = 0, 1, \ldots, 5$ гэж тэмдэглэе. Энд $k = 0$ нь түүврийн ковариацын матриц, $k = 1, \ldots, 5$ нь агшилтын үнэлэгчид юм. Сургалтын цонх бүрд ковариацын матрицыг

$$\widehat{\boldsymbol{\Sigma}}_t^{(k)} = \widehat{\boldsymbol{\Sigma}}^{(k)}(\mathcal{D}_t)$$

гэж үнэлнэ. Нэг хүчин зүйлийн үнэлэгчийн хувьд сургалтын цонхтой ижил хугацааны зах зээлийн индексийн өгөөжийг нэмж ашиглана.

Үнэлсэн ковариацын матрицад үндэслэн багцын оновчтой жинг

$$\begin{aligned} \widehat{\boldsymbol{w}}_t^{(k)} \in \arg\min_{\boldsymbol{w}} \quad & \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}}_t^{(k)} \boldsymbol{w}, \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{w} = 1, \\ & w_i \geq 0, \qquad i = 1, \ldots, N \end{aligned}$$

гэсэн long-only GMVP бодлогоор тодорхойлно.

Тэгвэл дараагийн сарын багцын өгөөж нь

$$r_{p,t+1}^{(k)} = \left(\widehat{\boldsymbol{w}}_t^{(k)}\right)^\top \boldsymbol{R}_{t+1}$$

байна.

Сургалтын цонхыг сар бүр нэг алхмаар урагшлуулж, ковариацын матриц, агшилтын эрчим болон багцын жинг дахин тооцно. Ирээдүйн өгөөжийг параметрийн үнэлгээнд ашиглахгүй.

Үндсэн шинжилгээнд $N = 10$, $n = 172$, $T = 120$ тул түүврээс гадуурх ажиглалтын тоо

$$M = n - T = 172 - 120 = 52$$

байна. Ийнхүү үнэлэгч бүрийн хувьд ижил 52 сарын OOS өгөөжийн цуваа үүсгэнэ.

2.6.2 Багцын гүйцэтгэлийн үзүүлэлтүүд

Ковариацын үнэлэгчдийн гүйцэтгэлийг OOS хэлбэлзэл, харьцангуй дисперсийн бууралт (RVR) болон Sharpe-ийн харьцаагаар үнэлнэ.

Түүврээс гадуурх хэлбэлзэл (Out-of-Sample Volatility). k-р үнэлэгчээр байгуулсан багцын дундаж сарын өгөөж болон түүврийн вариацыг

$$\overline{r}_p^{(k)} = \frac{1}{M} \sum_{t=T+1}^{n} r_{p,t}^{(k)},$$

$$\widehat{\sigma}_{p,k}^2 = \frac{1}{M-1} \sum_{t=T+1}^{n} \left(r_{p,t}^{(k)} - \overline{r}_p^{(k)} \right)^2$$

гэж тодорхойлно.

Тэгвэл сарын болон жилийн хэлбэлзэл нь

$$\widehat{\sigma}_{p,k} = \sqrt{\widehat{\sigma}_{p,k}^2}, \qquad \widehat{\sigma}_{p,k}^{ann} = \sqrt{12}\, \widehat{\sigma}_{p,k}$$

байна. Жилийн хэлбэлзэлд шилжүүлэхдээ сарын өгөөжүүдийн автоковариацыг тэг гэж үзнэ.

Харьцангуй дисперсийн бууралт (Relative Variance Reduction). Агшилтын үнэлэгчийн OOS вариацыг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулж,

$$RVR_k^{(\%)} = 100 \left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,0}^2} \right), \qquad k = 1, \ldots, 5$$

гэж тооцно.

$RVR_k^{(\%)} > 0$ бол агшилтын үнэлэгчийн багц суурь загвараас бага вариацтай, харин $RVR_k^{(\%)} < 0$ бол их вариацтай байна.

Sharpe-ийн харьцаа (Sharpe Ratio). Сарын эрсдэлгүй өгөөжийг $r_{f,t}$ гэвэл илүүдэл өгөөж нь

$$r_{e,t}^{(k)} = r_{p,t}^{(k)} - r_{f,t}$$

байна. Сарын Sharpe-ийн харьцааг

$$\widehat{SR}_k = \frac{\overline{r}_e^{(k)}}{\widehat{\sigma}_{e,k}}$$

гэж тодорхойлно.

Энэхүү судалгаанд $r_{f,t} = 0$ гэж авч үзсэн тул

$$\widehat{SR}_k = \frac{\overline{r}_p^{(k)}}{\widehat{\sigma}_{p,k}}, \qquad \widehat{SR}_k^{ann} = \sqrt{12}\, \widehat{SR}_k.$$

Жилийн Sharpe-ийн харьцаанд шилжүүлэхдээ мөн сарын өгөөжийн автоковариацыг тэг гэж үзнэ. GMVP-ийн зорилго нь вариацыг хамгийн бага байлгах тул Sharpe-ийн харьцааг нэмэлт гүйцэтгэлийн үзүүлэлт болгон ашиглана.

2.6.3 Багцын жингийн тогтвортой байдал ба эргэлт

Ковариацын үнэлэгчийн сонголт нь багцын жингийн бүтэц болон дахин тэнцвэржүүлэлтийн хэмжээнд нөлөөлж болох тул багцын эргэлт, жингийн төвлөрлийг үнэлнэ.

Багцын эргэлт (Portfolio Turnover). t сард ашиглах багцын жинг $\widehat{\boldsymbol{w}}_{t-1}^{(k)}$ гэж тэмдэглэе. Тухайн сарын өгөөж хэрэгжсэний дараах, дахин тэнцвэржүүлэхээс өмнөх жин нь

$$\widetilde{w}_{i,t}^{(k)} = \frac{\widehat{w}_{i,t-1}^{(k)}(1+R_{i,t})}{1+r_{p,t}^{(k)}}$$

байна.

Дараагийн сард ашиглах шинэ оновчтой жинд шилжихэд шаардагдах багцын эргэлтийг

$$TO_t^{(k)} = \frac{1}{2}\sum_{i=1}^{N}\left|\widehat{w}_{i,t}^{(k)} - \widetilde{w}_{i,t}^{(k)}\right|$$

гэж тодорхойлно.

Түүврээс гадуурх дундаж эргэлт нь

$$\overline{TO}^{(k)} = \frac{1}{M-1}\sum_{t=T+1}^{n-1} TO_t^{(k)}$$

байна.

Ийнхүү 52 сарын OOS хугацаанд 51 удаагийн дахин тэнцвэржүүлэлтийг тооцно. Эхний багц бүрдүүлэлтийг эргэлтийн тооцоонд оруулахгүй. Энд тооцсон үндсэн OOS өгөөж нь арилжааны зардлын өмнөх өгөөж юм. Арилжааны зардлын нөлөөг нэмэлт шинжилгээнд тусад нь үнэлнэ.

Багцын жингийн төвлөрөл (Weight Concentration). Жингийн төвлөрлийг Herfindahl–Hirschman Index (HHI)-ээр

$$HHI_t^{(k)} = \sum_{i=1}^{N}\left(\widehat{w}_{i,t}^{(k)}\right)^2$$

гэж хэмжинэ.

Long-only GMVP-ийн хувьд

$$\frac{1}{N} \le HHI_t^{(k)} \le 1.$$

Түүврээс гадуурх дундаж төвлөрөл нь

$$\overline{HHI}^{(k)} = \frac{1}{M}\sum_{t=T}^{n-1} HHI_t^{(k)}$$

байна. HHI өндөр байх нь багцын жин цөөн хөрөнгөд төвлөрснийг илэрхийлнэ.

2.6.4 Ковариацын үнэлэгчдийн статистик харьцуулалт

Агшилтын үнэлэгчдийн OOS гүйцэтгэлийн ялгааг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулан статистикаар үнэлнэ.

k-р агшилтын үнэлэгч болон суурь загварын сарын квадрат өгөөжийн ялгааг

$$d_t^{(k)} = \left(r_{p,t}^{(k)}\right)^2 - \left(r_{p,t}^{(0)}\right)^2, \qquad t = T+1, \ldots, n$$

гэж тодорхойлно.

Дараах хоёр талт таамаглалыг шалгана:

$$H_0 : E[d_t^{(k)}] = 0, \qquad H_1 : E[d_t^{(k)}] \neq 0.$$

Дундаж ялгааны стандарт алдааг Newey–West төрлийн HAC аргаар, гурван лаг ашиглан үнэлнэ. Шалгах статистик нь

$$t_{HAC}^{(k)} = \frac{\overline{d}^{(k)}}{\widehat{SE}_{HAC}(\overline{d}^{(k)})}, \qquad \overline{d}^{(k)} = \frac{1}{M}\sum_{t=T+1}^{n} d_t^{(k)}$$

байна.

Хоёр талт p-утгыг асимптотик нормаль ойролцооллоор тооцож, таван агшилтын үнэлэгчийг суурь загвартай харьцуулсан олон шалгалтад Holm-ийн засвар хэрэглэнэ.

Квадрат өгөөжийн дундаж ялгаа нь дисперсийн ялгаатай заавал тэнцүү биш. Учир нь

$$E[r_p^2] = \mathrm{Var}(r_p) + \left(E[r_p]\right)^2.$$

Иймээс HAC шалгалтыг RVR болон OOS хэлбэлзлийн үр дүнтэй хамтатган тайлбарлана. Мөн OOS хугацаа 52 сар тул статистик шалгалтын чадал хязгаарлагдмал байж болно.

2.6.5 Хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцааны мэдрэмжийн шинжилгээ

Ковариацын матрицын үнэлгээний алдаа нь хөрөнгийн тоо N болон сургалтын ажиглалтын тоо T-ийн харьцаанаас хамаарч болно. Уг харьцааг

$$c = \frac{N}{T}$$

гэж тодорхойлно.

Энэхүү судалгаанд $N = 10$ гэж тогтмол байлгаж,

$$T \in \{60, 90, 120\}$$

гэсэн сургалтын цонхуудыг авч үзнэ. Харгалзах N/T харьцаа нь

$$\frac{10}{60} \approx 0.1667, \qquad \frac{10}{90} \approx 0.1111, \qquad \frac{10}{120} \approx 0.0833$$

байна.

Сургалтын цонхны уртаас үүдэх OOS хугацааны ялгааг арилгахын тулд бүх хувилбарт хамгийн урт сургалтын цонхонд харгалзах ижил 52 сарын OOS хугацааг ашиглана.

Цонхны урт бүрд зургаан үнэлэгчийг дахин тооцож, багцын хэлбэлзэл, RVR, Sharpe-ийн харьцаа, эргэлт болон төвлөрлийг харьцуулна.

Энэ шинжилгээнд N тогтмол тул N/T харьцааны өөрчлөлт нь сургалтын цонхны уртын өөрчлөлттэй давхцана. Иймээс тэдгээрийн нөлөөг бүрэн тусгаарлан тайлбарлахгүй.

2.6.6 Багцын сонголтын robustness шинжилгээ

Агшилтын үнэлэгчдийн гүйцэтгэл сонгосон хөрөнгүүдийн бүрэлдэхүүнээс хамаарах эсэхийг үнэлэхийн тулд корреляцийн ялгаатай бүтэцтэй 150 багцад шинжилгээг давтан гүйцэтгэнэ.

Сарын өгөөжийн бүрэн өгөгдөлтэй 337 хувьцаанаас тус бүр 10 хөрөнгөтэй багцуудыг сонгоно. Энэхүү 337 хувьцааны олонлог нь 2012–2026 оны хугацаанд бүрэн өгөгдөлтэй байх шалгууруар бүрдсэн тул үр дүнг уг сонгогдсон олонлогийн хүрээнд тайлбарлана. Өгөгдлийн

бүрэн байдлын шалгуураас үүдэх сонголтын хазайлтыг энэ шинжилгээ бүрэн арилгахгүй. Корреляцыг эхний 120 сарын сургалтын өгөөжөөр тооцож, багцын дундаж хос корреляцыг

$$\overline{\rho} = \frac{2}{N(N-1)} \sum_{i<j} \rho_{ij}$$

гэж тодорхойлно.

Багцуудыг өндөр (High), дунд (Medium), бага (Low) корреляцтай гурван ангиллаар авч үзнэ. Үндсэн шинжилгээнд сонгосон High, Medium, Low багцуудын эхний 120 сарын өгөөжөөр тооцсон дундаж хос корреляц нь харгалзан 0.557048, 0.303609, 0.101523 байна. Robustness шинжилгээнд эдгээр утгыг зорилтот корреляц болгон ашиглана.

Багц сонгохдоо 337 хувьцаанаас 10 хувьцааг буцаалтгүйгээр санамсаргүй сонгох туршилтыг 250000 удаа гүйцэтгэж, давхардсан нэр дэвшигч багцуудыг хасна.

Үлдсэн багцуудыг зорилтот корреляцаас хазайх абсолют зөрүүгээр эрэмбэлж, ангилал бүрд 50 багц сонгоно. Нэг ангиллын сонгогдсон дурын хоёр багцын нийтлэг хувьцааны тоо зургаагаас хэтрэхгүй байх хязгаарлалт тавина.

Ийнхүү сонгосон 150 багц бүрд зургаан үнэлэгчээр long-only GMVP байгуулж, 120 сарын шилжих цонх болон ижил 52 сарын OOS хугацаагаар үнэлнэ. Багц сонгох үе шатанд OOS өгөөжийг ашиглахгүй.

Багц тус бүрийн RVR-ийг тооцож, ангилал бүрийн дундаж, медиан болон эрэг RVR-тэй багцын эзлэх хувийг харьцуулна.

Эдгээр 150 багц нь бүх боломжит 10 хувьцаатай багцуудаас энгийн санамсаргүй түүврийн аргаар сонгогдоогүй, харин зорилтот корреляцийн түвшинд ойр байх нөхцөлөөр сонгогдсон болохыг үр дүнг тайлбарлахдаа харгалзан үзнэ.

2.6.7 RVR-ийн bootstrap итгэх завсар

150 багцын robustness шинжилгээнд ажиглагдсан дундаж RVR-ийн тодорхой бус байдлыг үнэлэхийн тулд circular moving-block bootstrap аргыг ашиглана.

Корреляцын ангиллыг $g \in \{H, M, L\}$, тухайн ангиллын багцын тоог $P_g = 50$ гэж тэмдэглэе. j-р багцын k-р үнэлэгчийн RVR-ийг $RVR^{(\%)}_{g,j,k}$ гэвэл ангиллын дундаж RVR нь

$$\overline{RVR}^{(\%)}_{g,k} = \frac{1}{P_g} \sum_{j=1}^{P_g} RVR^{(\%)}_{g,j,k}$$

байна.

Bootstrap давталт бүрд 52 сарын OOS хугацаанаас зургаан сарын урттай блокуудын эхлэх байрлалыг санамсаргүй сонгоно. Блокийг цувааны төгсгөлд хүрвэл эхлэлээс үргэлжлүүлэх circular зарчмаар байгуулж, сонгосон блокуудыг нэгтгэн 52 ажиглалттай түүвэр үүсгэнэ.

Тухайн давталтад сонгосон сарын индексүүдийг бүх 150 багц болон зургаан үнэлэгчид ижил хэрэглэнэ. Ингэснээр багцуудын өгөөжийн хоорондын хамаарлыг дахин түүвэрлэх явцад хадгална.

Bootstrap түүвэр бүрд багц тус бүрийн OOS вариац, RVR болон ангиллын дундаж RVR-ийг шинээр тооцно.

Нийт $B = 3000$ давталт гүйцэтгэж, давталтуудаас гарсан дундаж RVR-ийн тархалтын 2.5 болон 97.5 хувийн квантилуудаар 95%-ийн percentile bootstrap итгэх завсрыг байгуулна.

Итгэх завсар тэгийг агуулаагүй тохиолдолд тухайн ангиллын дундаж RVR тэгээс ялгаатай байж болохыг илтгэх боловч энэ нь олон харьцуулалтын засвартай шалгалттай адил биш. Эдгээр нь олон харьцуулалтын засвар хийгдээгүй итгэх завсрууд тул үр дүнг болгоомжтой тайлбарлана.

Харин итгэх завсар тэгийг агуулсан тохиолдолд эрэг эсвэл сөрөг нөлөөг статистикийн хувьд баталгаатай гэж дүгнэхгүй.

Энэхүү bootstrap шинжилгээнд сонгосон 150 багцын бүрэлдэхүүнийг тогтмол байлгаж, зөвхөн OOS хугацааны ажиглалтуудыг дахин түүвэрлэнэ.

Иймээс итгэх завсар нь тухайн сонгосон багцуудын OOS гүйцэтгэлийн тодорхой бус байдлыг илэрхийлэх бөгөөд бүх боломжит хувьцааны багцад шууд ерөнхийлөх үндэслэл болохгүй.

2.6.8 Тэнцүү жинтэй багц ба арилжааны зардлын шинжилгээ

GMVP загваруудын практик гүйцэтгэлийг харьцуулах нэмэлт жишиг болгон хөрөнгө бүрд ижил жин оноодог $1/N$ багцыг ашиглана. Тухайн багцын зорилтот жин нь

$$\boldsymbol{w}^{EW} = \frac{1}{N}\mathbf{1}, \qquad N = 10,$$

бөгөөд сарын эхэнд дахин тэнцвэржүүлж, зорилтот жинг хадгална. Иймээс t сарын жишиг багцын зардлын өмнөх өгөөж нь

$$r_{p,t}^{EW} = \left(\boldsymbol{w}^{EW}\right)^{\top} \boldsymbol{R}_t = \frac{1}{N}\sum_{i=1}^{N} R_{i,t}.$$

$1/N$ багц болон зургаан GMVP загварт OOS хугацаа, жилийн хэлбэлзэл, Sharpe-ийн харьцаа, багцын эргэлт, HHI үзүүлэлтийг ижил аргачлалаар тооцно. Тэнцүү жинтэй багцын төвлөрөл нь бүх сард $HHI^{EW} = 1/N$ байна.

Арилжааны зардлыг тооцохдоо нэг талын арилжааны зардлын хувь хэмжээг c гэж тэмдэглэж, $c \in \{0, 5, 10, 25\}$ суурь пункт (basis points) гэсэн хувилбаруудыг авч үзнэ. Энд нэг суурь пункт нь 0.0001-тэй тэнцэнэ.

Өмнөх сарын өгөөж хэрэгжсэний дараах жин $\widetilde{\boldsymbol{w}}_t^{(k)}$ болон шинэ зорилтот жингийн ялгаагаар тооцсон $TO_t^{(k)}$ нь нийт худалдан авалт эсвэл нийт борлуулалтын эзлэх хувийг илэрхийлнэ. Тиймээс нэг талын зардлын хувь c үед хоёр талын нийт арилжааны зардлын хувь нь

$$C_t^{(k)} = 2cTO_t^{(k)}$$

байна. Тухайн сарын эхэнд зардлыг суутгасан гэж үзвэл цэвэр өгөөж нь

$$r_{p,t}^{(k),net} = \left(1 - C_t^{(k)}\right)\left(1 + r_{p,t}^{(k)}\right) - 1,$$

энд $k \in \{0, 1, \ldots, 5, EW\}$.

OOS эхний сарын багцыг анх бүрдүүлэх арилжааны зардлыг тооцохгүй, өөрөөр хэлбэл $C_{T+1}^{(k)} = 0$ гэж авна. Үлдсэн 51 сарын дахин тэнцвэржүүлэлтийн зардлыг тооцно. Арилжааны зардлын хувилбар бүрд цэвэр өгөөжийн цуваагаар жилийн хэлбэлзэл, Sharpe-ийн харьцаа, хуримтлагдсан өгөөжийг дахин үнэлнэ. Хуримтлагдсан цэвэр өгөөжийг

$$CR_k^{net} = \prod_{t=T+1}^{n}\left(1 + r_{p,t}^{(k),net}\right) - 1$$

гэж тодорхойлно.

2.6.9 GMVP ба тэнцүү жинтэй багцын bootstrap харьцуулалт

Үндсэн High, Medium, Low багц тус бүрд зургаан GMVP загварын OOS вариацыг $1/N$ багцын вариацтай харьцуулна. k-р GMVP загварын $1/N$ багцтай харьцуулсан дисперсийн бууралтыг

$$RVR_{k|EW}^{(\%)} = 100\left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,EW}^2}\right), \qquad k = 0, \ldots, 5$$

гэж тодорхойлно. Энэ үзүүлэлтийн суурь нь өмнөх хэсгийн Sample GMVP биш, харин $1/N$ багц юм.

Тодорхой бус байдлыг үнэлэхдээ 52 сарын OOS өгөөжид зургаан сарын блокийн урттай circular moving-block bootstrap аргыг хэрэглэнэ. Нэг багцын долоон стратегийн (зургаан

GMVP болон $1/N$) өгөөжийг нэг ижил сарын индексээр дахин түүвэрлэж, стратегиудын хоорондын хос хамаарлыг хадгална.

Нийт $B = 3000$ давталт бүрд түүврийн вариац ($M - 1$ хуваарьтай) болон $RVR^{(\%)}_{k|EW}$-ийг шинээр тооцно. Bootstrap тархалтын 2.5 ба 97.5 хувийн квантилуудаар засвар хийгдээгүй 95%-ийн percentile итгэх завсар байгуулна.

Мөн тэг таамаглал $H_0 : RVR^{(\%)}_{k|EW} = 0$-ийг хоёр талт, ажиглагдсан статистикийн эргэн тойронд төвлөрүүлсэн bootstrap ойролцооллоор үнэлнэ. Ажиглагдсан RVR-ийг $\widehat{\theta}$, bootstrap давталтын RVR-ийг $\widehat{\theta}^{*(b)}$ гэвэл тооцоолсон p-утга нь

$$\widehat{p}_{boot} = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{\left|\widehat{\theta}^{*(b)} - \widehat{\theta}\right| \geq \left|\widehat{\theta}\right|\right\}}{B + 1}.$$

Нэг үндсэн багц дахь зургаан GMVP–$1/N$ харьцуулалтын p-утгуудад Holm-ийн засвар хэрэглэнэ. Гурван багцын нийт 18 шалгалтыг нэг бүл болгон засварлахгүй. Percentile итгэх завсар болон төвлөрүүлсэн bootstrap p-утга нь нэг шалгалтын харилцан урвуу хувилбар биш тул тэдгээрийн дүгнэлт зарим тохиолдолд зөрж болно.

Энэ шинжилгээ нь зөвхөн үндсэн гурван багцын зардлын өмнөх OOS өгөөжид тулгуурлана. Иймээс арилжааны зардлын дараах гүйцэтгэлийн статистик шалгалт гэж тайлбарлахгүй. OOS хугацаа 52 сар болохыг үр дүнгийн тодорхой бус байдлыг тайлбарлахдаа харгалзан үзнэ.

3 Өгөгдөл

Энэхүү судалгаанд ковариацын матрицын агшилтын үнэлэгчдийн гүйцэтгэлийг хөрөнгүүдийн хоорондын корреляцийн ялгаатай бүтэцтэй багцуудад харьцуулах зорилгоор АНУ-ын S&P 500 индексийн түүхэн бүрэлдэхүүнээс сонгосон хувьцааны сарын өгөөжийг ашигласан.

3.1 Өгөгдлийн эх сурвалж ба өгөөжийн тооцоолол

Нэр дэвшигч хувьцаануудыг S&P 500 индексийн түүхэн бүрэлдэхүүний нээлттэй өгөгдлийн сангаас 2012 оны 5 дугаар сарын 30-ны өдрийн байдлаар сонгосон [chinobing]. Тухайн жагсаалтад 453 хувьцааны код байсан бөгөөд 2012 оны 5 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх сарын эцсийн үнийн мэдээлэл бүрэн байгаа 337 хувьцааг шинжилгээнд хамруулсан.

Хувьцааны үнийн өгөгдлийг Yahoo Finance мэдээллийн сангаас Python програмчлалын хэлний `yfinance` сангаар татаж, `auto_adjust=True` тохиргоогоор ногдол ашиг болон хувьцаа хуваалтын нөлөөг харгалзан үзсэн.

Хувьцаа тус бүрийн сарын энгийн өгөөжийг

$$R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

гэж тооцсон. Энд $P_{i,t}$ нь i-р хувьцааны t сарын эцсийн тохируулгатай хаалтын үнэ юм.

Судалгаанд 2012 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх нийт $n = 172$ сарын өгөөжийг ашигласан. Эдгээрээс эхний 120 сарын өгөөжийг багцын бүрэлдэхүүнийг сонгох сургалтын хугацаа, үлдсэн 52 сарын өгөөжийг түүврээс гадуурх гүйцэтгэлийг үнэлэх хугацаа болгон ашигласан.

3.2 Корреляцийн бүтцээр багц сонгох

Ковариацын матрицын агшилтын аргуудын гүйцэтгэл хөрөнгүүдийн хоорондын корреляцийн бүтцээс хамаарах эсэхийг судлах зорилгоор өндөр, дунд, бага дундаж корреляцитай гурван багц байгуулсан.

Багцын бүрэлдэхүүнийг сонгохдоо 2012 оны 6 дугаар сараас 2022 оны 5 дугаар сар хүртэлх эхний 120 сарын өгөөжид үндэслэн 337 хувьцааны хоорондын түүврийн корреляцийн матрицыг тооцсон. Ингэснээр багцын бүрэлдэхүүнийг тодорхойлоход түүврээс гадуурх хугацааны өгөөжийг ашиглаагүй.

Хөрөнгийн тоо $N = 10$ байх багцын дундаж хос корреляцийг

$$\bar{\rho}_P = \frac{2}{N(N-1)} \sum_{i<j,\, i,j \in P} \rho_{ij}$$

гэж тодорхойлсон. Энд P нь тухайн багцын хөрөнгүүдийн олонлог, ρ_{ij} нь сургалтын хугацааны өгөөжөөс тооцсон i, j хөрөнгийн түүврийн корреляци юм.

Үндсэн гурван багцыг Monte Carlo хайлтын аргаар сонгосон. Үүнд 337 хувьцаанаас 10 хувьцаатай багцын 100 000 санамсаргүй хувилбарыг ангилал тус бүрд шалгасан.

Эхлээд дундаж хос корреляц хамгийн өндөр байх багцыг, дараа нь хамгийн бага байх багцыг сонгосон. Эцэст нь дундаж хос корреляци нь 337 хувьцааны бүх хосын дундаж корреляцад хамгийн ойр байх багцыг сонгосон.

Багцуудыг өндөр, бага, дунд гэсэн дарааллаар сонгохдоо өмнөх багцуудад орсон хувьцаануудыг дараагийн сонголтоос хассан. Иймээс үндсэн гурван багц хоорондоо давхцахгүй бөгөөд нийт 30 ялгаатай хувьцаанаас бүрдэнэ.

Энэхүү Monte Carlo хайлтаар боломжит бүх багцыг бүрэн шалгаагүй тул сонгосон гурван багцыг дундаж корреляцийн хувьд глобал оновчтой гэж үзэхгүй. Харин эдгээр нь санамсаргүй хайлтын хүрээнд тодорхойлсон, корреляцийн ялгаатай түвшнийг төлөөлөх багцууд юм.

Хүснэгт 1: Үндсэн шинжилгээнд сонгосон багцуудын шинж чанар

Үзүүлэлт	Өндөр	Дунд	Бага
Хөрөнгийн тоо	10	10	10
Дундаж хос корреляци	0.5570	0.3036	0.1015
Ковариацын матрицын нөхцөлт тоо	72.99	16.82	27.45

Хүснэгт 1-д үзүүлсэн дундаж хос корреляцийг багц тус бүрийн эхний 120 сарын өгөөжид үндэслэн тооцсон.

Ковариацын матрицын нөхцөлт тоог мөн тухайн 120 сарын өгөөжөөс тооцсон түүврийн ковариацын матрицаар тодорхойлсон. Эерэг тодорхой ковариацын матрицын хувьд нөхцөлт тоо нь хамгийн их болон хамгийн бага хувийн утгын харьцаатай тэнцүү бөгөөд

$$\kappa(S) = \frac{\lambda_{\max}(S)}{\lambda_{\min}(S)}$$

гэж илэрхийлэгдэнэ.

Нөхцөлт тоо их байх тусам матрицын нөхцөлжилт муу байгааг илэрхийлнэ. Хүснэгтээс өндөр корреляцитай багцын ковариацын матрицын нөхцөлт тоо хамгийн их байгааг харж болно. Гэхдээ нөхцөлт тоо нь зөвхөн дундаж корреляциар тодорхойлогдохгүй, хөрөнгүүдийн дисперс болон ковариацын бүтцээс мөн хамаарна.

Өндөр корреляцитай багцад CCL, CME, COF, CTAS, FLS, MET, PRU, SWK, UNM, WFC; дунд корреляцитай багцад AMGN, AMT, BEN, DTE, EXPD, MO, MRK, PG, SNA, UPS; бага корреляцитай багцад BAX, BIIB, CTSH, GNW, HRB, MTB, NEM, QCOM, RRC, WEC хувьцаанууд сонгогдсон.

3.3 Нэмэлт багцууд ба түүврээс гадуурх үнэлгээ

Үндсэн шинжилгээний үр дүн тодорхой 30 хувьцааны сонголтоос хамаарах эсэхийг шалгах зорилгоор нэмэлт 150 багц сонгосон. Үүнд өндөр, дунд, бага корреляцын ангилал тус бүрээс 50 багц хамруулсан.

Нэмэлт багцуудыг мөн эхний 120 сарын өгөөжид үндэслэн Monte Carlo хайлтын аргаар сонгож, нэг ангиллын хоёр багцад хамгийн ихдээ зургаан ижил хувьцаа байх нөхцөл тавьсан.

Үндсэн шинжилгээнд ковариацын матрицыг $T = 120$ сарын шилжих цонхоор үнэлж, 2022 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх $M = 52$ сарын түүврээс гадуурх (OOS) гүйцэтгэлийг харьцуулсан.

Сонгосон багц бүрийн хувьцааны бүрэлдэхүүнийг OOS хугацаанд тогтмол хадгалж, багцын оновчтой жинг сар бүр шинэчилсэн.

3.4 Өгөгдлийн сонголтын хязгаарлалт

Судалгааны нэг хязгаарлалт нь шинжилгээний бүх хугацаанд үнийн мэдээлэл бүрэн байгаа хувьцаануудыг сонгосон явдал юм.

Хэдийгээр нэр дэвшигч хувьцаануудыг 2012 оны түүхэн бүрэлдэхүүнээс тодорхойлж, багцын корреляцын бүтцийг зөвхөн 2022 оны 5 дугаар сар хүртэлх өгөөжид үндэслэн сонгосон боловч шинжилгээнд хамрагдах 337 хувьцааг тодорхойлохдоо 2026 оны 9 дүгээр сар хүртэлх үнийн өгөгдлийн бүрэн байдлыг шаардсан.

Иймээс өгөгдлийн олдоцтой холбоотой сонголтын хазайлт, тэр дундаа survivorship bias болон ирээдүйн мэдээлэлд тулгуурласан сонголтын хазайлт үүсэх боломжийг бүрэн үгүйсгэхгүй.

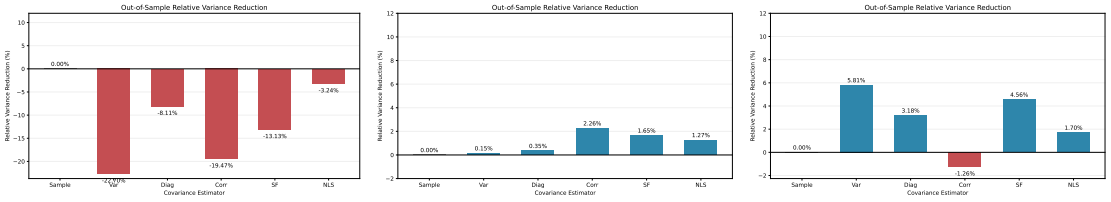
Энэ хязгаарлалтыг үр дүнг тайлбарлах, ялангуяа судалгааны дүгнэлтийг илүү өргөн хүрээний хөрөнгийн зах зээлд ерөнхийлөн хэрэглэх үед харгалзан үзнэ.

4 Эмпирик судалгааны үр дүн

Хүснэгт 2: Summary of the three selected portfolios

Portfolio	Mean_Pairwise_Correlation	Covariance_Condition_Number	Smallest_Covariance_Eigenvalue	Tickers
High	0.557048	72.99059	0.000564	CCL, CME, COF, CTAS, FLS, MET, PRU, SWK, UNM, WFC
Medium	0.303609	16.81762	0.000833	AMGN, AMT, BEN, DTE, EXPD, MO, MRK, PG, SNA, UPS
Low	0.101523	27.44796	0.001674	BAX, BIIB, CTSH, GNW, HRB, MTB, NEM, QCOM, RRC, WEC

Нийт 337 хувьцааны эхний 120 сарын өгөөжид үндэслэн, дундаж хос корреляцийн түвшнээр ялгаатай High, Medium, Low гэсэн гурван багцыг сонгосон. Багц тус бүр 10 хувьцаанаас бүрдэх бөгөөд дундаж корреляци нь харгалзан 0.557048, 0.303609, 0.101523 байна. High болон Low багцын дундаж корреляцийн зөрүү 0.455525 байгаа нь сонгосон багцуудын корреляцийн бүтэц мэдэгдэхүйц ялгаатайг харуулж байна. Ковариацын матрицын нөхцөлийн тоо High багцад 72.99052, Medium багцад 16.81759, Low багцад 27.44792 байна. Эдгээр үр дүн нь дундаж корреляцийн түвшин болон ковариацын матрицын нөхцөлжилт заавал ижил чиглэлд өөрчлөгдөхгүйг харуулж байна. Сонгосон гурван багцыг ковариацын матрицын агшилтын аргуудын гүйцэтгэлийг корреляцийн ялгаатай орчинд үнэлэх robustness шинжилгээнд ашиглав.



Ковариацын матрицын агшилтын аргуудын үр дүн багцын бүрэлдэхүүн болон хөрөнгүүдийн хоорондын корреляцийн бүтцээс хэрхэн хамааарч байгааг үнэлэх зорилгоор өндөр, дунд, бага корреляцитай ангилал тус бүрээс 50, нийт 150 багцад шинжилгээг давтан гүйцэтгэв. Хүснэгтэд Sample ковариацын матрицыг суурь болгон авч, агшилтын таван аргын OOS дисперсийн бууралт, өгөөж, хэлбэлзэл, Sharpe харьцаа, багцын жингийн тогтвортой байдал болон төвлөрлийн үзүүлэлтүүдийг нэгтгэн харуулав.

Өндөр корреляцитай багцуудын хувьд бүх агшилтын арга эерэг дундаж RVR үзүүлсэн бөгөөд тогтмол дисперсийн зорилтот матрицтай Var арга хамгийн өндөр дундаж дисперсийн бууралттай (1.128%) байна. Харин Diag арга 50 багцын 82%-д дисперс бууруулж, хамгийн өндөр эерэг RVR-ийн эзлэх хувьтай гарсан. Түүнчлэн Diag аргын HAC шалгуурын үр дүн ($p = 0.0203$) нь Sample аргатай харьцуулсан дундаж дисперсийн ялгаа 5%-ийн түвшинд статистикийн ач холбогдолтой болохыг харуулж байна. Бусад агшилтын аргуудын хувьд статистикийн ач холбогдолтой ялгаа илрээгүй.

Хүснэгт 3: Robustness results across 150 portfolios

Tier	Method	Mean RVR (%)	Median RVR (%)	Positive RVR (%)	Mean Return (monthly)	OOS Variance (monthly)	OOS Volatility (annual)	Sharpe (annual)	Turnover	HHI	HAC p
High	Var	1.128	1.354	72	0.01119	0.003108	0.19220	0.7024	0.02638	0.2855	0.1629
	Diag	0.808	0.789	82	0.01111	0.003121	0.19257	0.6966	0.02624	0.3297	0.0203
	Corr	0.651	0.911	60	0.01098	0.003116	0.19253	0.6883	0.02357	0.3530	0.3840
	SF	0.530	0.453	74	0.01100	0.003130	0.19285	0.6881	0.02580	0.3410	0.2236
	NLS	0.389	0.584	66	0.01105	0.003134	0.19298	0.6907	0.02657	0.3273	0.2003
Medium	Var	-1.305	-0.676	48	0.00648	0.002138	0.15909	0.4890	0.02622	0.2102	0.4168
	Diag	0.568	0.477	68	0.00624	0.002093	0.15755	0.4756	0.02627	0.2523	0.3231
	Corr	0.547	0.593	54	0.00571	0.002093	0.15752	0.4350	0.02339	0.2673	0.3557
	SF	0.670	0.905	64	0.00563	0.002088	0.15739	0.4293	0.02436	0.2627	0.1907
	NLS	0.365	0.328	56	0.00618	0.002097	0.15770	0.4707	0.02677	0.2476	0.3640
Low	Var	-35.018	-29.789	28	0.00831	0.002472	0.17081	0.5749	0.03089	0.1210	0.0149
	Diag	-0.611	0.518	54	0.00622	0.001868	0.14921	0.5040	0.02503	0.1701	0.8698
	Corr	0.158	0.895	64	0.00538	0.001859	0.14878	0.4396	0.02463	0.2118	0.8593
	SF	-1.356	-0.850	42	0.00513	0.001883	0.14981	0.4150	0.02360	0.2179	0.5334
	NLS	0.986	0.950	74	0.00582	0.001843	0.14817	0.4773	0.02791	0.1996	0.1317

Тайлбар: Корреляцийн ангилал бүрд 50 багц хамрагдсан. Дундаж болон медиан RVR, эерэг RVR-тэй багцын эзлэх хувийг хувиар илэрхийлсэн. Өгөөж болон дисперсийг сарын, харин хэлбэлзэл болон Sharpe харьцааг жилийн хэмжээсээр тооцсон. HAC шалгуурын p-утгууд нь хоёр талт бөгөөд олон харьцуулалтын засвар хийгээгүй.

Дунд корреляцитай багцуудын хувьд Single–Factor (SF) арга хамгийн өндөр дундаж RVR (0.670%) үзүүлсэн бол Diag (0.568%) болон Corr (0.547%) аргууд ойролцоо үр дүнтэй байна. Харин Var аргын дундаж RVR сөрөг (−1.305%) бөгөөд багцуудын 48%-д дисперс бууруулжээ. Гэсэн хэдий ч энэ ангилалд бүх аргын HAC шалгуурын p-утга 0.05-аас их байгаа тул Sample аргатай харьцуулсан дундаж дисперсийн ялгаа статистикийн ач холбогдолтой гэж үзэх үндэслэлгүй байна.

Бага корреляцитай багцуудын хувьд аргуудын үр дүн илүү ялгаатай байна. Var арга хамгийн өндөр эрсдэлтэй бөгөөд дундаж RVR −35.018%, медиан RVR −29.789% гарч, багцуудын ердөө 28%-д дисперс бууруулсан. HAC шалгуурын үр дүн ($p = 0.0149$) нь энэ аргын дисперс Sample аргатай харьцуулахад өссөн чиглэлтэй статистикийн ач холбогдолтой ялгааг харуулж байна. Харин NLS арга хамгийн өндөр дундаж RVR (0.986%) үзүүлж, багцуудын 74%-д дисперс бууруулсан боловч HAC шалгуурын үр дүн ($p = 0.1317$) статистикийн ач холбогдолгүй байна.

Багцын бусад үзүүлэлтүүдийг авч үзвэл, агшилтын аргуудын OOS хэлбэлзэл, Sharpe харьцаа болон жингийн бүтцэд тодорхой ялгаа ажиглагдсан. Тухайлбал, бага корреляцитай багцуудын Var арга хамгийн бага дундаж HHI (0.121) буюу хөрөнгө оруулалтын жин харьцангуй тархмал бүтэцтэй боловч хамгийн өндөр жилийн OOS хэлбэлзэлтэй (17.081%) байна. Харин NLS арга энэ ангилалд хамгийн бага жилийн OOS хэлбэлзэлтэй (14.817%) гарсан. Энэ нь багцын жингийн төвлөрөл бага байх нь заавал эрсдэл бага байх нөхцөл биш болохыг харуулж байна.

Ерөнхийд нь дүгнэвэл, 150 багцын robustness шинжилгээний үр дүн ковариацын матрицын агшилтын аргуудын давуу тал бүх багцад ижил хэмжээгээр илэрдэггүйг харуулж байна. Өндөр корреляцитай багцуудад бүх арга эерэг дундаж дисперсийн бууралт үзүүлсэн бол бага корреляцитай багцуудад аргуудын үр дүн илүү ялгаатай, ялангуяа Var аргын гүйцэтгэл мэдэгдэхүйц сул байна. HAC шалгууруар 15 харьцуулалтын зөвхөн хоёрт нь 5%-ийн түвшинд статистикийн ач холбогдол илэрсэн бөгөөд эдгээр p-утгад олон харьцуулалтын засвар хийгээгүй тул үр дүнг болгоомжтой тайлбарлах шаардлагатай. Иймээс бага N/T нөхцөлд ковариацын матрицын агшилт нь Sample аргатай харьцуулахад OOS дисперсийг тогтвортой бууруулдаг гэсэн ерөнхий дүгнэлт хийх боломжгүй бөгөөд түүний үр нөлөө багцын корреляцийн бүтэц болон сонгосон агшилтын аргаас хамаарч байгааг энэхүү шинжилгээ харуулж байна.

All шалгууруар сонгосон багцын хувьд бүх агшилтын арга Sample аргатай харьцуулахад OOS дисперсийг бууруулсан байна. Эдгээрээс Var арга хамгийн өндөр RVR (4.952%) үзүүлж, сарын хэлбэлзлийг 3.850%-аас 3.753% болгон бууруулсан бөгөөд HAC шалгуурын үр дүн ($p = 0.0331$) нь энэхүү ялгаа 5%-ийн түвшинд статистикийн ач холбогдолтойг харуулж байна. Diag арга мөн дисперсийг 3.217%-иар бууруулсан бөгөөд статистикийн ач холбогдолтой ($p = 0.0436$) байна. Харин Corr, SF болон NLS аргуудын RVR эерэг боловч статистикийн ач холбогдолгүй байна. Иймээс All багцад **Var арга дисперсийн бууралт болон HAC шалгуурын үр дүнгээр хамгийн давуу** байна.

Var шалгууруар сонгосон багцын хувьд All шалгууруар сонгосон багцтай ижил 10 хувьцаа сонгогдсон тул OOS гүйцэтгэлийн бүх үзүүлэлт давхцаж байна. Тухайлбал, Var арга хамгийн өндөр RVR (4.952%) үзүүлж, статистикийн ач холбогдолтой ($p = 0.0331$) байна. Иймээс Var шалгууруар сонгосон багцад мөн Var арга хамгийн сайн үр дүн үзүүлсэн боловч энэ нь All багцаас тусдаа, бие даасан үр дүн биш юм.

Diag шалгууруар сонгосон багцын хувьд NLS арга хамгийн өндөр RVR (0.794%) үзүүлсэн боловч HAC шалгууруар статистикийн ач холбогдолгүй ($p = 0.8468$) байна. Diag аргын RVR 0.613% бөгөөд мөн статистикийн ач холбогдолгүй ($p = 0.9673$) байна. Харин Var, Corr болон SF аргуудын RVR сөрөг гарсан нь Sample аргатай харьцуулахад OOS дисперс өссөнийг илэрхийлнэ. Гэвч эдгээр өсөлт ч статистикийн ач холбогдолгүй байна. Иймээс Diag багцад **Sample аргаас статистикийн ач холбогдолтойгоор бага дисперстэй агшилтын арга илрээгүй** бөгөөд тухайн багцад аль нэг агшилтын аргыг давуу гэж сонгох статистикийн үндэслэл тогтоогдсонгүй.

Corr шалгууруар сонгосон багцын хувьд Var арга хамгийн өндөр RVR (8.632%) үзүүлсэн боловч HAC шалгуурын үр дүн ($p = 0.1223$) статистикийн ач холбогдолгүй байна. Харин NLS арга 5.657%-ийн дисперсийн бууралт үзүүлсэн бөгөөд HAC шалгууруар статистикийн ач холбогдолтой ($p = 0.0124$) байна. Үүний эсрэгээр Corr аргын RVR −5.166% гарч, OOS

Хүснэгт 4: Нэмэлтээр сонгосон багцуудын OOS гүйцэтгэлийн харьцуулалт

Selection Target	Estimator	Mean Corr.	RVR (%)	Monthly Return (%)	Monthly Volatility (%)	Sharpe	Turnover	HHI	HAC p-value	Tickers
All	Sample	0.3073	0.000	1.103	3.850	0.993	0.0292	0.2043	–	BA, BMY, COST, DHI, FTI, IBM, NKE, RF, SCHW, VRSN
	Var^*	0.3073	4.952	1.046	3.753	0.965	0.0274	0.1867	0.0331	
	Diag	0.3073	3.217	1.073	3.787	0.981	0.0279	0.1966	0.0436	
	Corr	0.3073	3.600	1.049	3.780	0.962	0.0278	0.2046	0.6070	
	SF	0.3073	4.019	1.111	3.772	1.020	0.0273	0.2033	0.1884	
	NLS	0.3073	4.540	1.041	3.761	0.959	0.0269	0.1939	0.0607	
Var	Sample	0.3073	0.000	1.103	3.850	0.993	0.0292	0.2043	–	BA, BMY, COST, DHI, FTI, IBM, NKE, RF, SCHW, VRSN
	Var^*	0.3073	4.952	1.046	3.753	0.965	0.0274	0.1867	0.0331	
	Diag	0.3073	3.217	1.073	3.787	0.981	0.0279	0.1966	0.0436	
	Corr	0.3073	3.600	1.049	3.780	0.962	0.0278	0.2046	0.6070	
	SF	0.3073	4.019	1.111	3.772	1.020	0.0273	0.2033	0.1884	
	NLS	0.3073	4.540	1.041	3.761	0.959	0.0269	0.1939	0.0607	
Diag	Sample	0.2432	0.000	0.141	3.998	0.122	0.0268	0.2376	–	ADBE, AN, CTAS, ES, GME, MAS, NTAP, SRE, SYY, TAP
	Var	0.2432	-12.701	0.217	4.244	0.177	0.0287	0.1000	0.5644	
	Diag	0.2432	0.613	0.141	3.985	0.122	0.0244	0.1402	0.9673	
	Corr	0.2432	-0.107	0.145	4.000	0.126	0.0274	0.2339	0.9560	
	SF	0.2432	-8.020	0.182	4.155	0.151	0.0211	0.2763	0.3830	
	NLS	0.2432	0.794	0.078	3.982	0.068	0.0273	0.2175	0.8468	
Corr	Sample	0.2335	0.000	0.308	4.368	0.244	0.0382	0.2082	–	BDX, DRI, EFX, GPC, HRB, HRL, HSY, INTC, ORLY, TRIP
	Var	0.2335	8.632	0.329	4.175	0.273	0.0373	0.1681	0.1223	
	Diag	0.2335	4.858	0.245	4.261	0.199	0.0372	0.1879	0.2307	
	Corr	0.2335	-5.166	0.031	4.480	0.024	0.0320	0.1866	0.7313	
	SF	0.2335	4.791	0.011	4.262	0.009	0.0313	0.1954	0.6546	
	NLS^*	0.2335	5.657	0.337	4.243	0.275	0.0381	0.1868	0.0124	
SF	Sample	0.2092	0.000	0.407	4.242	0.332	0.0348	0.2048	–	ADBE, ED, GME, HSY, LMT, MCHP, PFG, PH, WDC, WMT
	Var^*	0.2092	-51.840	1.654	5.227	1.096	0.0350	0.1000	0.0334	
	Diag	0.2092	3.220	0.937	4.173	0.778	0.0286	0.1443	0.7040	
	Corr	0.2092	1.976	0.469	4.200	0.387	0.0321	0.2061	0.0659	
	SF	0.2092	-17.000	0.657	4.588	0.496	0.0246	0.2540	0.3028	
	NLS	0.2092	-0.006	0.411	4.242	0.336	0.0326	0.1981	0.9973	
NLS	Sample	0.2723	0.000	-0.215	4.745	-0.157	0.0433	0.2195	–	BKNG, COF, COST, HRL, HUM, KIM, NKE, ORCL, PHM, UNH
	Var	0.2723	2.490	-0.187	4.686	-0.138	0.0394	0.1832	0.4114	
	Diag	0.2723	3.958	-0.226	4.650	-0.168	0.0395	0.2024	0.1352	
	Corr	0.2723	11.084	-0.329	4.475	-0.255	0.0352	0.2043	0.1833	
	SF	0.2723	2.404	-0.397	4.688	-0.293	0.0377	0.2143	0.4767	
	NLS	0.2723	1.137	-0.280	4.718	-0.206	0.0414	0.1976	0.5294	

Тайлбар: Selection Target нь validation хугацаанд багцыг сонгоход ашигласан зорилтот шалгуур юм. All шалгуур нь таван агшилтын аргын хамгийн бага RVR-ийг хамгийн өндөр болгох, бусад шалгуур нь харгалзах аргын RVR-ийг хамгийн өндөр болгоход чиглэсэн.
All болон Var шалгууруар ижил 10 хувьцааны багц сонгогдсон тул эдгээрийн OOS үр дүн давхцаж байна. Tickers баганад тухайн багцын хувьцааны кодыг нэг удаа харуулав.
Бүх багцад $N = 10$, $T = 120$, $N/T = 0.0833$. Mean Corr. нь сургалтын хугацааны дундаж хос корреляци юм. RVR нь Sample аргатай харьцуулсан OOS дисперсийн бууралтын хувь бөгөөд эерэг утга нь дисперс буурсныг, сөрөг утга нь өссөнийг илэрхийлнэ.
Өгөөж болон хэлбэлзлийг сарын хувиар, Sharpe харьцааг жилийн хэмжээсээр илэрхийлсэн. Turnover нь нэг талын багцын эргэлт, HHI нь багцын төвлөрлийн үзүүлэлт юм.
HAC p-value нь төвлөрүүлсэн квадрат өгөөжийн ялгаанд суурилсан, Newey–West стандарт алдаатай ($L = 3$) хоёр талт шалгуурын утга юм. Sample нь харьцуулах суурь арга тул p-value тооцоогүй.

дисперс Sample аргатай харьцуулахад өссөн боловч ялгаа статистикийн ач холбогдолгүй ($p = 0.7313$) байна. Иймээс Corr багцад **NLS арга статистикийн ач холбогдолтой дисперсийн бууралт үзүүлсэн цорын ганц агшилтын арга** бөгөөд Corr аргын хувьд дисперсийн бууралтын давуу тал ажиглагдсангүй.

SF шалгууураар сонгосон багцын хувьд Diag арга хамгийн өндөр эерэг RVR (3.220%) үзүүлсэн боловч статистикийн ач холбогдолгүй ($p = 0.7040$) байна. Corr арга мөн дисперсийг 1.976%-иар бууруулсан боловч HAC шалгуурын үр дүн ($p = 0.0659$) нь 5%-ийн түвшинд статистикийн ач холбогдолгүй байна. Харин Var арга хамгийн их дисперсийн өсөлттэй (RVR -51.840%) бөгөөд энэ ялгаа статистикийн ач холбогдолтой ($p = 0.0334$) байна. SF аргын RVR -17.000% гарсан боловч статистикийн ач холбогдолгүй ($p = 0.3028$) байна. Иймээс SF багцад **Sample аргаас статистикийн ач холбогдолтойгоор бага дисперстэй агшилтын арга илрээгүй**, харин Var арга статистикийн ач холбогдолтойгоор өндөр дисперстэй байна.

NLS шалгууураар сонгосон багцын хувьд бүх агшилтын арга Sample аргатай харьцуулахад OOS дисперсийг бууруулсан байна. Эдгээрээс Corr арга хамгийн өндөр RVR (11.084%) үзүүлж, сарын хэлбэлзлийг 4.745%-аас 4.475% болгон бууруулсан. Харин NLS аргын RVR 1.137% байна. Гэсэн хэдий ч бүх аргын HAC шалгуурын p-утга 0.05-аас их байгаа тул дисперсийн бууралтууд статистикийн ач холбогдолгүй байна. Иймээс NLS багцад **Corr арга тоон үзүүлэлтээр хамгийн өндөр дисперсийн бууралт үзүүлсэн боловч статистикийн ач холбогдолтой давуу тал тогтоогдсонгүй**.

Нийт үр дүнгээс харахад, All болон Var шалгууураар сонгосон ижил багцад Var арга, Corr шалгууураар сонгосон багцад NLS арга Sample аргатай харьцуулахад статистикийн ач холбогдолтой дисперсийн бууралт үзүүлсэн байна. Харин Diag, SF болон NLS шалгууураар сонгосон багцуудад Sample аргаас статистикийн ач холбогдолтойгоор бага дисперстэй агшилтын арга илрээгүй.

Түүнчлэн SF шалгууураар сонгосон багцад Var аргын RVR -51.840% гарч, Sample аргатай харьцуулахад OOS дисперс өссөн бөгөөд HAC шалгуурын үр дүн ($p = 0.0334$) нь энэхүү өсөлт 5%-ийн түвшинд статистикийн ач холбогдолтойг харуулж байна.

Иймээс нэмэлт шинжилгээнд агшилтын аргуудын OOS дисперсийн бууралт багцын сонголтоос хамааран ялгаатай гарсан бөгөөд бүх багцад тогтвортой давуу тал үзүүлсэн нэг арга тогтоогдсонгүй.

Хүснэгт 5-д OOS дисперсийн ялгаа нь статистикийн ач холбогдолтой гарсан гурван үр дүнгийн багцын жингийн бүтцийг харуулав. All болон Var шалгууураар ижил багц сонгогдсон тул тэдгээрийн Var аргын жинг нэгтгэн үзүүлсэн.

All/Var багцын хувьд Var аргаар тооцсон жин BMY (24.47%), COST (23.82%), VRSN (19.35%), SCHW (13.15%) болон IBM (11.66%) хувьцаанд голчлон төвлөрсөн байна. Харин BA, DHI, FTI болон RF хувьцааны жин тэг гарсан. Энэ багцад Var арга Sample аргатай харьцуулахад OOS дисперсийг 4.952%-иар бууруулсан бөгөөд ялгаа статистикийн ач холбогдолтой ($p = 0.0331$) байна.

Corr шалгууураар сонгосон багцын хувьд NLS аргаар тооцсон жин HSY (26.24%), HRL (22.58%), BDX (18.80%) болон HRB (13.18%) хувьцаанд харьцангуй өндөр төвлөрсөн байна. Харин EFX болон GPC хувьцааны жин тэг гарсан. Энэ багцад NLS арга OOS дисперсийг 5.657%-иар бууруулж, статистикийн ач холбогдолтой үр дүн үзүүлсэн ($p = 0.0124$) байна.

SF шалгууураар сонгосон багцын хувьд Var аргаар тооцсон жин бүх 10 хувьцаанд ижил буюу 10.00% байна. Ингэснээр тэнцүү жинтэй багц үүссэн боловч Sample аргатай харьцуулахад OOS дисперс 51.840%-иар өссөн бөгөөд энэхүү өсөлт статистикийн ач холбогдолтой ($p = 0.0334$) байна.

Эдгээр үр дүнгээс харахад статистикийн ач холбогдолтой дисперсийн бууралт үзүүлсэн All/Var–Var болон Corr–NLS багцуудын жин тодорхой хувьцаанд төвлөрсөн байхад, дисперсийн өсөлт үзүүлсэн SF–Var багцын жин тэнцүү хуваарилагдсан байна. Гэхдээ энэхүү ялгаа нь багцын жингийн төвлөрөл дангаараа OOS дисперсийн өөрчлөлтийг тодорхойлдог гэсэн үг биш юм.

Хүснэгт 5: Статистикийн ач холбогдолтой OOS дисперсийн ялгаа үзүүлсэн багцуудын хөрөнгө оруулалтын жин

Ticker	All/Var–Var	Corr–NLS	SF–Var
ADBE	–	–	10.00
BA	0.00	–	–
BDX	–	18.80	–
BMY	24.47	–	–
COST	23.82	–	–
DHI	0.00	–	–
DRI	–	2.23	–
ED	–	–	10.00
EFX	–	0.00	–
FTI	0.00	–	–
GME	–	–	10.00
GPC	–	0.00	–
HRB	–	13.18	–
HRL	–	22.58	–
HSY	–	26.24	10.00
IBM	11.66	–	–
INTC	–	6.10	–
LMT	–	–	10.00
MCHP	–	–	10.00
NKE	7.55	–	–
ORLY	–	7.11	–
PFG	–	–	10.00
PH	–	–	10.00
RF	0.00	–	–
SCHW	13.15	–	–
TRIP	–	3.76	–
VRSN	19.35	–	–
WDC	–	–	10.00
WMT	–	–	10.00
Total (%)	**100.00**	**100.00**	**100.00**
RVR (%)	4.952	5.657	-51.840
HAC p-value	0.0331	0.0124	0.0334

Тайлбар: Багцын жинг хувиар илэрхийлэв. – тэмдэглэгээ нь тухайн хувьцаа багцад сонгогдоогүй, 0.00 нь сонгогдсон боловч тэг жинтэй байгааг илэрхийлнэ. Жингийн нийлбэрийг 100.00% болгохын тулд тоймлолтын зөрүүг сүүлийн сонгосон хувьцааны жинд тохируулсан.
All болон Var шалгууруар ижил 10 хувьцааны багц сонгогдсон тул тэдгээрийн Var аргын жинг нэг баганад харуулав.
All/Var–Var болон Corr–NLS аргууд статистикийн ач холбогдолтой OOS дисперсийн бууралт үзүүлсэн бол SF–Var арга статистикийн ач холбогдолтой дисперсийн өсөлт үзүүлсэн.
HAC p-утгууд нь олон харьцуулалтын засвар хийгдээгүй хоёр талт шалгуурын үр дүн юм.

5 Дүгнэлт

Энэхүү судалгаанд хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцаа (N/T) бага үед ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багцын (GMVP) гүйцэтгэлийг харьцуулан шинжиллээ. Түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцын (Corr), нэг хүчин зүйлийн (SF) зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид болон шугаман бус агшилтын үнэлэгчийг (NLS) авч үзсэн. Корреляцын бүтэц ялгаатай, тус бүр 10 хувьцаатай гурван багцад богино борлуулалтыг зөвшөөрөөгүй GMVP байгуулж, 120 сарын шилжих сургалтын цонх болон 52 сарын түүврээс гадуурх (OOS) хугацаагаар үнэлэв.

Үндсэн гурван багцын үр дүнгээр агшилтын үнэлэгчдийн гүйцэтгэл корреляцын бүтцээс хамааран ялгаатай байлаа. Өндөр корреляцтай багцад Var үнэлэгч Sample аргатай харьцуулахад OOS дисперсийг 5.81%-иар, дунд корреляцтай багцад Corr үнэлэгч 2.26%-иар бууруулсан. Харин бага корреляцтай багцад Sample арга хамгийн бага OOS дисперстэй байсан бөгөөд агшилтын таван үнэлэгчийн харьцангуй дисперсийн бууралт (RVR) бүгд сөрөг гарсан. Иймээс аль нэг агшилтын үнэлэгч бүх багцад тогтмол давуу байгаагүй.

Жингийн бүтцийн шинжилгээнд Corr үнэлэгч гурван багцад хамгийн бага дундаж жингийн эргэлт (turnover), Var үнэлэгч хамгийн бага дундаж төвлөрлийн индекс (HHI) үзүүлсэн. Гэхдээ бага эргэлт, бага төвлөрөл нь бага OOS дисперсийг заавал илэрхийлээгүй. Тухайлбал, бага корреляцтай багцад Var үнэлэгчийн OOS дисперс Sample аргынхаас 22.70%-иар өндөр байв. Сургалтын цонхыг 60, 90, 120 сар болгон өөрчлөхөд үнэлэгчдийн эрэмбэ бүх багцад тогтвортой хадгалагдсангүй. Иймээс судалсан хүрээнд N/T харьцаа буурах тусам агшилтын давуу тал заавал нэмэгдэнэ гэсэн зүй тогтол ажиглагдсангүй.

Үндсэн гурван багцын сарын квадрат өгөөжийн ялгаанд хийсэн HAC шалгалтаар Holm-ийн олон харьцуулалтын засварын дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй; сургалтын цонхны мэдрэмжийн шинжилгээнд мөн адил байв. Эдгээр шалгалт квадрат өгөөжийн дундаж ялгаанд суурилдаг тул OOS дисперсийн ялгааг шууд шалгасан гэж тайлбарлахгүй.

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг шалгахын тулд корреляцын ангилал тус бүрд 50, нийт 150 нэмэлт багцад шинжилгээг давтсан. Өндөр корреляцтай ангилалд агшилтын бүх үнэлэгчийн дундаж RVR эерэг байсан бол дунд болон бага корреляцтай ангиллуудад үр дүн ялгаатай байв. Бага корреляцтай ангилалд Var үнэлэгчийн дундаж RVR -35.02%, NLS үнэлэгчийнх 0.99% байсан нь үндсэн бага корреляцтай багцын сөрөг RVR-ийн дүр зураг бүх нэмэлт багцад ижил давтагдаагүйг харуулна. Circular moving-block bootstrap аргаар тооцсон засварлаагүй 95%-ийн итгэх завсар бага корреляцтай ангиллын Var үнэлэгчийн хувьд $[-65.61, -14.67]$ байсан бол бусад үнэлэгчдийнх тэгийг агуулсан. Гэвч ангилал хоорондын Var үнэлэгчийн High–Low болон Medium–Low ялгааны засварлаагүй bootstrap p-утгууд 0.0147, 0.0180 байсан ч 15 харьцуулалтад Holm-ийн засвар хийсний дараа 0.2199, 0.2519 болж, статистикийн ач холбогдолтой ялгаа тогтоогдоогүй.

Тэнцүү жинтэй $1/N$ багцыг жишиг болгон авч үзэхэд үндсэн гурван багцад ковариацын зургаан үнэлэгчид суурилсан GMVP стратегиуд бүгд түүнээс бага OOS хэлбэлзэлтэй байв. Өндөр корреляцтай багцад Var, дунд корреляцтай багцад Corr, бага корреляцтай багцад Sample аргын $1/N$-тэй харьцуулсан дисперсийн бууралт харгалзан 39.61%, 17.63%, 26.06% байв. Гэвч эдгээр харьцуулалтын засварлаагүй bootstrap 95%-ийн итгэх завсрууд харгалзан $[-7.09, 62.44]$, $[-3.95, 34.33]$, $[-7.84, 51.16]$ бөгөөд бүгд тэгийг агуулсан. Holm-ийн засварын дараа ч статистикийн ач холбогдолтой ялгаа тогтоогдоогүй. Мөн бага корреляцтай багцад $1/N$ стратегийн жилийн Sharpe-ийн харьцаа GMVP стратегиудынхаас өндөр байсан. Иймээс ажиглагдсан хэлбэлзлийн бууралтыг эрсдэлд тохируулсан өгөөжийн эсвэл статистикийн хувьд батлагдсан давуу тал гэж үзэхгүй.

Нэг талын 10 суурь нэгжийн арилжааны зардлыг тооцоход стратегиудын Sharpe-ийн харьцаа бага хэмжээгээр буурсан ч үндсэн харьцуулалтын ерөнхий дүр зураг өөрчлөгдөөгүй. Иймээс ковариацын үнэлэгчийн практик үр ашгийг зөвхөн OOS дисперсээр бус, жингийн эргэлт, төвлөрөл, Sharpe-ийн харьцаа болон арилжааны зардлын дараах гүйцэтгэлтэй хамтатган үнэлэх шаардлагатай.

Судалгааны үр дүнг тайлбарлахад хэд хэдэн хязгаарлалтыг харгалзана. Нэгдүгээрт, шинжилгээ нь сонгосон хувьцаанууд, богино борлуулалтыг зөвшөөрөөгүй GMVP болон 52 сарын OOS хугацаагаар хязгаарлагдана. Хоёрдугаарт, 2012 оны S&P 500 индексийн түү-

хэн бүрэлдэхүүний 453 хувьцаанаас 337 нь 2022 оны 5 дугаар сар хүртэлх сургалтын хугацаанд бүрэн үнийн мэдээлэлтэй байсан бөгөөд бүрэн байдлын шаардлагыг 2026 оны 9 дүгээр сар хүртэл сунгахад нэмэлт хувьцаа хасагдаагүй. Гэвч сургалтын хугацаанд өгөгдөл дутуу байсан 116 хувьцааг хассан нь сонголтын хазайлт үүсгэсэн байх боломжийг үгүйсгэхгүй. Гуравдугаарт, сургалтын цонхны уртыг өөрчлөхөд N/T харьцаатай зэрэгцэн ашигласан сургалтын өгөгдлийн хугацаа өөрчлөгдөнө. Дөрөвдүгээрт, нэмэлт 150 багц нь бие даасан санамсаргүй түүвэр биш бөгөөд bootstrap шинжилгээнд багцын бүрэлдэхүүнийг тогтмол гэж үзсэн. Түүнчлэн арилжааны зардлын тооцоолол нь тогтмол зардлын таамаглалд тулгуурласан.

Нэгдсэн дүнгээр бага N/T харьцаатай нөхцөлд ковариацын матрицын агшилт GMVP-ийн OOS дисперсийг зарим багцад бууруулж болох боловч энэхүү үр нөлөө багцын корреляцын бүтэц, бүрэлдэхүүн болон сургалтын цонхны уртаас хамаарч байна. Богино борлуулалтыг хязгаарласан нөхцөлд агшилтын нэмэлт үр ашиг бүх тохиолдолд илэрнэ гэж үзэх үндэслэлгүй байгаа нь Jagannathan and Ma [2003] болон De Nard and Kostovic [2026]-ийн судалгаатай харьцуулан хэлэлцэх боломжтой үр дүн юм. Гэвч олон харьцуулалтын засварын дараах статистикийн шалгалтууд агшилтын үнэлэгчдийн Sample аргаас, эсвэл GMVP стратегиудын $1/N$ багцаас тогтвортой давуу гүйцэтгэлийг батлаагүй. Иймээс агшилтын аргыг бага N/T нөхцөлд эрсдэлийг заавал бууруулах шийдэл бус, харин тухайн багцын бүтэц, түүврээс гадуурх гүйцэтгэл болон хэрэгжүүлэх зардалд тулгуурлан сонгох шаардлагатай хувилбар гэж дүгнэв.

Ашигласан ном

Sakai Ando and Mingmei Xiao. High-dimensional covariance matrix estimation: Shrinkage toward a diagonal target. IMF Working Paper WP/23/257, International Monetary Fund, 2023.

chinobing. Historical S&P 500 constituents. GitHub repository. URL https://github.com/chinobing/historical_sp500_constituents. Accessed: 2026-10-21.

Gianluca De Nard and Damjan Kostovic. Learning the shrinkage intensity: A data-driven approach for risk-optimized portfolios. *Journal of Financial Econometrics*, 24(2):nbag002, 2026. doi: 10.1093/jjfinec/nbag002.

Victor DeMiguel, Lorenzo Garlappi, and Raman Uppal. Optimal versus naive diversification: How inefficient is the 1/n portfolio strategy? *The Review of Financial Studies*, 22(5):1915–1953, 2009. doi: 10.1093/rfs/hhm075.

M. Sipke Dom, Clint Howard, Maarten Jansen, and Harald Lohre. Beyond GMV: The relevance of covariance matrix estimation for risk-based portfolio construction. *Quantitative Finance*, 25(3):403–419, 2025. doi: 10.1080/14697688.2025.2468268.

Ravi Jagannathan and Tongshu Ma. Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4):1651–1683, 2003. doi: 10.1111/1540-6261.00580.

Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5):603–621, 2003. doi: 10.1016/S0927-5398(03)00007-0.

Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004a. doi: 10.1016/S0047-259X(03)00096-4.

Olivier Ledoit and Michael Wolf. Honey, i shrunk the sample covariance matrix. *The Journal of Portfolio Management*, 30(4):110–119, 2004b. doi: 10.3905/jpm.2004.110.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage estimation of large-dimensional covariance matrices. *The Annals of Statistics*, 40(2):1024–1060, 2012. doi: 10.1214/12-AOS989.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets goldilocks. *The Review of Financial Studies*, 30(12):4349–4388, 2017. doi: 10.1093/rfs/hhx052.

Olivier Ledoit and Michael Wolf. Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5):3043–3065, 2020. doi: 10.1214/19-AOS1921.

Olivier Ledoit and Michael Wolf. The power of (non-)linear shrinking: A review and guide to covariance matrix estimation. *Journal of Financial Econometrics*, 20(1):187–218, 2022. doi: 10.1093/jjfinec/nbaa007.

Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952. doi: 10.1111/j.1540-6261.1952.tb01525.x.

Juliane Schäfer and Korbinian Strimmer. A shrinkage approach to large-scale covariance matrix estimation and implications for functional genomics. *Statistical Applications in Genetics and Molecular Biology*, 4(1):Article 32, 2005. doi: 10.2202/1544-6115.1175.

Fangquan Shi, Lianjie Shu, Fangyi He, and Wenpo Huang. Improving minimum-variance portfolio through shrinkage of large covariance matrices. *Economic Modelling*, 144:106981, 2025. doi: 10.1016/j.econmod.2024.106981.