N/T харьцаа бага үед багцын оновчлолд ковариацын матрицын агшилтын аргуудыг харьцуулах нь

Г.Нарангоо[1] Ч.Анхбаяр[2]

[1]Монгол улсын их сургууль, Мэдээллийн технологи, электроникийн сургууль

narangoo.g@num.edu.mn

[2]Монгол улсын их сургууль, Бизнесийн сургууль

ankhbayar.ch@num.edu.mn

Хураангуй

Энэхүү судалгаагаар хөрөнгийн тоо болон сургалтын ажиглалтын тооны харьцаа (N/T) бага нөхцөлд ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багцын (GMVP) түүврээс гадуурх гүйцэтгэлийг харьцуулан үнэлэв. Түүврийн ковариацын матриц, дөрвөн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгч болон шугаман бус агшилтын үнэлэгчийг богино борлуулалтыг зөвшөөрөөгүй багцын оновчлолд ашиглав. Корреляцын бүтэц ялгаатай, тус бүр 10 хувьцаанаас бүрдсэн гурван багцад 120 сарын сургалтын цонх бүхий шилжих цонхны аргаар 52 сарын түүврээс гадуурх үнэлгээ хийв. Үр дүнгийн тогтвортой байдлыг сургалтын цонхны мэдрэмжийн шинжилгээ, нэмэлт 150 багцын шинжилгээ, HAC шалгалт болон блок bootstrap аргаар үнэлэв. Үндсэн шинжилгээнд өндөр корреляцтай багцад тогтмол вариацын агшилтын үнэлэгч түүврийн ковариацын аргатай харьцуулахад дисперсийг 5.81%, дунд корреляцтай багцад тогтмол корреляцын агшилтын үнэлэгч 2.26%-иар бууруулсан бол бага корреляцтай багцад агшилтын бүх үнэлэгчийн харьцангуй дисперсийн бууралт сөрөг байв. Нэмэлт 150 багцын шинжилгээгээр агшилтын үнэлэгчдийн гүйцэтгэл багцын бүрэлдэхүүнээс хамааран өөрчлөгдөж байгааг тогтоов. Тэнцүү жинтэй багцтай харьцуулахад GMVP стратегиуд бага хэлбэлзэл үзүүлсэн боловч олон харьцуулалтын засварын дараа агшилтын үнэлэгчдийн түүврийн ковариацын аргаас, мөн GMVP стратегиудын тэнцүү жинтэй багцаас статистикийн ач холбогдолтой давуу байдал тогтоогдоогүй. Арилжааны зардлын шинжилгээ нь бага хэлбэлзэл өндөр эрсдэлд тохируулсан өгөөжийг заавал илэрхийлэхгүйг харуулав. Ийнхүү бага (N/T) нөхцөлд ковариацын матрицын агшилтын аргуудын эрсдэл бууруулах үр ашиг нь багцын бүтэц, сургалтын цонхны уртаас хамаарах бөгөөд бүх нөхцөлд тогтвортой давуу тал үзүүлэхгүй гэж дүгнэв.

Keywords: Ковариацын матрицын агшилт; глобал хамгийн бага вариацтай багц; түүврээс гадуурх гүйцэтгэл; харьцангуй дисперсийн бууралт; шилжих цонхны арга; блок bootstrap.

1 Удиртгал

Багц сонголтын орчин үеийн онолын суурийг Markowitz [1952]-ийн дундаж–вариацын загвар тавьсан бөгөөд уг загварт багцын эрсдэлийг хөрөнгийн өгөөжийн ковариацын матрицаар тодорхойлдог. Глобал хамгийн бага вариацтай багц (Global Minimum

Variance Portfolio, GMVP) нь хүлээгдэж буй өгөөжийн үнэлгээ шаардахгүйгээр ковариацын матрицад тулгуурлан багцын дисперсийг хамгийн бага байлгах жинг сонгодог. Гэвч жинхэнэ ковариацын матриц үл мэдэгдэх учир түүнийг түүхэн өгөгдлөөс үнэлэх шаардлагатай бөгөөд үнэлгээний алдаа нь багцын жин болон түүврээс гадуурх эрсдэлд нөлөөлж болно.

Түүврийн ковариацын матриц нь N хөрөнгийн хувьд $N(N+1)/2$ ялгаатай параметр агуулдаг. Хөрөнгийн тоо N нь ажиглалтын тоо T-тэй харьцуулахад ихсэх үед эдгээр параметрийн үнэлгээ тогтворгүй болох, цаашлаад $N > T$ нөхцөлд түүврийн ковариацын матриц сингуляр болох асуудал үүсдэг [Ledoit and Wolf, 2004a]. Гэхдээ матриц урвуулагдах боломжтой, N/T харьцаа бага үед ч үнэлгээний алдаа бүрэн арилна гэсэн баталгаа байхгүй. Ялангуяа багцын оновчлол нь ковариацын матрицын үнэлгээний алдааг жингийн сонголтоор дамжуулан өсгөж болзошгүй. DeMiguel et al. [2009] багц сонголтын олон стратегийг бодит өгөгдөл дээр харьцуулж, параметрийн үнэлгээний алдаа нь оновчлолын практик үр дүнг хязгаарлаж болохыг харуулсан.

Энэ асуудлыг шийдвэрлэх нэг чиглэл нь ковариацын матрицын агшилтын үнэлгээ (shrinkage estimation) юм. Шугаман агшилт нь түүврийн ковариацын матриц S-ийг тодорхой бүтцийн таамаглалтай зорилтот матриц T-тай $\widehat{\Sigma} = (1-\alpha)S + \alpha T$ хэлбэрээр хослуулдаг бөгөөд $\alpha \in [0,1]$ нь агшилтын эрчим юм. Түүврийн мэдээллийг хадгалах болон үнэлгээний хэлбэлзлийг багасгах хоёр зорилгын тэнцвэр нь зорилтот матрицын бүтэц, агшилтын эрчмээс хамаарна. Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн дисперсийг ижил, ковариацыг тэг гэж үздэг [Ledoit and Wolf, 2004a]; диагональ зорилтот матриц нь хөрөнгө тус бүрийн дисперсийг хадгалж, ковариацыг тэглэдэг [Ledoit, 1995]. Тогтмол корреляцын зорилтот матриц нь хөрөнгийн хосуудын корреляцыг нэг нийтлэг утгаар төлөөлүүлдэг [Ledoit, 1995, Ledoit and Wolf, 2004b], харин нэг хүчин зүйлийн зорилтот матриц нь өгөөжийн хамтын хөдөлгөөнийг зах зээлийн нийтлэг хүчин зүйлээр загварчилдаг [Ledoit and Wolf, 2003]. Эдгээр зорилтот матрицын тодорхойлолт, таамаглал болон үнэлгээний томьёог дараагийн онол, арга зүйн хэсэгт дэлгэрэнгүй авч үзнэ.

Шугаман агшилтаас ялгаатай нь шугаман бус агшилт (nonlinear shrinkage, NLS) түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засах боломж олгодог. Ledoit and Wolf [2012] энэ чиглэлийн аргыг хөгжүүлж, Ledoit and Wolf [2020] аналитик хэрэгжилтийг санал болгосон. Түүнчлэн ковариацын матрицын үнэлгээний чанар нь сонгосон алдагдлын функцээс хамаарч болохыг Ledoit and Wolf [2022] судалсан. Иймээс ковариацын матрицыг статистикийн тодорхой шалгууруур сайн үнэлэх нь GMVP-ийн түүврээс гадуурх дисперсийг заавал хамгийн бага болгоно гэсэн үг биш. GMVP-ийн хүрээнд агшилтын аргуудын практик гүйцэтгэлийг судалсан сүүлийн үеийн ажлууд ч зорилтот матриц болон агшилтын эрчмийн сонголт чухал болохыг онцолж байна [Shi et al., 2025].

Өмнөх судалгаанууд агшилтын үнэлэгчдийн онолын үндэслэл, өндөр хэмжээст нөхцөл дэх шинж чанар болон багцын оновчлол дахь хэрэглээг өргөн авч үзсэн. Харин хөрөнгийн тоо ажиглалтын тооноос харьцангуй бага, түүврийн ковариацын матриц тооцооллын хувьд ашиглах боломжтой үед агшилтын аргууд GMVP-ийн түүврээс гадуурх эрсдэлийг хэр тогтвортой бууруулах нь тусад нь эмпирик үнэлэх шаардлагатай асуудал хэвээр байна. Ялангуяа нэг багц дээр ажиглагдсан давуу тал нь хөрөнгүүдийн корреляцын бүтэц, багцын бүрэлдэхүүн болон сургалтын цонхны уртаас хамаарах эсэхийг ялган шалгах нь чухал. Иймээс энэ судалгаа агшилтын аргуудын давуу талыг урьдчилан таамаглахын оронд бага N/T нөхцөл дэх тэдгээрийн гүйцэтгэл, тогтвортой байдал болон статистикийн тодорхой бус байдлыг үнэлэхэд чиглэнэ.

Судалгааны зорилго нь түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцын (Corr), нэг хүчин зүйлийн (SF) зорилтот матрицад суурилсан шугаман агшилтын дөрвөн үнэлэгч болон аналитик шугаман бус агшилтын үнэлэгчийг (NLS) богино борлуулалтыг зөвшөөрөөгүй GMVP-

ийн нэг ижил нөхцөлд харьцуулах явдал юм. Үнэлгээнд сарын өгөөж ашиглаж, корреляцын бүтэц ялгаатай, тус бүр 10 хувьцаанаас бүрдсэн өндөр, дунд, бага корреляцтай гурван багцын хувьд 120 сарын сургалтын цонхтой rolling-window аргаар 52 сарын түүврээс гадуурх гүйцэтгэлийг тооцно. Гол үзүүлэлтүүд нь түүврээс гадуурх хэлбэлзэл, Sample аргатай харьцуулсан дисперсийн бууралт (RVR), Sharpe-ийн харьцаа, багцын жингийн эргэлт (turnover) болон төвлөрөл (HHI) юм.

Энэхүү судалгааны эмпирик хувь нэмэр нь хэд хэдэн харилцан нөхөх шинжилгээг нэг хүрээнд хэрэгжүүлсэнд оршино. Нэгдүгээрт, корреляцын ялгаатай бүтэцтэй багцуудын үр дүнг харьцуулж, сургалтын цонхыг 60, 90, 120 сар болгон өөрчлөх замаар N/T-ийн мэдрэмжийг үнэлнэ. Хоёрдугаарт, корреляцын ангилал тус бүрээс сонгосон 50, нийт 150 нэмэлт багцад шинжилгээг давтаж, анхны гурван багцын үр дүн бүрэлдэхүүний сонголтоос хэр хамаарч байгааг шалгана. Гуравдугаарт, HAC болон circular moving-block bootstrap аргаар ажиглагдсан ялгааны тодорхой бус байдлыг үнэлж, олон харьцуулалтад Holm-ийн засвар хэрэглэнэ. Дөрөвдүгээрт, тэнцүү жинтэй $1/N$ багцыг нэмэлт жишиг болгон ашиглаж, арилжааны зардлын дараах гүйцэтгэлийг мөн харьцуулна.

Үндсэн үр дүнгээр өндөр корреляцтай багцад Var, дунд корреляцтай багцад Corr үнэлэгч Sample аргатай харьцуулахад түүврээс гадуурх дисперсийг тус тус 5.81% болон 2.26%-иар бууруулсан бол бага корреляцтай багцад агшилтын таван үнэлэгчийн RVR бүгд сөрөг байв. Нэмэлт 150 багцын шинжилгээнд үр дүн багцын бүрэлдэхүүнээс хамааран өөрчлөгдсөн. Үндсэн гурван багцад GMVP стратегиуд $1/N$ багцаас бага хэлбэлзэл үзүүлсэн боловч олон харьцуулалтын засварын дараа агшилтын үнэлэгчдийн Sample аргаас, мөн GMVP стратегиудын $1/N$ багцаас статистикийн ач холбогдолтой давуу байдал тогтоогдоогүй. Иймээс бага N/T нөхцөлд агшилтын үр ашгийг зөвхөн үнэлэгчийн онолын шинж чанараар бус, багцын бүтэц болон түүврээс гадуурх гүйцэтгэлд тулгуурлан үнэлэх шаардлагатайг үр дүн харуулж байна.

2 Онол, арга зүйн үндэслэл

2.1 Багцын өгөөж ба эрсдэл

Энэхүү судалгаанд N ширхэг хөрөнгөөс бүрдэх хөрөнгө оруулалтын багцыг авч үзье. x_i нь i-р хөрөнгийн багцад эзлэх жин, G_i нь тухайн хөрөнгийн өгөөж гэж тэмдэглэвэл багцын өгөөжийг

$$r_p = \sum_{i=1}^{N} x_i G_i$$

гэж тодорхойлно. Багцын хүлээгдэж буй өгөөж нь

$$\mu_p = E[r_p] = E\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i E[G_i]$$

байна. Энд $E[G_i]$ нь i-р хөрөнгийн хүлээгдэж буй өгөөжийг илэрхийлнэ.

Багцын эрсдэлийг өгөөжийн вариацаар хэмжвэл

$$\sigma_p^2 = \mathrm{Var}(r_p) = \mathrm{Var}\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i^2 \sigma_i^2 + \sum_{i \neq j} x_i x_j \sigma_{ij},$$

байна. Энд $\sigma_i^2 = \mathrm{Var}(G_i)$ нь i-р хөрөнгийн өгөөжийн вариац, харин

$$\sigma_{ij} = \mathrm{Cov}(G_i, G_j)$$

нь i болон j-р хөрөнгийн өгөөжийн ковариац юм.

Багцын жингийн векторыг

$$\mathbf{x} = (x_1, x_2, \ldots, x_N)^\top,$$

хөрөнгүүдийн өгөөжийн ковариацын матрицыг

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1N} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \cdots & \sigma_{NN} \end{pmatrix}$$

гэж тэмдэглэвэл багцын вариацыг матриц хэлбэрээр

$$\sigma_p^2 = \mathbf{x}^\top \Sigma \mathbf{x}$$

гэж бичиж болно.

Иймээс багцын эрсдэл нь хөрөнгө тус бүрийн вариацаас гадна хөрөнгүүдийн өгөөж хоорондын ковариацаас хамаарна. Иймд ковариацын матрицыг хэрхэн үнэлэх нь багц сонголтын үр дүнд чухал нөлөөтэй.

2.2 Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)

Энэхүү судалгаанд ковариацын матрицын өөр өөр үнэлэгчийг багцын оновчлолд ашиглахад үүсэх ялгааг харьцуулахын тулд глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)-ийг ашиглана. GMVP-ийн зорилго нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилах нөхцөлд багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлоход оршино. GMVP-ийн оновчтой жинг тодорхойлоход хөрөнгүүдийн хүлээгдэж буй өгөөжийн үнэлгээ шаардлагагүй бөгөөд ковариацын матрицад тулгуурладаг.

Энэхүү судалгаанд богино арилжааг зөвшөөрөхгүй, хөрөнгө бүрийн багцад эзлэх жин сөрөг биш байх long-only GMVP загварыг ашиглана. Энэхүү хязгаарлалт нь богино арилжаа болон сөрөг жингээс үүдэх хөшүүрэгтэй байрлалыг хязгаарлахаас гадна ковариацын матрицын үнэлгээний алдаанаас шалтгаалан багцын жин хэт туйлшрах эрсдэлийг бууруулах боломжтой. [Jagannathan and Ma, 2003] нарын судалгаанд багцын жинг сөрөг бишээр хязгаарлах нь үнэлсэн оновчтой багцын эрсдэлийг бууруулж болохыг харуулсан. Түүнчлэн ийм хязгаарлалт нь ковариацын матрицын зарим элементийг агшаасантай төстэй нөлөө үзүүлж болохыг тайлбарласан.

Гэхдээ long-only хязгаарлалт нь өөрөө ковариацын матрицын үнэлгээний алдааны нөлөөг бууруулж болох тул агшилтын үнэлэгчдийн хоорондын гүйцэтгэлийн ялгааг багасгаж болзошгүй. Иймээс энэхүү судалгаанд ковариацын матрицын үнэлэгчдийн үр дүнг ижил long-only оновчлолын нөхцөлийн хүрээнд харьцуулж, гарсан дүгнэлтийг уг хязгаарлалтын хүрээнд тайлбарлана.

N ширхэг хөрөнгөөс бүрдэх багцын жингийн векторыг

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_N)^\top$$

гэж тэмдэглэе. Мөн хөрөнгүүдийн өгөөжийн ковариацын матрицын үнэлэгчийг $\widehat{\Sigma}$ гэвэл багцын үнэлэгдсэн вариац

$$\widehat{\sigma}_p^2 = \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x}$$

байна.

Тэгвэл long-only GMVP-ийн оновчлолын бодлогыг

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x} \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{x} = 1, \\ & x_i \geq 0, \qquad i = 1, 2, \ldots, N \end{aligned}$$

гэж тодорхойлно. Энд $\mathbf{1}$ нь бүх элемент нь нэгтэй N хэмжээст вектор юм.

$\mathbf{1}^\top \boldsymbol{x} = 1$ нөхцөл нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилахыг, харин $x_i \geq 0$ нөхцөл нь хөрөнгө бүрийн жин сөрөг биш байхыг илэрхийлнэ. Эдгээр нөхцөлөөс

$$0 \leq x_i \leq 1, \qquad i = 1, 2, \ldots, N$$

байх нь шууд мөрдөнө.

Long-only GMVP-ийн оновчтой жинг хязгаарлалттай квадратлаг оновчлолын бодлогын шийдээр тодорхойлно. Хэрэв $\widehat{\Sigma}$ нь эерэг хагас тодорхой матриц бол зорилгын функц гүдгэр байна. Мөн боломжит жингийн олонлог хоосон биш, хаалттай, хязгаарлагдмал тул оновчтой шийд оршино. Харин оновчтой шийд цорын ганц байх нь ковариацын матрицын шинж чанараас хамаарна.

Энэхүү судалгаанд түүврийн ковариацын матрицыг суурь үнэлэгч болгон авч, тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг харьцуулна.

Эдгээр зургаан ковариацын матрицын үнэлэгчийг ерөнхийд нь $\widehat{\Sigma}^{(k)}$, $k = 1, 2, \ldots, 6$ гэж тэмдэглэе. Тэгвэл k-р үнэлэгчид харгалзах long-only GMVP-ийн оновчтой жинг

$$\widehat{\boldsymbol{x}}^{(k)} \in \underset{\substack{\boldsymbol{x} \in \mathbb{R}^N \\ \mathbf{1}^\top \boldsymbol{x} = 1 \\ \boldsymbol{x} \geq \mathbf{0}}}{\arg\min} \boldsymbol{x}^\top \widehat{\Sigma}^{(k)} \boldsymbol{x}$$

гэж тодорхойлно.

Энд бүх үнэлэгчийн хувьд багцын оновчлолын зорилгын функцийн хэлбэр болон хөрөнгө оруулалтын жинд тавих хязгаарлалтууд ижил байх бөгөөд зөвхөн ковариацын матрицын үнэлэгч $\widehat{\Sigma}^{(k)}$ өөрчлөгдөнө.

Иймээс ковариацын матрицын үнэлэгчийн сонголтоос хамааран GMVP-ийн оновчтой жин, улмаар багцын эрсдэл болон бодит өгөөжийн үзүүлэлтүүд ялгаатай байж болно. Энэхүү судалгаанд эдгээр үнэлэгчээр байгуулсан long-only GMVP-үүдийн гүйцэтгэлийг ижил нөхцөлд харьцуулан үнэлнэ.

2.3 Түүврийн ковариацын матриц

Бодит нөхцөлд хөрөнгүүдийн өгөөжийн эх олонлогийн ковариацын матриц Σ үл мэдэгдэх тул түүнийг ажиглагдсан өгөгдлөөс үнэлэх шаардлагатай. Энэхүү судалгаанд n ажиглалт, N хөрөнгөөс бүрдэх өгөөжийн ажиглалтын матрицыг

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1N} \\ y_{21} & y_{22} & \cdots & y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nN} \end{pmatrix} \in \mathbb{R}^{n \times N}$$

гэж тэмдэглэнэ. Энд y_{ti} нь t-р хугацаанд ажиглагдсан i-р хөрөнгийн өгөөж, n нь ажиглалтын тоо, N нь хөрөнгийн тоо юм.

i-р хөрөнгийн дундаж өгөөжийг

$$\overline{Y}_i = \frac{1}{n}\sum_{t=1}^{n} y_{ti}, \qquad i = 1, 2, \ldots, N,$$

гэж тооцно.

Тэгвэл i болон j-р хөрөнгийн өгөөжийн түүврийн ковариацыг

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

гэж тодорхойлно. Эдгээр түүврийн ковариацуудаас бүрдэх түүврийн ковариацын матриц нь

$$S = (s_{ij}) = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1N} \\ s_{21} & s_{22} & \cdots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \cdots & s_{NN} \end{pmatrix}$$

байна. Энд S нь $N \times N$ хэмжээст түүврийн ковариацын матриц бөгөөд эх олонлогийн ковариацын матриц Σ-г үнэлэхэд ашиглагдана.

2.4 Шугаман агшилтын үнэлгээ (Linear Shrinkage Estimation)

Шугаман агшилт (Linear Shrinkage) нь агшилтын үнэлгээний хамгийн өргөн хэрэглэгддэг хэлбэрүүдийн нэг юм. Энэхүү аргын үндсэн санаа нь түүврийн ковариацын матриц болон тодорхой бүтэц бүхий зорилтот матрицыг гүдгэр хослол хэлбэрээр нэгтгэн ковариацын матрицын үнэлэгчийг байгуулахад оршино. Шугаман агшилтын үнэлэгчийг ерөнхий хэлбэрээр

$$\widehat{\Sigma}_{LS} = (1 - \alpha)S + \alpha T, \qquad 0 \leq \alpha \leq 1,$$

гэж тодорхойлно. Энд S нь түүврийн ковариацын матриц, T нь зорилтот матриц, α нь агшилтын эрчим юм. $\alpha = 0$ үед $\widehat{\Sigma}_{LS} = S$, харин $\alpha = 1$ үед $\widehat{\Sigma}_{LS} = T$ болно. Иймээс α-ийн утга ихсэх тусам зорилтот матриц T-д өгөх жин нэмэгдэж, түүврийн ковариацын матриц S-д өгөх жин буурна.

Хэрэв зорилтот матриц T нь эерэг тодорхой бөгөөд $0 < \alpha \leq 1$ бол шугаман агшилтын үнэлэгч $\widehat{\Sigma}_{LS}$ нь эерэг тодорхой байна. Энэ шинж нь ковариацын матрицын тооцооллын тогтвортой байдлыг сайжруулахад ач холбогдолтой.

Шугаман агшилтын арга нь түүврийн ковариацын матрицын бүх элементэд нэг ижил агшилтын эрчим α-г хэрэглэдэг. Иймээс ковариацын матрицын бодит бүтэц нарийн төвөгтэй, эсвэл хөрөнгүүдийн хоорондын хамаарал харилцан адилгүй үед нэг ижил агшилтын эрчим хэрэглэх нь уг аргын уян хатан байдлыг хязгаарлаж болно.

Шугаман агшилтын үнэлгээний үр дүнд зорилтот матрицын сонголт чухал үүрэгтэй. Энэхүү судалгаанд тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицыг авч үзнэ. Эдгээр зорилтот матрицууд нь шугаман агшилтын ерөнхий хэлбэр дэх T-ийн үүргийг гүйцэтгэх бөгөөд тэдгээрийн ялгаа нь ковариацын матрицын бүтцэд тавих таамаглалд оршино.

2.4.1 Тогтмол вариацын зорилтот матриц

Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн вариацыг нэг нийтлэг утгаар төлөөлүүлж, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг. Уг зорилтот мат-

рицыг

$$T_{\text{var}} = \widehat{\mu} I$$

гэж тодорхойлно. Энд I нь $N \times N$ хэмжээст нэгж матриц, харин

$$\widehat{\mu} = \frac{1}{N} \sum_{i=1}^{N} s_{ii} = \frac{\text{tr}(S)}{N}$$

нь хөрөнгүүдийн өгөөжийн түүврийн вариацуудын дундаж юм. Иймээс

$$T_{\text{var}} = \begin{pmatrix} \widehat{\mu} & 0 & \cdots & 0 \\ 0 & \widehat{\mu} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \widehat{\mu} \end{pmatrix}$$

хэлбэртэй байна [Ledoit and Wolf, 2004a].

Тогтмол вариацын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{var}} = (1 - \widehat{\alpha}_{\text{var}}) S + \widehat{\alpha}_{\text{var}} T_{\text{var}}, \qquad 0 \leq \widehat{\alpha}_{\text{var}} \leq 1$$

гэж тодорхойлно.

Агшилтын эрчмийн онолын үндэслэлийг Ledoit болон Wolf (2004)-ийн үр дүнд тулгуурлан дараах хэмжигдэхүүнүүдийг авч үзье:

$$\begin{aligned} a &= E\left[\|\Sigma - T\|^2\right] = \|\Sigma - T\|^2, \\ b &= E\left[\|S - \Sigma\|^2\right], \\ d &= E\left[\|S - T\|^2\right]. \end{aligned}$$

Лемма 1 (Ledoit–Wolf, 2004). Хэрэв $E[S] = \Sigma$ бөгөөд квадратын математик дундажууд төгсгөлөг бол

$$a + b = d$$

тэнцэтгэл биелнэ.

Баталгаа. Математик дундаж ба нормын чанараас

$$\begin{aligned} d &= E\left[\|S - T\|^2\right] = E\left[\|S - \Sigma + \Sigma - T\|^2\right] \\ &= E\left[\|S - \Sigma\|^2\right] + \|\Sigma - T\|^2 + 2E\left[\langle S - \Sigma, \Sigma - T \rangle\right]. \end{aligned}$$

$E[S] = \Sigma$ бөгөөд T нь санамсаргүй бус матриц тул

$$E\left[\langle S - \Sigma, \Sigma - T \rangle\right] = \langle E[S - \Sigma], \Sigma - T \rangle = 0.$$

Иймээс

$$d = b + a.$$

Лемма батлагдав. □

Теорем 1 (Ledoit–Wolf, 2004). Дараах оновчлолын бодлогыг авч үзье:

$$\min_{0 \leq \alpha \leq 1} E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right],$$

энд

$$\Sigma^*(\alpha) = (1 - \alpha) S + \alpha T.$$

Хэрэв $d > 0$ бол оновчтой агшилтын эрчим

$$\alpha^* = \frac{b}{d}$$

бөгөөд харгалзах үнэлэгч

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T$$

байна.

Баталгаа. Агшилтын үнэлэгчийн алдааг

$$\Sigma^*(\alpha) - \Sigma = (1-\alpha)(S-\Sigma) + \alpha(T-\Sigma)$$

гэж бичиж болно.

Одоо нормын квадратын томьёо болон математик дунджийн шугаман чанарыг хэрэглэнэ.

$$\begin{aligned}\|\Sigma^*(\alpha) - \Sigma\|^2 &= \|(1-\alpha)(S-\Sigma) + \alpha(T-\Sigma)\|^2 \\ &= (1-\alpha)^2\|S-\Sigma\|^2 + \alpha^2\|T-\Sigma\|^2 + 2\alpha(1-\alpha)\langle S-\Sigma, T-\Sigma\rangle.\end{aligned}$$

Хоёр талаас математик дундаж авбал:

$$\begin{aligned}E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right] &= (1-\alpha)^2 E\left[\|S-\Sigma\|^2\right] + \alpha^2 E\left[\|T-\Sigma\|^2\right] + 2\alpha(1-\alpha)E\left[\langle S-\Sigma, T-\Sigma\rangle\right] \\ &= (1-\alpha)^2 b + \alpha^2 a.\end{aligned}$$

Иймээс зорилгын функц

$$R(\alpha) = (1-\alpha)^2 b + \alpha^2 a$$

болно.

Алдааг хамгийн бага болгох α-г олох нь бидний зорилго учраас уламжлал аваад тэгтэй тэнцүүлнэ.

$$R'(\alpha) = -2(1-\alpha)b + 2\alpha a = 0.$$

Лемма 1-ээс $a + b = d$ тул

$$\alpha^* = \frac{b}{d}, \qquad 1 - \alpha^* = \frac{a}{d}.$$

Иймээс

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T.$$

$R''(\alpha) = 2d > 0$ учраас энэ нь минимум шийд юм.

Теорем батлагдав. □

Теорем 1-ээс оновчтой агшилтын эрчим нь түүврийн ковариацын матрицын үнэлгээний алдаа болон зорилтот матрицаас хазайх хэмжээнээс хамаарах нь харагдана.

Гэвч b болон d нь үл мэдэгдэх бодит ковариацын матрицаас хамаардаг тул тэдгээрийг өгөгдлөөс үнэлэх шаардлагатай. Ledoit болон Wolf (2004)-ийн оновчтой агшилтын эрчмийг өгөгдлөөс үнэлэх аргыг боловсруулсан.

Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын квадрат Фробениусын зайг

$$\widehat{d}_{\text{var}} = \|S - T_{\text{var}}\|_F^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг нормчилсон Фробениусын нормын тодорхойлолтоос

$$b_{var} = E\left[\|S - \Sigma\|^2\right] = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N} E\left[(s_{ij} - \sigma_{ij})^2\right].$$

Хэрэв $E[S] = \Sigma$ бол $E\left[(s_{ij} - \sigma_{ij})^2\right] = \mathrm{Var}(s_{ij})$.

Иймээс

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N} \mathrm{Var}(s_{ij}).$$

Одоо

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\}$$

гэж тэмдэглэе.

Ажиглалтууд хугацааны хувьд харилцан хамааралгүй, ижил тархалттай бол

$$\mathrm{Var}(s_{ij}) \approx \frac{1}{n^2}\sum_{t=1}^{n} \mathrm{Var}\left((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\right) = \frac{1}{n}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Тэгвэл

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\frac{1}{n}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right) = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Энд $\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right)$ нь үл мэдэгдэх тул түүний үнэлгээг $\frac{1}{n}\sum_{t=1}^{n}((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij})^2$ байгуулвал

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right] =$$

$$= \frac{1}{nN}\left[\frac{1}{n}\sum_{t=1}^{n}\sum_{i=1}^{N}\sum_{j=1}^{N}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right].$$

Иймээс агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\mathrm{var}} = \max\left\{0,\ \min\left\{1,\ \frac{\widehat{b}_{var}}{\widehat{d}_{\mathrm{var}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004a].

Тооцоолох алгоритм. Тогтмол вариацын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Түүврийн ковариацын матрицыг байгуулах.

n ажиглалт, N хөрөнгийн өгөөжийн өгөгдлөөс

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

гэж тооцож, $S = (s_{ij})$ матрицыг байгуулна.

2. Тогтмол вариацын зорилтот матрицыг байгуулах.

$$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii}, \qquad T_{\text{var}} = \widehat{\mu} I.$$

3. Ковариацын матрицын квадрат алдааг үнэлэх.

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\}^2\right].$$

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{var}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

$\widehat{d}_{\text{var}} > 0$ үед

$$\widehat{\alpha}_{\text{var}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\boxed{\widehat{\Sigma}_{\text{var}} = (1 - \widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}}.$$

2.4.2 Диагональ зорилтот матриц

Диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг гэж үзнэ. Уг зорилтот матрицыг

$$T_{\text{diag}} = \text{diag}(S) = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

гэж тодорхойлно. Матриц хэлбэрээр

$$T_{\text{diag}} = \begin{pmatrix} s_{11} & 0 & \cdots & 0 \\ 0 & s_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_{NN} \end{pmatrix}.$$

Өөрөөр хэлбэл,

$$(T_{\text{diag}})_{ij} = \begin{cases} s_{ii}, & i = j, \\ 0, & i \neq j. \end{cases}$$

Иймээс диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалах боловч хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг болгон хялбаршуулдаг.

Диагональ зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}}T_{\text{diag}}, \qquad 0 \leq \widehat{\alpha}_{\text{diag}} \leq 1,$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{diag}}$ нь диагональ зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Диагональ зорилтот матриц нь түүврийн ковариацын матрицын диагональ элементүүдийг өөрчлөхгүй хадгалдаг тул агшилт нь зөвхөн диагоналийн бус элементүүдэд үйлчилнэ.

Иймээс агшилтын эрчмийг үнэлэхдээ диагоналийн бус элементүүдийн квадрат алдааг авч үзнэ.

Түүврийн ковариацын матриц болон диагональ зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{diag}} = \|S - T_{\text{diag}}\|^2 = \frac{1}{N}\sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2$$

гэж тодорхойлно.

Учир нь S болон T_{diag} матрицын диагональ элементүүд ижил тул тэдгээрийн ялгавар диагональ дээр тэг байна.

Өмнөх тогтмол вариацын зорилтот матрицын хэсэгт үзсэнтэй адилтаар $\widehat{b}_{diag}$-г дараах байдлаар тодорхойлно.

$$\widehat{b}_{\text{diag}} = \frac{1}{nN}\sum_{\substack{i,j=1 \\ i \neq j}}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}(z_{tij} - s_{ij})^2\right].$$

Иймээс диагональ зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{diag}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}}\right\}\right\}$$

гэж байгуулна.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}}T_{\text{diag}}$$

гэж тооцно.

Тооцоолох алгоритм. Диагональ зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Диагональ зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$T_{\text{diag}} = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

   гэж байгуулна.

2. Диагоналийн бус элементүүдийн квадрат алдааг үнэлэх.

$$\widehat{b}_{\text{diag}} = \frac{1}{nN} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} (z_{tij} - s_{ij})^2 \right].$$

3. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{diag}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} s_{ij}^2.$$

4. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{diag}} > 0$ үед

$$\widehat{\alpha}_{\text{diag}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}} \right\} \right\}.$$

5. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}}) S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}.$$

2.4.3 Тогтмол корреляцын зорилтот матриц

Тогтмол корреляцын зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг тэдгээрийн дундаж утгаар төлөөлүүлэн байгуулдаг зорилтот матриц юм [Ledoit and Wolf, 2004b].

i болон j дугаар хөрөнгийн өгөөжийн түүврийн корреляцын коэффициентийг

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii} s_{jj}}}$$

гэж тодорхойлно [Ledoit and Wolf, 2004b].

Хөрөнгүүдийн хоорондын түүврийн корреляцуудын дундажийг

$$\bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

гэж тооцно.

Тогтмол корреляцын зорилтот матрицын элементүүдийг

$$(T_{\text{corr}})_{ij} = t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r} \sqrt{s_{ii} s_{jj}}, & i \neq j \end{cases}$$

гэж тодорхойлно.

Иймээс уг зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг нэг ижил дундаж утгаар орлуулна.

Тогтмол корреляцын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}}) S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}, \qquad 0 \leq \widehat{\alpha}_{\text{corr}} \leq 1$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{corr}}$ нь тогтмол корреляцын зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Тогтмол корреляцын зорилтот матриц нь түүврийн ковариацын матрицын элементүүдээс хамааран байгуулагддаг тул агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг харгалзан үзнэ.

Түүврийн ковариацын матриц болон тогтмол корреляцын зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{corr}} = \|S - T_{\text{corr}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2 = \frac{1}{N}\sum_{\substack{i,j=1 \\ i\neq j}}^{N}\left(s_{ij} - \bar{r}\sqrt{s_{ii}s_{jj}}\right)^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг өмнөх хэсгүүдэд үзсэнтэй адилаар

$$\widehat{b}_{\text{corr}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж бичигдэнэ.

Тогтмол корреляцын зорилтот матриц нь түүврийн ковариацын матрицаас хамаардаг учраас тэдгээрийн харгалзах элементүүдийн асимптотик ковариацыг тооцох шаардлагатай.

Энэ хэмжигдэхүүний нормчилсон үнэлгээг $\widehat{c}_{\text{corr}}$ гэж тэмдэглэе.

Эхлээд

$$\widehat{\vartheta}_{ii,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

болон

$$\widehat{\vartheta}_{jj,ij} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{tj} - \overline{Y}_j)^2 - s_{jj}\right\}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}$$

гэж тодорхойлно.

Эдгээр нь түүврийн вариац болон ковариацын элементүүдийн асимптотик ковариацыг үнэлэхэд ашиглагдана.

Ledoit болон Wolf (2004) нь түүврийн ковариацын матриц болон тогтмол корреляцын зорилтот матрицын асимптотик хам хэлбэлзлийг тооцох аргыг боловсруулсан [Ledoit and Wolf, 2004b]. Тэдгээрийн Appendix B-д өгсөн үр дүнд тулгуурлан

$$\widehat{c}_{\text{corr}} = \frac{1}{nN}\left[\sum_{i=1}^{N}\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) + \frac{\bar{r}}{2}\sum_{\substack{i,j=1 \\ i\neq j}}^{N}\left(\sqrt{\frac{s_{jj}}{s_{ii}}}\widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\widehat{\vartheta}_{jj,ij}\right)\right]$$

гэж үнэлнэ.

Энд

$$\widehat{\text{Var}}\left((y_{1i} - \overline{Y}_i)^2\right) = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2$$

юм.

Иймээс тогтмол корреляцын зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{corr}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}}\right\}\right\}$$

гэж байгуулна [Ledoit and Wolf, 2004b].

Энд $\widehat{b}_{\text{corr}}$ нь түүврийн ковариацын матрицын үнэлгээний квадрат алдааны асимптотик ойролцоо үнэлгээ, $\widehat{c}_{\text{corr}}$ нь түүврийн ковариацын матриц болон зорилтот матрицын харгалзах элементүүдийн асимптотик ковариацуудын нийлбэрийн нормчилсон үнэлгээ, $\widehat{d}_{\text{corr}}$ нь хоёр матрицын хоорондын нормчилсон квадрат Фробениусын зай юм.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}$$

гэж тооцно.

Тооцоолох алгоритм. Тогтмол корреляцын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Тогтмол корреляцын зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}, \qquad \bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

   гэж тооцно.

   Дараа нь

   $$t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii}s_{jj}}, & i \neq j \end{cases}$$

   гэж тодорхойлж, $T_{\text{corr}} = (t_{ij})$ матрицыг байгуулна.

2. Ковариацын матрицын квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{corr}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right]$$

   гэж тооцно.

3. Түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг үнэлэх.

   $$\widehat{\vartheta}_{ii,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   болон

   $$\widehat{\vartheta}_{jj,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{tj} - \overline{Y}_j)^2 - s_{jj} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   гэж тооцно.

Дараа нь

$$\widehat{c}_{\text{corr}} = \frac{1}{nN}\left[\sum_{i=1}^{N}\widehat{\text{Var}}\left((y_{1i}-\overline{Y}_i)^2\right) + \frac{\bar{r}}{2}\sum_{\substack{i,j=1\\ i\neq j}}^{N}\left(\sqrt{\frac{s_{jj}}{s_{ii}}}\widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\widehat{\vartheta}_{jj,ij}\right)\right]$$

гэж үнэлнэ.

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{corr}} = \frac{1}{N}\sum_{\substack{i,j=1\\ i\neq j}}^{N}(s_{ij}-t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{corr}} > 0$ үед

$$\widehat{\alpha}_{\text{corr}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}}\right\}\right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{corr}} = (1-\widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}}T_{\text{corr}}.$$

2.4.4 Нэг хүчин зүйлийн зорилтот матриц

Нэг хүчин зүйлийн зорилтот матриц нь хөрөнгүүдийн өгөөжийн хоорондын хамаарлыг зах зээлийн нийтлэг хүчин зүйлээр тайлбарлах нэг хүчин зүйлийн загварт (Single-Index Model) суурилдаг. Уг загварт хөрөнгийн өгөөжийг зах зээлийн нийтлэг хүчин зүйлтэй холбоотой хэсэг болон тухайн хөрөнгийн өөрийн онцлогоос хамаарах үлдэгдэл хэсэгт хуваан авч үздэг [Ledoit and Wolf, 2003].

Энэхүү судалгаанд зах зээлийн нийтлэг хүчин зүйлийг S&P 500 индексийн өгөөжөөр төлөөлүүлнэ.

i-р хөрөнгийн t-р хугацаан дахь өгөөжийг

$$y_{ti} = a_i + \beta_i R_{m,t} + \varepsilon_{ti}$$

гэж загварчилна. Энд $R_{m,t}$ нь t-р хугацаан дахь зах зээлийн өгөөж, a_i нь регрессийн тогтмол коэффициент, β_i нь i-р хөрөнгийн өгөөжийн зах зээлийн өөрчлөлтөд мэдрэг байдлыг илэрхийлэх коэффициент, ε_{ti} нь тухайн хөрөнгийн үлдэгдэл өгөөж юм.

Нэг хүчин зүйлийн загварын регрессийн коэффициентийг

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n}(y_{ti}-\overline{Y}_i)(R_{m,t}-\overline{R}_m)}{\sum_{t=1}^{n}(R_{m,t}-\overline{R}_m)^2}$$

гэж үнэлнэ. Энд

$$\overline{R}_m = \frac{1}{n}\sum_{t=1}^{n}R_{m,t}$$

нь зах зээлийн өгөөжийн түүврийн дундаж юм.

Регрессийн тогтмол коэффициентийг

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i\overline{R}_m$$

гэж тооцно.

Тэгвэл i-р хөрөнгийн t-р хугацаан дахь регрессийн үлдэгдэл

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}$$

болно. Үүнийг

$$\widehat{\varepsilon}_{ti} = (y_{ti} - \overline{Y}_i) - \widehat{\beta}_i (R_{m,t} - \overline{R}_m)$$

гэж илэрхийлж болно.

Нэг хүчин зүйлийн загварын үндсэн таамаглалаар үлдэгдэл өгөөжүүд нь зах зээлийн хүчин зүйлтэй хамааралгүй, мөн өөр өөр хөрөнгүүдийн үлдэгдэл өгөөжүүд хоорондоо хамааралгүй байна. Өөрөөр хэлбэл,

$$\mathrm{Cov}(R_m, \varepsilon_i) = 0, \qquad i = 1, 2, \ldots, N,$$

ба

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0, \qquad i \neq j.$$

Эдгээр таамаглалын дор i болон j-р хөрөнгийн өгөөжийн ковариацыг

$$\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cov}(a_i + \beta_i R_m + \varepsilon_i, a_j + \beta_j R_m + \varepsilon_j)$$

гэж илэрхийлнэ.

Ковариацын чанарыг ашиглавал

$$\mathrm{Cov}(Y_i, Y_j) = \beta_i \beta_j \,\mathrm{Var}(R_m), \qquad i \neq j,$$

болно.

Харин i-р хөрөнгийн өгөөжийн вариац

$$\mathrm{Var}(Y_i) = \beta_i^2 \,\mathrm{Var}(R_m) + \mathrm{Var}(\varepsilon_i)$$

болно.

Зах зээлийн өгөөжийн түүврийн вариацыг

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2$$

гэж тооцно.

Мөн i-р хөрөнгийн регрессийн үлдэгдлийн вариацыг

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2$$

гэж тооцно.

Иймээс нэг хүчин зүйлийн зорилтот матриц $T_{\mathrm{SF}} = (t_{ij})$-ын элементүүдийг

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j \end{cases}$$

гэж тодорхойлно [Ledoit and Wolf, 2003].

Нэг хүчин зүйлийн зорилтот матрицыг матриц хэлбэрээр

$$T_{\mathrm{SF}} = \widehat{\boldsymbol{\beta}} \widehat{\boldsymbol{\beta}}^{\top} \widehat{\sigma}_m^2 + \widehat{D}_{\varepsilon}$$

гэж илэрхийлж болно.

Энд

$$\widehat{\boldsymbol{\beta}} = (\widehat{\beta}_1, \widehat{\beta}_2, \ldots, \widehat{\beta}_N)^\top$$

нь регрессийн коэффициентүүдийн вектор, харин

$$\widehat{D}_\varepsilon = \operatorname{diag}\left(\widehat{\sigma}^2_{\varepsilon,1}, \ldots, \widehat{\sigma}^2_{\varepsilon,N}\right)$$

нь үлдэгдлийн вариацуудаас бүрдэх диагональ матриц юм.

Нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}, \qquad 0 \le \widehat{\alpha}_{\mathrm{SF}} \le 1,$$

гэж тодорхойлно.

Энд $\widehat{\alpha}_{\mathrm{SF}}$ нь нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Ledoit and Wolf [2003] нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзэл, түүврийн ковариацын матриц болон зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзэл, мөн эдгээр матрицуудын хоорондын зайг харгалзан үзсэн.

Эхлээд түүврийн ковариацын матриц S болон нэг хүчин зүйлийн зорилтот матриц T_{SF} хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\mathrm{SF}} = \|S - T_{\mathrm{SF}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Дараа нь түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг нэгтгэн хэмжих хэмжигдэхүүнийг

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж тооцно.

Нэг хүчин зүйлийн зорилтот матриц нь түүврийн өгөгдлөөс үнэлэгддэг учраас S болон T_{SF} матрицуудын үнэлгээний алдаанууд хоорондоо хамааралтай байж болно.

Иймээс агшилтын эрчмийг тооцоход эдгээр үнэлгээний алдаануудын хам хэлбэлзлийг харгалзах шаардлагатай.

Энэ хам хэлбэлзлийн нөлөөг $\widehat{c}_{\mathrm{SF}}$ хэмжигдэхүүнээр илэрхийлнэ.

Нэг хүчин зүйлийн зорилтот матрицын диагональ элементүүд нь түүврийн ковариацын матрицын диагональ элементүүдтэй тэнцүү буюу $t_{ii} = s_{ii}$ байна.

Ledoit and Wolf [2003]-ийн Lemma 2-т үндэслэн үнэлгээний алдаануудын хам хэлбэлзлийг дараах байдлаар тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

Харин $i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big] \times$$

$$\times\Big[(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\Big].$$

Иймээс хам хэлбэлзлийн нийлбэрийн нормчилсон үнэлгээг

$$\widehat{c}_{\mathrm{SF}}=\frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тодорхойлно. Ингэснээр нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчмийг

$$\widehat{\alpha}_{\mathrm{SF}}=\max\left\{0,\min\left\{1,\frac{\widehat{b}_{\mathrm{SF}}-\widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}$$

гэж үнэлнэ.

Энэ нь Ledoit and Wolf [2003]-ийн асимптотик оновчтой агшилтын эрчмийн үнэлгээг нормчилсон квадрат Фробениусын зайд нийцүүлэн илэрхийлсэн хэлбэр юм.

Энд $\widehat{d}_{\mathrm{SF}}>0$ байхыг шаардана.

Эцэст нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\mathrm{SF}}=(1-\widehat{\alpha}_{\mathrm{SF}})S+\widehat{\alpha}_{\mathrm{SF}}T_{\mathrm{SF}}$$

гэж олно.

Тооцоолох алгоритм. Нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Зах зээлийн дундаж өгөөжийг тооцно.

$$\overline{R}_m=\frac{1}{n}\sum_{t=1}^{n}R_{m,t}.$$

2. Зах зээлийн өгөөжийн түүврийн вариацыг тооцно.

$$\widehat{\sigma}_m^2=\frac{1}{n}\sum_{t=1}^{n}(R_{m,t}-\overline{R}_m)^2.$$

3. Хөрөнгө тус бүрийн регрессийн коэффициентийг тооцно.

$$\widehat{\beta}_i=\frac{\sum_{t=1}^{n}(y_{ti}-\overline{Y}_i)(R_{m,t}-\overline{R}_m)}{\sum_{t=1}^{n}(R_{m,t}-\overline{R}_m)^2}.$$

4. Регрессийн тогтмол коэффициент болон үлдэгдлийг тооцно.

$$\widehat{a}_i=\overline{Y}_i-\widehat{\beta}_i\overline{R}_m,$$

$$\widehat{\varepsilon}_{ti}=y_{ti}-\widehat{a}_i-\widehat{\beta}_iR_{m,t}.$$

5. Хөрөнгө тус бүрийн үлдэгдлийн вариацыг тооцно.

$$\widehat{\sigma}_{\varepsilon,i}^2=\frac{1}{n}\sum_{t=1}^{n}\widehat{\varepsilon}_{ti}^2.$$

6. Нэг хүчин зүйлийн зорилтот матрицыг байгуулна.

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j. \end{cases}$$

Эдгээр элементүүдээр $T_{\mathrm{SF}} = (t_{ij})$ матрицыг байгуулна.

7. Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг тооцно.

$$\widehat{d}_{\mathrm{SF}} = \frac{1}{N} \sum_{i=1}^{N} \sum_{j=1}^{N} (s_{ij} - t_{ij})^2.$$

8. Түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг тооцно.

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right].$$

9. Түүврийн ковариацын матриц болон нэг хүчин зүйлийн зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзлийг тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\}^2.$$

$i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n} \sum_{t=1}^{n} \Big[\widehat{\beta}_j (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i (y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i \widehat{\beta}_j (R_{m,t} - \overline{R}_m)^2 - t_{ij} \Big] \times$$

$$\times \Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \Big].$$

Дараа нь

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \widehat{q}_{ij}$$

гэж тооцно.

10. Агшилтын эрчмийг тооцно.

$\widehat{d}_{\mathrm{SF}} > 0$ үед

$$\widehat{\alpha}_{\mathrm{SF}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\mathrm{SF}} - \widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}} \right\} \right\}.$$

11. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}}) S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}.$$

2.5 Шугаман бус агшилтын үнэлгээ

Шугаман агшилтын аргын хязгаарлалтыг даван туулах зорилгоор шугаман бус агшилтын (Nonlinear Shrinkage) аргуудыг боловсруулсан. Эдгээр аргууд нь түүврийн ковариацын матрицын спектрийн задлалд суурилдаг бөгөөд урьдчилан тодорхойлсон нэг зорилтот матриц руу бүхэлд нь агшаахын оронд түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засварладаг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U\Lambda U^\top$$

гэж тэмдэглэе. Энд $U = (u_1, u_2, \ldots, u_N)$ нь S матрицын хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь түүврийн ковариацын матрицын хувийн утгуудыг агуулсан диагональ матриц юм.

Шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\widehat{D}U^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d_1}, \widehat{d_2}, \ldots, \widehat{d_N})$$

нь агшааж засварласан хувийн утгуудаас бүрдэх диагональ матриц бөгөөд $\widehat{d_i}$ нь λ_i хувийн утгад харгалзах засварласан хувийн утга юм.

Шугаман бус агшилтын арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, харин хувийн утга бүрийг өгөгдөлд тулгуурлан ялгаатай хэмжээгээр засварладаг. Иймээс хувийн утгуудын хэмжээ болон тэдгээрийн спектрийн тархалт дахь байрлалаас хамааран агшилтын хэмжээ өөр өөр байж болно.

Шугаман агшилтын аргын хувьд түүврийн ковариацын матриц болон зорилтот матрицыг нэг агшилтын эрчмээр хослуулдаг бол шугаман бус агшилтын арга нь хувийн утга бүрд тусгайлан тохируулсан хувиргалт хийдгээрээ ялгаатай. Ингэснээр түүврийн ковариацын матрицын хувийн утгуудын үнэлгээний алдааг бууруулах боломжийг олгодог.

Ledoit болон Wolf (2012) нар шугаман бус агшилтын аргын онолын үндэслэлийг боловсруулж, улмаар Ledoit болон Wolf (2015) нар QuEST (Quantized Eigenvalues Sampling Transform) алгоритмд суурилсан тоон хэрэгжилтийг хөгжүүлсэн. Энэхүү арга нь тоон оновчлол шаарддаг тул тооцооллын хувьд харьцангуй төвөгтэй байдаг.

Үүний дараа Ledoit and Wolf [2020] санамсаргүй матрицын онол болон спектрийн тархалтын шинж чанарт тулгуурласан аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн утгуудыг аналитик илэрхийлэлд суурилан засварладаг. Энэхүү судалгаанд аналитик шугаман бус агшилтын аргыг ашиглах бөгөөд түүний математик үндэслэл болон тооцоолох алгоритмыг дараагийн хэсэгт авч үзнэ.

2.5.1 Аналитик шугаман бус агшилтын үнэлгээ

Аналитик шугаман бус агшилтын үнэлгээ (Analytical Nonlinear Shrinkage Estimation) нь санамсаргүй матрицын онол (Random Matrix Theory)-д тулгуурлан түүврийн ковариацын матрицын хувийн утгуудыг засварлах арга юм. Шугаман агшилтын аргуудаас ялгаатай нь энэхүү арга нь хувийн утга бүрийн хэмжээ болон спектрийн тархалт дахь байрлалыг харгалзан ялгаатай агшилт хийдэг.

Ledoit and Wolf [2020] нь спектрийн тархалтын нягт болон түүний Hilbert хувиргалтыг kernel аргаар үнэлэх замаар аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж,

хувийн утгуудыг засварлах замаар ковариацын матрицын үнэлгээний алдааг бууруулахад чиглэдэг.

Судалгаанд хамрагдсан хөрөнгийн тоог N, ажиглалтын тоог n гэж тэмдэглэж, тэдгээрийн харьцааг

$$c = \frac{N}{n}$$

гэж тодорхойлно. Аргын үндсэн онолын хувьд $N, n \to \infty$ үед

$$\frac{N}{n} \longrightarrow c \in (0, 1)$$

байх асимптотик нөхцөлийг авч үздэг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U \Lambda U^\top$$

гэж тэмдэглэе. Энд

$$U = (u_1, u_2, \ldots, u_N), \qquad U^\top U = I_N,$$

нь хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \operatorname{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь хувийн утгуудыг агуулсан диагональ матриц юм. Хувийн утгуудыг

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_N > 0$$

гэж эрэмбэлнэ.

Аналитик шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U \widehat{D} U^\top = \sum_{i=1}^{N} \widehat{d}_i u_i u_i^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \operatorname{diag}(\widehat{d}_1, \ldots, \widehat{d}_N)$$

нь агшсан хувийн утгуудаас бүрдэх диагональ матриц юм.

Агшсан хувийн утгуудын үнэлгээ. Ledoit and Wolf [2020]-ийн (4.3) томьёоны дагуу агшсан хувийн утгуудыг

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}$$

гэж тооцно.

Энд $\widehat{f}(\lambda_i)$ нь спектрийн тархалтын нягтын үнэлгээ, $\widehat{Hf}(\lambda_i)$ нь уг нягтын Hilbert хувиргалтын үнэлгээ юм. Эдгээрийг түүврийн ковариацын матрицын хувийн утгуудад тулгуурлан kernel аргаар тооцдог.

Иймээс агшсан хувийн утга нь зөвхөн тухайн λ_i-ийн хэмжээнээс бус, спектрийн тархалтын нягт болон түүний Hilbert хувиргалтын утгаас хамаарна.

Тооцоолох алгоритм. Ledoit and Wolf [2020]-ийн Section 4.7-д үндэслэн аналитик шугаман бус агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Түүврийн ковариацын матрицын спектрийн задлалыг байгуулна.

$$S = U\Lambda U^\top.$$

2. Хөрөнгийн тоо болон ажиглалтын тооны харьцааг тооцно.

$$c = \frac{N}{n}.$$

3. Спектрийн нягтыг үнэлэхэд ашиглах bandwidth параметрийг

$$h = n^{-1/3}$$

гэж сонгоно. Хувийн утга бүрд харгалзах локал bandwidth нь

$$h_j = \lambda_j h, \qquad j = 1, \dots, N$$

байна.

4. Спектрийн нягтыг Epanechnikov kernel ашиглан үнэлнэ.

$$\widehat{f}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} k\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд

$$k(x) = \begin{cases} \dfrac{3}{4\sqrt{5}}\left(1 - \dfrac{x^2}{5}\right), & |x| \le \sqrt{5}, \\ 0, & |x| > \sqrt{5}. \end{cases}$$

5. Спектрийн нягтын Hilbert хувиргалтыг үнэлнэ.

$$\widehat{Hf}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{h_j} \ell\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд $\ell(x) = Hk(x)$ бөгөөд

$$\ell(x) = \begin{cases} -\dfrac{3x}{10\pi} + \dfrac{3}{4\sqrt{5}\pi}\left(1 - \dfrac{x^2}{5}\right)\ln\left|\dfrac{\sqrt{5} - x}{\sqrt{5} + x}\right|, & |x| \ne \sqrt{5}, \\ -\dfrac{3x}{10\pi}, & |x| = \sqrt{5}. \end{cases}$$

6. Агшсан хувийн утгуудыг тооцно.

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}.$$

7. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\,\mathrm{diag}(\widehat{d}_1, \dots, \widehat{d}_N)U^\top.$$

2.6 Эмпирик үнэлгээний арга зүй

Энэхүү судалгаанд түүврийн ковариацын матриц болон агшилтын таван үнэлэгчийг ижил long-only GMVP загварын хүрээнд түүврээс гадуурх (out-of-sample, OOS) гүйцэтгэлээр харьцуулна. Ковариацын матрицын үнэлгээний алдаа бага байх нь багцын бодит эрсдэл заавал бага байна гэсэн үг биш тул үнэлэгчдийн гүйцэтгэлийг багцын түвшинд үнэлэх шаардлагатай.

Энэ зорилгоор [??] судалгаанд хэрэглэсэн эмпирик үнэлгээний зарчимд тулгуурлан шилжих цонхны аргыг ашиглана. Бүх үнэлэгчийн хувьд хөрөнгө оруулалтын хязгаарлалт, түүврээс гадуурх үнэлгээний хугацаа болон гүйцэтгэлийн шалгуурыг ижил байлгана.

2.6.1 Шилжих цонхны аргаар түүврээс гадуурх үнэлгээ хийх

Шилжих цонхны (rolling-window) арга нь тогтмол урттай түүхэн өгөгдлөөр ковариацын матрицыг үнэлж, багцын жинг тодорхойлсны дараа уг жинг дараагийн сарын өгөөжид хэрэглэнэ.

Нийт сарын өгөөжийн ажиглалтын тоог n, хөрөнгийн тоог N, сургалтын цонхны уртыг T гэж тэмдэглэе. t сарын өгөөжийн вектор нь

$$\boldsymbol{R}_t = (R_{1,t}, R_{2,t}, \ldots, R_{N,t})^\top.$$

t сарын эцэст ашиглах сургалтын өгөгдлийг

$$\mathcal{D}_t = \{\boldsymbol{R}_{t-T+1}, \ldots, \boldsymbol{R}_t\}, \qquad t = T, \ldots, n-1$$

гэж тодорхойлно.

Ковариацын матрицын үнэлэгчийг $k = 0, 1, \ldots, 5$ гэж тэмдэглэе. Энд $k = 0$ нь түүврийн ковариацын матриц, $k = 1, \ldots, 5$ нь агшилтын үнэлэгчид юм. Сургалтын цонх бүрд ковариацын матрицыг

$$\widehat{\boldsymbol{\Sigma}}_t^{(k)} = \widehat{\boldsymbol{\Sigma}}^{(k)}(\mathcal{D}_t)$$

гэж үнэлнэ. Нэг хүчин зүйлийн үнэлэгчийн хувьд сургалтын цонхтой ижил хугацааны зах зээлийн индексийн өгөөжийг нэмж ашиглана.

Үнэлсэн ковариацын матрицад үндэслэн багцын оновчтой жинг

$$\begin{aligned} \widehat{\boldsymbol{w}}_t^{(k)} \in \arg\min_{\boldsymbol{w}} \quad & \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}}_t^{(k)} \boldsymbol{w}, \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{w} = 1, \\ & w_i \geq 0, \qquad i = 1, \ldots, N \end{aligned}$$

гэсэн long-only GMVP бодлогоор тодорхойлно.

Тэгвэл дараагийн сарын багцын өгөөж нь

$$r_{p,t+1}^{(k)} = \left(\widehat{\boldsymbol{w}}_t^{(k)}\right)^\top \boldsymbol{R}_{t+1}$$

байна.

Сургалтын цонхыг сар бүр нэг алхмаар урагшлуулж, ковариацын матриц, агшилтын эрчим болон багцын жинг дахин тооцно. Ирээдүйн өгөөжийг параметрийн үнэлгээнд ашиглахгүй.

Үндсэн шинжилгээнд $N = 10$, $n = 172$, $T = 120$ тул түүврээс гадуурх ажиглалтын тоо

$$M = n - T = 172 - 120 = 52$$

байна. Ийнхүү үнэлэгч бүрийн хувьд ижил 52 сарын OOS өгөөжийн цуваа үүсгэнэ.

2.6.2 Багцын гүйцэтгэлийн үзүүлэлтүүд

Ковариацын үнэлэгчдийн гүйцэтгэлийг OOS хэлбэлзэл, харьцангуй вариацын бууралт (RVR) болон Sharpe-ийн харьцаагаар үнэлнэ.

Түүврээс гадуурх хэлбэлзэл (Out-of-Sample Volatility). k-р үнэлэгчээр байгуулсан багцын дундаж сарын өгөөж болон түүврийн вариацыг

$$\overline{r}_p^{(k)} = \frac{1}{M}\sum_{t=T+1}^{n} r_{p,t}^{(k)},$$

$$\widehat{\sigma}_{p,k}^2 = \frac{1}{M-1}\sum_{t=T+1}^{n}\left(r_{p,t}^{(k)} - \overline{r}_p^{(k)}\right)^2$$

гэж тодорхойлно.

Тэгвэл сарын болон жилийн хэлбэлзэл нь

$$\widehat{\sigma}_{p,k} = \sqrt{\widehat{\sigma}_{p,k}^2}, \qquad \widehat{\sigma}_{p,k}^{ann} = \sqrt{12}\,\widehat{\sigma}_{p,k}$$

байна. Жилийн хэлбэлзэлд шилжүүлэхдээ сарын өгөөжүүдийн автоковариацыг тэг гэж үзнэ.

Харьцангуй вариацын бууралт (Relative Variance Reduction). Агшилтын үнэлэгчийн OOS вариацыг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулж,

$$RVR_k^{(\%)} = 100\left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,0}^2}\right), \qquad k = 1,\ldots,5$$

гэж тооцно.

$RVR_k^{(\%)} > 0$ бол агшилтын үнэлэгчийн багц суурь загвараас бага вариацтай, харин $RVR_k^{(\%)} < 0$ бол их вариацтай байна.

Sharpe-ийн харьцаа (Sharpe Ratio). Сарын эрсдэлгүй өгөөжийг $r_{f,t}$ гэвэл илүүдэл өгөөж нь

$$r_{e,t}^{(k)} = r_{p,t}^{(k)} - r_{f,t}$$

байна. Сарын Sharpe-ийн харьцааг

$$\widehat{SR}_k = \frac{\overline{r}_e^{(k)}}{\widehat{\sigma}_{e,k}}$$

гэж тодорхойлно.

Энэхүү судалгаанд $r_{f,t} = 0$ гэж авч үзсэн тул

$$\widehat{SR}_k = \frac{\overline{r}_p^{(k)}}{\widehat{\sigma}_{p,k}}, \qquad \widehat{SR}_k^{ann} = \sqrt{12}\,\widehat{SR}_k.$$

Жилийн Sharpe-ийн харьцаанд шилжүүлэхдээ мөн сарын өгөөжийн автоковариацыг тэг гэж үзнэ. GMVP-ийн зорилго нь вариацыг хамгийн бага байлгах тул Sharpe-ийн харьцааг нэмэлт гүйцэтгэлийн үзүүлэлт болгон ашиглана.

2.6.3 Багцын жингийн тогтвортой байдал ба эргэлт

Ковариацын үнэлэгчийн сонголт нь багцын жингийн бүтэц болон дахин тэнцвэржүүлэлтийн хэмжээнд нөлөөлж болох тул багцын эргэлт, жингийн төвлөрлийг үнэлнэ.

Багцын эргэлт (Portfolio Turnover). t сард ашиглах багцын жинг $\widehat{\boldsymbol{w}}_{t-1}^{(k)}$ гэж тэмдэглэе. Тухайн сарын өгөөж хэрэгжсэний дараах, дахин тэнцвэржүүлэхээс өмнөх жин нь

$$\widetilde{w}_{i,t}^{(k)} = \frac{\widehat{w}_{i,t-1}^{(k)}(1+R_{i,t})}{1+r_{p,t}^{(k)}}$$

байна.

Дараагийн сард ашиглах шинэ оновчтой жинд шилжихэд шаардагдах багцын эргэлтийг

$$TO_t^{(k)} = \frac{1}{2}\sum_{i=1}^{N}\left|\widehat{w}_{i,t}^{(k)} - \widetilde{w}_{i,t}^{(k)}\right|$$

гэж тодорхойлно.

Түүврээс гадуурх дундаж эргэлт нь

$$\overline{TO}^{(k)} = \frac{1}{M-1}\sum_{t=T+1}^{n-1} TO_t^{(k)}$$

байна.

Ийнхүү 52 сарын OOS хугацаанд 51 удаагийн дахин тэнцвэржүүлэлтийг тооцно. Эхний багц бүрдүүлэлтийг эргэлтийн тооцоонд оруулахгүй. Энд тооцсон үндсэн OOS өгөөж нь арилжааны зардлын өмнөх өгөөж юм. Арилжааны зардлын нөлөөг нэмэлт шинжилгээнд тусад нь үнэлнэ.

Багцын жингийн төвлөрөл (Weight Concentration). Жингийн төвлөрлийг Herfindahl–Hirschman Index (HHI)-ээр

$$HHI_t^{(k)} = \sum_{i=1}^{N}\left(\widehat{w}_{i,t}^{(k)}\right)^2$$

гэж хэмжинэ.

Long-only GMVP-ийн хувьд

$$\frac{1}{N} \le HHI_t^{(k)} \le 1.$$

Түүврээс гадуурх дундаж төвлөрөл нь

$$\overline{HHI}^{(k)} = \frac{1}{M}\sum_{t=T}^{n-1} HHI_t^{(k)}$$

байна. HHI өндөр байх нь багцын жин цөөн хөрөнгөд төвлөрснийг илэрхийлнэ.

2.6.4 Ковариацын үнэлэгчдийн статистик харьцуулалт

Агшилтын үнэлэгчдийн OOS гүйцэтгэлийн ялгааг түүврийн ковариацын матрицад суурилсан GMVP-тэй харьцуулан статистикаар үнэлнэ.

k-р агшилтын үнэлэгч болон суурь загварын сарын квадрат өгөөжийн ялгааг

$$d_t^{(k)} = \left(r_{p,t}^{(k)}\right)^2 - \left(r_{p,t}^{(0)}\right)^2, \qquad t = T+1, \ldots, n$$

гэж тодорхойлно.

Дараах хоёр талт таамаглалыг шалгана:

$$H_0 : E[d_t^{(k)}] = 0, \qquad H_1 : E[d_t^{(k)}] \neq 0.$$

Дундаж ялгааны стандарт алдааг Newey–West төрлийн HAC аргаар, гурван лаг ашиглан үнэлнэ. Шалгах статистик нь

$$t_{HAC}^{(k)} = \frac{\overline{d}^{(k)}}{\widehat{SE}_{HAC}(\overline{d}^{(k)})}, \qquad \overline{d}^{(k)} = \frac{1}{M}\sum_{t=T+1}^{n} d_t^{(k)}$$

байна.

Хоёр талт p-утгыг асимптотик нормаль ойролцооллоор тооцож, таван агшилтын үнэлэгчийг суурь загвартай харьцуулсан олон шалгалтад Holm-ийн засвар хэрэглэнэ.

Квадрат өгөөжийн дундаж ялгаа нь вариацын ялгаатай заавал тэнцүү биш. Учир нь

$$E[r_p^2] = \mathrm{Var}(r_p) + (E[r_p])^2 .$$

Иймээс HAC шалгалтыг RVR болон OOS хэлбэлзлийн үр дүнтэй хамтатган тайлбарлана. Мөн OOS хугацаа 52 сар тул статистик шалгалтын чадал хязгаарлагдмал байж болно.

2.6.5 Хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцааны мэдрэмжийн шинжилгээ

Ковариацын матрицын үнэлгээний алдаа нь хөрөнгийн тоо N болон сургалтын ажиглалтын тоо T-ийн харьцаанаас хамаарч болно. Уг харьцааг

$$c = \frac{N}{T}$$

гэж тодорхойлно.

Энэхүү судалгаанд $N = 10$ гэж тогтмол байлгаж,

$$T \in \{60, 90, 120\}$$

гэсэн сургалтын цонхуудыг авч үзнэ. Харгалзах N/T харьцаа нь

$$\frac{10}{60} \approx 0.1667, \qquad \frac{10}{90} \approx 0.1111, \qquad \frac{10}{120} \approx 0.0833$$

байна.

Сургалтын цонхны уртаас үүдэх OOS хугацааны ялгааг арилгахын тулд бүх хувилбарт хамгийн урт сургалтын цонхонд харгалзах ижил 52 сарын OOS хугацааг ашиглана.

Цонхны урт бүрд зургаан үнэлэгчийг дахин тооцож, багцын хэлбэлзэл, RVR, Sharpe-ийн харьцаа, эргэлт болон төвлөрлийг харьцуулна.

Энэ шинжилгээнд N тогтмол тул N/T харьцааны өөрчлөлт нь сургалтын цонхны уртын өөрчлөлттэй давхцана. Иймээс тэдгээрийн нөлөөг бүрэн тусгаарлан тайлбарлахгүй.

2.6.6 Багцын сонголтын robustness шинжилгээ

Агшилтын үнэлэгчдийн гүйцэтгэл сонгосон хөрөнгүүдийн бүрэлдэхүүнээс хамаарах эсэхийг үнэлэхийн тулд корреляцын ялгаатай бүтэцтэй 150 багцад шинжилгээг давтан гүйцэтгэнэ.

Сарын өгөөжийн бүрэн өгөгдөлтэй 337 хувьцаанаас тус бүр 10 хөрөнгөтэй багцуудыг сонгоно. Корреляцыг эхний 120 сарын сургалтын өгөөжөөр тооцож, багцын дундаж хос корреляцыг

$$\overline{\rho} = \frac{2}{N(N-1)} \sum_{i<j} \rho_{ij}$$

гэж тодорхойлно.

Багцуудыг өндөр (High), дунд (Medium), бага (Low) корреляцтай гурван ангиллаар авч үзнэ. Үндсэн шинжилгээнд сонгосон High, Medium, Low багцуудын эхний 120 сарын өгөөжөөр тооцсон дундаж хос корреляц нь харгалзан 0.557048, 0.303609, 0.101523 байна. Robustness шинжилгээнд эдгээр утгыг зорилтот корреляц болгон ашиглана.

Багц сонгохдоо 337 хувьцаанаас 10 хувьцааг буцаалтгүйгээр санамсаргүй сонгох туршилтыг 250000 удаа гүйцэтгэж, давхардсан нэр дэвшигч багцуудыг хасна.

Үлдсэн багцуудыг зорилтот корреляцаас хазайх абсолют зөрүүгээр эрэмбэлж, ангилал бүрд 50 багц сонгоно. Нэг ангиллын сонгогдсон дурын хоёр багцын нийтлэг хувьцааны тоо зургаагаас хэтрэхгүй байх хязгаарлалт тавина.

Ийнхүү сонгосон 150 багц бүрд зургаан үнэлэгчээр long-only GMVP байгуулж, 120 сарын шилжих цонх болон ижил 52 сарын OOS хугацаагаар үнэлнэ. Багц сонгох үе шатанд OOS өгөөжийг ашиглахгүй.

Багц тус бүрийн RVR-ийг тооцож, ангилал бүрийн дундаж, медиан болон эерэг RVR-тэй багцын эзлэх хувийг харьцуулна.

Эдгээр 150 багц нь бүх боломжит 10 хувьцаатай багцуудаас энгийн санамсаргүй түүврийн аргаар сонгогдоогүй, харин зорилтот корреляцын түвшинд ойр байх нөхцөлөөр сонгогдсон болохыг үр дүнг тайлбарлахдаа харгалзан үзнэ.

2.6.7 RVR-ийн bootstrap итгэх завсар

150 багцын robustness шинжилгээнд ажиглагдсан дундаж RVR-ийн тодорхой бус байдлыг үнэлэхийн тулд circular moving-block bootstrap аргыг ашиглана.

Корреляцын ангиллыг $g \in \{H, M, L\}$, тухайн ангиллын багцын тоог $P_g = 50$ гэж тэмдэглэе. j-р багцын k-р үнэлэгчийн RVR-ийг $RVR_{g,j,k}^{(\%)}$ гэвэл ангиллын дундаж RVR нь

$$\overline{RVR}_{g,k}^{(\%)} = \frac{1}{P_g} \sum_{j=1}^{P_g} RVR_{g,j,k}^{(\%)}$$

байна.

Bootstrap давталт бүрд 52 сарын OOS хугацаанаас зургаан сарын урттай блокуудын эхлэх байрлалыг санамсаргүй сонгоно. Блокийг цувааны төгсгөлд хүрвэл эхлэлээс үргэлжлүүлэх circular зарчмаар байгуулж, сонгосон блокуудыг нэгтгэн 52 ажиглалттай түүвэр үүсгэнэ.

Тухайн давталтад сонгосон сарын индексүүдийг бүх 150 багц болон зургаан үнэлэгчид ижил хэрэглэнэ. Ингэснээр багцуудын өгөөжийн хоорондын хамаарлыг дахин түүвэрлэх явцад хадгална.

Bootstrap түүвэр бүрд багц тус бүрийн OOS вариац, RVR болон ангиллын дундаж RVR-ийг шинээр тооцно.

Нийт $B = 3000$ давталт гүйцэтгэж, давталтуудаас гарсан дундаж RVR-ийн тархалтын 2.5 болон 97.5 хувийн квантилуудаар 95%-ийн percentile bootstrap итгэх завсрыг байгуулна.

Итгэх завсар тэгийг агуулаагүй тохиолдолд тухайн ангиллын дундаж RVR тэгээс ялгаатай байж болохыг илтгэх боловч энэ нь олон харьцуулалтын засвартай шалгалттай адил биш. Эдгээр нь олон харьцуулалтын засвар хийгдээгүй итгэх завсрууд тул үр дүнг болгоомжтой тайлбарлана.

Харин итгэх завсар тэгийг агуулсан тохиолдолд эерэг эсвэл сөрөг нөлөөг статистикийн хувьд баталгаатай гэж дүгнэхгүй.

Энэхүү bootstrap шинжилгээнд сонгосон 150 багцын бүрэлдэхүүнийг тогтмол байлгаж, зөвхөн OOS хугацааны ажиглалтуудыг дахин түүвэрлэнэ.

Иймээс итгэх завсар нь тухайн сонгосон багцуудын OOS гүйцэтгэлийн тодорхой бус байдлыг илэрхийлэх бөгөөд бүх боломжит хувьцааны багцад шууд ерөнхийлөх үндэслэл болохгүй.

2.6.8 Тэнцүү жинтэй багц ба арилжааны зардлын шинжилгээ

GMVP загваруудын практик гүйцэтгэлийг харьцуулах нэмэлт жишиг болгон хөрөнгө бүрд ижил жин оноодог $1/N$ багцыг ашиглана. Тухайн багцын зорилтот жин нь

$$\boldsymbol{w}^{EW} = \frac{1}{N}\mathbf{1}, \qquad N = 10,$$

бөгөөд сарын эхэнд дахин тэнцвэржүүлж, зорилтот жинг хадгална. Иймээс t сарын жишиг багцын зардлын өмнөх өгөөж нь

$$r_{p,t}^{EW} = \left(\boldsymbol{w}^{EW}\right)^{\top} \boldsymbol{R}_t = \frac{1}{N}\sum_{i=1}^{N} R_{i,t}.$$

$1/N$ багц болон зургаан GMVP загварт OOS хугацаа, жилийн хэлбэлзэл, Sharpe-ийн харьцаа, багцын эргэлт, HHI үзүүлэлтийг ижил аргачлалаар тооцно. Тэнцүү жинтэй багцын төвлөрөл нь бүх сард $HHI^{EW} = 1/N$ байна.

Арилжааны зардлыг тооцохдоо нэг талын арилжааны зардлын хувь хэмжээг c гэж тэмдэглэж, $c \in \{0, 5, 10, 25\}$ суурь пункт (basis points) гэсэн хувилбаруудыг авч үзнэ. Энд нэг суурь пункт нь 0.0001-тэй тэнцэнэ.

Өмнөх сарын өгөөж хэрэгжсэний дараах жин $\widetilde{\boldsymbol{w}}_t^{(k)}$ болон шинэ зорилтот жингийн ялгаагаар тооцсон $TO_t^{(k)}$ нь нийт худалдан авалт эсвэл нийт борлуулалтын эзлэх хувийг илэрхийлнэ. Тиймээс нэг талын зардлын хувь c үед хоёр талын нийт арилжааны зардлын хувь нь

$$C_t^{(k)} = 2c\,TO_t^{(k)}$$

байна. Тухайн сарын эхэнд зардлыг суутгасан гэж үзвэл цэвэр өгөөж нь

$$r_{p,t}^{(k),net} = \left(1 - C_t^{(k)}\right)\left(1 + r_{p,t}^{(k)}\right) - 1,$$

энд $k \in \{0, 1, \ldots, 5, EW\}$.

OOS эхний сарын багцыг анх бүрдүүлэх арилжааны зардлыг тооцохгүй, өөрөөр хэлбэл $C_{T+1}^{(k)} = 0$ гэж авна. Үлдсэн 51 сарын дахин тэнцвэржүүлэлтийн зардлыг тооцно. Арилжааны зардлын хувилбар бүрд цэвэр өгөөжийн цуваагаар жилийн хэлбэлзэл, Sharpe-ийн харьцаа, хуримтлагдсан өгөөжийг дахин үнэлнэ. Хуримтлагдсан цэвэр өгөөжийг

$$CR_k^{net} = \prod_{t=T+1}^{n}\left(1 + r_{p,t}^{(k),net}\right) - 1$$

гэж тодорхойлно.

2.6.9 GMVP ба тэнцүү жинтэй багцын bootstrap харьцуулалт

Үндсэн High, Medium, Low багц тус бүрд зургаан GMVP загварын OOS вариацыг $1/N$ багцын вариацтай харьцуулна. k-р GMVP загварын $1/N$ багцтай харьцуулсан дисперсийн бууралтыг

$$RVR_{k|EW}^{(\%)} = 100\left(1 - \frac{\widehat{\sigma}_{p,k}^2}{\widehat{\sigma}_{p,EW}^2}\right), \qquad k = 0, \ldots, 5$$

гэж тодорхойлно. Энэ үзүүлэлтийн суурь нь өмнөх хэсгийн Sample GMVP биш, харин $1/N$ багц юм.

Тодорхой бус байдлыг үнэлэхдээ 52 сарын OOS өгөөжид зургаан сарын блокийн урттай circular moving-block bootstrap аргыг хэрэглэнэ. Нэг багцын долоон стратегийн (зургаан GMVP болон $1/N$) өгөөжийг нэг ижил сарын индексээр дахин түүвэрлэж, стратегиудын хоорондын хос хамаарлыг хадгална.

Нийт $B = 3000$ давталт бүрд түүврийн вариац ($M-1$ хуваарьтай) болон $RVR_{k|EW}^{(\%)}$-ийг шинээр тооцно. Bootstrap тархалтын 2.5 ба 97.5 хувийн квантилуудаар засвар хийгдээгүй 95%-ийн percentile итгэх завсар байгуулна.

Мөн тэг таамаглал $H_0 : RVR_{k|EW}^{(\%)} = 0$-ийг хоёр талт, ажиглагдсан статистикийн эргэн тойронд төвлөрүүлсэн bootstrap ойролцооллоор үнэлнэ. Ажиглагдсан RVR-ийг $\widehat{\theta}$, bootstrap давталтын RVR-ийг $\widehat{\theta}^{*(b)}$ гэвэл тооцоолсон p-утга нь

$$\widehat{p}_{boot} = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{\left|\widehat{\theta}^{*(b)} - \widehat{\theta}\right| \geq \left|\widehat{\theta}\right|\right\}}{B+1}.$$

Нэг үндсэн багц дахь зургаан GMVP–$1/N$ харьцуулалтын p-утгуудад Holm-ийн засвар хэрэглэнэ. Гурван багцын нийт 18 шалгалтыг нэг гэр бүл болгон засварлахгүй. Percentile итгэх завсар болон төвлөрүүлсэн bootstrap p-утга нь нэг шалгалтын харилцан урвуу хувилбар биш тул тэдгээрийн дүгнэлт зарим тохиолдолд зөрж болно.

Энэ шинжилгээ нь зөвхөн үндсэн гурван багцын зардлын өмнөх OOS өгөөжид тулгуурлана. Иймээс арилжааны зардлын дараах гүйцэтгэлийн статистик шалгалт гэж тайлбарлахгүй. OOS хугацаа 52 сар болохыг үр дүнгийн тодорхой бус байдлыг тайлбарлахдаа харгалзан үзнэ.

3 Өгөгдөл

Энэхүү судалгаанд ковариацын матрицын агшилтын үнэлэгчдийн гүйцэтгэлийг хөрөнгүүдийн хоорондын корреляцын ялгаатай бүтэцтэй багцуудад харьцуулах зорилгоор АНУ-ын S&P 500 индексийн түүхэн бүрэлдэхүүнээс сонгосон хувьцааны сарын өгөөжийг ашигласан.

Нэр дэвшигч хувьцаануудыг S&P 500 индексийн түүхэн бүрэлдэхүүний нээлттэй өгөгдлийн сангаас 2012 оны 5 дугаар сарын 30-ны өдрийн байдлаар сонгосон [chinobing]. Тухайн жагсаалтад 453 хувьцааны код байсан бөгөөд 2012 оны 5 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх сарын эцсийн үнийн мэдээлэл бүрэн байгаа 337 хувьцааг шинжилгээнд хамруулсан.

Хувьцааны үнийн өгөгдлийг Yahoo Finance мэдээллийн сангаас Python программчлалын хэлний `yfinance` сангаар татаж, `auto_adjust=True` тохиргоогоор ногдол ашиг болон хувьцаа хуваалтын нөлөөг харгалзан үзсэн. Хувьцаа тус бүрийн сарын энгийн өгөөжийг

$$R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

гэж тооцсон. Энд $P_{i,t}$ нь i-р хувьцааны t сарын эцсийн тохируулгатай хаалтын үнэ юм.

Судалгаанд 2012 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх нийт $n = 172$ сарын өгөөжийг ашигласан. Багцуудыг сонгохдоо 2012 оны 6 дугаар сараас 2022 оны 5 дугаар сар хүртэлх эхний 120 сарын өгөөжид үндэслэн хөрөнгүүдийн хоорондын корреляцыг тооцсон.

Үндсэн шинжилгээнд дундаж хос корреляц өндөр, дунд болон бага байх тус бүр 10 хувьцаатай, хоорондоо давхцахгүй гурван багцыг Monte Carlo хайлтын аргаар байгуулсан. Дунд корреляцын зорилтот түвшнийг 337 хувьцааны бүх хосын дундаж корреляцаар тодорхойлсон.

Хүснэгт 1: Үндсэн шинжилгээнд сонгосон багцуудын шинж чанар

Үзүүлэлт	Өндөр	Дунд	Бага
Хөрөнгийн тоо	10	10	10
Дундаж корреляц	0.5570	0.3036	0.1015
Нөхцөлт тоо	72.99	16.82	27.45

Өндөр корреляцтай багцад CCL, CME, COF, CTAS, FLS, MET, PRU, SWK, UNM, WFC; дунд корреляцтай багцад AMGN, AMT, BEN, DTE, EXPD, MO, MRK, PG, SNA, UPS; бага корреляцтай багцад BAX, BIIB, CTSH, GNW, HRB, MTB, NEM, QCOM, RRC, WEC хувьцаанууд сонгогдсон.

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг шалгах зорилгоор нэмэлт 150 багц сонгосон. Үүнд өндөр, дунд, бага корреляцын ангилал тус бүрээс 50 багц хамруулсан. Багцуудыг эхний 120 сарын өгөөжид үндэслэн Monte Carlo хайлтын аргаар сонгож, нэг ангиллын хоёр багцад хамгийн ихдээ зургаан ижил хувьцаа байх нөхцөл тавьсан. Сонголтын дэлгэрэнгүй аргачлалыг 2.6.6 хэсэгт тайлбарласан.

Үндсэн шинжилгээнд ковариацын матрицыг $T = 120$ сарын шилжих цонхоор үнэлж, 2022 оны 6 дугаар сараас 2026 оны 9 дүгээр сар хүртэлх $M = 52$ сарын түүврээс гадуурх (OOS) гүйцэтгэлийг харьцуулсан. Сонгосон багц бүрийн хувьцааны бүрэлдэхүүнийг OOS хугацаанд тогтмол хадгалж, багцын оновчтой жинг сар бүр шинэчилсэн.

Судалгааны нэг хязгаарлалт нь шинжилгээний бүх хугацаанд үнийн мэдээлэл бүрэн байгаа хувьцаануудыг сонгосон явдал юм. Энэ нь survivorship bias болон ирээдүйн мэдээлэлд тулгуурласан сонголтын хазайлт үүсгэж болзошгүй тул үр дүнг тайлбарлахдаа уг хязгаарлалтыг харгалзан үзнэ.

4 Эмпирик судалгааны үр дүн

Энэ хэсэгт ковариацын матрицын зургаан үнэлэгчийн гүйцэтгэлийг корреляцын бүтэц ялгаатай багцуудад харьцуулна. Үндсэн шинжилгээнд 120 сарын сургалтын цонх, 52 сарын түүврээс гадуурх (OOS) өгөөжийг ашигласан. Үр дүнгийн тогтвортой байдлыг сургалтын цонхны мэдрэмжийн шинжилгээ, нэмэлт 150 багц болон bootstrap аргаар шалгав. Мөн тэнцүү жинтэй $1/N$ жишиг багц, арилжааны зардлын нөлөө болон GMVP–$1/N$ харьцуулалтын bootstrap үр дүнг авч үзэв.

4.1 Сонгосон багцуудын шинж чанар

Үндсэн шинжилгээнд сонгосон гурван багцын корреляцын бүтэц болон түүврийн ковариацын матрицын нөхцөлт тоог Хүснэгт 2-д үзүүлэв.

High багцын дундаж корреляц болон нөхцөлт тоо хамгийн өндөр байна. Харин Low багцын нөхцөлт тоо Medium багцынхаас өндөр байгаа нь дундаж корреляц бага

Хүснэгт 2: Үндсэн шинжилгээний багцуудын шинж чанар

Багц	Хөрөнгийн тоо	Дундаж корреляц	Нөхцөлт тоо
High	10	0.5570	72.99
Medium	10	0.3036	16.82
Low	10	0.1015	27.45

байх нь ковариацын матрицын нөхцөлт тоо заавал бага байна гэсэн үг биш болохыг харуулна.

4.2 Ковариацын үнэлэгчдийн OOS гүйцэтгэл

Ковариацын үнэлэгчдийн жилд шилжүүлсэн хэлбэлзэл, харьцангуй дисперсийн бууралт (RVR) болон Sharpe-ийн харьцааг Хүснэгт 3-д үзүүлэв.

Хүснэгт 3: Ковариацын үнэлэгчдийн OOS гүйцэтгэл ($T = 120$)

Багц	Үнэлэгч	Жилийн хэлбэлзэл	RVR (%)	Sharpe
High	Sample	0.1705	0.00	0.7877
	Var	0.1655	5.81	0.8435
	Diag	0.1678	3.18	0.8159
	Corr	0.1716	-1.26	0.8207
	SF	0.1666	4.56	0.8192
	NLS	0.1690	1.70	0.8011
Medium	Sample	0.1428	0.00	0.6006
	Var	0.1427	0.15	0.6117
	Diag	0.1426	0.35	0.6035
	Corr	0.1412	2.26	0.5550
	SF	0.1416	1.65	0.5774
	NLS	0.1419	1.27	0.6035
Low	Sample	0.1377	0.00	0.2687
	Var	0.1526	-22.70	0.3925
	Diag	0.1432	-8.11	0.2549
	Corr	0.1505	-19.47	0.1109
	SF	0.1465	-13.13	0.1905
	NLS	0.1399	-3.24	0.3132

High багцад Var үнэлэгчийн RVR хамгийн өндөр буюу 5.81%, Medium багцад Corr үнэлэгчийнх 2.26% байна. Харин Low багцад агшилтын бүх үнэлэгчийн RVR сөрөг гарч, Sample арга хамгийн бага OOS дисперстэй байв.

Иймээс анхны гурван багцын хувьд нэг үнэлэгч бүх нөхцөлд тогтмол давуу гүйцэтгэл үзүүлээгүй.

4.3 Багцын жингийн тогтвортой байдал

Багцын жингийн тогтвортой байдлыг дундаж turnover, төвлөрлийг Херфиндал–Хиршманы индексээр (HHI) үнэлэв.

Corr үнэлэгч гурван багцад хамгийн бага turnover, Var үнэлэгч хамгийн бага HHI үзүүлсэн. Гэвч эдгээр үзүүлэлт бага байх нь OOS дисперс заавал бага байхыг илэрхийлэхгүй байна.

Хүснэгт 4: Багцын дундаж turnover болон HHI

Багц	Үнэлэгч	Turnover	HHI
High	Sample	0.02767	0.44468
	Var	0.02744	0.33715
	Diag	0.02769	0.40338
	Corr	0.02062	0.50315
	SF	0.02571	0.40821
	NLS	0.02757	0.40117
Medium	Sample	0.03009	0.20008
	Var	0.02701	0.17750
	Diag	0.02804	0.18949
	Corr	0.02297	0.20775
	SF	0.02479	0.19316
	NLS	0.02603	0.18178
Low	Sample	0.02964	0.24203
	Var	0.02926	0.12850
	Diag	0.02631	0.18012
	Corr	0.02534	0.20568
	SF	0.02569	0.20912
	NLS	0.02856	0.19904

4.4 Статистик харьцуулалт

Агшилтын үнэлэгчдийн сарын квадрат өгөөжийн дундаж ялгааг Sample аргатай HAC шалгалтаар харьцуулж, олон харьцуулалтад Holm-ийн засвар хэрэглэв.

Хүснэгт 5: Ковариацын үнэлэгчдийн HAC шалгалт ($T = 120$)

Багц	Үнэлэгч	HAC p	Holm p
High	Var	0.3266	0.9799
	Diag	0.0762	0.3048
	Corr	0.8850	0.9799
	SF	0.0368	0.1842
	NLS	0.4639	0.9799
Medium	Var	0.9747	1.0000
	Diag	0.5811	1.0000
	Corr	0.2840	1.0000
	SF	0.3197	1.0000
	NLS	0.4438	1.0000
Low	Var	0.0680	0.2041
	Diag	0.0983	0.2041
	Corr	0.0100	0.0501
	SF	0.0286	0.1145
	NLS	0.1995	0.2041

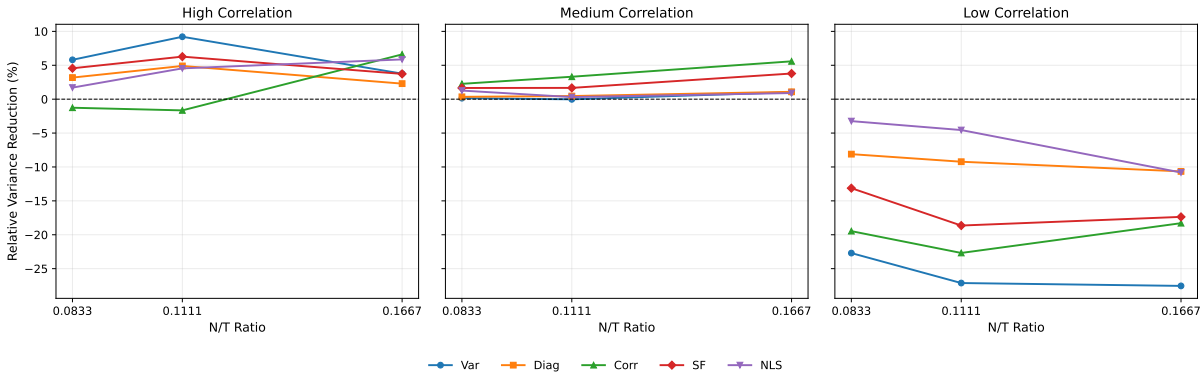
Holm-ийн засварын дараа бүх p-утга 0.05-аас их байна. Иймээс анхны гурван багцад квадрат өгөөжийн дундаж ялгаа 5%-ийн түвшинд статистикийн хувьд ач холбогдолтой болох нь тогтоогдсонгүй.

4.5 Сургалтын цонхны мэдрэмжийн шинжилгээ

Сургалтын цонхны уртыг $T = 60, 90, 120$ сар болгон өөрчилж, ижил 52 сарын түүврээс гадуурх (OOS) хугацаанд ковариацын үнэлэгчдийн гүйцэтгэлийг харьцуулав. Хөрөнгийн тоо $N = 10$ тогтмол тул харгалзах N/T харьцаа нь 0.1667, 0.1111, 0.0833 байна. Үр дүнг Хүснэгт 6 болон Зураг 1-т үзүүлэв.

Хүснэгт 6: Сургалтын цонхны уртаас хамаарах RVR (%)

Багц	T	Var	Diag	Corr	SF	NLS
High	60	3.76	2.29	6.60	3.73	5.86
	90	9.21	4.90	-1.65	6.28	4.54
	120	5.81	3.18	-1.26	4.56	1.70
Medium	60	1.03	1.09	5.58	3.78	0.90
	90	-0.02	0.46	3.31	1.66	0.31
	120	0.15	0.35	2.26	1.65	1.27
Low	60	-27.54	-10.65	-18.29	-17.36	-10.81
	90	-27.12	-9.23	-22.68	-18.64	-4.55
	120	-22.70	-8.11	-19.47	-13.13	-3.24



Зураг 1: Корреляцын бүтэц ялгаатай гурван багцын N/T харьцаанаас хамаарах RVR

Зураг 1-ээс харахад High багцад Corr үнэлэгчээс бусад аргууд бүх сургалтын цонхонд эерэг RVR үзүүлсэн боловч хамгийн сайн үнэлэгч N/T харьцаанаас хамааран өөрчлөгдөж байна. Medium багцад RVR-ийн хэмжээ харьцангуй бага бөгөөд Corr үнэлэгч бүх цонхонд хамгийн өндөр дисперсийн бууралт үзүүлэв. Харин Low багцад бүх үнэлэгчийн RVR сөрөг байгаа нь Sample арга бүх цонхонд хамгийн бага OOS дисперстэй байсныг харуулна.

Ийнхүү агшилтын үнэлэгчдийн гүйцэтгэл корреляцын бүтэц болон сургалтын цонхны уртаас хамааран ялгаатай байна. Гэхдээ T-г өөрчлөхөд сургалтын өгөгдлийн хугацаа давхар өөрчлөгдөх тул ажиглагдсан ялгааг зөвхөн N/T харьцааны нөлөө гэж тайлбарлах боломжгүй.

Мэдрэмжийн шинжилгээний HAC шалгалт. Багц тус бүрийн 15 харьцуулалтад Holm-ийн засвар хэрэглэв.

Тайлбар: Багц тус бүрийн хамгийн бага засварлаагүй p-утгатай хувилбарыг үзүүлэв.

Holm-ийн засварын дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй.

Хүснэгт 7: Мэдрэмжийн шинжилгээний HAC шалгалт

Багц	T	Үнэлэгч	HAC p	Holm p
High	90	Diag	0.0189	0.2839
Medium	90	Corr	0.1860	1.0000
Low	120	Corr	0.0100	0.1504

4.6 150 багцын robustness шинжилгээ

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг шалгах зорилгоор High, Medium, Low ангилал тус бүрээс 50, нийт 150 багцад шинжилгээг давтав. Ангиллуудын сургалтын хугацааны дундаж корреляц харгалзан 0.5267, 0.3036, 0.1346 байв.

Хүснэгт 8: 150 багцын дундаж RVR болон эерэг RVR-ийн хувь

Ангилал	Үнэлэгч	Дундаж RVR (%)	Эерэг RVR (%)
High	Var	1.13	72
	Diag	0.81	82
	Corr	0.65	60
	SF	0.53	74
	NLS	0.39	66
Medium	Var	-1.31	48
	Diag	0.57	68
	Corr	0.55	54
	SF	0.67	64
	NLS	0.37	56
Low	Var	-35.02	28
	Diag	-0.61	54
	Corr	0.16	64
	SF	-1.36	42
	NLS	0.99	74

High ангилалд бүх агшилтын үнэлэгчийн дундаж RVR эерэг байна. Medium ангилалд Var-аас бусад үнэлэгчдийн дундаж RVR эерэг боловч бууралтын хэмжээ бага байв.

Low ангилалд Var үнэлэгчийн дундаж RVR -35.02% байгаа бол NLS үнэлэгчийнх 0.99% байна. Иймээс анхны Low багцад бүх агшилтын үнэлэгчийн RVR сөрөг гарсан үр дүн нэмэлт 50 багцад бүрэн давтагдсангүй.

4.7 Bootstrap итгэх завсар

Ангилал тус бүрийн дундаж RVR-ийн тодорхой бус байдлыг зургаан сарын блоктой, 3000 давталт бүхий circular moving-block bootstrap аргаар үнэлэв.

Low ангиллын Var үнэлэгчээс бусад бүх үнэлэгчийн 95%-ийн итгэх завсар тэгийг агуулж байна. Харин Low ангиллын Var үнэлэгчийн итгэх завсар $[-65.61, -14.67]$ байгаа нь Sample аргатай харьцуулахад дундаж OOS дисперс өссөнийг дэмжиж байна.

Иймээс 150 багцын хүрээнд агшилтын үнэлэгчид Sample аргаас OOS дисперсийг статистикийн хувьд баталгаатай бууруулсан нотолгоо илрээгүй.

Хүснэгт 9: Дундаж RVR-ийн 95%-ийн bootstrap итгэх завсар

Ангилал	Үнэлэгч	RVR (%)	Доод	Дээд
High	Var	1.13	-1.16	3.38
	Diag	0.81	-0.09	1.83
	Corr	0.65	-1.83	3.45
	SF	0.53	-0.54	1.55
	NLS	0.39	-0.45	1.40
Medium	Var	-1.31	-5.08	2.55
	Diag	0.57	-0.67	1.87
	Corr	0.55	-0.96	1.85
	SF	0.67	-0.39	1.46
	NLS	0.37	-0.66	1.45
Low	Var	-35.02	-65.61	-14.67
	Diag	-0.61	-5.21	3.58
	Corr	0.16	-1.95	2.15
	SF	-1.36	-5.58	1.76
	NLS	0.99	-0.52	2.41

4.8 Корреляцын ангилал хоорондын харьцуулалт

Агшилтын үнэлэгчдийн дундаж RVR корреляцын ангиллаар ялгаатай эсэхийг шалгахын тулд High–Medium, High–Low болон Medium–Low гэсэн гурван хос харьцуулалт хийв.

Ангилал хоорондын дундаж RVR-ийн ялгааг ижил сарын индексүүдээр гүйцэтгэсэн circular moving-block bootstrap аргаар үнэлж, нийт 15 харьцуулалтын p-утгад Holm-ийн засвар хэрэглэв.

Хүснэгт 10: Ангилал хоорондын RVR-ийн ялгааны сонгосон үр дүн

Харьцуулалт	Үнэлэгч	Ялгаа	95% CI доод	95% CI дээд
High–Low	Var	36.15	16.55	66.37
Medium–Low	Var	33.71	15.23	63.54

Тайлбар: Ялгааг эхний ангиллын дундаж RVR-ээс хоёр дахь ангиллын дундаж RVR-ийг хасаж тооцсон. Бүх утга процентын пунктээр илэрхийлэгдсэн. Хүснэгтэд тэгийг агуулаагүй засварлаагүй 95%-ийн итгэх завсартай харьцуулалтуудыг үзүүлэв.

Var үнэлэгчийн High–Low болон Medium–Low ялгааны bootstrap итгэх завсар тэгийг агуулаагүй. Гэвч 15 харьцуулалтад Holm-ийн засвар хэрэглэсний дараа аль ч харьцуулалтын засварласан p-утга 0.05-аас бага гараагүй.

Иймээс корреляцын ангиллуудын хооронд RVR-ийн ялгаа ажиглагдсан боловч олон харьцуулалтын засварын дараа статистикийн ач холбогдолтой ялгаа тогтоогдсонгүй.

4.9 Тэнцүү жинтэй багцтай харьцуулалт

Ковариацын үнэлэгчид суурилсан GMVP-ийн практик гүйцэтгэлийг үнэлэхийн тулд хөрөнгө тус бүрд $1/N$ жин оноож, сар бүр дахин тэнцвэржүүлдэг жишиг багцтай харьцуулав. Бүх стратегид үндсэн шинжилгээтэй ижил 52 сарын OOS хугацааг ашиглав.

Хүснэгт 11-ээс харахад гурван багцын хувьд зургаан GMVP стратеги бүгд $1/N$ жишиг багцаас бага OOS хэлбэлзэлтэй байна. $1/N$ багцын жилийн хэлбэлзэл High, Medium, Low багцад харгалзан 21.29%, 15.56%, 16.02% байв. Харин хамгийн бага

Хүснэгт 11: GMVP болон $1/N$ багцын OOS гүйцэтгэл ($T = 120$)

Багц	Стратеги	Жилийн хэлбэлзэл (%)	$1/N$-тэй харьцуулсан RVR (%)	Sharpe
High	Sample	17.05	35.89	0.788
	Var	16.55	39.61	0.843
	Diag	16.78	37.93	0.816
	Corr	17.16	35.08	0.821
	SF	16.66	38.81	0.819
	NLS	16.90	36.98	0.801
	$1/N$	21.29	0.00	0.840
Medium	Sample	14.28	15.72	0.601
	Var	14.27	15.85	0.612
	Diag	14.26	16.02	0.603
	Corr	14.12	17.63	0.555
	SF	14.16	17.11	0.577
	NLS	14.19	16.79	0.603
	$1/N$	15.56	0.00	0.602
Low	Sample	13.77	26.06	0.269
	Var	15.26	9.28	0.393
	Diag	14.32	20.07	0.255
	Corr	15.05	11.67	0.111
	SF	14.65	16.36	0.190
	NLS	13.99	23.67	0.313
	$1/N$	16.02	0.00	0.573

хэлбэлзэлтэй GMVP стратегиуд нь High багцад Var (16.55%), Medium багцад Corr (14.12%), Low багцад Sample (13.77%) байна.

Гэхдээ хэлбэлзлийн давуу байдал нь Sharpe-ийн харьцаагаар давуу байна гэсэн үг биш. Тухайлбал, Low багцад $1/N$ стратегийн Sharpe 0.573 байхад GMVP стратегиудын Sharpe 0.111–0.393 хооронд байна. Иймээс GMVP-ийн эрсдэлийг бууруулах зорилгыг өгөөж–эрсдэлийн харьцааны үнэлгээнээс тусад нь авч үзэх шаардлагатай.

4.10 Арилжааны зардлын нөлөө

Сар бүрийн дахин тэнцвэржүүлэлтийн арилжааны зардлыг тооцохдоо нэг талын арилжаанд 0, 5, 10, 25 суурь нэгж (basis points, bps)-ийн хувилбаруудыг ашиглав. Эхний OOS багц бүрдүүлэлтийн зардлыг тооцоогүй. Доорх хүснэгтэд нэг талын 10 bps зардлын хувилбарын үр дүнг үзүүлэв.

Арилжааны зардлыг тусгахад стратегиудын Sharpe-ийн харьцаа зардалгүй хувилбартай харьцуулахад бага зэрэг буурч байна. Тухайлбал, High багцад Var стратегийн Sharpe 0.843-аас 0.840 болж буурсан. Medium багцад Var стратегийн цэвэр Sharpe 0.607, Low багцад $1/N$ стратегийнх 0.568 байна.

High багцад $1/N$ стратегийн хуримтлагдсан цэвэр өгөөж 96.05% байхад Var стратегийнх 71.91% байна. Иймээс GMVP стратегиудын хэлбэлзэл бага байгаа нь хуримтлагдсан өгөөж өндөр байна гэсэн баталгаа биш. Эдгээр дүгнэлт нь сонгосон зардлын хувилбар, сарын дахин тэнцвэржүүлэлт болон 52 сарын OOS хугацаанд хамаарна.

4.11 GMVP ба $1/N$ багцын bootstrap харьцуулалт

GMVP стратегиудын $1/N$ жишиг багцтай харьцуулсан дисперсийн бууралтын тодорхой бус байдлыг 52 сарын OOS өгөөжид суурилсан, зургаан сарын блоктой, 3000

Хүснэгт 12: Нэг талын 10 bps арилжааны зардлын дараах OOS гүйцэтгэл

Багц	Стратеги	Цэвэр Sharpe	Хуримтлагдсан цэвэр өгөөж (%)
High	Sample	0.784	67.46
	Var	0.840	71.91
	Diag	0.812	69.65
	Corr	0.818	72.27
	SF	0.816	69.53
	NLS	0.797	68.45
	$1/N$	0.837	96.05
Medium	Sample	0.596	38.36
	Var	0.607	39.31
	Diag	0.599	38.56
	Corr	0.551	34.21
	SF	0.573	36.15
	NLS	0.599	38.40
	$1/N$	0.599	42.07
Low	Sample	0.264	12.35
	Var	0.388	22.92
	Diag	0.251	11.77
	Corr	0.107	2.13
	SF	0.186	7.48
	NLS	0.308	15.57
	$1/N$	0.568	40.28

давталт бүхий circular moving-block bootstrap аргаар үнэлэв. Сар бүрийн индексүүдийг харьцуулж буй стратегиудад ижил сонгож, 95%-ийн percentile итгэх завсар байгуулав. Багц тус бүрийн зургаан харьцуулалтын bootstrap p-утгад Holm-ийн засвар хэрэглэв.

Хүснэгт 13-д бүх GMVP стратегийн RVR эерэг байна. Хамгийн бага хэлбэлзэлтэй стратегиудын $1/N$-тэй харьцуулсан RVR нь High багцад Var 39.61%, Medium багцад Corr 17.63%, Low багцад Sample 26.06% байна. Гэвч эдгээрийн 95%-ийн итгэх завсар харгалзан $[-7.09, 62.44]$, $[-3.95, 34.33]$, $[-7.84, 51.16]$ тул тэгийг агуулж байна.

Мөн багц тус бүрийн зургаан харьцуулалтад Holm-ийн засвар хэрэглэсний дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй. Bootstrap p-утгыг төвлөрүүлсэн bootstrap тархалтаас, харин итгэх завсрыг percentile аргаар байгуулсан тул засварлаагүй p-утга ба итгэх завсрын шийдвэр зарим тохиолдолд зөрж болохыг харгалзан үзнэ. Иймээс ажиглагдсан эерэг RVR-ийг статистикийн хувьд баталгаатай давуу байдал гэж тайлбарлахгүй.

4.12 Үр дүнгийн нэгтгэл

Эмпирик шинжилгээгээр ковариацын матрицын агшилтын үнэлэгчдийн гүйцэтгэл багцын бүрэлдэхүүн болон сургалтын цонхны уртаас хамааран ялгаатай байгааг ажиглав.

Анхны гурван багцын HAC шалгалт болон 150 багцын bootstrap шинжилгээ нь агшилтын үнэлэгчдийн Sample аргаас тогтвортой давуу байдлыг статистикийн хувьд батлаагүй.

Харин бага корреляцтай багцуудад Var үнэлэгчийн дундаж RVR мэдэгдэхүйц сөрөг гарсан нь агшилтын арга бүр OOS эрсдэлийг бууруулах баталгаагүйг харуулж байна.

Ангилал хоорондын харьцуулалтаар ажиглагдсан ялгаа олон шалгалтын засва-

Хүснэгт 13: GMVP-ийн $1/N$-тэй харьцуулсан RVR ба bootstrap шалгалт

Багц	Стратеги	RVR (%)	95% CI доод	95% CI дээд	Holm p
High	Sample	35.89	-21.61	63.60	0.3149
	Var	39.61	-7.09	62.44	0.2639
	Diag	37.93	-15.32	64.14	0.3149
	Corr	35.08	-38.50	69.33	0.3149
	SF	38.81	-15.41	64.90	0.3149
	NLS	36.98	-16.53	62.84	0.3149
Medium	Sample	15.72	-4.31	31.44	0.3399
	Var	15.85	-2.62	30.02	0.3399
	Diag	16.02	-3.31	31.15	0.3399
	Corr	17.63	-3.95	34.33	0.3399
	SF	17.11	-4.21	33.32	0.3399
	NLS	16.79	-3.61	31.72	0.3399
Low	Sample	26.06	-7.84	51.16	0.5498
	Var	9.28	-16.30	29.00	0.8144
	Diag	20.07	-9.26	42.20	0.5498
	Corr	11.67	-20.01	35.14	0.8144
	SF	16.36	-18.68	40.65	0.8107
	NLS	23.67	-8.70	47.86	0.5498

рын дараа статистикийн ач холбогдолтой болох нь тогтоогдсонгүй.

$1/N$ жишиг багцтай харьцуулахад зургаан GMVP стратеги гурван багцад бүгд бага OOS хэлбэлзэлтэй байсан боловч bootstrap шалгалтын олон харьцуулалтын засварын дараа статистикийн ач холбогдолтой давуу байдал тогтоогдсонгүй. Мөн арилжааны зардлыг тооцоход стратегиудын цэвэр гүйцэтгэл буурч, хэлбэлзлийн давуу байдал Sharpe болон хуримтлагдсан өгөөжийн давуу байдалтай заавал давхцахгүй байв.

5 Дүгнэлт

Энэхүү судалгаагаар хөрөнгийн тоо болон сургалтын ажиглалтын тооны харьцаа (N/T) бага нөхцөлд ковариацын матрицын агшилтын үнэлэгчдийн глобал хамгийн бага вариацтай багц (GMVP)-ын оновчлол дахь гүйцэтгэлийг харьцуулан шинжиллээ. Түүврийн ковариацын матриц (Sample), тогтмол вариацын (Var), диагональ (Diag), тогтмол корреляцын (Corr), нэг хүчин зүйлийн (SF) зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид болон шугаман бус агшилтын үнэлэгчийг (NLS) авч үзэв. Корреляцын бүтэц ялгаатай, тус бүр 10 хувьцаанаас бүрдсэн гурван багцад богино борлуулалтыг зөвшөөрөөгүй GMVP байгуулж, 120 сарын сургалтын цонх болон 52 сарын түүврээс гадуурх (OOS) хугацаанд үнэлэв.

Үндсэн шинжилгээнд агшилтын үнэлэгчдийн гүйцэтгэл багцын корреляцын бүтцээс хамааран ялгаатай байв. Өндөр корреляцтай багцад Var үнэлэгч Sample аргатай харьцуулахад OOS дисперсийг 5.81%-иар, дунд корреляцтай багцад Corr үнэлэгч 2.26%-иар бууруулсан. Харин бага корреляцтай багцад Sample арга хамгийн бага OOS дисперстэй байсан бөгөөд агшилтын таван үнэлэгчийн харьцангуй дисперсийн бууралт (RVR) бүгд сөрөг гарсан. Иймээс нэг үнэлэгч бүх багцад тогтмол давуу гүйцэтгэл үзүүлээгүй.

Багцын жингийн шинжилгээгээр Corr үнэлэгч гурван багцад хамгийн бага дундаж turnover, Var үнэлэгч хамгийн бага дундаж HHI үзүүлсэн. Гэвч жингийн эргэлт болон төвлөрөл бага байх нь OOS дисперс заавал бага байхыг илэрхийлээгүй. Ту-

хайлбал, бага корреляцтай багцад Var үнэлэгч хамгийн бага HHI-тэй боловч OOS дисперс нь Sample аргынхаас 22.70%-иар өндөр байв.

Сургалтын цонхны уртыг 60, 90 болон 120 сар болгон өөрчилсөн мэдрэмжийн шинжилгээнд үнэлэгчдийн гүйцэтгэлийн эрэмбэ бүх багцад тогтвортой хадгалагдсангүй. Өндөр корреляцтай багцад хамгийн өндөр RVR үзүүлсэн үнэлэгч сургалтын цонхноос хамааран өөрчлөгдсөн бол дунд корреляцтай багцад Corr үнэлэгч, бага корреляцтай багцад Sample арга бүх цонхонд хамгийн бага OOS дисперстэй байв. Иймээс N/T харьцаа буурах тусам агшилтын аргуудын давуу тал заавал нэмэгдэнэ гэсэн зүй тогтол ажиглагдсангүй.

Үндсэн гурван багцын сарын квадрат өгөөжийн ялгаанд хийсэн HAC шалгалтаар Holm-ийн засварын дараа 5%-ийн түвшинд статистикийн ач холбогдолтой ялгаа илрээгүй. Сургалтын цонхны мэдрэмжийн шинжилгээнд мөн ижил үр дүн гарсан. Эдгээр шалгалт нь квадрат өгөөжийн дундаж ялгаанд суурилсан тул OOS дисперсийн ялгааг шууд шалгасан гэж үзэхгүй.

Үр дүн багцын бүрэлдэхүүнээс хамаарах эсэхийг үнэлэхийн тулд корреляцын ангилал тус бүрээс 50, нийт 150 нэмэлт багцад шинжилгээг давтав. Өндөр корреляцтай ангилалд агшилтын бүх үнэлэгчийн дундаж RVR эерэг байсан бол дунд болон бага корреляцтай ангиллуудад үр дүн харилцан адилгүй байв. Ялангуяа бага корреляцтай ангилалд Var үнэлэгчийн дундаж RVR -35.02%, харин NLS үнэлэгчийнх 0.99% байв. Иймээс анхны бага корреляцтай багцад бүх агшилтын үнэлэгчийн RVR сөрөг гарсан үр дүн нэмэлт 50 багцад бүрэн давтагдсангүй.

Нэмэлт 150 багцын дундаж RVR-ийн тодорхой бус байдлыг circular moving-block bootstrap аргаар үнэлэхэд бага корреляцтай ангиллын Var үнэлэгчээс бусад бүх үнэлэгчийн засварлаагүй 95%-ийн итгэх завсар тэгийг агуулсан. Бага корреляцтай ангиллын Var үнэлэгчийн итгэх завсар $[-65.61, -14.67]$ байв. Корреляцын ангилал хоорондын харьцуулалтад Var үнэлэгчийн High–Low болон Medium–Low ялгааны засварлаагүй bootstrap p-утга харгалзан 0.0147, 0.0180 байсан боловч 15 харьцуулалтад Holm-ийн засвар хэрэглэсний дараа 0.2199, 0.2519 болсон. Иймээс ангилал хоорондын ялгаа олон харьцуулалтын засварын дараа статистикийн хувьд батлагдсангүй.

Тэнцүү жинтэй $1/N$ багцыг нэмэлт жишиг болгон авч үзэхэд үндсэн гурван багцад ковариацын зургаан үнэлэгчид суурилсан GMVP стратегиуд бүгд $1/N$ багцаас бага OOS хэлбэлзэл үзүүлсэн. Өндөр корреляцтай багцад Var үнэлэгчийн $1/N$-тэй харьцуулсан дисперсийн бууралт 39.61%, дунд корреляцтай багцад Corr үнэлэгчийнх 17.63%, бага корреляцтай багцад Sample аргынх 26.06% байв. Гэвч эрсдэлд тохируулсан өгөөжийн хувьд GMVP стратегиуд бүх нөхцөлд давуу байгаагүй. Тухайлбал, бага корреляцтай багцад $1/N$ стратегийн жилийн Sharpe-ийн харьцаа GMVP стратегиудынхаас өндөр байв.

GMVP болон $1/N$ багцын OOS дисперсийн харьцаанд хийсэн circular moving-block bootstrap шинжилгээгээр дээрх гурван харьцуулалтын засварлаагүй 95%-ийн итгэх завсар харгалзан $[-7.09, 62.44]$, $[-3.95, 34.33]$ болон $[-7.84, 51.16]$ байв. Итгэх завсруud тэгийг агуулж, багц тус бүрийн зургаан харьцуулалтад Holm-ийн засвар хэрэглэсний дараа статистикийн ач холбогдолтой ялгаа тогтоогдоогүй. Иймээс GMVP стратегиуд $1/N$ багцаас бага OOS дисперстэй байсан нь ажиглагдсан үр дүн боловч статистикийн хувьд тогтвортой давуу байдлыг батлахад хангалтгүй байна.

Арилжааны зардлын мэдрэмжийн шинжилгээнд багцын дахин тэнцвэржүүлэлттэй холбоотой нэг талын 10 суурь нэгжийн зардлыг тооцоход стратегиудын Sharpeийн харьцаа бага хэмжээгээр буурсан боловч үндсэн харьцуулалтын ерөнхий дүр зураг өөрчлөгдөөгүй. Гэсэн хэдий ч хамгийн бага дисперстэй стратеги нь хамгийн өндөр хуримтлагдсан өгөөжтэй байх албагүй. Иймээс ковариацын үнэлэгчийн практик үр ашгийг зөвхөн OOS хэлбэлзлээр бус, арилжааны зардлын дараах гүйцэтгэлтэй хамтатган үнэлэх шаардлагатай.

Практик ач холбогдол. Судалгааны үр дүн нь бага N/T харьцаатай нөхцөлд ковариацын матрицын агшилтыг түүврийн ковариацын матрицаас үргэлж давуу гэж үзэх үндэслэлгүйг харуулж байна. Агшилтын үнэлэгчдийн гүйцэтгэл багцын корреляцын бүтэц, хөрөнгийн бүрэлдэхүүн болон сургалтын цонхны уртаас хамааран өөрчлөгдөж байна.

Нөгөө талаас GMVP стратегиуд тэнцүү жинтэй багцаас бага OOS хэлбэлзэл үзүүлсэн нь ковариацын матрицад суурилсан оновчлол эрсдэлийг удирдахад ашигтай байж болохыг харуулна. Гэхдээ энэхүү ажиглагдсан давуу тал статистикийн хувьд батлагдаагүй бөгөөд бага хэлбэлзэл нь өндөр Sharpe-ийн харьцаа эсвэл өндөр хуримтлагдсан өгөөжийг заавал илэрхийлэхгүй.

Иймээс хөрөнгө оруулалтын практикт ковариацын үнэлэгчийг зөвхөн онолын шинж чанар эсвэл агшилтын аргын төрлөөр сонгохын оронд rolling-window OOS шинжилгээгээр харьцуулж, дисперс, жингийн эргэлт, төвлөрөл, эрсдэлд тохируулсан өгөөж болон арилжааны зардлыг хамтад нь үнэлэх нь зүйтэй. Мөн Sample болон $1/N$ стратегийг харьцуулалтын жишиг болгон ашиглах нь оновчлолын болон агшилтын аргын нэмэлт үр ашгийг ялган үнэлэхэд чухал юм.

Энэхүү судалгааны үр дүн нь сонгосон хувьцааны багцууд, богино борлуулалтыг зөвшөөрөөгүй оновчлол болон 52 сарын OOS хугацааны хүрээнд хязгаарлагдана. Багцуудыг бүрэн хугацааны өгөгдөлтэй хувьцаануудаас сонгосон нь сонголтын хазайлт үүсгэх боломжтой. Мөн сургалтын цонхны уртыг өөрчлөхөд N/T харьцаанаас гадна сургалтын өгөгдлийн хугацаа өөрчлөгдсөн. Нэмэлт 150 багц нь бие даасан санамсаргүй түүвэр биш бөгөөд bootstrap шинжилгээнд багцын бүрэлдэхүүнийг тогтмол гэж үзсэн. Түүнчлэн арилжааны зардлын шинжилгээ нь нэг талын тогтмол зардлын таамаглалд суурилсан бөгөөд зах зээлийн нөлөөлөл болон бусад бодит арилжааны хязгаарлалтыг бүрэн тусгаагүй.

Нэгдсэн дүнгээр бага N/T харьцаатай нөхцөлд ковариацын матрицын агшилтын үнэлэгчид GMVP-ийн OOS дисперсийг бууруулах боломжтой боловч энэхүү давуу тал нь бүх багц болон үнэлэгчид тогтвортой хадгалагдсангүй. Харин GMVP стратегиудын $1/N$ багцаас бага хэлбэлзэлтэй байсан үр дүн нь ковариацын матрицад суурилсан оновчлолын боломжит ач холбогдлыг харуулж байна. Гэвч статистикийн шалгалтуудын олон харьцуулалтын засварын дараа агшилтын үнэлэгчдийн Sample аргаас, мөн GMVP стратегиудын $1/N$ багцаас давуу гүйцэтгэлийг батлах хангалттай нотолгоо илрээгүй. Иймээс ковариацын матрицын агшилтыг бага N/T нөхцөлд эрсдэлийг заавал бууруулах арга бус, харин багцын бүтэц, түүврээс гадуурх гүйцэтгэл болон практик зардалд тулгуурлан үнэлэх шаардлагатай хувилбар гэж дүгнэв.

Ашигласан ном

chinobing. Historical S&P 500 constituents. GitHub repository. URL https://github.com/chinobing/historical_sp500_constituents. Accessed: 2026-10-21.

Victor DeMiguel, Lorenzo Garlappi, and Raman Uppal. Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies*, 22(5):1915–1953, 2009. doi: 10.1093/rfs/hhm075.

Ravi Jagannathan and Tongshu Ma. Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4):1651–1683, 2003. doi: 10.1111/1540-6261.00580.

Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5): 603–621, 2003. doi: 10.1016/S0927-5398(03)00007-0.

Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004a. doi: 10.1016/S0047-259X(03)00096-4.

Olivier Ledoit and Michael Wolf. Honey, i shrunk the sample covariance matrix. *The Journal of Portfolio Management*, 30(4):110–119, 2004b. doi: 10.3905/jpm.2004.110.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage estimation of large-dimensional covariance matrices. *The Annals of Statistics*, 40(2):1024–1060, 2012. doi: 10.1214/12-AOS989.

Olivier Ledoit and Michael Wolf. Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5):3043–3065, 2020. doi: 10.1214/19-AOS1921.

Olivier Ledoit and Michael Wolf. The power of (non-)linear shrinking: A review and guide to covariance matrix estimation. *Journal of Financial Econometrics*, 20(1):187–218, 2022. doi: 10.1093/jjfinec/nbaa007.

Olivier Richard Henri Ledoit. *Essays on Risk and Return in the Stock Market*. PhD thesis, Massachusetts Institute of Technology, Sloan School of Management, 1995. URL https://hdl.handle.net/1721.1/11875.

Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952. doi: 10.1111/j.1540-6261.1952.tb01525.x.

Fangquan Shi, Lianjie Shu, Fangyi He, and Wenpo Huang. Improving minimum-variance portfolio through shrinkage of large covariance matrices. *Economic Modelling*, 144: 106981, 2025. doi: 10.1016/j.econmod.2024.106981.