N/T харьцаа бага үед багцын оновчлолд ковариацын матрицын агшилтын аргуудыг харьцуулах нь

Г.Нарангоо[1] Ч.Анхбаяр[2]

[1]Монгол улсын их сургууль, Мэдээллийн технологи, электроникийн сургууль

narangoo.g@num.edu.mn

[2]Монгол улсын их сургууль, Бизнесийн сургууль

ankhbayar.ch@num.edu.mn

Хураангуй

Энэ судалгаанд ковариацын матрицыг агшаах аргуудыг харьцуулна.

Keywords: Ковариацын матриц, Агшилтын үнэлгээ, Багц сонголт, Global minimum variance portfolio

1 Удиртгал

Багц сонголтын орчин үеийн онолын суурийг Markowitz (1952)-ийн дундаж–вариацын загвар тавьсан бөгөөд уг загварт багцын эрсдэл нь хөрөнгийн өгөөжийн ковариацын матрицаар тодорхойлогддог. Ялангуяа глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP) нь хүлээгдэж буй өгөөжийг үнэлэх шаардлагагүйгээр зөвхөн ковариацын матрицад тулгуурлан багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлдог. Иймээс GMVP-ийн практик үр дүн нь ковариацын матрицыг хэр найдвартай үнэлснээс шууд хамаарна.

Гэвч бодит нөхцөлд хөрөнгийн өгөөжийн жинхэнэ ковариацын матриц үл мэдэгдэх тул түүнийг түүхэн өгөгдлөөс тооцсон түүврийн ковариацын матрицаар үнэлдэг. Энэ нь хэд хэдэн статистикийн хүндрэл үүсгэдэг. N хөрөнгийн ковариацын матриц нь $N(N+1)/2$ ялгаатай параметр агуулдаг тул хөрөнгийн тоо ажиглалтын тоотой харьцуулахад нэмэгдэх тусам хязгаарлагдмал тооны ажиглалтаар олон параметр үнэлэх шаардлагатай болдог. Ledoit and Wolf (2004b) хөрөнгийн тоо ажиглалтын тоотой харьцуулахад ихсэх үед түүврийн ковариацын матрицын үнэлгээ тогтворгүй болж, түүний урвууг найдвартай тооцоход хүндрэл үүсдэг бөгөөд хөрөнгийн тоо ажиглалтын тооноос их үед матриц сингуляр болж, урвуу матриц нь оршихгүй болдгийг харуулсан.

Энэ асуудал багцын оновчлолд онцгой ач холбогдолтой. Учир нь GMVP-ийн оновчтой жин нь ковариацын матрицын үнэлгээнээс шууд хамаардаг. Иймээс ковариацын матрицын үнэлгээний бага хэмжээний алдаа ч багцын оновчтой жинд ихээхэн өөрчлөлт үүсгэж, улмаар багцын эрсдэлийг нэмэгдүүлэх боломжтой. Өөрөөр хэлбэл, түүхэн өгөгдлөөр тооцсон ковариацын матриц тухайн өгөгдөлд сайн тохирч байсан ч шинэ өгөгдөл дээр тогтвортой үр дүн үзүүлэх баталгаа байхгүй. DeMiguel et al. (2009) долоон бодит өгөгдлийн багц дээр багц сонголтын 14 загварыг харьцуулан судалж, параметрүүдийн үнэлгээний алдаа нь оновчтой багц сонголтын үр ашгийг бууруулах чухал хүчин зүйл болохыг харуулсан.

Ковариацын матрицын үнэлгээний алдааг бууруулах үндсэн аргуудын нэг нь агшилтын үнэлгээ (shrinkage estimation) юм. Агшилтын аргыг ерөнхийд нь шугаман

болон шугаман бус агшилт гэж авч үздэг. Шугаман агшилтын үндсэн санаа нь түүврийн ковариацын матрицыг ковариацын матрицын талаар тодорхой бүтцийн таамаглал тавьсан зорилтот матрицтай хослуулахад оршино.

Түүврийн ковариацын матриц нь өгөгдөлд агуулагдах мэдээллийг шууд ашигладаг боловч хөрөнгийн тоо ажиглалтын тоотой харьцуулахад их үед үнэлгээний алдаа нэмэгдэж болно. Харин зорилтот матриц нь ковариацын матрицад тодорхой бүтцийн таамаглал тавьснаар үнэлэх параметрийн тоог багасгаж, үнэлгээний алдааг бууруулах боломжтой боловч тавьсан таамаглал бодит байдалтай тохирохгүй тохиолдолд өгөгдөлд агуулагдах зарим мэдээллийг алдах эрсдэлтэй. Иймээс түүврийн ковариацын матриц болон зорилтот матрицыг зохистой харьцаагаар хослуулах замаар эдгээр хоёр үнэлэгчийн мэдээллийг хамтад нь ашигладаг.

Шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma} = (1-\alpha)S + \alpha T, \qquad 0 \leq \alpha \leq 1,$$

гэж илэрхийлж болох бөгөөд энд S нь түүврийн ковариацын матриц, T нь зорилтот матриц, α нь агшилтын эрчим юм. α-ийн утга ихсэх тусам зорилтот матрицад өгөх жин нэмэгдэх бөгөөд $\alpha = 0$ үед түүврийн ковариацын матриц, $\alpha = 1$ үед зорилтот матрицыг ашиглана.

Шугаман агшилтын үр дүнд зорилтот матрицын сонголт чухал нөлөөтэй. Учир нь зорилтот матриц бүр ковариацын матрицад өөр өөр бүтцийн таамаглал тавьдаг. Иймээс энэхүү судалгаанд тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицуудыг авч үзнэ.

Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн вариацыг нэг ижил утгаар төлөөлүүлж, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг. Тогтмол вариацын зорилтот матрицыг

$$T_{\text{var}} = \mu I, \qquad \mu = \frac{\text{tr}(S)}{N}$$

гэж тодорхойлох бөгөөд энд μ нь хөрөнгүүдийн түүврийн вариацуудын дундаж, I нь нэгж матриц юм. Ийнхүү олон тооны ковариацын параметрийг тэгээр, хөрөнгө тус бүрийн ялгаатай вариацыг нэг нийтлэг утгаар орлуулснаар зорилтот матрицын бүтцийг хялбарчилж, түүврээс шалтгаалах үнэлгээний алдааг бууруулах боломжтой. Ledoit and Wolf (2004b) түүврийн ковариацын матрицыг нэгж матрицын скаляр үржвэр хэлбэрийн зорилтот матрицтай хослуулан агшаах нь өндөр хэмжээст нөхцөлд түүврийн ковариацын матрицыг дангаар нь ашигласнаас илүү найдвартай үнэлгээ бий болгох боломжтойг харуулсан. Гэвч бүх хөрөнгийн вариацыг ижил, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үзэх нь хөрөнгө тус бүрийн эрсдэлийн ялгаа болон тэдгээрийн хоорондын хамаарлыг үл тооцсон хүчтэй таамаглал юм.

“Бүх хөрөнгийн вариац ижил” гэсэн таамаглалыг сулруулсан хувилбар нь диагональ зорилтот матриц юм. Энэ тохиолдолд хөрөнгө тус бүрийн түүврийн вариацыг хадгалах боловч хөрөнгүүдийн хоорондын ковариацыг тэг гэж үзсэн хэвээр байна. Диагональ зорилтот матрицыг

$$T_{\text{diag}} = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

гэж тодорхойлох бөгөөд энд s_{ii} нь i-р хөрөнгийн түүврийн вариац юм. Иймээс тогтмол вариацын зорилтот матрицын “ижил вариац, тэг ковариац” гэсэн таамаглал диагональ зорилтот матрицад “ялгаатай вариац, тэг ковариац” болж өөрчлөгдөнө.

Ledoit (1995) ковариацын матрицын агшилтын хүрээнд диагональ матрицыг тодорхой бүтэц бүхий үнэлэгчийн нэг хувилбар болгон авч үзсэн. Диагональ зорилтот матриц нь хөрөнгө тус бүрийн вариацын ялгааг хадгалдаг давуу талтай боловч хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг тул тэдгээрийн өгөөжийн хоорондын хамаарлын мэдээллийг тусгадаггүй.

Диагональ зорилтот матрицын хөрөнгүүдийн хоорондын ковариацыг тэг гэж үзэх

хязгаарлалтыг сулруулсан нэг хувилбар нь тогтмол корреляцийн зорилтот матриц юм. Үүнийг

$$(T_{\text{corr}})_{ii} = s_{ii},$$
$$(T_{\text{corr}})_{ij} = \bar{\rho}\sqrt{s_{ii}s_{jj}}, \qquad i \neq j,$$

гэж тодорхойлох бөгөөд $\bar{\rho}$ нь түүврийн корреляцийн матрицын диагоналийн бус элементүүдийн дундаж юм. Ийнхүү диагональ зорилтот матрицтай харьцуулахад хөрөнгүүдийн хоорондын хамаарлын мэдээллийг тодорхой хэмжээгээр хадгалах боломжтой.

Тогтмол корреляцийн бүтцийг Ledoit (1995) тодорхой бүтэц бүхий ковариацын матрицын үнэлэгчдийн нэг болгон авч үзсэн бөгөөд хожим Ledoit and Wolf (2004a) уг бүтцийг агшилтын зорилтот матриц болгон ашиглан хөгжүүлсэн. Тогтмол корреляцийн зорилтот матриц нь диагональ зорилтот матрицаас илүү хамаарлын мэдээлэл агуулдаг боловч хөрөнгийн бүх хос ижил корреляцитай гэсэн таамаглал тавьдаг. Бодит зах зээлд хөрөнгийн хос бүрийн хамаарал ижил байх шаардлагагүй тул энэхүү таамаглал нь ковариацын матрицын хамаарлын бүтцийг хэт хялбарчилж болно.

Хөрөнгүүдийн хоорондын хамаарлыг нэг ижил корреляцийн утгаар төлөөлүүлэхийн оронд тэдгээрийн нийтлэг зах зээлийн хүчин зүйлтэй хамаарах байдлаар загварчлах боломжтой. Үүний нэг хувилбар нь нэг хүчин зүйлийн зорилтот матриц юм. Нэг хүчин зүйлийн загварт i-р хөрөнгийн өгөөжийг

$$R_{i,t} = \alpha_i + \beta_i R_{m,t} + \varepsilon_{i,t}$$

гэж илэрхийлэх бөгөөд энд $R_{m,t}$ нь зах зээлийн өгөөж, β_i нь тухайн хөрөнгийн зах зээлийн өгөөжийн өөрчлөлтөд мэдрэг байдлыг илэрхийлнэ. Энэ тохиолдолд хөрөнгүүдийн хоорондын ковариац нь тэдгээрийн зах зээлийн нийтлэг хүчин зүйлтэй хамаарах байдлаар тодорхойлогдоно. Ledoit and Wolf (2003) түүврийн ковариацын матрицыг Sharpe-ийн нэг хүчин зүйлийн загварт (single-index model) суурилсан ковариацын матрицтай хослуулах агшилтын үнэлэгчийг хөгжүүлсэн.

Дээрх аргууд нь бүгд түүврийн ковариацын матрицыг урьдчилан тодорхойлсон бүтэц бүхий зорилтот матрицтай нэг агшилтын эрчмээр хослуулдаг шугаман агшилтын аргууд юм. Гэвч түүврийн ковариацын матрицын өөр өөр бүрэлдэхүүн хэсгийн үнэлгээний алдаа ижил байх албагүй тул бүх мэдээллийг нэг ижил хэмжээгээр агшаах нь хязгаарлалттай байж болно. Энэ асуудлыг шийдвэрлэх өөр нэг чиглэл нь ковариацын матрицын хувийн утгуудыг тус бүрд нь ялгаатай хэмжээгээр засах шугаман бус агшилтын арга юм.

Ledoit and Wolf (2012) түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, харин түүврийн хувийн утга бүрд шугаман бус өөрчлөлт хийх замаар ковариацын матрицыг үнэлэх шугаман бус агшилтын аргыг боловсруулсан. Ингэснээр шугаман агшилтын нэг ижил агшилтын эрчмийг бүх хувийн утгад хэрэглэхийн оронд хувийн утга бүрийг өөр өөр хэмжээгээр засах боломжтой болсон.

Шугаман бус агшилтын эхний аргуудын практик хэрэгжилт нь санамсаргүй матрицын онолд (random matrix theory) тулгуурласан харьцангуй төвөгтэй тоон тооцоолол шаарддаг байсан. Ledoit and Wolf (2020) аналитик шугаман бус агшилтын аргыг боловсруулснаар уг тооцооллыг хялбаршуулж, өндөр хэмжээст ковариацын матрицыг илүү хурдан үнэлэх боломж бүрдүүлсэн. Ингэснээр урьдчилан тодорхойлсон нэг зорилтот матриц сонгохын оронд түүврийн ковариацын матрицын хувийн утгуудын мэдээлэлд тулгуурлан тэдгээрийг ялгаатай хэмжээгээр засах боломжтой болсон.

Сүүлийн үеийн судалгаанууд ковариацын матрицын үнэлгээний статистикийн нарийвчлал болон уг үнэлгээг багцын оновчлолд ашиглах үеийн үр дүнг ялгаж авч үзэх шаардлагатайг харуулж байна. Ledoit and Wolf (2022) шугаман бус агшилтын оновчтой хэлбэр нь сонгосон алдагдлын функцээс хамаарч болохыг судалсан. Энэ нь ковариацын матрицыг статистикийн тодорхой шалгууруар илүү сайн үнэлсэн арга нь заавал GMVP-ийн хувьд хамгийн сайн үр дүн үзүүлнэ гэсэн үг биш болохыг

харуулж байна.

Энэ асуудлыг GMVP-ийн хүрээнд Shi et al. (2025) цааш судалж, шугаман агшилтын эрчмийг сонгох өөр аргыг авч үзсэн. Тэдний эмпирик судалгаанд диагональ болон нэг хүчин зүйлийн зорилтот матриц ашигласан шугаман агшилтын үнэлэгчид түүврээс гадуурх багцын гүйцэтгэлийн хэд хэдэн үзүүлэлтээр сайн үр дүн үзүүлсэн. Энэ нь зорилтот матрицын сонголт болон агшилтын эрчмийг тодорхойлох арга нь GMVP-ийн практик үр дүнд чухал нөлөөтэй хэвээр байгааг харуулж байна.

Ийнхүү өмнөх судалгаануудад ковариацын матрицын үнэлгээний алдааг бууруулахын тулд ковариацын матрицад өөр өөр бүтцийн таамаглал тавьсан зорилтот матрицуудтай хослуулах шугаман агшилтын аргууд, мөн түүврийн хувийн утгуудыг ялгаатай хэмжээгээр засах шугаман бус агшилтын аргуудыг хөгжүүлсэн байна. Эдгээр аргуудын үндэслэл, тавих таамаглал болон агшилтын хэлбэр өөр тул тэдгээрийн үр дүн өгөгдлийн бүтэц, түүврийн хэмжээ, хөрөнгийн тоо болон багцын оновчлолын зорилгоос хамаарч ялгаатай байж болно.

Иймээс энэхүү судалгааны зорилго нь түүврийн ковариацын матрицыг суурь үнэлэгч болгон авч, тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг нэг ижил GMVP загварын хүрээнд харьцуулан үнэлэхэд оршино. Эдгээр аргыг ашиглан ковариацын матрицын үнэлэгчийн сонголт нь GMVP-ийн эрсдэл, Sharpe-ийн харьцаа, хөрөнгө оруулалтын жингийн бүтэц болон багцын эргэлтэд хэрхэн нөлөөлж байгааг эмпирик түвшинд харьцуулан шинжилнэ.

2 Онол, арга зүйн үндэслэл

2.1 Багцын өгөөж ба эрсдэл

Энэхүү судалгаанд N ширхэг хөрөнгөөс бүрдэх хөрөнгө оруулалтын багцыг авч үзье. x_i нь i-р хөрөнгийн багцад эзлэх жин, G_i нь тухайн хөрөнгийн өгөөж гэж тэмдэглэвэл багцын өгөөжийг

$$r_p = \sum_{i=1}^{N} x_i G_i$$

гэж тодорхойлно. Багцын хүлээгдэж буй өгөөж нь

$$\mu_p = E[r_p] = E\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i E[G_i]$$

байна. Энд $E[G_i]$ нь i-р хөрөнгийн хүлээгдэж буй өгөөжийг илэрхийлнэ.

Багцын эрсдэлийг өгөөжийн вариацаар хэмжвэл

$$\sigma_p^2 = \mathrm{Var}(r_p) = \mathrm{Var}\left[\sum_{i=1}^{N} x_i G_i\right] = \sum_{i=1}^{N} x_i^2 \sigma_i^2 + \sum_{i \neq j} x_i x_j \sigma_{ij},$$

байна. Энд $\sigma_i^2 = \mathrm{Var}(G_i)$ нь i-р хөрөнгийн өгөөжийн вариац, харин

$$\sigma_{ij} = \mathrm{Cov}(G_i, G_j)$$

нь i болон j-р хөрөнгийн өгөөжийн ковариац юм.

Багцын жингийн векторыг

$$\mathbf{x} = (x_1, x_2, \ldots, x_N)^\top,$$

хөрөнгүүдийн өгөөжийн ковариацын матрицыг

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1N} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \cdots & \sigma_{NN} \end{pmatrix}$$

гэж тэмдэглэвэл багцын вариацыг матриц хэлбэрээр

$$\sigma_p^2 = \mathbf{x}^\top \Sigma \mathbf{x}$$

гэж бичиж болно.

Иймээс багцын эрсдэл нь хөрөнгө тус бүрийн вариацаас гадна хөрөнгүүдийн өгөөж хоорондын ковариацаас хамаарна. Иймд ковариацын матрицыг хэрхэн үнэлэх нь багц сонголтын үр дүнд чухал нөлөөтэй.

2.2 Глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)

Энэхүү судалгаанд ковариацын матрицын өөр өөр үнэлэгчийг багцын оновчлолд ашиглахад үүсэх ялгааг харьцуулахын тулд глобал хамгийн бага вариацтай багц (Global Minimum Variance Portfolio, GMVP)-ийг ашиглана. GMVP-ийн зорилго нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилах нөхцөлд багцын вариацыг хамгийн бага байлгах хөрөнгө оруулалтын жинг тодорхойлоход оршино. GMVP-ийн оновчтой жинг тодорхойлоход хөрөнгүүдийн хүлээгдэж буй өгөөжийн үнэлгээ шаардлагагүй бөгөөд ковариацын матрицад тулгуурладаг.

Энэхүү судалгаанд богино арилжааг зөвшөөрөхгүй, хөрөнгө бүрийн багцад эзлэх жин сөрөг биш байх long-only GMVP загварыг ашиглана. Энэхүү хязгаарлалт нь богино арилжаа болон сөрөг жингээс үүдэх хөшүүрэгтэй байрлалыг хязгаарлахаас гадна ковариацын матрицын үнэлгээний алдаанаас шалтгаалан багцын жин хэт туйлшрах эрсдэлийг бууруулах боломжтой. (Jagannathan and Ma, 2003) нарын судалгаанд багцын жинг сөрөг бишээр хязгаарлах нь үнэлсэн оновчтой багцын эрсдэлийг бууруулж болохыг харуулсан. Түүнчлэн ийм хязгаарлалт нь ковариацын матрицын зарим элементийг агшаасантай төстэй нөлөө үзүүлж болохыг тайлбарласан.

Гэхдээ long-only хязгаарлалт нь өөрөө ковариацын матрицын үнэлгээний алдааны нөлөөг бууруулж болох тул агшилтын үнэлэгчдийн хоорондын гүйцэтгэлийн ялгааг багасгаж болзошгүй. Иймээс энэхүү судалгаанд ковариацын матрицын үнэлэгчдийн үр дүнг ижил long-only оновчлолын нөхцөлийн хүрээнд харьцуулж, гарсан дүгнэлтийг уг хязгаарлалтын хүрээнд тайлбарлана.

N ширхэг хөрөнгөөс бүрдэх багцын жингийн векторыг

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_N)^\top$$

гэж тэмдэглэе. Мөн хөрөнгүүдийн өгөөжийн ковариацын матрицын үнэлэгчийг $\widehat{\Sigma}$ гэвэл багцын үнэлэгдсэн вариац

$$\widehat{\sigma}_p^2 = \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x}$$

байна.

Тэгвэл long-only GMVP-ийн оновчлолын бодлогыг

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{x}^\top \widehat{\Sigma} \boldsymbol{x} \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{x} = 1, \\ & x_i \geq 0, \qquad i = 1, 2, \ldots, N \end{aligned}$$

гэж тодорхойлно. Энд $\mathbf{1}$ нь бүх элемент нь нэгтэй N хэмжээст вектор юм.

$\mathbf{1}^\top \boldsymbol{x} = 1$ нөхцөл нь нийт хөрөнгө оруулалтыг багцад бүрэн хуваарилахыг, харин $x_i \geq 0$ нөхцөл нь хөрөнгө бүрийн жин сөрөг биш байхыг илэрхийлнэ. Эдгээр нөхцөлөөс

$$0 \leq x_i \leq 1, \qquad i = 1, 2, \ldots, N$$

байх нь шууд мөрдөнө.

Long-only GMVP-ийн оновчтой жинг хязгаарлалттай квадратлаг оновчлолын бодлогын шийдээр тодорхойлно. Хэрэв $\widehat{\Sigma}$ нь эерэг хагас тодорхой матриц бол зорилгын функц гүдгэр байна. Мөн боломжит жингийн олонлог хоосон биш, хаалттай, хязгаарлагдмал тул оновчтой шийд оршино. Харин оновчтой шийд цорын ганц байх нь ковариацын матрицын шинж чанараас хамаарна.

Энэхүү судалгаанд түүврийн ковариацын матрицыг суурь үнэлэгч болгон авч, тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг харьцуулна.

Эдгээр зургаан ковариацын матрицын үнэлэгчийг ерөнхийд нь $\widehat{\Sigma}^{(k)}$, $k = 1, 2, \ldots, 6$ гэж тэмдэглэе. Тэгвэл k-р үнэлэгчид харгалзах long-only GMVP-ийн оновчтой жинг

$$\widehat{\boldsymbol{x}}^{(k)} \in \arg\min_{\substack{\boldsymbol{x} \in \mathbb{R}^N \\ \mathbf{1}^\top \boldsymbol{x} = 1 \\ \boldsymbol{x} \geq \mathbf{0}}} \boldsymbol{x}^\top \widehat{\Sigma}^{(k)} \boldsymbol{x}$$

гэж тодорхойлно.

Энд бүх үнэлэгчийн хувьд багцын оновчлолын зорилгын функцийн хэлбэр болон хөрөнгө оруулалтын жинд тавих хязгаарлалтууд ижил байх бөгөөд зөвхөн ковариацын матрицын үнэлэгч $\widehat{\Sigma}^{(k)}$ өөрчлөгдөнө.

Иймээс ковариацын матрицын үнэлэгчийн сонголтоос хамааран GMVP-ийн оновчтой жин, улмаар багцын эрсдэл болон бодит өгөөжийн үзүүлэлтүүд ялгаатай байж болно. Энэхүү судалгаанд эдгээр үнэлэгчээр байгуулсан long-only GMVP-үүдийн гүйцэтгэлийг ижил нөхцөлд харьцуулан үнэлнэ.

2.3 Түүврийн ковариацын матриц

Бодит нөхцөлд хөрөнгүүдийн өгөөжийн эх олонлогийн ковариацын матриц Σ үл мэдэгдэх тул түүнийг ажиглагдсан өгөгдлөөс үнэлэх шаардлагатай. Энэхүү судалгаанд n ажиглалт, N хөрөнгөөс бүрдэх өгөөжийн ажиглалтын матрицыг

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1N} \\ y_{21} & y_{22} & \cdots & y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nN} \end{pmatrix} \in \mathbb{R}^{n \times N}$$

гэж тэмдэглэнэ. Энд y_{ti} нь t-р хугацаанд ажиглагдсан i-р хөрөнгийн өгөөж, n нь ажиглалтын тоо, N нь хөрөнгийн тоо юм.

i-р хөрөнгийн дундаж өгөөжийг

$$\overline{Y}_i = \frac{1}{n} \sum_{t=1}^{n} y_{ti}, \qquad i = 1, 2, \ldots, N,$$

гэж тооцно.

Тэгвэл i болон j-р хөрөнгийн өгөөжийн түүврийн ковариацыг

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

гэж тодорхойлно. Эдгээр түүврийн ковариацуудаас бүрдэх түүврийн ковариацын матриц нь

$$S = (s_{ij}) = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1N} \\ s_{21} & s_{22} & \cdots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \cdots & s_{NN} \end{pmatrix}$$

байна. Энд S нь $N \times N$ хэмжээст түүврийн ковариацын матриц бөгөөд эх олонлогийн ковариацын матриц Σ-г үнэлэхэд ашиглагдана.

2.4 Шугаман агшилтын үнэлгээ (Linear Shrinkage Estimation)

Шугаман агшилт (Linear Shrinkage) нь агшилтын үнэлгээний хамгийн өргөн хэрэглэгддэг хэлбэрүүдийн нэг юм. Энэхүү аргын үндсэн санаа нь түүврийн ковариацын матриц болон тодорхой бүтэц бүхий зорилтот матрицыг гүдгэр хослол хэлбэрээр нэгтгэн ковариацын матрицын үнэлэгчийг байгуулахад оршино. Шугаман агшилтын үнэлэгчийг ерөнхий хэлбэрээр

$$\widehat{\Sigma}_{LS} = (1-\alpha)S + \alpha T, \qquad 0 \leq \alpha \leq 1,$$

гэж тодорхойлно. Энд S нь түүврийн ковариацын матриц, T нь зорилтот матриц, α нь агшилтын эрчим юм. $\alpha = 0$ үед $\widehat{\Sigma}_{LS} = S$, харин $\alpha = 1$ үед $\widehat{\Sigma}_{LS} = T$ болно. Иймээс α-ийн утга ихсэх тусам зорилтот матриц T-д өгөх жин нэмэгдэж, түүврийн ковариацын матриц S-д өгөх жин буурна.

Хэрэв зорилтот матриц T нь эерэг тодорхой бөгөөд $0 < \alpha \leq 1$ бол шугаман агшилтын үнэлэгч $\widehat{\Sigma}_{LS}$ нь эерэг тодорхой байна. Энэ шинж нь ковариацын матрицын тооцооллын тогтвортой байдлыг сайжруулахад ач холбогдолтой.

Шугаман агшилтын арга нь түүврийн ковариацын матрицын бүх элементэд нэг ижил агшилтын эрчим α-г хэрэглэдэг. Иймээс ковариацын матрицын бодит бүтэц нарийн төвөгтэй, эсвэл хөрөнгүүдийн хоорондын хамаарал харилцан адилгүй үед нэг ижил агшилтын эрчим хэрэглэх нь уг аргын уян хатан байдлыг хязгаарлаж болно.

Шугаман агшилтын үнэлгээний үр дүнд зорилтот матрицын сонголт чухал үүрэгтэй. Энэхүү судалгаанд тогтмол вариацын, диагональ, тогтмол корреляцийн болон нэг хүчин зүйлийн зорилтот матрицыг авч үзнэ. Эдгээр зорилтот матрицууд нь шугаман агшилтын ерөнхий хэлбэр дэх T-ийн үүргийг гүйцэтгэх бөгөөд тэдгээрийн ялгаа нь ковариацын матрицын бүтцэд тавих таамаглалд оршино.

2.4.1 Тогтмол вариацын зорилтот матриц

Тогтмол вариацын зорилтот матриц нь бүх хөрөнгийн вариацыг нэг нийтлэг утгаар төлөөлүүлж, хөрөнгүүдийн хоорондын ковариацыг тэг гэж үздэг. Уг зорилтот матрицыг

$$T_{\text{var}} = \widehat{\mu} I$$

гэж тодорхойлно. Энд I нь $N \times N$ хэмжээст нэгж матриц, харин

$$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N} s_{ii} = \frac{\text{tr}(S)}{N}$$

нь хөрөнгүүдийн өгөөжийн түүврийн вариацуудын дундаж юм. Иймээс

$$T_{\text{var}} = \begin{pmatrix} \widehat{\mu} & 0 & \cdots & 0 \\ 0 & \widehat{\mu} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \widehat{\mu} \end{pmatrix}$$

хэлбэртэй байна (Ledoit and Wolf, 2004b).

Тогтмол вариацын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{var}} = (1 - \widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}} T_{\text{var}}, \qquad 0 \leq \widehat{\alpha}_{\text{var}} \leq 1$$

гэж тодорхойлно.

Агшилтын эрчмийн онолын үндэслэлийг Ledoit болон Wolf (2004)-ийн үр дүнд тулгуурлан дараах хэмжигдэхүүнүүдийг авч үзье:

$$\begin{aligned} a &= E\left[\|\Sigma - T\|^2\right] = \|\Sigma - T\|^2, \\ b &= E\left[\|S - \Sigma\|^2\right], \\ d &= E\left[\|S - T\|^2\right]. \end{aligned}$$

Лемма 1 (Ledoit–Wolf, 2004). Хэрэв $E[S] = \Sigma$ бөгөөд квадратын математик дундажууд төгсгөлөг бол

$$a + b = d$$

тэнцэтгэл биелнэ.

Баталгаа. Математик дундаж ба нормын чанараас

$$\begin{aligned} d &= E\left[\|S - T\|^2\right] = E\left[\|S - \Sigma + \Sigma - T\|^2\right] \\ &= E\left[\|S - \Sigma\|^2\right] + \|\Sigma - T\|^2 + 2E\left[\langle S - \Sigma, \Sigma - T\rangle\right]. \end{aligned}$$

$E[S] = \Sigma$ бөгөөд T нь санамсаргүй бус матриц тул

$$E\left[\langle S - \Sigma, \Sigma - T\rangle\right] = \langle E[S - \Sigma], \Sigma - T\rangle = 0.$$

Иймээс

$$d = b + a.$$

Лемма батлагдав. □

Теорем 1 (Ledoit–Wolf, 2004). Дараах оновчлолын бодлогыг авч үзье:

$$\min_{0 \leq \alpha \leq 1} E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right],$$

энд

$$\Sigma^*(\alpha) = (1 - \alpha)S + \alpha T.$$

Хэрэв $d > 0$ бол оновчтой агшилтын эрчим

$$\alpha^* = \frac{b}{d}$$

бөгөөд харгалзах үнэлэгч

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T$$

байна.

Баталгаа. Агшилтын үнэлэгчийн алдааг

$$\Sigma^*(\alpha) - \Sigma = (1-\alpha)(S-\Sigma) + \alpha(T-\Sigma)$$

гэж бичиж болно.

Одоо нормын квадратын томьёо болон математик дунджийн шугаман чанарыг хэрэглэнэ.

$$\begin{aligned}\|\Sigma^*(\alpha) - \Sigma\|^2 &= \|(1-\alpha)(S-\Sigma) + \alpha(T-\Sigma)\|^2 \\ &= (1-\alpha)^2\|S-\Sigma\|^2 + \alpha^2\|T-\Sigma\|^2 + 2\alpha(1-\alpha)\langle S-\Sigma, T-\Sigma\rangle.\end{aligned}$$

Хоёр талаас математик дундаж авбал:

$$\begin{aligned}E\left[\|\Sigma^*(\alpha) - \Sigma\|^2\right] &= (1-\alpha)^2 E\left[\|S-\Sigma\|^2\right] + \alpha^2 E\left[\|T-\Sigma\|^2\right] + 2\alpha(1-\alpha)E\left[\langle S-\Sigma, T-\Sigma\rangle\right] \\ &= (1-\alpha)^2 b + \alpha^2 a.\end{aligned}$$

Иймээс зорилгын функц

$$R(\alpha) = (1-\alpha)^2 b + \alpha^2 a$$

болно.

Алдааг хамгийн бага болгох α-г олох нь бидний зорилго учраас уламжлал аваад тэгтэй тэнцүүлнэ.

$$R'(\alpha) = -2(1-\alpha)b + 2\alpha a = 0.$$

Лемма 1-ээс $a + b = d$ тул

$$\alpha^* = \frac{b}{d}, \qquad 1 - \alpha^* = \frac{a}{d}.$$

Иймээс

$$\Sigma^* = \frac{a}{d}S + \frac{b}{d}T.$$

$R''(\alpha) = 2d > 0$ учраас энэ нь минимум шийд юм.

Теорем батлагдав. □

Теорем 1-ээс оновчтой агшилтын эрчим нь түүврийн ковариацын матрицын үнэлгээний алдаа болон зорилтот матрицаас хазайх хэмжээнээс хамаарах нь харагдана.

Гэвч b болон d нь үл мэдэгдэх бодит ковариацын матрицаас хамаардаг тул тэдгээрийг өгөгдлөөс үнэлэх шаардлагатай. Ledoit болон Wolf (2004)-ийн оновчтой агшилтын эрчмийг өгөгдлөөс үнэлэх аргыг боловсруулсан.

Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын квадрат Фробениусын зайг

$$\widehat{d}_{\text{var}} = \|S - T_{\text{var}}\|_F^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг нормчилсон Фробениусын нормын тодорхойлолтоос

$$b_{var} = E\left[\|S-\Sigma\|^2\right] = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N} E\left[(s_{ij} - \sigma_{ij})^2\right].$$

Хэрэв $E[S] = \Sigma$ бол $E\left[(s_{ij} - \sigma_{ij})^2\right] = \text{Var}(s_{ij})$.

Иймээс

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\mathrm{Var}(s_{ij}).$$

Одоо

$$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\}$$

гэж тэмдэглэе.

Ажиглалтууд хугацааны хувьд харилцан хамааралгүй, ижил тархалттай бол

$$\mathrm{Var}(s_{ij}) \approx \frac{1}{n^2}\sum_{t=1}^{n}\mathrm{Var}\left((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)\right) = \frac{1}{n}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Тэгвэл

$$b_{var} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\frac{1}{n}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right) = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right).$$

Энд $\mathrm{Var}\left((y_{1i} - \overline{Y}_i)(y_{1j} - \overline{Y}_j)\right)$ нь үл мэдэгдэх тул түүний үнэлгээг $\frac{1}{n}\sum_{t=1}^{n}((y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij})^2$ байгуулвал

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right] =$$

$$= \frac{1}{nN}\left[\frac{1}{n}\sum_{t=1}^{n}\sum_{i=1}^{N}\sum_{j=1}^{N}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right].$$

Иймээс агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\mathrm{var}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{var}}{\widehat{d}_{\mathrm{var}}}\right\}\right\}$$

гэж байгуулна (Ledoit and Wolf, 2004b).

Тооцоолох алгоритм. Тогтмол вариацын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дараалаар тооцоолно.

1. Түүврийн ковариацын матрицыг байгуулах.

   n ажиглалт, N хөрөнгийн өгөөжийн өгөгдлөөс

   $$s_{ij} = \frac{1}{n}\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j)$$

   гэж тооцож, $S = (s_{ij})$ матрицыг байгуулна.

2. Тогтмол вариацын зорилтот матрицыг байгуулах.

   $$\widehat{\mu} = \frac{1}{N}\sum_{i=1}^{N}s_{ii}, \qquad T_{\mathrm{var}} = \widehat{\mu}I.$$

3. Ковариацын матрицын квадрат алдааг үнэлэх.

$$\widehat{b}_{var} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\{(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\}^2\right].$$

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

$$\widehat{d}_{\text{var}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij}-t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{var}} > 0$ үед

$$\widehat{\alpha}_{\text{var}} = \max\left\{0,\ \min\left\{1,\ \frac{\widehat{b}_{var}}{\widehat{d}_{\text{var}}}\right\}\right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\boxed{\widehat{\Sigma}_{\text{var}} = (1-\widehat{\alpha}_{\text{var}})S + \widehat{\alpha}_{\text{var}}T_{\text{var}}}.$$

2.4.2 Диагональ зорилтот матриц

Диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг гэж үзнэ. Уг зорилтот матрицыг

$$T_{\text{diag}} = \text{diag}(S) = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

гэж тодорхойлно. Матриц хэлбэрээр

$$T_{\text{diag}} = \begin{pmatrix} s_{11} & 0 & \cdots & 0 \\ 0 & s_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_{NN} \end{pmatrix}.$$

Өөрөөр хэлбэл,

$$(T_{\text{diag}})_{ij} = \begin{cases} s_{ii}, & i = j, \\ 0, & i \neq j. \end{cases}$$

Иймээс диагональ зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалах боловч хөрөнгүүдийн өгөөж хоорондын ковариацыг тэг болгон хялбаршуулдаг.

Диагональ зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{diag}} = (1-\widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}}T_{\text{diag}}, \qquad 0 \le \widehat{\alpha}_{\text{diag}} \le 1,$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{diag}}$ нь диагональ зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Диагональ зорилтот матриц нь түүврийн ковариацын матрицын диагональ элементүүдийг өөрчлөхгүй хадгалдаг тул агшилт нь зөвхөн диагоналийн бус элементүүдэд үйлчилнэ.

Иймээс агшилтын эрчмийг үнэлэхдээ диагоналийн бус элементүүдийн квадрат алдааг авч үзнэ.

Түүврийн ковариацын матриц болон диагональ зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{diag}} = \|S - T_{\text{diag}}\|^2 = \frac{1}{N}\sum_{\substack{i,j=1\\ i\neq j}}^{N} s_{ij}^2$$

гэж тодорхойлно.

Учир нь S болон T_{diag} матрицын диагональ элементүүд ижил тул тэдгээрийн ялгавар диагональ дээр тэг байна.

Өмнөх тогтмол вариацын зорилтот матрицын хэсэгт үзсэнтэй адилтаар $\widehat{b}_{diag}$-г дараах байдлаар тодорхойлно.

$$\widehat{b}_{\text{diag}} = \frac{1}{nN}\sum_{\substack{i,j=1\\ i\neq j}}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}(z_{tij} - s_{ij})^2\right].$$

Иймээс диагональ зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{diag}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}}\right\}\right\}$$

гэж байгуулна.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}$$

гэж тооцно.

Тооцоолох алгоритм. Диагональ зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Диагональ зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$T_{\text{diag}} = \text{diag}(s_{11}, s_{22}, \ldots, s_{NN})$$

   гэж байгуулна.

2. Диагоналийн бус элементүүдийн квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{diag}} = \frac{1}{nN}\sum_{\substack{i,j=1\\ i\neq j}}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}(z_{tij} - s_{ij})^2\right].$$

3. Зорилтот матрицаас хазайх квадрат зайг тооцох.

   $$\widehat{d}_{\text{diag}} = \frac{1}{N}\sum_{\substack{i,j=1\\ i\neq j}}^{N} s_{ij}^2.$$

4. Агшилтын эрчмийг үнэлэх.

   $\widehat{d}_{\text{diag}} > 0$ үед

$$\widehat{\alpha}_{\text{diag}} = \max\left\{0,\, \min\left\{1,\, \frac{\widehat{b}_{\text{diag}}}{\widehat{d}_{\text{diag}}}\right\}\right\}.$$

5. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{diag}} = (1 - \widehat{\alpha}_{\text{diag}})S + \widehat{\alpha}_{\text{diag}} T_{\text{diag}}.$$

2.4.3 Тогтмол корреляцын зорилтот матриц

Тогтмол корреляцын зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг тэдгээрийн дундаж утгаар төлөөлүүлэн байгуулдаг зорилтот матриц юм (Ledoit and Wolf, 2004a).

i болон j дугаар хөрөнгийн өгөөжийн түүврийн корреляцын коэффициентийг

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}$$

гэж тодорхойлно (Ledoit and Wolf, 2004a).

Хөрөнгүүдийн хоорондын түүврийн корреляцуудын дундажийг

$$\bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

гэж тооцно.

Тогтмол корреляцын зорилтот матрицын элементүүдийг

$$(T_{\text{corr}})_{ij} = t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii}s_{jj}}, & i \neq j \end{cases}$$

гэж тодорхойлно.

Иймээс уг зорилтот матриц нь хөрөнгө тус бүрийн өгөөжийн түүврийн вариацыг өөрчлөхгүй хадгалж, харин хөрөнгүүдийн хоорондын корреляцыг нэг ижил дундаж утгаар орлуулна.

Тогтмол корреляцын зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}, \qquad 0 \leq \widehat{\alpha}_{\text{corr}} \leq 1$$

гэж тодорхойлно. Энд $\widehat{\alpha}_{\text{corr}}$ нь тогтмол корреляцын зорилтот матрицад харгалзах агшилтын эрчим юм.

Агшилтын эрчмийн үнэлгээ. Тогтмол корреляцын зорилтот матриц нь түүврийн ковариацын матрицын элементүүдээс хамааран байгуулагддаг тул агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг харгалзан үзнэ.

Түүврийн ковариацын матриц болон тогтмол корреляцын зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{corr}} = \|S - T_{\text{corr}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2 = \frac{1}{N}\sum_{\substack{i,j=1 \\ i\neq j}}^{N}\left(s_{ij} - \bar{r}\sqrt{s_{ii}s_{jj}}\right)^2$$

гэж тодорхойлно.

Түүврийн ковариацын матрицын хүлээгдэж буй квадрат алдааг өмнөх хэсгүүдэд үзсэнтэй адилаар

$$\widehat{b}_{\text{corr}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right]$$

гэж бичигдэнэ.

Тогтмол корреляцын зорилтот матриц нь түүврийн ковариацын матрицаас хамаардаг учраас тэдгээрийн харгалзах элементүүдийн асимптотик ковариацыг тооцох шаардлагатай.

Энэ хэмжигдэхүүний нормчилсон үнэлгээг $\widehat{c}_{\text{corr}}$ гэж тэмдэглэе.

Эхлээд

$$\widehat{\vartheta}_{ii,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

болон

$$\widehat{\vartheta}_{jj,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{tj} - \overline{Y}_j)^2 - s_{jj} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

гэж тодорхойлно.

Эдгээр нь түүврийн вариац болон ковариацын элементүүдийн асимптотик ковариацыг үнэлэхэд ашиглагдана.

Ledoit болон Wolf (2004) нь түүврийн ковариацын матриц болон тогтмол корреляцын зорилтот матрицын асимптотик хам хэлбэлзлийг тооцох аргыг боловсруулсан (Ledoit and Wolf, 2004a). Тэдгээрийн Appendix B-д өгсөн үр дүнд тулгуурлан

$$\widehat{c}_{\text{corr}} = \frac{1}{nN} \left[\sum_{i=1}^{N} \widehat{\text{Var}} \left((y_{1i} - \overline{Y}_i)^2 \right) + \frac{\bar{r}}{2} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left(\sqrt{\frac{s_{jj}}{s_{ii}}} \widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}} \widehat{\vartheta}_{jj,ij} \right) \right]$$

гэж үнэлнэ.

Энд

$$\widehat{\text{Var}} \left((y_{1i} - \overline{Y}_i)^2 \right) = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\}^2$$

юм.

Иймээс тогтмол корреляцын зорилтот матрицад харгалзах агшилтын эрчмийн практик үнэлгээг

$$\widehat{\alpha}_{\text{corr}} = \max \left\{ 0, \min \left\{ 1, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}} \right\} \right\}$$

гэж байгуулна (Ledoit and Wolf, 2004a).

Энд $\widehat{b}_{\text{corr}}$ нь түүврийн ковариацын матрицын үнэлгээний квадрат алдааны асимптотик ойролцоо үнэлгээ, $\widehat{c}_{\text{corr}}$ нь түүврийн ковариацын матриц болон зорилтот матрицын харгалзах элементүүдийн асимптотик ковариацуудын нийлбэрийн нормчилсон үнэлгээ, $\widehat{d}_{\text{corr}}$ нь хоёр матрицын хоорондын нормчилсон квадрат Фробениусын зай юм.

Эцэст нь агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}}) S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}$$

гэж тооцно.

Тооцоолох алгоритм. Тогтмол корреляцын зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах дарааллаар тооцоолно.

1. Тогтмол корреляцын зорилтот матрицыг байгуулах.

   Өмнөх хэсэгт тооцсон түүврийн ковариацын матриц $S = (s_{ij})$-ийг ашиглан

   $$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}, \qquad \bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} r_{ij}$$

   гэж тооцно.

   Дараа нь

   $$t_{ij} = \begin{cases} s_{ii}, & i = j, \\ \bar{r}\sqrt{s_{ii}s_{jj}}, & i \neq j \end{cases}$$

   гэж тодорхойлж, $T_{\text{corr}} = (t_{ij})$ матрицыг байгуулна.

2. Ковариацын матрицын квадрат алдааг үнэлэх.

   $$\widehat{b}_{\text{corr}} = \frac{1}{nN} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[\frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}^2 \right]$$

   гэж тооцно.

3. Түүврийн ковариацын матриц болон зорилтот матрицын хам хэлбэлзлийг үнэлэх.

   $$\widehat{\vartheta}_{ii,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{ti} - \overline{Y}_i)^2 - s_{ii} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   болон

   $$\widehat{\vartheta}_{jj,ij} = \frac{1}{n} \sum_{t=1}^{n} \left\{ (y_{tj} - \overline{Y}_j)^2 - s_{jj} \right\} \left\{ (y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij} \right\}$$

   гэж тооцно.

   Дараа нь

   $$\widehat{c}_{\text{corr}} = \frac{1}{nN} \left[\sum_{i=1}^{N} \widehat{\text{Var}} \left((y_{1i} - \overline{Y}_i)^2 \right) + \frac{\bar{r}}{2} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \left(\sqrt{\frac{s_{jj}}{s_{ii}}} \widehat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}} \widehat{\vartheta}_{jj,ij} \right) \right]$$

   гэж үнэлнэ.

4. Зорилтот матрицаас хазайх квадрат зайг тооцох.

   $$\widehat{d}_{\text{corr}} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} (s_{ij} - t_{ij})^2.$$

5. Агшилтын эрчмийг үнэлэх.

$\widehat{d}_{\text{corr}} > 0$ үед

$$\widehat{\alpha}_{\text{corr}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\text{corr}} - \widehat{c}_{\text{corr}}}{\widehat{d}_{\text{corr}}}\right\}\right\}.$$

6. Агшилтын ковариацын матрицыг байгуулах.

$$\widehat{\Sigma}_{\text{corr}} = (1 - \widehat{\alpha}_{\text{corr}})S + \widehat{\alpha}_{\text{corr}} T_{\text{corr}}.$$

2.4.4 Нэг хүчин зүйлийн зорилтот матриц

Нэг хүчин зүйлийн зорилтот матриц нь хөрөнгүүдийн өгөөжийн хоорондын хамаарлыг зах зээлийн нийтлэг хүчин зүйлээр тайлбарлах нэг хүчин зүйлийн загварт (Single-Index Model) суурилдаг. Уг загварт хөрөнгийн өгөөжийг зах зээлийн нийтлэг хүчин зүйлтэй холбоотой хэсэг болон тухайн хөрөнгийн өөрийн онцлогоос хамаарах үлдэгдэл хэсэгт хуваан авч үздэг (Ledoit and Wolf, 2003).

Энэхүү судалгаанд зах зээлийн нийтлэг хүчин зүйлийг S&P 500 индексийн өгөөжөөр төлөөлүүлнэ.

i-р хөрөнгийн t-р хугацаан дахь өгөөжийг

$$y_{ti} = a_i + \beta_i R_{m,t} + \varepsilon_{ti}$$

гэж загварчилна. Энд $R_{m,t}$ нь t-р хугацаан дахь зах зээлийн өгөөж, a_i нь регрессийн тогтмол коэффициент, β_i нь i-р хөрөнгийн өгөөжийн зах зээлийн өөрчлөлтөд мэдрэг байдлыг илэрхийлэх коэффициент, ε_{ti} нь тухайн хөрөнгийн үлдэгдэл өгөөж юм.

Нэг хүчин зүйлийн загварын регрессийн коэффициентийг

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n}(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n}(R_{m,t} - \overline{R}_m)^2}$$

гэж үнэлнэ. Энд

$$\overline{R}_m = \frac{1}{n}\sum_{t=1}^{n} R_{m,t}$$

нь зах зээлийн өгөөжийн түүврийн дундаж юм.

Регрессийн тогтмол коэффициентийг

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m$$

гэж тооцно.

Тэгвэл i-р хөрөнгийн t-р хугацаан дахь регрессийн үлдэгдэл

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}$$

болно. Үүнийг

$$\widehat{\varepsilon}_{ti} = (y_{ti} - \overline{Y}_i) - \widehat{\beta}_i(R_{m,t} - \overline{R}_m)$$

гэж илэрхийлж болно.

Нэг хүчин зүйлийн загварын үндсэн таамаглалаар үлдэгдэл өгөөжүүд нь зах зээлийн хүчин зүйлтэй хамааралгүй, мөн өөр өөр хөрөнгүүдийн үлдэгдэл өгөөжүүд хооронд хамааралгүй байна. Өөрөөр хэлбэл,

$$\mathrm{Cov}(R_m, \varepsilon_i) = 0, \qquad i = 1, 2, \ldots, N,$$

ба

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0, \qquad i \neq j.$$

Эдгээр таамаглалын дор i болон j-р хөрөнгийн өгөөжийн ковариацыг

$$\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cov}(a_i + \beta_i R_m + \varepsilon_i, a_j + \beta_j R_m + \varepsilon_j)$$

гэж илэрхийлнэ.

Ковариацын чанарыг ашиглавал

$$\mathrm{Cov}(Y_i, Y_j) = \beta_i \beta_j \,\mathrm{Var}(R_m), \qquad i \neq j,$$

болно.

Харин i-р хөрөнгийн өгөөжийн вариац

$$\mathrm{Var}(Y_i) = \beta_i^2 \,\mathrm{Var}(R_m) + \mathrm{Var}(\varepsilon_i)$$

болно.

Зах зээлийн өгөөжийн түүврийн вариацыг

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2$$

гэж тооцно.

Мөн i-р хөрөнгийн регрессийн үлдэгдлийн вариацыг

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2$$

гэж тооцно.

Иймээс нэг хүчин зүйлийн зорилтот матриц $T_{\mathrm{SF}} = (t_{ij})$-ын элементүүдийг

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j \end{cases}$$

гэж тодорхойлно (Ledoit and Wolf, 2003).

Нэг хүчин зүйлийн зорилтот матрицыг матриц хэлбэрээр

$$T_{\mathrm{SF}} = \widehat{\boldsymbol{\beta}} \widehat{\boldsymbol{\beta}}^{\top} \widehat{\sigma}_m^2 + \widehat{D}_{\varepsilon}$$

гэж илэрхийлж болно.

Энд

$$\widehat{\boldsymbol{\beta}} = (\widehat{\beta}_1, \widehat{\beta}_2, \ldots, \widehat{\beta}_N)^{\top}$$

нь регрессийн коэффициентүүдийн вектор, харин

$$\widehat{D}_{\varepsilon} = \mathrm{diag}\left(\widehat{\sigma}_{\varepsilon,1}^2, \ldots, \widehat{\sigma}_{\varepsilon,N}^2\right)$$

нь үлдэгдлийн вариацуудаас бүрдэх диагональ матриц юм.

Нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}}) S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}, \qquad 0 \leq \widehat{\alpha}_{\mathrm{SF}} \leq 1,$$

гэж тодорхойлно.

Энд $\widehat{\alpha}_{\mathrm{SF}}$ нь нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчим

юм.

Агшилтын эрчмийн үнэлгээ. Ledoit and Wolf (2003) нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын эрчмийг үнэлэхдээ түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзэл, түүврийн ковариацын матриц болон зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзэл, мөн эдгээр матрицуудын хоорондын зайг харгалзан үзсэн.

Эхлээд түүврийн ковариацын матриц S болон нэг хүчин зүйлийн зорилтот матриц T_{SF} хоорондын нормчилсон квадрат Фробениусын зайг

$$\widehat{d}_{\text{SF}} = \|S - T_{\text{SF}}\|^2 = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}(s_{ij} - t_{ij})^2$$

гэж тодорхойлно.

Дараа нь түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг нэгтгэн хэмжих хэмжигдэхүүнийг

$$\widehat{b}_{\text{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\right\}^2\right]$$

гэж тооцно.

Нэг хүчин зүйлийн зорилтот матриц нь түүврийн өгөгдлөөс үнэлэгддэг учраас S болон T_{SF} матрицуудын үнэлгээний алдаанууд хоорондоо хамааралтай байж болно.

Иймээс агшилтын эрчмийг тооцоход эдгээр үнэлгээний алдаануудын хам хэлбэлзлийг харгалзах шаардлагатай.

Энэ хам хэлбэлзлийн нөлөөг $\widehat{c}_{\text{SF}}$ хэмжигдэхүүнээр илэрхийлнэ.

Нэг хүчин зүйлийн зорилтот матрицын диагональ элементүүд нь түүврийн ковариацын матрицын диагональ элементүүдтэй тэнцүү буюу $t_{ii} = s_{ii}$ байна.

Ledoit and Wolf (2003)-ийн Lemma 2-т үндэслэн үнэлгээний алдаануудын хам хэлбэлзлийг дараах байдлаар тооцно.

$i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti} - \overline{Y}_i)^2 - s_{ii}\right\}^2.$$

Харин $i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m) + \widehat{\beta}_i(y_{tj} - \overline{Y}_j)(R_{m,t} - \overline{R}_m) - \widehat{\beta}_i\widehat{\beta}_j(R_{m,t} - \overline{R}_m)^2 - t_{ij}\Big]\times$$

$$\times\Big[(y_{ti} - \overline{Y}_i)(y_{tj} - \overline{Y}_j) - s_{ij}\Big].$$

Иймээс хам хэлбэлзлийн нийлбэрийн нормчилсон үнэлгээг

$$\widehat{c}_{\text{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

гэж тодорхойлно. Ингэснээр нэг хүчин зүйлийн зорилтот матрицад харгалзах агшилтын эрчмийг

$$\widehat{\alpha}_{\text{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\text{SF}} - \widehat{c}_{\text{SF}}}{\widehat{d}_{\text{SF}}}\right\}\right\}$$

гэж үнэлнэ.

Энэ нь Ledoit and Wolf (2003)-ийн асимптотик оновчтой агшилтын эрчмийн үнэлгээг нормчилсон квадрат Фробениусын зайд нийцүүлэн илэрхийлсэн хэлбэр юм.

Энд $\widehat{d}_{\mathrm{SF}} > 0$ байхыг шаардана.

Эцэст нь нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг

$$\widehat{\Sigma}_{\mathrm{SF}} = (1 - \widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}} T_{\mathrm{SF}}$$

гэж олно.

Тооцоолох алгоритм. Нэг хүчин зүйлийн зорилтот матрицад суурилсан агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Зах зээлийн дундаж өгөөжийг тооцно.

$$\overline{R}_m = \frac{1}{n} \sum_{t=1}^{n} R_{m,t}.$$

2. Зах зээлийн өгөөжийн түүврийн вариацыг тооцно.

$$\widehat{\sigma}_m^2 = \frac{1}{n} \sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2.$$

3. Хөрөнгө тус бүрийн регрессийн коэффициентийг тооцно.

$$\widehat{\beta}_i = \frac{\sum_{t=1}^{n} (y_{ti} - \overline{Y}_i)(R_{m,t} - \overline{R}_m)}{\sum_{t=1}^{n} (R_{m,t} - \overline{R}_m)^2}.$$

4. Регрессийн тогтмол коэффициент болон үлдэгдлийг тооцно.

$$\widehat{a}_i = \overline{Y}_i - \widehat{\beta}_i \overline{R}_m,$$

$$\widehat{\varepsilon}_{ti} = y_{ti} - \widehat{a}_i - \widehat{\beta}_i R_{m,t}.$$

5. Хөрөнгө тус бүрийн үлдэгдлийн вариацыг тооцно.

$$\widehat{\sigma}_{\varepsilon,i}^2 = \frac{1}{n} \sum_{t=1}^{n} \widehat{\varepsilon}_{ti}^2.$$

6. Нэг хүчин зүйлийн зорилтот матрицыг байгуулна.

$$t_{ij} = \begin{cases} \widehat{\beta}_i^2 \widehat{\sigma}_m^2 + \widehat{\sigma}_{\varepsilon,i}^2, & i = j, \\ \widehat{\beta}_i \widehat{\beta}_j \widehat{\sigma}_m^2, & i \neq j. \end{cases}$$

   Эдгээр элементүүдээр $T_{\mathrm{SF}} = (t_{ij})$ матрицыг байгуулна.

7. Түүврийн ковариацын матриц болон зорилтот матрицын хоорондын нормчилсон квадрат Фробениусын зайг тооцно.

$$\widehat{d}_{\mathrm{SF}} = \frac{1}{N} \sum_{i=1}^{N} \sum_{j=1}^{N} (s_{ij} - t_{ij})^2.$$

8. Түүврийн ковариацын матрицын элементүүдийн түүвэрлэлтийн хэлбэлзлийг тооцно.

$$\widehat{b}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[\frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\right\}^2\right].$$

9. Түүврийн ковариацын матриц болон нэг хүчин зүйлийн зорилтот матрицын үнэлгээний алдаануудын хам хэлбэлзлийг тооцно.

   $i = j$ үед

$$\widehat{q}_{ii} = \frac{1}{n}\sum_{t=1}^{n}\left\{(y_{ti}-\overline{Y}_i)^2 - s_{ii}\right\}^2.$$

   $i \neq j$ үед

$$\widehat{q}_{ij} = \frac{1}{n}\sum_{t=1}^{n}\Big[\widehat{\beta}_j(y_{ti}-\overline{Y}_i)(R_{m,t}-\overline{R}_m)+\widehat{\beta}_i(y_{tj}-\overline{Y}_j)(R_{m,t}-\overline{R}_m)-\widehat{\beta}_i\widehat{\beta}_j(R_{m,t}-\overline{R}_m)^2-t_{ij}\Big]\times$$

$$\times\Big[(y_{ti}-\overline{Y}_i)(y_{tj}-\overline{Y}_j)-s_{ij}\Big].$$

   Дараа нь

$$\widehat{c}_{\mathrm{SF}} = \frac{1}{nN}\sum_{i=1}^{N}\sum_{j=1}^{N}\widehat{q}_{ij}$$

   гэж тооцно.

10. Агшилтын эрчмийг тооцно.

    $\widehat{d}_{\mathrm{SF}} > 0$ үед

$$\widehat{\alpha}_{\mathrm{SF}} = \max\left\{0, \min\left\{1, \frac{\widehat{b}_{\mathrm{SF}}-\widehat{c}_{\mathrm{SF}}}{\widehat{d}_{\mathrm{SF}}}\right\}\right\}.$$

11. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{SF}} = (1-\widehat{\alpha}_{\mathrm{SF}})S + \widehat{\alpha}_{\mathrm{SF}}T_{\mathrm{SF}}.$$

2.5 Шугаман бус агшилтын үнэлгээ

Шугаман агшилтын аргын хязгаарлалтыг даван туулах зорилгоор шугаман бус агшилтын (Nonlinear Shrinkage) аргуудыг боловсруулсан. Эдгээр аргууд нь түүврийн ковариацын матрицын спектрийн задлалд суурилдаг бөгөөд урьдчилан тодорхойлсон нэг зорилтот матриц руу бүхэлд нь агшаахын оронд түүврийн ковариацын матрицын хувийн утгуудыг ялгаатай хэмжээгээр засварладаг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U\Lambda U^{\top}$$

гэж тэмдэглэе. Энд $U = (u_1, u_2, \ldots, u_N)$ нь S матрицын хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь түүврийн ковариацын матрицын хувийн утгуудыг агуулсан диагональ матриц юм.

Шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\widehat{D}U^{\top}$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \widehat{d}_2, \ldots, \widehat{d}_N)$$

нь агшааж засварласан хувийн утгуудаас бүрдэх диагональ матриц бөгөөд $\widehat{d}_i$ нь λ_i хувийн утгад харгалзах засварласан хувийн утга юм.

Шугаман бус агшилтын арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, харин хувийн утга бүрийг өгөгдөлд тулгуурлан ялгаатай хэмжээгээр засварладаг. Иймээс хувийн утгуудын хэмжээ болон тэдгээрийн спектрийн тархалт дахь байрлалаас хамааран агшилтын хэмжээ өөр өөр байж болно.

Шугаман агшилтын аргын хувьд түүврийн ковариацын матриц болон зорилтот матрицыг нэг агшилтын эрчмээр хослуулдаг бол шугаман бус агшилтын арга нь хувийн утга бүрд тусгайлан тохируулсан хувиргалт хийдгээрээ ялгаатай. Ингэснээр түүврийн ковариацын матрицын хувийн утгуудын үнэлгээний алдааг бууруулах боломжийг олгодог.

Ledoit болон Wolf (2012) нар шугаман бус агшилтын аргын онолын үндэслэлийг боловсруулж, улмаар Ledoit болон Wolf (2015) нар QuEST (Quantized Eigenvalues Sampling Transform) алгоритмд суурилсан тоон хэрэгжилтийг хөгжүүлсэн. Энэхүү арга нь тоон оновчлол шаарддаг тул тооцооллын хувьд харьцангуй төвөгтэй байдаг.

Үүний дараа Ledoit and Wolf (2020) санамсаргүй матрицын онол болон спектрийн тархалтын шинж чанарт тулгуурласан аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн утгуудыг аналитик илэрхийлэлд суурилан засварладаг. Энэхүү судалгаанд аналитик шугаман бус агшилтын аргыг ашиглах бөгөөд түүний математик үндэслэл болон тооцоолох алгоритмыг дараагийн хэсэгт авч үзнэ.

2.5.1 Аналитик шугаман бус агшилтын үнэлгээ

Аналитик шугаман бус агшилтын үнэлгээ (Analytical Nonlinear Shrinkage Estimation) нь санамсаргүй матрицын онол (Random Matrix Theory)-д тулгуурлан түүврийн ковариацын матрицын хувийн утгуудыг засварлах арга юм. Шугаман агшилтын аргуудаас ялгаатай нь энэхүү арга нь хувийн утга бүрийн хэмжээ болон спектрийн тархалт дахь байрлалыг харгалзан ялгаатай агшилт хийдэг.

Ledoit and Wolf (2020) нь спектрийн тархалтын нягт болон түүний Hilbert хувиргалтыг kernel аргаар үнэлэх замаар аналитик шугаман бус агшилтын аргыг боловсруулсан. Уг арга нь түүврийн ковариацын матрицын хувийн векторуудыг хадгалж, хувийн утгуудыг засварлах замаар ковариацын матрицын үнэлгээний алдааг бууруулахад чиглэдэг.

Судалгаанд хамрагдсан хөрөнгийн тоог N, ажиглалтын тоог n гэж тэмдэглэж, тэдгээрийн харьцааг

$$c = \frac{N}{n}$$

гэж тодорхойлно. Аргын үндсэн онолын хувьд $N, n \to \infty$ үед

$$\frac{N}{n} \longrightarrow c \in (0, 1)$$

байх асимптотик нөхцөлийг авч үздэг.

Түүврийн ковариацын матрицын спектрийн задлалыг

$$S = U \Lambda U^\top$$

гэж тэмдэглэе. Энд

$$U = (u_1, u_2, \ldots, u_N), \qquad U^\top U = I_N,$$

нь хувийн векторуудаас бүрдэх ортогональ матриц, харин

$$\Lambda = \mathrm{diag}(\lambda_1, \lambda_2, \ldots, \lambda_N)$$

нь хувийн утгуудыг агуулсан диагональ матриц юм. Хувийн утгуудыг

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_N > 0$$

гэж эрэмбэлнэ.

Аналитик шугаман бус агшилтын үнэлэгчийг

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\widehat{D}U^\top = \sum_{i=1}^{N} \widehat{d}_i u_i u_i^\top$$

гэж тодорхойлно. Энд

$$\widehat{D} = \mathrm{diag}(\widehat{d}_1, \ldots, \widehat{d}_N)$$

нь агшсан хувийн утгуудаас бүрдэх диагональ матриц юм.

Агшсан хувийн утгуудын үнэлгээ. Ledoit and Wolf (2020)-ийн (4.3) томьёоны дагуу агшсан хувийн утгуудыг

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i \widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i \widehat{f}(\lambda_i)\right)^2}$$

гэж тооцно.

Энд $\widehat{f}(\lambda_i)$ нь спектрийн тархалтын нягтын үнэлгээ, $\widehat{Hf}(\lambda_i)$ нь уг нягтын Hilbert хувиргалтын үнэлгээ юм. Эдгээрийг түүврийн ковариацын матрицын хувийн утгуудад тулгуурлан kernel аргаар тооцдог.

Иймээс агшсан хувийн утга нь зөвхөн тухайн λ_i-ийн хэмжээнээс бус, спектрийн тархалтын нягт болон түүний Hilbert хувиргалтын утгаас хамаарна.

Тооцоолох алгоритм. Ledoit and Wolf (2020)-ийн Section 4.7-д үндэслэн аналитик шугаман бус агшилтын ковариацын матрицыг дараах үе шаттайгаар тооцно.

1. Түүврийн ковариацын матрицын спектрийн задлалыг байгуулна.

$$S = U\Lambda U^\top.$$

2. Хөрөнгийн тоо болон ажиглалтын тооны харьцааг тооцно.

$$c = \frac{N}{n}.$$

3. Спектрийн нягтыг үнэлэхэд ашиглах bandwidth параметрийг

$$h = n^{-1/3}$$

гэж сонгоно. Хувийн утга бүрд харгалзах локал bandwidth нь

$$h_j = \lambda_j h, \qquad j = 1, \ldots, N$$

байна.

4. Спектрийн нягтыг Epanechnikov kernel ашиглан үнэлнэ.

$$\widehat{f}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N}\frac{1}{h_j}k\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд

$$k(x) = \begin{cases} \dfrac{3}{4\sqrt{5}}\left(1 - \dfrac{x^2}{5}\right), & |x| \le \sqrt{5}, \\ 0, & |x| > \sqrt{5}. \end{cases}$$

5. Спектрийн нягтын Hilbert хувиргалтыг үнэлнэ.

$$\widehat{Hf}(\lambda_i) = \frac{1}{N}\sum_{j=1}^{N}\frac{1}{h_j}\ell\left(\frac{\lambda_i - \lambda_j}{h_j}\right),$$

энд $\ell(x) = Hk(x)$ бөгөөд

$$\ell(x) = \begin{cases} -\dfrac{3x}{10\pi} + \dfrac{3}{4\sqrt{5}\pi}\left(1 - \dfrac{x^2}{5}\right)\ln\left|\dfrac{\sqrt{5}-x}{\sqrt{5}+x}\right|, & |x| \ne \sqrt{5}, \\ -\dfrac{3x}{10\pi}, & |x| = \sqrt{5}. \end{cases}$$

6. Агшсан хувийн утгуудыг тооцно.

$$\widehat{d}_i = \frac{\lambda_i}{\left(1 - c - c\pi\lambda_i\widehat{Hf}(\lambda_i)\right)^2 + \left(c\pi\lambda_i\widehat{f}(\lambda_i)\right)^2}.$$

7. Агшилтын ковариацын матрицыг байгуулна.

$$\widehat{\Sigma}_{\mathrm{NLS}} = U\,\mathrm{diag}(\widehat{d}_1, \ldots, \widehat{d}_N)U^\top.$$

2.6 Эмпирик үнэлгээний арга зүй

Энэхүү судалгаанд ковариацын матрицын үнэлэгчдийн багцын оновчлолд үзүүлэх нөлөөг түүврээс гадуурх (out-of-sample, OOS) гүйцэтгэлд тулгуурлан харьцуулан үнэлнэ. Үүнд түүврийн ковариацын матриц, тогтмол вариацын, диагональ, тогтмол корреляцын болон нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид, мөн аналитик шугаман бус агшилтын үнэлэгчийг авч үзнэ.

Ковариацын матрицын үнэлгээний нарийвчлал болон түүнийг ашиглан байгуулсан багцын гүйцэтгэл нь ялгаатай ойлголтууд юм. Тухайлбал, ковариацын матрицын үнэлгээний алдааг бууруулсан арга нь багцын оновчлолын үр дүнд заавал хамгийн бага бодит эрсдэл бий болгох албагүй. Иймээс ковариацын үнэлэгчдийг зөвхөн үнэлсэн матрицын шинж чанараар бус, тэдгээрт үндэслэн байгуулсан багцын түүврээс гадуурх гүйцэтгэлээр харьцуулах шаардлагатай.

Ковариацын матрицын агшилтын үнэлэгчдийг багцын оновчлолд ашиглаж, түүврээс гадуурх эрсдэлийг харьцуулан үнэлэх аргачлалыг (**?**) судалгаанд хэрэглэсэн. Мөн (**?**) судалгаанд багцын оновчлолын аргуудыг сарын өгөгдөлд суурилсан шилжих цонхны аргаар үнэлж, тэдгээрийн түүврээс гадуурх гүйцэтгэлийг харьцуулсан.

Эдгээр судалгааны эмпирик үнэлгээний зарчимд тулгуурлан энэхүү судалгаанд бүх үнэлэгчийн хувьд ижил хөрөнгө оруулалтын хязгаарлалттай long-only GMVP

загварыг ашиглана. Үнэлгээний хугацаа, багцын жинг шинэчлэх давтамж болон гүйцэтгэлийн шалгуурыг бүх аргын хувьд ижил байлгана. Ингэснээр багцын гүйцэтгэлд үүсэх ялгааг ковариацын матрицын үнэлэгчийн сонголттой холбон харьцуулан үнэлэх боломж бүрдэнэ.

2.6.1 Шилжих цонхны (rolling-window) аргаар түүврээс гадуурх үнэлгээ хийх

Ковариацын матрицын үнэлэгчдийн багцын оновчлолд үзүүлэх нөлөөг үнэлэхийн тулд шилжих цонхны (rolling-window) аргыг ашиглана. Энэ арга нь тогтмол урттай түүхэн өгөгдөлд үндэслэн загварын параметрүүдийг үнэлж, багцын оновчтой жинг тодорхойлсны дараа уг жинг сургалтын өгөгдөлд ороогүй дараагийн хугацааны өгөөжид хэрэглэдэг.

(**?**) судалгаанд багцын оновчлолын аргуудыг харьцуулахдаа шилжих цонхны аргаар параметрүүдийг дахин үнэлж, дараагийн сарын өгөөжөөр түүврээс гадуурх гүйцэтгэлийг тодорхойлсон.

Нийт сарын өгөөжийн ажиглалтын тоог n, хөрөнгийн тоог N, сургалтын цонхны уртыг T гэж тэмдэглэе. t сарын N хөрөнгийн өгөөжийн векторыг

$$\boldsymbol{R}_t = (R_{1,t}, R_{2,t}, \ldots, R_{N,t})^\top$$

гэж тодорхойлно.

t сарын эцэст ашиглах сургалтын өгөгдөл нь

$$\mathcal{D}_t = \{\boldsymbol{R}_{t-T+1}, \boldsymbol{R}_{t-T+2}, \ldots, \boldsymbol{R}_t\}, \qquad t = T, T+1, \ldots, n-1$$

байна.

Ковариацын матрицын үнэлгээний аргыг $k = 0, 1, \ldots, 5$ гэж тэмдэглэе. Энд $k = 0$ нь түүврийн ковариацын матриц, харин $k = 1, \ldots, 5$ нь агшилтын таван үнэлэгчийг илэрхийлнэ.

Сургалтын цонх бүрд k-р аргаар тооцсон ковариацын матрицыг

$$\widehat{\boldsymbol{\Sigma}}_t^{(k)} = \widehat{\boldsymbol{\Sigma}}^{(k)}(\mathcal{D}_t)$$

гэж тэмдэглэнэ.

Нэг хүчин зүйлийн зорилтот матрицад суурилсан үнэлэгчийн хувьд $\mathcal{D}_t$-тэй ижил хугацааны зах зээлийн индексийн өгөөжийг нэмж ашиглана. Бусад үнэлэгчийн хувьд тухайн сургалтын цонхны хөрөнгүүдийн өгөөжид үндэслэн ковариацын матрицыг үнэлнэ.

Үнэлсэн ковариацын матрицад үндэслэн long-only GMVP-ийн оновчтой жинг дараах бодлогоор тодорхойлно:

$$\begin{aligned} \widehat{\boldsymbol{w}}_t^{(k)} = \arg\min_{\boldsymbol{w}} \quad & \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}}_t^{(k)} \boldsymbol{w}, \\ \text{subject to} \quad & \mathbf{1}^\top \boldsymbol{w} = 1, \\ & w_i \geq 0, \qquad i = 1, \ldots, N. \end{aligned}$$

Энд $\widehat{\boldsymbol{w}}_t^{(k)}$ нь t сарын эцэст тодорхойлж, дараагийн сард хэрэглэх багцын жингийн вектор юм.

Тухайн жинг ашиглан $t+1$ сард хэрэгжих багцын өгөөжийг

$$r_{p,t+1}^{(k)} = \left(\widehat{\boldsymbol{w}}_t^{(k)}\right)^\top \boldsymbol{R}_{t+1}$$

гэж тооцно.

Энэ тооцоололд $\boldsymbol{R}_{t+1}$ нь ковариацын матриц болон багцын жинг тодорхойлоход ашиглагдахгүй. Иймээс ирээдүйн мэдээллийг сургалтын өгөгдөлд оруулахгүй байх нөхцөл хангагдана.

Дараагийн алхамд сургалтын цонхыг нэг сараар урагшлуулж, ковариацын матрицын бүх үнэлэгч, тэдгээрийн агшилтын эрчим болон багцын оновчтой жинг шинээр тооцно. Энэ үйлдлийг үнэлгээний хугацааны турш давтан гүйцэтгэнэ.

Энэхүү судалгааны үндсэн шинжилгээнд $N = 10$ хөрөнгө, $n = 172$ сарын өгөөж, $T = 120$ сарын сургалтын цонхыг ашиглана.

Түүврээс гадуурх өгөөжийн ажиглалтын тоог

$$M = n - T$$

гэж тэмдэглэвэл

$$M = 172 - 120 = 52$$

байна.

Иймээс үнэлэгч бүрийн хувьд

$$\left\{ r_{p,T+1}^{(k)}, r_{p,T+2}^{(k)}, \ldots, r_{p,n}^{(k)} \right\}$$

гэсэн 52 сарын өгөөжийн цуваа үүснэ.

Ийнхүү бүх аргыг ижил хугацааны бодит өгөөжөөр үнэлэх нь тэдгээрийн гүйцэтгэлийг харьцуулах үндэслэл болно.

2.6.2 Багцын гүйцэтгэлийн үзүүлэлтүүд

Ковариацын матрицын үнэлэгчдийн гүйцэтгэлийг түүврээс гадуурх өгөөжийн хэлбэлзэл, түүврийн ковариацын матрицтай харьцуулсан вариацын бууралт болон Sharpe-ийн харьцаагаар үнэлнэ.

Түүврээс гадуурх хэлбэлзэл (Out-of-Sample Volatility). k-р үнэлэгчээр байгуулсан багцын түүврээс гадуурх дундаж сарын өгөөжийг

$$\overline{r}_p^{(k)} = \frac{1}{M} \sum_{t=T}^{n-1} r_{p,t+1}^{(k)}$$

гэж тодорхойлно.

Тэгвэл түүврээс гадуурх вариацын үнэлгээ нь

$$\widehat{\sigma}_{p,k}^2 = \frac{1}{M-1} \sum_{t=T}^{n-1} \left(r_{p,t+1}^{(k)} - \overline{r}_p^{(k)} \right)^2$$

байна.

Үүнээс багцын сарын стандарт хазайлтыг

$$\widehat{\sigma}_{p,k} = \sqrt{\widehat{\sigma}_{p,k}^2}$$

гэж тооцно.

Сарын өгөөжийн стандарт хазайлтыг жилийн хэмжээнд шилжүүлэхдээ

$$\widehat{\sigma}_{p,k}^{ann} = \sqrt{12}\, \widehat{\sigma}_{p,k}$$

гэсэн томьёог ашиглана.

Энэхүү хөрвүүлэлт нь сарын өгөөжүүдийн хугацааны автоковариацыг тэг гэж үзсэн нөхцөлд үндэслэнэ.

Түүврээс гадуурх хэлбэлзэл бага байх нь тухайн ковариацын үнэлэгчээр байгуулсан багц харьцангуй бага эрсдэлтэй байгааг илэрхийлнэ.

Харьцангуй вариацын бууралт (Relative Variance Reduction). Агшилтын үнэлэгчээр байгуулсан багцын эрсдэлийг түүврийн ковариацын матрицад суурилсан GMVP-ийн эрсдэлтэй харьцуулахын тулд харьцангуй вариацын бууралтыг ашиглана.

Үүнийг

$$RVR_k = 1 - \frac{\widehat{\sigma}^2_{p,k}}{\widehat{\sigma}^2_{p,0}}, \qquad k = 1, \ldots, 5$$

гэж тодорхойлно.

Энд $\widehat{\sigma}^2_{p,0}$ нь түүврийн ковариацын матрицад суурилсан GMVP-ийн түүврээс гадуурх вариац юм.

$RVR_k > 0$ бол k-р агшилтын үнэлэгчээр байгуулсан багц суурь загвараас бага вариацтай, харин $RVR_k < 0$ бол их вариацтай байгааг илэрхийлнэ.

Харьцангуй вариацын бууралтыг хувиар илэрхийлэхдээ

$$RVR_k^{(\%)} = 100 \left(1 - \frac{\widehat{\sigma}^2_{p,k}}{\widehat{\sigma}^2_{p,0}}\right)$$

гэж тооцно.

Sharpe-ийн харьцаа (Sharpe Ratio). Багцын эрсдэлд харьцуулсан өгөөжийг үнэлэхийн тулд Sharpe-ийн харьцааг ашиглана.

Ерөнхий тохиолдолд t сарын эрсдэлгүй өгөөжийг $r_{f,t}$ гэж тэмдэглэвэл багцын илүүдэл өгөөж нь

$$r^{(k)}_{e,t} = r^{(k)}_{p,t} - r_{f,t}$$

байна.

Түүврээс гадуурх дундаж илүүдэл өгөөжийг

$$\overline{r}^{(k)}_e = \frac{1}{M} \sum_{t=T}^{n-1} \left(r^{(k)}_{p,t+1} - r_{f,t+1}\right)$$

гэж тодорхойлно.

Тэгвэл сарын Sharpe-ийн харьцаа нь

$$\widehat{SR}_k = \frac{\overline{r}^{(k)}_e}{\widehat{\sigma}_{e,k}}$$

байна.

Энд $\widehat{\sigma}_{e,k}$ нь түүврээс гадуурх сарын илүүдэл өгөөжийн стандарт хазайлт юм.

Энэхүү судалгааны тооцоололд сарын эрсдэлгүй өгөөжийг

$$r_{f,t} = 0$$

гэж авч үзсэн.

Иймээс

$$\overline{r}^{(k)}_e = \overline{r}^{(k)}_p, \qquad \widehat{\sigma}_{e,k} = \widehat{\sigma}_{p,k}$$

бөгөөд сарын Sharpe-ийн харьцааг

$$\widehat{SR}_k = \frac{\overline{r}_p^{(k)}}{\widehat{\sigma}_{p,k}}$$

гэж тооцно.

Сарын өгөөжүүдийн автоковариацыг тэг гэж үзсэн нөхцөлд жилийн Sharpe-ийн харьцааг

$$\widehat{SR}_k^{ann} = \sqrt{12}\,\widehat{SR}_k$$

гэж хөрвүүлнэ.

Sharpe-ийн харьцаа өндөр байх нь нэгж эрсдэлд ногдох дундаж илүүдэл өгөөж харьцангуй өндөр байгааг илэрхийлнэ.

GMVP-ийн зорилго нь Sharpe-ийн харьцааг хамгийн их байлгах биш, харин багцын вариацыг хамгийн бага байлгах явдал гэдгийг анхаарах шаардлагатай. Иймээс Sharpe-ийн харьцааг багцын гүйцэтгэлийн нэмэлт үзүүлэлт болгон ашиглана.

2.6.3 Багцын жингийн тогтвортой байдал ба эргэлт

Ковариацын матрицын үнэлэгчийн сонголт нь багцын эрсдэлээс гадна хөрөнгө оруулалтын жингийн бүтэц болон хугацааны явц дахь өөрчлөлтөд нөлөөлж болно.

Иймээс багцын жингийн бүтцийг төвлөрлийн үзүүлэлтээр, харин жингийн өөрчлөлтийг багцын эргэлтээр үнэлнэ.

Багцын эргэлт (Portfolio Turnover). Багцын эргэлт нь багцын жинг шинэчлэх үед худалдах болон худалдан авах шаардлагатай хөрөнгийн хэмжээг илэрхийлнэ.

t сарын өгөөж хэрэгжихээс өмнө ашигласан багцын жинг $\widehat{\boldsymbol{w}}_{t-1}^{(k)}$ гэж тэмдэглэе.

t сарын өгөөж хэрэгжсэний дараа, дахин тэнцвэржүүлэхээс өмнөх i-р хөрөнгийн жин нь

$$\widetilde{w}_{i,t}^{(k)} = \frac{\widehat{w}_{i,t-1}^{(k)}(1+R_{i,t})}{1+r_{p,t}^{(k)}}$$

байна.

Энд

$$r_{p,t}^{(k)} = \sum_{i=1}^{N} \widehat{w}_{i,t-1}^{(k)} R_{i,t}$$

нь тухайн сард хэрэгжсэн багцын өгөөж юм.

Ийнхүү хөрөнгүүдийн өгөөж ялгаатай байснаас шалтгаалан багцын жин анхны түвшнээс өөрчлөгдөнө.

t сарын эцэст шинээр тодорхойлсон $\widehat{\boldsymbol{w}}_t^{(k)}$ жинд шилжихэд шаардагдах багцын эргэлтийг

$$TO_t^{(k)} = \frac{1}{2}\sum_{i=1}^{N}\left|\widehat{w}_{i,t}^{(k)} - \widetilde{w}_{i,t}^{(k)}\right|$$

гэж тодорхойлно.

Энд $1/2$ үржүүлэгч нь худалдах болон худалдан авах хэмжээг давхар тооцохоос сэргийлнэ.

Түүврээс гадуурх хугацааны дундаж эргэлтийг

$$\overline{TO}^{(k)} = \frac{1}{M-1}\sum_{t=T+1}^{n-1} TO_t^{(k)}$$

гэж тооцно.

Эхний түүврээс гадуурх сард хэрэглэсэн жинг дараагийн сарын жингийн өөрчлөлтийг тооцох эхлэл болгон ашиглана. Иймээс $M = 52$ сарын OOS өгөөжид харгалзах багцын эргэлтийг $M - 1 = 51$ удаагийн дахин тэнцвэржүүлэлтээр тооцно.

Багцын эргэлт бага байх нь хөрөнгө оруулалтын жинг шинэчлэх шаардлага харьцангуй бага байгааг илэрхийлнэ. Энэ үзүүлэлт нь арилжааны зардал үүсэх боломжийг үнэлэхэд ач холбогдолтой боловч энэхүү судалгаанд арилжааны бодит зардлыг багцын өгөөжөөс хасаагүй.

Багцын жингийн төвлөрөл (Weight Concentration). Багцын жингийн төвлөрлийг Herfindahl–Hirschman Index (HHI)-ээр хэмжинэ.

t сарын эцэст k-р үнэлэгчээр байгуулсан багцын төвлөрлийг

$$HHI_t^{(k)} = \sum_{i=1}^{N} \left(\widehat{w}_{i,t}^{(k)} \right)^2$$

гэж тодорхойлно.

Long-only GMVP-ийн хувьд

$$\frac{1}{N} \leq HHI_t^{(k)} \leq 1$$

байна.

Бүх хөрөнгийн жин ижил, өөрөөр хэлбэл $w_i = 1/N$ үед

$$HHI_t^{(k)} = \frac{1}{N}$$

болох бөгөөд багцын төвлөрөл хамгийн бага байна.

Харин бүх хөрөнгийг нэг хөрөнгөд байршуулсан үед

$$HHI_t^{(k)} = 1$$

болно.

Түүврээс гадуурх хугацааны дундаж төвлөрлийг

$$\overline{HHI}^{(k)} = \frac{1}{M} \sum_{t=T}^{n-1} HHI_t^{(k)}$$

гэж тооцно.

HHI өндөр байх нь багцын жин цөөн тооны хөрөнгөд төвлөрч байгааг илэрхийлнэ.

Багцын эргэлт болон төвлөрлийг хамтад нь авч үзсэнээр ковариацын үнэлэгчдийн багцын жингийн бүтэц болон хугацааны явц дахь өөрчлөлтийг харьцуулан үнэлнэ.

2.6.4 Ковариацын үнэлэгчдийн статистик харьцуулалт

Түүврээс гадуурх гүйцэтгэлийн үзүүлэлтүүдийн ялгаа нь санамсаргүй хэлбэлзлээс үүссэн эсэхийг үнэлэхийн тулд статистик харьцуулалт хийнэ.

Энэхүү судалгаанд түүврийн ковариацын матрицад суурилсан GMVP-ийг суурь загвар болгон авч, агшилтын үнэлэгч тус бүрийн багцын гүйцэтгэлийг түүнтэй харьцуулна.

k-р агшилтын үнэлэгч болон түүврийн ковариацын матрицад суурилсан багцын тухайн сарын квадрат өгөөжийн ялгааг

$$d_t^{(k)} = \left(r_{p,t}^{(k)}\right)^2 - \left(r_{p,t}^{(0)}\right)^2, \qquad t = T+1, \ldots, n$$

гэж тодорхойлно.

Энэ хэмжигдэхүүн нь хоёр багцын өгөөжийн тэг утгын орчим дахь квадрат хэмжигдэхүүний ялгааг илэрхийлнэ.

Түүний түүврээс гадуурх дундаж нь

$$\overline{d}^{(k)} = \frac{1}{M} \sum_{t=T+1}^{n} d_t^{(k)}$$

байна.

Дараах таамаглалуудыг шалгана:

$$H_0 : E[d_t^{(k)}] = 0,$$

$$H_1 : E[d_t^{(k)}] \neq 0.$$

H_0 таамаглал нь хоёр багцын хүлээгдэж буй квадрат өгөөжийн ялгаа тэг байгааг илэрхийлнэ.

$\overline{d}^{(k)} < 0$ бол k-р агшилтын үнэлэгчээр байгуулсан багцын дундаж квадрат өгөөж суурь загвараас бага байгааг илэрхийлнэ.

Хугацааны цувааны ажиглалтуудын хооронд автокорреляц болон гетероскедастик шинж илэрч болох тул дундаж ялгааны стандарт алдааг heteroskedasticity and autocorrelation consistent (HAC) аргаар үнэлнэ.

Үүний тулд

$$d_t^{(k)} = \mu_d^{(k)} + \varepsilon_t^{(k)}$$

гэсэн зөвхөн тогтмол гишүүнтэй регрессийн загварыг авч үзнэ.

Энд $\mu_d^{(k)}$ нь квадрат өгөөжийн ялгааны хүлээгдэж буй дундаж бөгөөд түүний үнэлгээ нь

$$\widehat{\mu}_d^{(k)} = \overline{d}^{(k)}$$

байна.

HAC стандарт алдааг тооцохдоо лагийн тоог

$$L = 3$$

гэж сонгож, Newey–West төрлийн HAC ковариацын үнэлгээг ашиглана.

Тэгвэл шалгах статистик нь

$$t_{HAC}^{(k)} = \frac{\overline{d}^{(k)}}{\widehat{SE}_{HAC}\left(\overline{d}^{(k)}\right)}$$

байна.

Энд $\widehat{SE}_{HAC}(\overline{d}^{(k)})$ нь дундаж ялгааны HAC стандарт алдаа юм.

Статистик шалгалтыг хоёр талт хэлбэрээр гүйцэтгэж, HAC статистикийн асимптотик нормаль ойролцоололд үндэслэн p-утгыг тооцно.

Энэхүү шалгалтаар агшилтын үнэлэгчдийн квадрат өгөөжийн дундаж ялгаа статистикийн хувьд ач холбогдолтой эсэхийг үнэлнэ.

Гэхдээ квадрат өгөөжийн ялгаа нь төвлөрүүлсэн вариацын ялгаатай яг ижил

хэмжигдэхүүн биш юм. Учир нь

$$E[r_p^2] = \mathrm{Var}(r_p) + (E[r_p])^2 .$$

Иймээс HAC шалгалтын үр дүнг түүврээс гадуурх стандарт хазайлт болон харьцангуй вариацын бууралтын үзүүлэлттэй хамтатган тайлбарлана.

Түүнчлэн суурь загвартай таван агшилтын үнэлэгчийг тус тусад нь харьцуулж байгаа тул олон удаагийн статистик шалгалтын асуудал үүсэж болохыг анхаарна.

Энэхүү судалгааны үндсэн HAC шалгалтаар гарсан p-утгууд нь олон харьцуулалтын засвар хийгдээгүй утгууд юм. Иймээс тэдгээрийг тайлбарлахдаа олон шалгалтын улмаас санамсаргүй ач холбогдолтой үр дүн илрэх боломжийг харгалзана.

Мөн түүврээс гадуурх хугацаа $M = 52$ сар тул статистик шалгалтын чадал хязгаарлагдмал байж болохыг анхаарах шаардлагатай.

2.6.5 Хөрөнгийн тоо ба сургалтын ажиглалтын тооны харьцааны мэдрэмжийн шинжилгээ

Ковариацын матрицын үнэлгээний нарийвчлалд хөрөнгийн тоо болон сургалтын ажиглалтын тооны харьцаа чухал нөлөөтэй.

Энэхүү харьцааг

$$c = \frac{N}{T}$$

гэж тодорхойлно.

Энд N нь хөрөнгийн тоо, T нь ковариацын матрицыг үнэлэхэд ашигласан сургалтын ажиглалтын тоо юм.

N/T харьцаа ихсэхэд нэг хөрөнгөд ногдох ажиглалтын тоо харьцангуй багасч, түүврийн ковариацын матрицын үнэлгээний алдаа нэмэгдэх боломжтой.

Харин N/T харьцаа бага үед түүврийн ковариацын матриц илүү олон ажиглалтад тулгуурлах боловч үнэлгээний алдаа бүрэн арилна гэсэн үг биш юм.

Энэхүү судалгаанд хөрөнгийн тоог $N = 10$ гэж тогтмол байлгаж, сургалтын цонхны уртыг өөрчлөх замаар N/T харьцааны мэдрэмжийг шинжилнэ.

Үүнд

$$T \in \{60, 90, 120\}$$

гэсэн сарын сургалтын цонхуудыг авч үзнэ.

Харгалзах харьцаанууд нь

$$\frac{N}{T} = \frac{10}{60} \approx 0.1667,$$
$$\frac{N}{T} = \frac{10}{90} \approx 0.1111,$$
$$\frac{N}{T} = \frac{10}{120} \approx 0.0833$$

байна.

Сургалтын цонхны урт ялгаатай үед түүврээс гадуурх үнэлгээний эхлэх хугацаа мөн ялгаатай болох тул гүйцэтгэлийг шууд харьцуулах нь хугацааны нөлөөг агуулж болно.

Иймээс мэдрэмжийн шинжилгээнд бүх сургалтын цонхны хувьд ижил түүврээс гадуурх хугацааг ашиглана.

Тодруулбал, хамгийн урт сургалтын цонх $T_{\max} = 120$ үед үүсэх

$$M = n - T_{\max}$$

ажиглалттай түүврээс гадуурх хугацааг бүх хувилбарт ижил хэрэглэнэ.

Энэхүү судалгаанд

$$M = 172 - 120 = 52$$

учраас сургалтын цонхны гурван хувилбарыг ижил 52 сарын OOS хугацаанд харьцуулна.

Ингэснээр $T = 60$, $T = 90$ болон $T = 120$ үед ковариацын матрицыг үнэлэхэд ашигласан түүхэн ажиглалтын тоо ялгаатай боловч багцын гүйцэтгэлийг нэг ижил зах зээлийн хугацаанд харьцуулна.

Сургалтын цонхны хувилбар бүрд зургаан ковариацын үнэлэгчийг дахин тооцож, long-only GMVP-ийн оновчтой жинг тодорхойлно.

Дараа нь түүврээс гадуурх хэлбэлзэл, харьцангуй вариацын бууралт, Sharpe-ийн харьцаа, багцын эргэлт болон жингийн төвлөрлийг харьцуулна.

Энэ шинжилгээнд хөрөнгийн тоо тогтмол байгаа учраас N/T харьцааны өөрчлөлт нь зөвхөн сургалтын цонхны уртын өөрчлөлтөөс үүднэ.

Иймээс шинжилгээний үр дүнг N/T харьцааны нөлөөг сургалтын цонхны уртын нөлөөнөөс бүрэн тусгаарлан үнэлсэн гэж тайлбарлахгүй.

Харин сургалтын ажиглалтын тоо өөрчлөгдөхөд ковариацын матрицын агшилтын аргуудын түүврээс гадуурх гүйцэтгэл хэрхэн өөрчлөгдөж байгааг эмпирик түвшинд үнэлнэ.

3 Өгөгдөл

Энэхүү судалгаанд ковариацын матрицын үнэлгээний аргуудын гүйцэтгэлийг харьцуулах зорилгоор технологи болон технологид суурилсан бизнесийн чиглэлээр үйл ажиллагаа явуулдаг олон улсын 10 компанийн хувьцааны түүхэн үнийн өгөгдлийг ашигласан. Судалгаанд Apple (AAPL), Microsoft (MSFT), Alphabet (GOOGL), Amazon (AMZN), Nvidia (NVDA), Meta (META), Samsung Electronics (005930.KS), Tesla (TSLA), Intel (INTC), Tencent (0700.HK) компаниудыг хамруулсан. Эдгээр компани нь программ хангамж, хагас дамжуулагч, электроник, интернэт үйлчилгээ, цахим худалдаа болон цахилгаан автомашины үйлдвэрлэл зэрэг чиглэлээр үйл ажиллагаа явуулдаг.

Хувьцааны үнийн өгөгдлийг Yahoo Finance мэдээллийн сангаас Python программчлалын хэлний `yfinance` санг ашиглан татсан. Өгөгдлийг татахдаа 2012 оны 1 дүгээр сарын 1-нээс 2026 оны 09 дугаар сарын 30 хүртэлх хугацааг сонгосон. Хувьцааны ногдол ашиг болон хувьцаа хуваалтын нөлөөг харгалзан үзэх зорилгоор `auto_adjust=True` тохиргоог ашиглаж, тохируулгатай хаалтын үнийг авсан.

Судалгаанд өдөр, долоо хоног, сар, жилийн дөрвөн өөр давтамжийн өгөгдлийг ашигласан. Өгөгдлийн давтамжийг ялгаатайгаар сонгосон нь ковариацын матрицын үнэлгээний аргуудын гүйцэтгэл ажиглалтын давтамж болон түүврийн хэмжээнээс хэрхэн хамаарч байгааг харьцуулан судлах боломжийг бүрдүүлнэ.

Өгөгдлийг боловсруулахдаа хөрөнгө тус бүрийн үнийг огноогоор нэгтгэж, аль нэг хөрөнгийн үнийн мэдээлэл дутуу ажиглалтуудыг хассан. Ингэснээр бүх хөрөнгийн хувьд үнийн мэдээлэл бүрэн байгаа ажиглалтуудыг шинжилгээнд ашигласан.

Хөрөнгө тус бүрийн энгийн өгөөжийг дараах томьёогоор тооцно.

$$y_{ti} = \frac{P_{ti} - P_{t-1,i}}{P_{t-1,i}} = \frac{P_{ti}}{P_{t-1,i}} - 1,$$

энд P_{ti} нь i-р хөрөнгийн t-р хугацаан дахь тохируулгатай хаалтын үнэ, y_{ti} нь тухайн хөрөнгийн өгөөж юм.

Өгөөжийн өгөгдлийг

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1N} \\ y_{21} & y_{22} & \cdots & y_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nN} \end{pmatrix}$$

матрицаар илэрхийлнэ. Энд $N = 10$ нь хөрөнгийн тоо, n нь тухайн давтамж дахь өгөөжийн ажиглалтын тоо юм.

Өгөгдлийн давтамж бүрийн хувьд түүврийн ковариацын матриц болон агшилтын үнэлэгчдийг байгуулж, тэдгээрт суурилсан глобал хамгийн бага вариацтай багцын гүйцэтгэлийг харьцуулна. Ингэснээр ковариацын матрицын үнэлгээний аргуудын үр дүн өгөгдлийн давтамжаас хамааран хэрхэн өөрчлөгдөж байгааг шинжилнэ.

4 Эмпирик судалгааны үр дүн

Энэ хэсэгт ковариацын матрицын үнэлгээний аргуудын гүйцэтгэлийг бодит санхүүгийн өгөгдөлд тулгуурлан харьцуулан шинжилнэ. Судалгаанд түүврийн ковариацын матриц, тогтмол вариацын, диагональ, тогтмол корреляцын, нэг хүчин зүйлийн зорилтот матрицад суурилсан шугаман агшилтын үнэлэгчид болон аналитик шугаман бус агшилтын үнэлэгчийг авч үзсэн. Эдгээр үнэлэгчдийн үр дүнг глобал хамгийн бага вариацтай багц (GMVP) байгуулах замаар үнэлнэ.

Ковариацын матрицын үнэлэгчдийн гүйцэтгэлийг 10 компанийн хувьцааны сарын өгөөжийн өгөгдөлд тулгуурлан харьцуулна. Үнэлэгч бүрийн хувьд 120 сарын сургалтын цонхтой шилжих цонхны (rolling-window) аргыг ашиглан багцын оновчтой жинг сар бүр шинэчилж, нийт 52 сарын түүврээс гадуурх (out-of-sample, OOS) гүйцэтгэлийг үнэлнэ. Ингэснээр ковариацын матрицын үнэлгээний аргуудын үр дүнг ижил хугацаа, ижил хөрөнгө оруулалтын хязгаарлалтын нөхцөлд харьцуулах боломж бүрдэнэ.

Хөрөнгө оруулалтын багцын гүйцэтгэлийг түүврээс гадуурх өгөөжийн хэлбэлзэл, харьцангуй вариацын бууралт болон Sharpe-ийн харьцаагаар үнэлнэ. Мөн ковариацын матрицын үнэлгээний аргуудын ялгаа хөрөнгө оруулалтын багцын жингийн бүтэц болон тогтвортой байдалд хэрхэн нөлөөлж байгааг багцын эргэлт (turnover) болон жингийн төвлөрөл (HHI)-ийн үзүүлэлтээр шинжилнэ. Үүнээс гадна агшилтын үнэлэгчдийн түүврээс гадуурх квадрат өгөөжийн дундаж ялгааг түүврийн ковариацын матрицад суурилсан багцтай HAC статистик шалгалтаар харьцуулж, олон харьцуулалтын Holm-ийн засварыг хэрэглэнэ.

Эмпирик шинжилгээний үр дүнг хувьцааны өгөөжийн тодорхойлох статистик, ковариацын матрицын үнэлэгчдийн түүврээс гадуурх гүйцэтгэл, багцын жингийн тогтвортой байдал ба төвлөрөл, статистик харьцуулалт, сургалтын цонхны уртаас хамаарах мэдрэмжийн шинжилгээ гэсэн дараалаар танилцуулна. Мэдрэмжийн шинжилгээнд сургалтын цонхны уртыг 60, 90, 120 сараар өөрчилж, бүх хувилбарыг ижил 52 сарын түүврээс гадуурх хугацаанд харьцуулна.

4.1 Хувьцааны өгөөжийн тодорхойлох статистик

Судалгаанд хамрагдсан 10 компанийн хувьцааны нийт 172 сарын өгөөжийн тодорхойлох статистикийг Хүснэгт 1-д үзүүлэв. Үүнд сарын дундаж өгөөж, стандарт хазайлт, хамгийн бага болон их утга, асимметр, эксцессийг тооцсон. Эдгээр үзүүлэлтүүд нь хувьцаануудын өгөөжийн түвшин, хэлбэлзэл болон тархалтын онцлогийг харьцуулан үнэлэх боломж олгоно.

Хүснэгт 1-ээс харахад судалгаанд хамрагдсан компаниудын сарын дундаж өгөөж болон хэлбэлзэл харилцан адилгүй байна. Nvidia компанийн сарын дундаж өгөөж 4.67 хувь байгаа нь хамгийн өндөр үзүүлэлт бол Intel компанийнх 1.85 хувь буюу

Хүснэгт 1: Хувьцааны сарын өгөөжийн тодорхойлох статистик

Компани	Дундаж	Ст. хаз.	Минимум	Максимум	Асимметр	Эксцесс
Apple	0.0202	0.0767	-0.1812	0.2166	-0.0956	-0.4090
Microsoft	0.0203	0.0655	-0.1715	0.2458	0.2486	0.7175
Google	0.0212	0.0731	-0.1795	0.3382	0.4017	1.6196
Amazon	0.0221	0.0867	-0.2375	0.2727	0.3164	0.7418
Nvidia	0.0467	0.1207	-0.3203	0.3854	0.0976	0.5879
Meta	0.0247	0.1095	-0.3263	0.4791	0.2659	2.3167
AMD	0.0414	0.1753	-0.4105	0.7426	0.6749	1.2709
Tesla	0.0451	0.1810	-0.3673	0.8107	1.0994	2.4087
Intel	0.0185	0.1340	-0.3540	1.1409	3.4576	28.6664
Broadcom	0.0337	0.0948	-0.2097	0.4342	0.7448	2.0475

хамгийн бага байна. Түүнчлэн Tesla болон AMD компаниудын сарын дундаж өгөөж харьцангуй өндөр буюу 4.51 болон 4.14 хувь байна.

Өгөөжийн хэлбэлзлийг стандарт хазайлтаар харьцуулахад Tesla компанийн сарын стандарт хазайлт 18.10 хувь, AMD компанийнх 17.53 хувь байгаа нь бусад компаниас өндөр байна. Харин Microsoft компанийн сарын стандарт хазайлт 6.55 хувь буюу хамгийн бага байна. Эдгээр үр дүн нь судалгааны хугацаанд хувьцаануудын өгөөжийн хэлбэлзэл мэдэгдэхүйц ялгаатай байгааг харуулж байна.

Өгөөжийн тархалтын асимметрийг авч үзвэл Apple компанийн хувьд сөрөг, бусад есөн компанийн хувьд эерэг утгатай байна. Ялангуяа Intel компанийн асимметр 3.4576, эксцесс 28.6664 байгаа нь бусад компаниас онцгой өндөр үзүүлэлт юм. Түүнчлэн Intel компанийн сарын хамгийн их өгөөж 1.1409 буюу 114.09 хувь байгаа нь өгөөжийн тархалтын баруун сүүлд онцгой өндөр утгатай ажиглалт байгааг илэрхийлнэ. Эдгээр үзүүлэлт нь Intel компанийн өгөөжийн тархалт хэвийн тархалтаас мэдэгдэхүйц ялгаатай байх шинжтэйг харуулж байна.

Хувьцаануудын өгөөжийн хоорондын шугаман хамаарлыг үнэлэх зорилгоор сарын өгөөжийн корреляцын матрицыг тооцож, Хүснэгт 2-д үзүүлэв.

Хүснэгт 2: Хувьцааны сарын өгөөжийн корреляцын матриц

	AAPL	MSFT	GOOGL	AMZN	NVDA	META	AMD	TSLA	INTC	AVGO
AAPL	1.0000	0.4821	0.3821	0.4669	0.4903	0.2509	0.3194	0.3911	0.2541	0.3657
MSFT	0.4821	1.0000	0.4621	0.5503	0.5389	0.2868	0.3733	0.2874	0.2004	0.3739
GOOGL	0.3821	0.4621	1.0000	0.6205	0.4038	0.3242	0.3933	0.2807	0.3899	0.4532
AMZN	0.4669	0.5503	0.6205	1.0000	0.5098	0.3836	0.4712	0.3277	0.2412	0.3939
NVDA	0.4903	0.5389	0.4038	0.5098	1.0000	0.3368	0.5066	0.3022	0.2401	0.4169
META	0.2509	0.2868	0.3242	0.3836	0.3368	1.0000	0.2645	0.2643	0.1220	0.2763
AMD	0.3194	0.3733	0.3933	0.4712	0.5066	0.2645	1.0000	0.2504	0.4109	0.3728
TSLA	0.3911	0.2874	0.2807	0.3277	0.3022	0.2643	0.2504	1.0000	0.1327	0.2953
INTC	0.2541	0.2004	0.3899	0.2412	0.2401	0.1220	0.4109	0.1327	1.0000	0.2993
AVGO	0.3657	0.3739	0.4532	0.3939	0.4169	0.2763	0.3728	0.2953	0.2993	1.0000

Хүснэгт 2-ээс харахад судалгаанд хамрагдсан 10 компанийн хувьцааны сарын өгөөжийн хоорондын корреляцын коэффициентүүд бүгд эерэг байна. Диагоналийн бус корреляцын коэффициентүүд 0.1220–0.6205-ын хооронд байгаа нь хувьцаануудын өгөөжийн хооронд эерэг шугаман хамаарал ажиглагдаж байгаа боловч хамаарлын хүч харилцан адилгүй байгааг харуулж байна.

Хамгийн өндөр корреляц Google болон Amazon компанийн хувьцааны өгөөжийн хооронд ажиглагдсан бөгөөд корреляцын коэффициент 0.6205 байна. Түүнчлэн Microsoft болон Amazon (0.5503), Microsoft болон Nvidia (0.5389), Nvidia болон AMD (0.5066)

компаниудын өгөөжийн хооронд харьцангуй өндөр эерэг хамаарал ажиглагдаж байна.

Харин хамгийн бага корреляц Meta болон Intel компанийн хувьцааны өгөөжийн хооронд ажиглагдсан бөгөөд коэффициент 0.1220 байна. Мөн Tesla болон Intel компанийн өгөөжийн корреляц 0.1327 байгаа нь бусад хосуудтай харьцуулахад бага үзүүлэлт юм.

Ерөнхийдөө тодорхойлох статистикийн үр дүнгээс харахад судалгаанд хамрагдсан хувьцаануудын өгөөжийн түвшин, хэлбэлзэл болон тархалтын хэлбэр ялгаатай байна. Түүнчлэн хувьцаануудын өгөөжийн корреляцын коэффициентүүд бүгд эерэг боловч нэгээс бага байгаа нь тэдгээрийг багцад нэгтгэх замаар төрөлжүүлэлтийн үр ашиг хүртэх боломж байгааг харуулж байна. Гэхдээ төрөлжүүлэлтийн үр ашиг нь хувьцаануудын эрсдэл, хоорондын хамаарал болон багцын жингийн бүтцээс хамаарна. Иймээс эдгээр шинж чанарыг харгалзан ковариацын матрицыг үнэлэх нь глобал хамгийн бага вариацтай багцын оновчтой жинг тодорхойлоход чухал ач холбогдолтой.

4.2 Ковариацын матрицын үнэлэгчдийн түүврээс гадуурх гүйцэтгэл

120 сарын rolling-window аргыг ашиглан ковариацын матрицын зургаан үнэлэгчид суурилсан GMVP портфелиудын 2022 оны 6-р сараас 2026 оны 9-р сар хүртэлх 52 сарын Out-of-Sample өгөөжийг тооцоолов. Үр дүнгээс харахад зургаан портфелийн сарын өгөөжүүд ерөнхийдөө ижил чиглэлд өөрчлөгдөж байгаа боловч өгөөжийн хэмжээнд ялгаа ажиглагдаж байна. Тухайлбал, 2022 оны 6-р сард бүх портфель сөрөг өгөөжтэй байсан бөгөөд тогтмол корреляцын зорилтот матриц ашигласан Corr арга хамгийн бага буюу 8.781%-ийн алдагдалтай байв. Харин 2026 оны 4-р сард бүх портфель эерэг өгөөжтэй байсан бөгөөд Var арга хамгийн өндөр буюу 29.179%-ийн өгөөж үзүүлжээ. Эдгээр үр дүн нь ковариацын матрицын үнэлгээний аргаас хамааран GMVP-ийн оновчтой жин болон портфелийн бодит өгөөж ялгаатай байгааг харуулж байна. Гэвч GMVP-ийн үндсэн зорилго нь өгөөжийг хамгийн их болгох бус эрсдэлийг хамгийн бага болгох тул аргуудын гүйцэтгэлийг зөвхөн сарын өгөөжөөр үнэлэх нь хангалтгүй юм.

4.3 Багцын жингийн тогтвортой байдал ба төвлөрөл

4.4 Ковариацын үнэлэгчдийн статистик харьцуулалт

4.5 Сургалтын цонхны уртаас хамаарах мэдрэмжийн шинжилгээ

5 Discussion

This section discusses the empirical differences between the covariance matrix estimators and their implications for portfolio selection.

6 Conclusion

This study compares several covariance matrix shrinkage methods for constructing global minimum variance portfolios.

The empirical results demonstrate how covariance estimation affects portfolio risk, asset allocation, and portfolio stability.

Ашигласан ном

Ando, S. and Xiao, M. (2023). High-dimensional covariance matrix estimation: Shrinkage toward a diagonal target. Technical Report 2023/257, International Monetary Fund.

De Nard, G., Ledoit, O., and Wolf, M. (2021). Factor models for portfolio selection in large dimensions: The good, the better and the ugly. *Journal of Financial Econometrics*, 19(2):236–257.

DeMiguel, V., Garlappi, L., and Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/n portfolio strategy? *The Review of Financial Studies*, 22(5):1915–1953.

Frost, P. A. and Savarino, J. E. (1986). An empirical bayes approach to efficient portfolio selection. *Journal of Financial and Quantitative Analysis*, 21(3):293–305.

Jagannathan, R. and Ma, T. (2003). Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4):1651–1683.

Ledoit, O. (1995). *Essays on Risk and Return in the Stock Market*. Ph.d. thesis, Massachusetts Institute of Technology.

Ledoit, O. and Wolf, M. (2003). Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5):603–621.

Ledoit, O. and Wolf, M. (2004a). Honey, i shrunk the sample covariance matrix. *The Journal of Portfolio Management*, 30(4):110–119.

Ledoit, O. and Wolf, M. (2004b). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411.

Ledoit, O. and Wolf, M. (2012). Nonlinear shrinkage estimation of large-dimensional covariance matrices. *The Annals of Statistics*, 40(2):1024–1060.

Ledoit, O. and Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5):3043–3065.

Ledoit, O. and Wolf, M. (2022). The power of (non-)linear shrinking: A review and guide to covariance matrix estimation. *Journal of Financial Econometrics*, 20(1):187–218.

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1):77–91.

Shi, F., Shu, L., and He, J. (2025). Improving minimum-variance portfolio through shrinkage of large covariance matrices. *Economic Modelling*.